

Actividad 2

Pesado, recuperación y evaluación sobre la colección Time

Bryan Ezequiel Violante Arriaga - Otoño 2026

Resumen

Partiendo del vocabulario obtenido en la actividad 1, se construyeron los vectores de los 423 documentos con pesado tf-idf y los de las 83 consultas con pesado binario, y se recuperó por similitud coseno para las primeras 10 consultas. Se evaluó contra los juicios de relevancia de la colección calculando precisión, recuerdo y F_1 . Como comparación adicional se repitió todo con Okapi BM25 y sobre los dos corpus truncados disponibles, el de Porter original y el de NLTK, lo que da cuatro sistemas.

1. Punto de partida

De la actividad 1 se heredan las matrices documento-término con las frecuencias crudas, para los dos modos de truncamiento.

Corpus	Documentos	Términos	Celdas no nulas
Porter (1980)	423	16 675	92 091
Porter (NLTK)	423	16 623	92 040

Las consultas se procesaron con el mismo pipeline y se realinearon al vocabulario de los documentos, de modo que ambos lados viven en el mismo espacio. Tienen entre 3 y 18 términos, con 8.7 de promedio.

2. Método

Pesado de los documentos

El pesado tf-idf sigue la definición que vimos en clase. La frecuencia se normaliza contra el término más frecuente del documento y se multiplica por el idf con logaritmo natural:

$$w_{i,j} = \frac{f_{i,j}}{\max_k f_{k,j}} \cdot \log \frac{N}{n_i},$$

con $N = 423$ y n_i el número de documentos que contienen al término i . La base del logaritmo solo escala todo por igual y no altera el orden del ranking.

Okapi BM25 se incluyó como comparación. Satura la frecuencia y normaliza contra la longitud promedio de la colección en vez de contra el pico del propio documento:

$$w_{i,j} = \log \left(\frac{N - n_i + 0.5}{n_i + 0.5} + 1 \right) \cdot \frac{f_{i,j} (k_1 + 1)}{f_{i,j} + k_1 \left(1 - b + b \frac{|d_j|}{|d|} \right)},$$

con los valores clásicos $k_1 = 1.2$ y $b = 0.75$. El +1 dentro del logaritmo mantiene el idf no negativo; sin él, un término presente en más de la mitad de la colección tendría peso negativo y restaría.

Pesado de las consultas y recuperación

Las consultas llevan pesado binario (usar *tf* sería igual que binario), todo término presente vale 1 y todo faltante vale 0.

La IR es por similitud coseno, normalizando ambos lados antes de multiplicar:

$$\text{sim}(d, q) = \frac{d \cdot q}{\|d\| \|q\|}.$$

Se conservan los documentos de coseno distinto de cero y se ordenan de forma decreciente

Métricas de evaluación

Sobre el ranking completo se calculan las tres medidas de conjunto vistas en clase. Con Rec el conjunto recuperado y Rel el de relevantes según los juicios:

$$P = \frac{|\text{Rec} \cap \text{Rel}|}{|\text{Rec}|}, \quad R = \frac{|\text{Rec} \cap \text{Rel}|}{|\text{Rel}|}, \quad F_1 = \frac{2 \cdot P \cdot R}{P + R}.$$

El denominador de R son todos los relevantes que existen, incluidos los que el sistema nunca recuperó, así que castiga lo que se quedó fuera. F_1 es la media armónica, que penaliza el desbalance: un sistema con $P = 1$ y $R = 0.01$ promedia 0.5 pero da $F_1 = 0.02$.

Estas tres ignoran el orden, y por eso hizo falta agregar medidas sensibles al rango, ya que todas salían iguales. La más simple es cortar el ranking en las primeras N posiciones y medir la precisión ahí:

$$P@N = \frac{\text{relevantes en las primeras } N}{N}.$$

Se reportan $P@5$ y $P@10$.

La medida que resume el ranking entero es la precisión promedio, que mide $P@k$ justo en cada posición donde apareció un relevante y promedia esos valores. Su promedio sobre las consultas es el MAP:

$$\text{AP}(q) = \frac{1}{|\text{Rel}|} \sum_{k=1}^n P@k \cdot \text{rel}(k), \quad \text{MAP} = \frac{1}{|Q|} \sum_{q \in Q} \text{AP}(q),$$

donde n es el tamaño del ranking y $\text{rel}(k)$ vale 1 si el documento de la posición k es relevante y 0 si no. Esa suma aproxima el área bajo la curva de recuerdo-precisión de la consulta, de modo que un relevante colocado arriba aporta mucho y uno enterrado casi nada.

3. Resultados

Comparación de los cuatro sistemas

Sistema	P	R	F_1	P@5	P@10	MAP
Porter tf-idf	0.0317	0.9550	0.0599	0.44	0.33	0.5389
Porter BM25	0.0317	0.9550	0.0599	0.40	0.33	0.4918
NLTK tf-idf	0.0317	0.9550	0.0599	0.44	0.33	0.5389
NLTK BM25	0.0317	0.9550	0.0599	0.40	0.33	0.4932

Tabla 1: Promedios sobre las primeras 10 consultas. Las tres primeras columnas se miden sobre el ranking completo y salen idénticas en los cuatro sistemas; las tres últimas son sensibles al orden.

Detalle por consulta

Q	Recup.	Rel.	P	R	F_1
1	147	7	0.0476	1.00	0.0909
2	287	2	0.0070	1.00	0.0138
3	312	4	0.0096	0.75	0.0190
4	371	5	0.0135	1.00	0.0266
5	135	5	0.0296	0.80	0.0571
6	206	9	0.0437	1.00	0.0837
7	345	2	0.0058	1.00	0.0115
8	196	2	0.0102	1.00	0.0202
9	77	8	0.1039	1.00	0.1882
10	131	6	0.0458	1.00	0.0876

Tabla 2: Métricas del ranking completo. Estos valores son *idénticos* en los cuatro sistemas, en secciones posteriores se extiende esta idea

Medidas sensibles al orden

Las mismas 10 consultas, ahora con las métricas que sí dependen de en qué posición salió cada documento relevante.

Q	Porter tf-idf			Porter BM25			NLTK tf-idf			NLTK BM25		
	P@5	P@10	AP	P@5	P@10	AP	P@5	P@10	AP	P@5	P@10	AP
1	0.6	0.7	.7497	0.4	0.6	.5495	0.6	0.7	.7497	0.4	0.6	.5495
2	0.4	0.2	.7000	0.4	0.2	.3667	0.4	0.2	.7000	0.4	0.2	.3667
3	0.2	0.1	.1401	0.0	0.1	.1138	0.2	0.1	.1401	0.0	0.1	.1138
4	0.0	0.1	.0487	0.0	0.0	.0299	0.0	0.1	.0489	0.0	0.0	.0300
5	0.0	0.0	.0418	0.0	0.0	.0544	0.0	0.0	.0418	0.0	0.0	.0544
6	1.0	0.7	.9114	1.0	0.8	.9396	1.0	0.7	.9114	1.0	0.8	.9535
7	0.0	0.0	.0305	0.0	0.1	.0710	0.0	0.0	.0305	0.0	0.1	.0710
8	0.4	0.2	1.000	0.4	0.2	1.000	0.4	0.2	1.000	0.4	0.2	1.000
9	1.0	0.7	.9185	1.0	0.7	.9375	1.0	0.7	.9185	1.0	0.7	.9375
10	0.8	0.6	.8486	0.8	0.6	.8556	0.8	0.6	.8486	0.8	0.6	.8556
media	0.44	0.33	.5389	0.40	0.33	.4918	0.44	0.33	.5389	0.40	0.33	.4932

Tabla 3: Métricas sensibles al orden, los cuatro sistemas. Contra la tabla 2, aquí sí aparecen diferencias, y son las que separan un pesado de otro. Las columnas de Porter y NLTK coinciden salvo en las consultas 4 y 6. El AP va sin el cero inicial por espacio.




Figura 1: Métricas de los cuatro sistemas. Del lado izquierdo las métricas del ranking completo, del derecho las sensibles al orden

Posición de los documentos relevantes

Q	Hall.	Posiciones tf-idf	Posiciones BM25	AP tf-idf	AP BM25
1	7/7	1, 3, 4, 6, 7, 8, 10	2, 5, 6, 7, 8, 9, 12	0.7497	0.5495
2	2/2	1, 5	3, 5	0.7000	0.3667
3	3/4	3, 13, 41	7, 11, 23	0.1401	0.1138
4	5/5	7, 68, 83, 220, 296	14, 74, 180, 219, 311	0.0487	0.0299
5	4/5	17, 28, 64, 126	12, 19, 57, 129	0.0418	0.0544
6	9/9	1, 2, 3, 4, 5, 6, 8, 11, 15	1, 2, 3, 4, 5, 6, 8, 9, 13	0.9114	0.9396
7	2/2	26, 89	8, 118	0.0305	0.0710
8	2/2	1, 2	1, 2	1.0000	1.0000
9	8/8	1, 2, 3, 4, 5, 6, 7, 23	1, 2, 3, 4, 5, 6, 7, 16	0.9185	0.9375
10	6/6	1, 2, 3, 5, 8, 9	1, 2, 4, 5, 6, 8	0.8486	0.8556

Tabla 4: En qué lugar del ranking sale cada documento relevante, sobre el corpus de Porter. Hall. es cuántos de los relevantes se alcanzaron a recuperar.

Q	Hall.	Posiciones tf-idf	Posiciones BM25	AP tf-idf	AP BM25
1	7/7	1, 3, 4, 6, 7, 8, 10	2, 5, 6, 7, 8, 9, 12	0.7497	0.5495
2	2/2	1, 5	3, 5	0.7000	0.3667
3	3/4	3, 13, 41	7, 11, 23	0.1401	0.1138
4	5/5	7, 68, 83, 215, 288	14, 75, 173, 220, 306	0.0489	0.0300
5	4/5	17, 28, 64, 126	12, 19, 57, 129	0.0418	0.0544
6	9/9	1, 2, 3, 4, 5, 6, 8, 11, 15	1, 2, 3, 4, 5, 6, 7, 9, 13	0.9114	0.9535
7	2/2	26, 89	8, 118	0.0305	0.0710
8	2/2	1, 2	1, 2	1.0000	1.0000
9	8/8	1, 2, 3, 4, 5, 6, 7, 23	1, 2, 3, 4, 5, 6, 7, 16	0.9185	0.9375
10	6/6	1, 2, 3, 5, 8, 9	1, 2, 4, 5, 6, 8	0.8486	0.8556

Tabla 5: Lo mismo sobre el corpus de NLTK

4. Discusión

Por qué los cuatro sistemas empatan en P, R y F_1

Un documento entra al ranking si su coseno es distinto de cero, es decir si comparte al menos un término con la consulta. Esa condición no depende del pesado, es decir, los pesos cambian el valor del coseno, no si es cero o no. Se verificó que el conjunto recuperado es literalmente el mismo entre tf-idf y BM25 en todas las consultas probadas, y que entre Porter y NLTK difiere a lo mucho en 4 documentos, por los términos donde los dos truncadores (Porter y NLTK) discrepan.

tf-idf resulta mejor que BM25

Según recuerdo, OkapiBM25 se presenta como una mejora o refinamiento de tf-idf pero en nuestro experimento, con MAP de 0.5389 contra 0.4918 y P@5 de 0.44 contra 0.40, tf-idf gana, lo cual es contradictorio. Dos razones lo explican. La primera es la saturación: BM25 aplanas las frecuencias altas, y en documentos cortos de revista que un término aparezca diez veces sí es señal fuerte del tema, así que aplanarla tira información útil. La segunda es que BM25 está calibrado para consultas con pesos propios, y aquí las consultas son binarias (constraints del experimento).

La ventaja no es uniforme. BM25 gana en las consultas 5, 6, 7, 9 y 10, y pierde por mucho en la 1, la 2 y la 4. En la consulta 2 la diferencia de AP es de 0.70 contra 0.37 por mover un solo documento de la posición 1 a la 3.

Porter original VS NLTK

Son prácticamente el mismo sistema; MAP idéntico hasta el cuarto decimal en tf-idf (0.5389) y una diferencia de 0.0014 en BM25, que es ruido. Matchea con lo medido en la actividad 1, donde los dos modos difieren en el 1.73 % de los tokens. La elección del modo de truncamiento no tiene consecuencias prácticas, al menos en esta colección.

5. Conclusiones

El sistema funciona. Con el mapeo correcto de los juicios, MAP de 0.5389 y P@10 de 0.33 sobre las primeras 10 consultas, con cuatro consultas que colocan todos sus relevantes dentro de los primeros quince resultados.

La lección metodológica principal es que, la métrica tiene que corresponder a lo que se quiere comparar. Precisión, recuerdo y F_1 sobre el ranking completo son incapaces de distinguir un pesado de otro, no por un defecto del experimento sino porque miden otra cosa. Reportarlas solas habría llevado a concluir que los cuatro sistemas son equivalentes, lo cual sería incorrecto.

Igual, queda pendiente extender la evaluación a las 83 consultas. Con solo diez, una diferencia de MAP de 0.047 entre tf-idf y BM25 no tiene respaldo estadístico suficiente para afirmarse como general, así como probar con pesos propios en las consultas.

Entregables

En out/actividad_2/, una línea por consulta con el formato Q<id> D<id> sim ... P R F_1 , con todos los documentos de coseno distinto de cero en orden decreciente:

<code>rec_porter_tfidf.txt</code>	Porter con tf-idf
<code>rec_porter_bm25.txt</code>	Porter con Okapi BM25
<code>rec_nltk_tfidf.txt</code>	NLTK con tf-idf
<code>rec_nltk_bm25.txt</code>	NLTK con Okapi BM25

El código está en `src/actividad.ipynb` y el entorno en `../requirements.txt`. Se agregó `matplotlib` para las gráficas comparativas.

Referencias

- [1] **Colección Time.** IR Group, University of Glasgow. Colecciones de prueba para recuperación de información.
http://ir.dcs.gla.ac.uk/resources/test_collections/
El archivo README de la colección es el que aclara que son 425 documentos con huecos en la numeración.
- [2] **Algoritmo de Porter.** Martin Porter.
<https://tartarus.org/martin/PorterStemmer/>
Publicado como *An algorithm for suffix stripping*
- [3] **Okapi BM25.** Robertson y Walker, *Some simple effective approximations to the 2-Poisson model for probabilistic weighted retrieval*, SIGIR 1994.
<https://dl.acm.org/doi/10.5555/188490.188561>