

Actividad 3

Expansión de consultas con Rocchio y semántica distribucional

Bryan Ezequiel Violante Arriaga - Otoño 2026

Resumen

Partiendo de la recuperación de la actividad 2, se recuperaron los 100 documentos de mayor similitud coseno para cada una de las primeras 10 consultas, se tomaron los 3 primeros como relevantes y con la fórmula de Rocchio se construyó una consulta expandida con la que se recuperó de nuevo. La comparación se hace con average precision antes y después, sobre los cuatro sistemas de la actividad anterior.

La expansión mejora el MAP en los cuatro, entre 0.018 y 0.024, pero el promedio esconde dos comportamientos opuestos: sube donde la semilla acertó y hunde la consulta donde no.

Y como complemento se implementó la tercera vía de la expansión, la automática, construyendo la matriz de coocurrencia $C = AA^T$

1. Start point

De la actividad 2 se heredan las matrices documento-término con pesado tf-idf y Okapi BM25 sobre los dos corpus truncados, las matrices de consulta con pesado binario, y las matrices de similitud coseno ya calculadas. Los juicios de relevancia de TIME.REL se usan para medir; no intervienen en la expansión.

Posteriormente se obtienen las 100 consultas con mayor similitud coseno (para la query 9 solo se obtuvieron 77 documentos)

2. Método

Expansión con la fórmula de Rocchio

Rocchio mueve el vector de la consulta hacia el centroide de lo que se asume relevante y lo aleja del centroide del resto:

$$q_m = \alpha q + \frac{\beta}{|D_r|} \sum_{d \in D_r} d - \frac{\gamma}{|D_{nr}|} \sum_{d \in D_{nr}} d,$$

con los valores por default $\alpha = 1$, $\beta = 0.75$ y $\gamma = 0.15$.

Esto se puede ver graficamente en la figura 2.

D_r son los primeros 3 documentos recuperados (pseudo-feedback, la relevancia la define la posición en el ranking, no los juicios).

D_{nr} se son los 97 restantes del top 100 y no la colección entera, es decir que solo se retroalimenta con lo que el sistema ya había traído

Cabe mencionar que las consultas se normalizan antes de sumar, ya que las consultas están pesadas en binario y los corpus en *tf-idf* y *BM25*, sin normalizar, α y β no pesan lo que la fórmula dice que pesan

Y también, pesos negativos que produce el término de γ se recortan a cero

Evaluación

La medida es la average precision, la misma de la actividad 2:

$$AP(q) = \frac{1}{|\text{Rel}|} \sum_{k=1}^n P@k \cdot \text{rel}(k).$$

El AP de antes se mide sobre los mismos 100 documentos de la primera pasada, no sobre el ranking completo, para que las dos cifras se comparen sobre el mismo corte. EN consecuencia estos valores no coinciden con los de la actividad 2, donde el AP se media sobre todo el ranking.

Semántica distribucional

Aqui, las asociaciones entre palabras salen de la colección misma, no de un tesoro externo ni del usuario. Se parte de la matriz de terminos contra contextos y se multiplica por su transpuesta:

$$C = AA^T, \quad A \in \mathbb{R}^{|V| \times |D|}, \quad C \in \mathbb{R}^{|V| \times |V|}.$$

Con A binaria, cada celda de C cuenta en cuántos contextos aparecen juntas dos palabras, y la diagonal queda con la frecuencia de contexto de cada término, debido a que un termino comparte consigo mismo todos sus contextos

Recordar la idea principal de esto (vista en clase): con un contexto grande deberían correlacionarse palabras relacionadas por tema, y con uno chico la relacion deberia acercarse a la sinonimia.

Se usaron dos tamaños; El contexto grande es el documento completo. El chico es una ventana de 12 palabras: el documento se parte en trozos de 12 palabras que no se traslapan, y cada trozo pasa a ser una columna de A . La formula no cambia, solo cambia qué es una columna.

Para ordenar los vecinos de un término no sirve el conteo crudo, que está dominado por las palabras más comunes de la colección. Se usa el coseno entre las dos filas binarias de A , que sale de la propia matriz:

$$\text{sim}(t, u) = \frac{C[t, u]}{\sqrt{C[t, t] \cdot C[u, u]}}.$$

3. Resultados

Efecto de la expansión

Sistema	MAP antes	MAP después	Diferencia
Porter tf-idf	0.5376	0.5618	+0.0242
Porter BM25	0.4893	0.5101	+0.0208
NLTK tf-idf	0.5376	0.5618	+0.0242
NLTK BM25	0.4907	0.5090	+0.0183

Tabla 1: Avg del AP sobre las primeras 10 consultas (medido sobre el top 100 en las dos pasadas).

Q	Porter tf-idf		Porter BM25		NLTK tf-idf		NLTK BM25	
	antes	desp.	antes	desp.	antes	desp.	antes	desp.
1	.7497	.8010	.5495	.5980	.7497	.8010	.5495	.5980
2	.7000	.7500	.3667	.4167	.7000	.7500	.3667	.4167
3	.1401	.1429	.1138	.1346	.1401	.1429	.1138	.1346
4	.0417	.0453	.0197	.0445	.0417	.0452	.0196	.0445
5	.0354	.0317	.0482	.0900	.0354	.0317	.0482	.0786
6	.9114	.9576	.9396	.9798	.9114	.9576	.9535	.9798
7	.0305	.0135	.0625	.0357	.0305	.0135	.0625	.0357
8	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
9	.9185	.9276	.9375	.9464	.9185	.9276	.9375	.9464
10	.8486	.9484	.8556	.8556	.8486	.9484	.8556	.8556
media	.5376	.5618	.4893	.5101	.5376	.5618	.4907	.5090

Tabla 2: AP por consulta, antes y después de la expansión




Figura 1: AP antes y después, sistema NLTK tf-idf.

Se puede notar (en la figura) que las consultas se parten en dos grupos. Seis de ellas ya estaban por encima de 0.70 y la expansión las mejora o las deja igual. Las otras cuatro, la 3, 4, 5 y 7, están por debajo de 0.15 antes y siguen por debajo después. La expansión no rescata una consulta que empezó mal.

Visualizando Rocchio




Figura 2: Proyección PCA del top 100 de dos consultas, sistema NLTK tf-idf

En las dos graficas la flecha apunta hacia $c+$, que es el centroide de la semilla, que es exactamente lo que hace Rocchio. Lo que cambia es dónde está ese centroide respecto de los relevantes. En la consulta 1 la semilla cae entre los triángulos y el AP sube de 0.7497 a 0.8010. En la consulta 7 los dos únicos relevantes quedaron lejos, la consulta se aleja todavía más de ellos y el AP baja de 0.0305 a 0.0135.

Matriz decoocurrencia

Contexto	Columnas de A	Tamaño de C	Celdas no nulas
Documento	423	16 623 ²	7.02 %
Ventana de 12	10 530	16 623 ²	0.41 %

Tabla 3: C mide lo mismo en los dos casos; lo que cambia es el ancho de A

	nuclear	soviet	africa	kennedi
nuclear	44	24	6	14
soviet	24	91	10	13
africa	6	10	51	7
kennedi	14	13	7	41

	nuclear	soviet	africa	kennedi
nuclear	111	5	0	2
soviet	5	240	1	2
africa	0	1	105	1
kennedi	2	2	1	71

Tabla 4: Bloques de C para cuatro términos, con contexto documento arriba y ventana de 12 abajo

Se puede observar que con contexto documento, **nuclear** y **soviet** comparten 24 artículos de los 44 en que aparece el primero. Con ventana de 12 comparten 5, y **nuclear** con **africa** pasa de 6 a ninguno.

Vecinos segun el tamaño de contexto

Término	Contexto	Vecinos más cercanos
soviet	documento	moscow .72, russian .69, russia .63, khrushchev .55
	ventana 12	union .14, moscow .10, russian .10, kremlin .10
nuclear	documento	nato .57, deterr .56, polari .51, multilater .43
	ventana 12	deterr .26, weapon .19, warhead .17, nato .16
kennedi	documento	washington .49, presid .44, u. .41, washington' .38
	ventana 12	presid .23, john .17, administr .14, devis .11
africa	documento	african .58, africa' .50, black .50, white .42
	ventana 12	south .16, asia .13, latin .13, central .11

Tabla 5: Los cuatro vecinos de mayor coseno bajo cada tamaño de contexto. Con el documento completo salen palabras del mismo tema; con la ventana salen las que forman frase.

Geometría de los vectores de término

Vectores de termino. El numero es el coseno real contra soviet




Figura 3: El vector de **soviet**, sus tres vecinos más cercanos y tres términos frecuentes que no comparten ni un documento con el

Los tres términos ajenos que eligió el procedimiento son **cong**, **diem** y **nam'**, es decir Viet Cong, Ngo Dinh Diem y Viet Nam's: en esta colección la cobertura de Vietnam y la de los soviéticos no coinciden nunca en el mismo documento

4. Discusión

Rocchio sirve?

La ganancia de MAP, entre 0.018 y 0.024, es consistente en los cuatro sistemas, pero, cuando la semilla de tres documentos era efectivamente relevante, la consulta se mueve hacia la zona correcta y el AP sube; cuando no lo era, se mueve en la dirección equivocada y el AP baja.

La consulta 7 es el caso evidente. Tiene solo dos documentos relevantes en toda la colección, y ninguno de los dos estaba entre los tres primeros de la primera pasada. La expansión reforzó lo que ya salía arriba, que era incorrecto, y empujó los dos relevantes más abajo. Es el modo de falla conocido de la pseudo-retroalimentación, y no es un defecto de la implementación sino del suponer que los primeros 3 son los relevantes. La query 7 era la peor antes de la expansión, al expandir sigue siendo la peor.

Mi opinion es que Rocchio sirve en general, pero su efectividad depende críticamente de la calidad de la semilla inicial

El tamaño de contexto no produce sinonimia

La primera mitad de la hipótesis se cumple. Con el documento completo como contexto, los vecinos de `soviet` son `moscow`, `russian`, `russia` y `khrushchev`, y los de `nuclear` son `nato`, `deterr`, `polari` y `multilater`, que son los temas relacionados.

La segunda mitad esta medio rara. Con ventana de 12 no aparecen sinónimos, aparecen colocaciones, `soviet union`, `south africa`, `president kennedy`, `nuclear warhead`. Aun no me queda claro el porque, tendria que investigar mas.

5. Conclusiones

La expansión con Rocchio mejora el MAP en los cuatro sistemas, de 0.5376 a 0.5618 en el mejor de ellos. La mejora existe pero es pequeña, y sobre todo desigual: seis consultas mejoran o quedan igual y dos empeoran.

La semántica distribucional reproduce la parte tematica de la hipótesis del tamaño de contexto y no reproduce la parte de la sinonimia. Puede que sea un problema de implementacion.

Al revisar las referencias es que la hipótesis de Harris y lo que calcula $C = AA^T$ no son la misma cosa. Harris dice que dos palabras se parecen si aparecen *en contextos similares*, lo que copararia las filas de C entre sí. Lo que mide $C[t, u]$ es que dos palabras aparezcan *juntas*, que es una relación distinta, por ejemplo `soviet` y `union` ocurren juntas todo el tiempo y no son sinonimos, y desde mi experiencia dos sinonimos de verdad casi nunca coocurren en una ventana corta, porque uno sustituye al otro en vez de acompañarlo

Si eso es correcto, entonces la sinonimia no deberia salir de leer las celdas de C sino de comparar sus filas, y mi implementacion estaria midiendo bien algo que no es lo que la hipótesis predice. Lo dejo como suposicion porque no alcance a probarlo. Agradeceria retroalimentación sobre este punto

Entregables

out/actividad_3/ap_por_consulta.csv	AP por consulta, antes y después
-------------------------------------	----------------------------------

El archivo trae una fila por sistema y consulta, con las columnas `sistema`, `query`, `AP antes`, `AP despues` y `delta`, o sea 40 filas para los cuatro sistemas y las diez consultas.

El código está en `src/actividad.ipynb` y el entorno en `../requirements.txt`.

Referencias

- [1] **Rocchio.** J. J. Rocchio, *Relevance feedback in information retrieval*, en *The SMART Retrieval System*, Prentice Hall, 1971.
- [2] **Tesauro automático.** Manning, Raghavan y Schütze, *Introduction to Information Retrieval*, Cambridge University
<https://nlp.stanford.edu/IR-book/>
- [3] **Hipótesis distribucional.** Zellig Harris, *Distributional structure*.
<https://doi.org/10.1080/00437956.1954.11659520>
- [4] **Colección Time.** IR Group, University of Glasgow. Colecciones de prueba para recuperación de información.
http://ir.dcs.gla.ac.uk/resources/test_collections/
- [5] **Algoritmo de Porter.** Martin Porter.
<https://tartarus.org/martin/PorterStemmer/>