

Actividad 4

Recuperación con *word embeddings* pre-entrenados

Bryan Ezequiel Violante Arriaga - Otoño 2026

Resumen

Se repitió la recuperación de la actividad 2, pero representando cada documento y cada consulta como el promedio de los vectores GloVe de sus palabras. Para cada una de las primeras 10 consultas se recuperaron los 100 documentos de mayor similitud coseno y se midió el average precision, para compararlo contra tf-idf y tf-idf con la expansión de Rocchio de la actividad 3.

GloVe obtiene un MAP de 0.5221, por debajo de tf-idf (0.5376) y de tf-idf con Rocchio (0.5618). El promedio esconde un patrón claro: GloVe gana en las consultas que describen un tema con palabras comunes, y pierde en las que dependen de un nombre propio o de un término raro.

1. Start point

De las actividades anteriores se usan los documentos y consultas ya preprocesados, en particular `texto_nn`, el texto sin palabras vacías y sin truncar; los juicios de relevancia de TIME.REL; y la tabla de AP por consulta de la actividad 3, de donde salen las columnas de tf-idf (AP antes de expandir) y de tf-idf con Rocchio (AP después), sobre el sistema NLTK tf-idf. Porter y NLTK dan el mismo AP con tf-idf, así que basta uno.

Los embeddings son los de GloVe 6B en 300 dimensiones: entrenados sobre Wikipedia 2014 y Gigaword 5, unos 6 mil millones de tokens, con un vocabulario de 400 mil palabras en minúsculas.

2. Método

Preprocesamiento para GloVe

GloVe tiene vectores de palabras completas, así que se parte de `texto_nn` y no de las variantes truncadas con Porter.

Tokenización	Apariciones sin vector	MAP
Sin quitar 's	5.15 %	0.4997
Quitando 's	2.54 %	0.5221

Tabla 1: Quitar el posesivo recupera la mitad de las apariciones que se quedaban sin vector y sube el MAP en 0.022.

Lo q sigue sin vector son sobre todo nombres propios de la época (**nenni**, **evtushenko**, **aflak**, **adoula**) y contracciones como **don't**, que GloVe también parte en dos. Esas palabras se saltan.

Representación por promedio

La representación de un texto es el promedio de los vectores de las palabras que lo conforman:

$$\bar{v}_d = \frac{1}{|T_d|} \sum_{t \in T_d} v_t,$$

donde T_d son las apariciones de palabras del documento d que sí tienen vector. Cada aparición cuenta, así que una palabra que sale tres veces pesa tres veces, que es lo más parecido al tf. Las consultas se representan igual; como casi nunca repiten palabras, en ellas el promedio equivale a un pesado binario.

Recuperación y evaluación

La similitud es el mismo coseno de la actividad 2, ahora sobre los vectores densos de 300 dimensiones. Para cada consulta se toman los 100 documentos de mayor coseno.

A diferencia de tf-idf, aquí no se puede filtrar por coseno mayor que cero, porque prácticamente todos los documentos lo tienen: los cosenos van de -0.112 a 0.893 , con mediana 0.585 , y solo 110 de los 35 109 pares consulta-documento salen negativos. Con tf-idf, en cambio, un documento que no comparte ningún término con la consulta tiene coseno exactamente cero.

El AP se mide sobre ese top 100 y sobre las mismas 10 consultas de la actividad 3, de modo que las tres columnas se comparan sobre el mismo corte:

$$\text{AP}(q) = \frac{1}{|\text{Rel}|} \sum_{k=1}^{100} P@k \cdot \text{rel}(k).$$

3. Resultados

AP de los tres sistemas

Sistema	MAP	Contra tf-idf
tf-idf	0.5376	
tf-idf + Rocchio	0.5618	+0.0242
GloVe (promedio)	0.5221	-0.0155

Tabla 2: Promedio del AP sobre las primeras 10 consultas, medido sobre el top 100.

Q	tf-idf	tf-idf + Rocchio	GloVe
1	.7497	.8010	.7860
2	.7000	.7500	.5909
3	.1401	.1429	.3232
4	.0417	.0452	.0422
5	.0354	.0317	.0942
6	.9114	.9576	.9192
7	.0305	.0135	.0000
8	1.000	1.000	1.000
9	.9185	.9276	.8454
10	.8486	.9484	.6199
media	.5376	.5618	.5221

Tabla 3: AP por consulta con cada representación.




Figura 1: AP por consulta de los tres sistemas.

GloVe le gana a tf-idf en cinco consultas (1, 3, 4, 5 y 6), empata en la 8 y pierde en cuatro (2, 7, 9 y 10). Las ganancias más grandes son la 3, de 0.14 a 0.32, y la 5, de 0.04 a 0.09; las pérdidas más grandes son la 10, de 0.85 a 0.62, y la 2, de 0.70 a 0.59. En la 7 llega a cero

4. Discusión

Porque no se obtienen mejores resultados en todas?

Creo que la diferencia depende de qué tipo de palabras trae cada consulta

En la 3 y la 5 GloVe le gana a tf-idf, mi observacion con los resultados obtenidos es que estas consultas describen un tema con palabras comunes, por ejemplo *persons involved in the viet nam coup*. Un documento relevante puede hablar del golpe sin usar *persons* ni *involved*, y para tf-idf si la palabra no está, no cuenta. De hecho, en las dos consultas hay un relevante que no comparte ningún término

con la consulta y que tf-idf nunca recupera. Con GloVe eso no pasa tanto, porque **coup** queda cerca de palabras como **overthrow** o **junta**, entonces un documento que usa esas palabras también se acerca a la consulta. En la 5, por ejemplo, los primeros relevantes suben de las posiciones 17 y 28 a la 6 y la 8.

En la 7 y la 10 pasa lo contrario, y en base a las observaciones la intuición podría decir que es por los nombres propios. La 7 depende casi toda de **norodom sihanouk**, que aparece en solo 4 documentos de la colección, así que en tf-idf tiene un idf alto y pesa mucho. Pero al promediar, esas dos palabras valen lo mismo que **further** o **nation**, y el nombre se pierde entre las demás. Los dos relevantes terminan en las posiciones 101 y 172, fuera del top 100, y por eso el AP sale en cero. Con la 10 me parece que pasa algo parecido con **malaysia**, que queda mezclada con palabras como **growing** o **proposed**, y los dos últimos relevantes bajan de las posiciones 8 y 9 a la 29 y la 46.

5. Conclusiones

Con el promedio de vectores GloVe el MAP es de 0.5221, por debajo de tf-idf (0.5376) y de tf-idf con Rocchio (0.5618). No es una mejor representación para esta colección, pero tampoco es peor en todo sino que es complementaria. Gana donde la consulta y los documentos usan palabras distintas para el mismo tema, y pierde donde la consulta depende de un nombre propio o de un término raro, que es justo donde tf-idf es fuerte.

Se puede concluir que el problema no está en GloVe sino en el promedio, que trata igual a **sihanouk** que a **further**.

Entregables

out/actividad_4/ap_por_consulta.csv	AP por consulta de los tres sistemas
-------------------------------------	--------------------------------------

El archivo trae una fila por consulta, con las columnas **query**, **tf-idf**, **tf-idf + rochio** y **glove**, o sea 10 filas.

El código está en `src/actividad.ipynb` y el entorno en `../requirements.txt`. Los vectores de GloVe no se versionan por su tamaño; las instrucciones para descargarlos están al inicio de la actividad 4 en el notebook.

Referencias

- [1] **GloVe**. Jeffrey Pennington, Richard Socher y Christopher Manning, *GloVe: Global Vectors for Word Representation*, EMNLP, 2014.
<https://nlp.stanford.edu/projects/glove/>
- [2] **Colección Time**. IR Group, University of Glasgow. Colecciones de prueba para recuperación de información.
http://ir.dcs.gla.ac.uk/resources/test_collections/