

Modelos de lenguaje de n -gramas

Factorización, supuesto de Markov, estimación, suavizado y perplejidad (ref. J&M SLP §3)

Material de apoyo para Fundamentos para el Análisis Automático de Lenguaje, INAOE

1. Qué objeto es un modelo de lenguaje

Antes de escribir cualquier fórmula conviene fijar qué se está modelando, porque la mayor parte de las confusiones posteriores vienen de perder de vista el objeto primario.

Definición 1.1. Un *modelo de lenguaje* (language model) es una distribución de probabilidad sobre $\mathcal{V}^*$, el conjunto de todas las cadenas finitas sobre un vocabulario finito $\mathcal{V}$. Asigna a cada secuencia $w_1 \cdots w_N$ un número $P(w_1 \cdots w_N) \geq 0$ sujeto a

$$\sum_{s \in \mathcal{V}^*} P(s) = 1.$$

Lo que hay que retener de entrada

El objeto primario es la **conjunta sobre secuencias completas**, no las probabilidades condicionales. Las condicionales aparecerán enseguida, pero como una *manera de parametrizar* esa conjunta, no como el objeto que se define. Esta distinción es la que se pierde cuando se afirma que “el modelo está normalizado” sin decir sobre qué espacio.

Nótese que $\mathcal{V}^*$ es infinito numerable: contiene cadenas de toda longitud finita. Una distribución sobre un conjunto infinito puede perfectamente sumar menos que 1 si parte de la masa se escapa hacia objetos que no pertenecen al conjunto; a este fenómeno volveremos en la sección 7, porque no es una patología teórica sino algo que un modelo mal construido produce con facilidad.

2. La regla de la cadena: factorización exacta

2.1. Enunciado

La regla de la cadena de la probabilidad (chain rule) no es más que la definición de probabilidad condicional aplicada repetidamente. Para dos eventos con $P(B) > 0$,

$$P(A | B) = \frac{P(A \cap B)}{P(B)} \implies P(A \cap B) = P(B) P(A | B),$$

y al iterar sobre N eventos se obtiene

$$P(A_1 \cap \cdots \cap A_N) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2) \cdots P(A_N | A_1 \cap \cdots \cap A_{N-1}).$$

En el caso del modelo de lenguaje, A_i es el evento “la i -ésima palabra es w_i ”, y la intersección de todos ellos es el evento “la secuencia es $w_1 \cdots w_N$ ”. Se obtiene entonces

$$P(w_1 \cdots w_N) = \prod_{i=1}^N P(w_i | w_1 \cdots w_{i-1}). \quad (1)$$

La factorización no aproxima nada

La ecuación (1) es una identidad, no un modelo. No se ha introducido ningún supuesto sobre el lenguaje. El único problema que queda es de *estimación*: el condicionante $w_1 \cdots w_{i-1}$ crece sin cota, de modo que habría un número no acotado de distribuciones distintas que estimar, una por cada historial posible.

2.2. Verificación por telescopio y por inducción

Conviene ver la cancelación explícitamente antes de aceptar la fórmula general. Para $N = 3$, reescribiendo cada factor con la definición de condicional:

$$P(w_1) \cdot \frac{P(w_1 w_2)}{P(w_1)} \cdot \frac{P(w_1 w_2 w_3)}{P(w_1 w_2)} = P(w_1 w_2 w_3),$$

donde $P(w_1)$ cancela con el denominador del segundo factor y $P(w_1 w_2)$ con el del tercero.

Proposición 2.1. *La identidad (1) vale para todo $N \geq 1$ siempre que $P(w_1 \cdots w_{i-1}) > 0$ para cada $i \leq N$.*

Demostración. Inducción sobre N , la longitud de la secuencia.

Base ($N = 1$): ambos lados son $P(w_1)$, tomando como convención que el producto sobre el historial vacío vale 1.

Paso inductivo: supóngase la identidad válida para $N - 1$. Aplíquese la regla de dos eventos con $A = \{X_N = w_N\}$ y $B = \{X_1 = w_1, \dots, X_{N-1} = w_{N-1}\}$, lo cual es lícito porque $P(B) > 0$ por hipótesis:

$$P(w_1 \cdots w_N) = P(w_1 \cdots w_{N-1}) \cdot P(w_N \mid w_1 \cdots w_{N-1}).$$

Sustituyendo la hipótesis inductiva en el primer factor se obtiene el producto de N términos. $\square$

Observación. **Puntos a verificar contra el material del curso.** Primero, la convención sobre el producto vacío en el caso base. Segundo, y más importante, qué se hace cuando algún prefijo tiene probabilidad cero: la convención usual es declarar que la conjunta es cero, pero eso es una convención y no un teorema, ya que el factor correspondiente sencillamente no está definido.

2.3. El orden de la factorización es una elección

La regla de la cadena vale para *cualquier* orden de los eventos: la demostración anterior funciona igual reetiquetando índices, y la conjunta resultante es idéntica. Factorizar de izquierda a derecha es una decisión de modelado, no una necesidad matemática.

Esto tiene una consecuencia que se aprecia mejor en la sección siguiente: la factorización exacta es simétrica respecto al orden, pero el supuesto de Markov *no* lo es. Truncar el historial a los $n - 1$ símbolos anteriores no es lo mismo que truncarlo a los $n - 1$ posteriores. La aproximación rompe una simetría que la identidad preservaba.

3. Cadenas de Markov y el supuesto de Markov

3.1. Tres objetos distintos

Conviene separar tres cosas que suelen mezclarse.

Un *proceso estocástico* es simplemente una secuencia de variables aleatorias $X_1, X_2, \dots$ sobre un espacio de estados S . En un modelo de lenguaje sobre palabras, X_i es la palabra en la posición i y $S = \mathcal{V}$; en un etiquetador morfosintáctico, X_i es la etiqueta y S el conjunto de categorías. Sin supuesto alguno, describir la conjunta de un proceso arbitrario de longitud N requiere del orden de $|S|^N$ números.

Definición 3.1. Un proceso es *markoviano de orden k* si para todo i y toda asignación de valores

$$P(X_i | X_1, \dots, X_{i-1}) = P(X_i | X_{i-k}, \dots, X_{i-1}).$$

Cuando se dice “cadena de Markov” sin calificar, se sobreentiende $k = 1$.

Definición 3.2. Una *cadena de Markov* (de orden 1) sobre un espacio finito es la tripleta (S, π, A) donde S es el conjunto de estados, π es la distribución inicial con $\sum_s \pi(s) = 1$, y A es la matriz de transición con $A_{ss'} = P(X_{i+1} = s' | X_i = s)$, sujeta a

$$\sum_{s' \in S} A_{ss'} = 1 \quad \text{para cada } s \in S.$$

La cadena es *homogénea* si A no depende de la posición i .

Obsérvese con cuidado la condición sobre A : lo que suma 1 es cada *renglón*, no cada columna. Es exactamente la misma observación sobre el espacio de normalización que reaparecerá en la sección 4, ahora en forma matricial.

Ejemplo 3.3 (Un ejemplo mínimo, para fijar la mecánica). Estados $S = \{\text{Sol}, \text{Lluvia}\}$ con

$$A = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix},$$

donde el renglón indica el estado de hoy y la columna el de mañana. Cada renglón suma 1; las columnas no suman nada en particular ($0.8 + 0.4 = 1.2$). Con $\pi(\text{Sol}) = 1$,

$$P(\text{Sol}, \text{Sol}, \text{Lluvia}) = \pi(\text{Sol}) \cdot A_{\text{Sol}, \text{Sol}} \cdot A_{\text{Sol}, \text{Lluvia}} = 1 \cdot 0.8 \cdot 0.2 = 0.16.$$

La probabilidad de una secuencia es el producto de las transiciones a lo largo del camino, multiplicado por la inicial.

3.2. El supuesto aplicado al lenguaje

Un modelo de n -gramas resulta de imponer la propiedad de Markov de orden $n - 1$ sobre la factorización (1):

$$P(w_i | w_1 \cdots w_{i-1}) \approx P(w_i | w_{i-n+1} \cdots w_{i-1}). \quad (2)$$

Con $n = 1$ se tiene el unigrama (historial de cero palabras), con $n = 2$ el bigrama (historial de una), con $n = 3$ el trigramas (historial de dos). Nótese que n cuenta el bloque completo, historial *más* la palabra predicha; el historial tiene longitud $n - 1$.

Qué se pierde, exactamente

El modelo induce una relación de equivalencia sobre el conjunto de historiales:

$$u \sim u' \iff \text{los últimos } n - 1 \text{ símbolos de } u \text{ y de } u' \text{ coinciden,}$$

y opera sobre las clases de equivalencia, no sobre los historiales. Toda distinción interna a una clase es **inaccesible**: no atenuada ni aproximada, sino irrecuperable. La contrapartida es que la conjunta pasa de requerir $|\mathcal{V}|^N$ parámetros a requerir $|\mathcal{V}|^n$, cifra independiente de N .

3.3. El orden depende de cómo se defina el estado

Un trigramma es markoviano de orden 2 sobre palabras, lo cual parece salirse del marco de las cadenas de orden 1. No es así, y la construcción que lo resuelve es estándar.

Proposición 3.4. *Todo proceso markoviano de orden k sobre S es equivalente a una cadena de Markov de orden 1 sobre S^k , tomando como estado la tupla de los últimos k símbolos.*

Para el trigramma el estado es el par (w_{i-2}, w_{i-1}) y la transición $(u, v) \rightarrow (v, w)$ tiene probabilidad $P(w \mid u, v)$. Obsérvese la restricción estructural: desde el estado (u, v) sólo son alcanzables estados cuya primera componente es v , de modo que la matriz resultante es enormemente dispersa.

Consecuencia conceptual

El orden **no es una propiedad del proceso** sino de cómo se definió el espacio de estados. “Orden 1” no significa “memoria de un paso” en ningún sentido absoluto: una cadena de orden 1 cuyos estados son tuplas de diez palabras recuerda diez palabras. La memoria está codificada en el estado. Lo único que no es gratis es el tamaño: el espacio pasa de $|\mathcal{V}|$ a $|\mathcal{V}|^k$.

3.4. El lenguaje no es markoviano de ningún orden finito

La afirmación precisa es la siguiente: no existe ningún k finito tal que, para toda oración del español, w_i sea condicionalmente independiente de $w_1 \cdots w_{i-k-1}$ dado $w_{i-k} \cdots w_{i-1}$.

Su forma operativa es un cuantificador universal con contraejemplo constructivo: *para todo k que se proponga, existe un par de oraciones que comparten sus últimos k tokens y exigen continuaciones distintas*. El procedimiento de construcción, en español, puede basarse en la selección de modo verbal:

Espero que mañana _____ $\rightarrow$ *llueva* (subjuntivo)
Sé que mañana _____ $\rightarrow$ *lloverá* (indicativo)

Dado cualquier k , basta insertar material intermedio hasta empujar el disparador (*espero* frente a *sé*) fuera de la ventana: *Espero que mañana por la tarde, si el clima no cambia demasiado y las condiciones se mantienen como hasta ahora, _____*. La concordancia de número admite construcciones análogas (*El libro que compré para mis hermanas* frente a *Los libros que compré para mis hermanas*).

Es importante ver por qué el argumento debe tener esta forma. Observar que “una sola palabra de contexto no basta” descarta únicamente $k = 1$; por la proposición 3.4, eso se arreglaría redefiniendo el estado como una tupla más larga. Lo que hay que descartar es todo k finito simultáneamente.

Observación. Punto a verificar. Este argumento está emparentado con la demostración clásica de que el inglés no es un lenguaje regular (dependencias anidadas arbitrariamente profundas), pero son afirmaciones distintas: una es sobre generación entendida como conjunto de cadenas, la otra sobre independencia condicional en una distribución. Conviene contrastar la formulación exacta con el material del curso antes de usarla.

Tres precisiones sobre lo que la afirmación *no* dice. Primero, no dice que el modelo sea inútil: un trigramma captura buena parte de la estructura local y la pregunta relevante no es si el supuesto es verdadero sino cuánto cuesta la aproximación en cada tarea. Segundo, y este es el punto central, no dice que más datos lo arreglen: con corpus infinito el estimador converge a la verdadera $P(w_i \mid \text{últimos } n-1)$, que existe y está bien definida, pero *no es igual* a $P(w_i \mid \text{todo el historial})$, sino su marginal, y la marginal ha borrado el disparador. Se trata de error de **especificación**, sesgo irreducible, y hay que distinguirlo con cuidado del error de *estimación* por dispersión de la sección 6, que sí mejora con datos y es el que justifica el suavizado. Tercero, no dice que las arquitecturas neuronales escapen: su ventana

de contexto también es finita, aunque el k efectivo sea de órdenes de magnitud mayor y los historiales compartan parámetros en vez de ser símbolos atómicos.

4. Estimación por máxima verosimilitud

4.1. El criterio y su solución

En el criterio aparecen cuatro objetos que se escriben parecido y significan cosas distintas. Conviene fijar los cuatro antes de la fórmula, porque casi todo lo que sigue es manipulación algebraica una vez que se sabe qué es cada cual.

Los parámetros $\theta_{v|u}$. Un modelo de bigramas no es más que una tabla de números, uno por cada par (historial u , palabra v). A ese número lo llamamos $\theta_{v|u}$. Es el mismo objeto que $P(v | u)$, y el cambio de nombre es deliberado: al escribir P se habla de una probabilidad dada, mientras que al escribir θ se la trata como una incógnita que hay que determinar a partir del corpus. Estimar el modelo es exactamente eso, llenar la tabla. El subíndice se lee “la palabra v dado el historial u ”, de modo que cada renglón de la tabla corresponde a un historial fijo y debe sumar 1 sobre todas las palabras posibles.

Los conteos $C(\cdot)$. $C(x)$ es el número de veces que la cadena x aparece en el corpus de entrenamiento. No tiene nada de estadístico: se recorre el corpus una vez y se lleva una cuenta con lápiz y papel, o con un diccionario. Así, $C(uv)$ cuenta las apariciones del bigrama uv , y $C(u)$ las del unigrama u . La sección siguiente hace ese conteo a mano sobre un corpus de tres oraciones. Los conteos son lo único que el corpus aporta: son un resumen del corpus y, una vez calculados, el corpus ya no se vuelve a mirar.

La verosimilitud $L(\theta)$. Es la probabilidad que el modelo asigna al corpus de entrenamiento, leída como función de los parámetros y no de los datos. Los datos están fijos, ya se observaron; lo que varía es la tabla, y L mide qué tan bien cada llenado posible de esa tabla explica lo que se vio. La probabilidad del corpus, por la regla de la cadena, es el producto de un factor $\theta_{v|u}$ por cada posición del corpus. Al agrupar las posiciones que comparten el mismo par (u, v) , ese factor idéntico se repite $C(uv)$ veces y el producto se vuelve una potencia. De ahí sale el exponente:

$$L(\theta) = \prod_{u,v} \theta_{v|u}^{C(uv)}.$$

La log-verosimilitud $\ell(\theta)$. Es simplemente $\log L(\theta)$, y el logaritmo convierte el producto en suma:

$$\ell(\theta) = \sum_u \sum_v C(uv) \log \theta_{v|u}.$$

Se trabaja con ℓ y no con L por dos razones. La primera es práctica: L es un producto de miles de números menores que 1 y se desborda por defecto en cualquier aritmética de punto flotante, cosa que a una suma de logaritmos no le pasa. La segunda es que el logaritmo es estrictamente creciente, así que L y ℓ alcanzan su máximo en el mismo punto, y derivar una suma es mucho más cómodo que derivar un producto.

Con eso, el criterio se enuncia en un renglón: el estimador de máxima verosimilitud es el valor de θ que maximiza ℓ sin salirse de la restricción de normalización,

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta) \quad \text{sujeto a} \quad \sum_v \theta_{v|u} = 1 \quad \text{para cada } u.$$

El sombrero de $\hat{\theta}$ distingue el valor estimado a partir de un corpus concreto del parámetro θ como incógnita.

Teorema 4.1. *El máximo de ℓ sobre el simplex se alcanza en las frecuencias relativas:*

$$\hat{P}(w_i \mid w_{i-n+1} \cdots w_{i-1}) = \frac{C(w_{i-n+1} \cdots w_i)}{C(w_{i-n+1} \cdots w_{i-1})},$$

y en particular, para el bigrama, $\hat{P}(v \mid u) = C(uv)/C(u)$.

Demostración. Paso 1 (separabilidad). La log-verosimilitud se descompone como $\ell(\theta) = \sum_u \ell_u(\theta)$ con $\ell_u = \sum_v C(uv) \log \theta_{v|u}$. Cada término involucra parámetros disjuntos y su restricción de normalización es independiente de las demás; por lo tanto maximizar ℓ equivale a maximizar cada ℓ_u por separado. Esto no es evidente a priori: se sigue de la estructura de la factorización (1). Fíjese un u en adelante.

Paso 2 (condición de primer orden). Con multiplicador de Lagrange para la restricción $\sum_v \theta_{v|u} = 1$,

$$\mathcal{L} = \sum_v C(uv) \log \theta_{v|u} - \lambda \left(\sum_v \theta_{v|u} - 1 \right), \quad \frac{\partial \mathcal{L}}{\partial \theta_{v|u}} = \frac{C(uv)}{\theta_{v|u}} - \lambda = 0,$$

de donde $\theta_{v|u} = C(uv)/\lambda$.

Paso 3 (despeje del multiplicador). Imponiendo la restricción,

$$\sum_v \theta_{v|u} = \frac{1}{\lambda} \sum_v C(uv) = 1 \implies \lambda = \sum_v C(uv) = C(u),$$

donde la última igualdad usa el lema 4.2. Sustituyendo, $\hat{\theta}_{v|u} = C(uv)/C(u)$.

Paso 4 (que es máximo). La segunda derivada es $\partial^2 \ell_u / \partial \theta_{v|u}^2 = -C(uv)/\theta_{v|u}^2 < 0$, y las cruzadas son nulas: la hessiana es diagonal con entradas negativas, luego ℓ_u es estrictamente cóncava en $\theta > 0$ y el punto crítico es máximo global sobre el simplex. $\square$

Lema 4.2. $\sum_{v \in \mathcal{V}} C(uv) = C(u)$ para todo u que sea seguido por algún símbolo en cada una de sus apariciones.

La justificación es directa: cada aparición de u va seguida por exactamente una palabra, de modo que las apariciones de u quedan particionadas según cuál sea esa palabra. La hipótesis restrictiva no es cosmética, y la sección siguiente exhibe dónde falla.

La fórmula es consecuencia, no punto de partida

La estimación por frecuencias relativas no es una regla *ad hoc* que resulte razonable; es la solución del problema de optimización planteado arriba. Reconocerlo importa porque el suavizado, más adelante, será un **abandono deliberado** de este criterio: se acepta peor ajuste al entrenamiento a cambio de no asignar cero a lo no visto.

5. Trazado completo sobre un corpus juguete

Se toma el corpus de tres oraciones

<s> el perro ladra </s> <s> el gato duerme </s> <s> el perro duerme </s>

y se estima el bigrama por máxima verosimilitud, llenando las tablas a mano.

5.1. Conteos

Los unigramas, que actuarán como denominadores:

u	$\langle s \rangle$	el	perro	gato	ladra	duerme	$\langle /s \rangle$
$C(u)$	3	3	2	1	1	2	3

Los bigramas, enumerados por oración: de la primera, ($\langle s \rangle$, el), (el, perro), (perro, ladra), (ladra, $\langle /s \rangle$); de la segunda, ($\langle s \rangle$, el), (el, gato), (gato, duerme), (duerme, $\langle /s \rangle$); de la tercera, ($\langle s \rangle$, el), (el, perro), (perro, duerme), (duerme, $\langle /s \rangle$). Agrupando:

uv	$C(uv)$	uv	$C(uv)$
($\langle s \rangle$, el)	3	(perro, duerme)	1
(el, perro)	2	(gato, duerme)	1
(el, gato)	1	(ladra, $\langle /s \rangle$)	1
(perro, ladra)	1	(duerme, $\langle /s \rangle$)	2

5.2. Condicionales y verificación de la normalización

Historial u	Distribución sobre v	$\sum_v \hat{P}(v u)$
$\langle s \rangle$	$\hat{P}(\text{el} \langle s \rangle) = 3/3 = 1$	1
el	$\hat{P}(\text{perro} \text{el}) = 2/3, \quad \hat{P}(\text{gato} \text{el}) = 1/3$	$2/3 + 1/3 = 1$
perro	$\hat{P}(\text{ladra} \text{perro}) = 1/2, \quad \hat{P}(\text{duerme} \text{perro}) = 1/2$	1
gato	$\hat{P}(\text{duerme} \text{gato}) = 1/1 = 1$	1
ladra	$\hat{P}(\langle /s \rangle \text{ladra}) = 1/1 = 1$	1
duerme	$\hat{P}(\langle /s \rangle \text{duerme}) = 2/2 = 1$	1

Cada renglón suma 1, como exige la condición sobre la matriz de transición. La verificación del lema 4.2, renglón por renglón, da $C(\text{el}) = 3 = 2 + 1$, $C(\text{perro}) = 2 = 1 + 1$, $C(\text{duerme}) = 2 = 2$, todos correctos; pero para $u = \langle /s \rangle$ se tiene $C(\langle /s \rangle) = 3$ mientras que $\sum_v C(\langle /s \rangle v) = 0$. Ahí falla la identidad.

Los símbolos de frontera son asimétricos

El lema falla exactamente para los tokens que nunca son seguidos por nada, que tratando cada oración por separado es únicamente $\langle /s \rangle$. El arreglo estándar consiste en no tratar $\langle /s \rangle$ como historial: es un estado absorbente y se excluye del dominio de la matriz de transición. Simétricamente, $\langle s \rangle$ nunca aparece como segundo elemento de un bigrama. Por lo tanto **el vocabulario de emisión y el conjunto de historiales no son el mismo conjunto**, y confundirlos al contar parámetros o al normalizar es una de las causas más frecuentes de reportar una distribución que no suma 1.

Vale la pena precisar para qué sirve cada símbolo. $\langle s \rangle$ existe para dar historial a las primeras posiciones: sin él, $\hat{P}(w_1)$ carecería de condicionante y el primer factor de la cadena sería de naturaleza distinta a los demás; para un modelo de orden n se anteponen $n - 1$ copias. $\langle /s \rangle$ existe porque es el símbolo emitible que permite que el proceso termine, y sin él la conjunta no queda definida sobre $\mathcal{V}^*$ sino sobre secuencias de longitud fija.

5.3. Probabilidad de las oraciones y qué revela la suma

Multiplicando a lo largo de cada camino:

$$\begin{aligned}\hat{P}(\text{el perro ladra}) &= 1 \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot 1 = \frac{1}{3}, \\ \hat{P}(\text{el gato duerme}) &= 1 \cdot \frac{1}{3} \cdot 1 \cdot 1 = \frac{1}{3}, \\ \hat{P}(\text{el perro duerme}) &= 1 \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot 1 = \frac{1}{3},\end{aligned}$$

cuya suma es exactamente 1.

La lectura ingenua sería que el modelo está bien normalizado y por tanto es correcto. Es la lectura equivocada. Que las tres oraciones del entrenamiento agoten toda la masa significa que el modelo **no asigna probabilidad positiva a ninguna otra cadena**. La oración *el gato ladra*, perfectamente gramatical y compuesta sólo de palabras del vocabulario, recibe

$$\hat{P}(\text{el gato ladra}) = 1 \cdot \frac{1}{3} \cdot 0 \cdot 1 = 0,$$

porque $C(\text{gato ladra}) = 0$. El modelo genera exactamente tres cadenas con probabilidad positiva, las tres vistas. Es un caso extremo pero limpio de lo que hace la máxima verosimilitud: maximizar la probabilidad del entrenamiento hasta dejar todo lo demás en cero.

Obsérvese que aquí la normalización global sí se cumple; lo que está mal no es cuánta masa hay sino *dónde* se colocó.

5.4. Contraste con el trigramas

Sobre el mismo corpus, $\hat{P}(\text{duerme} \mid \text{el perro}) = C(\text{el perro duerme})/C(\text{el perro}) = 1/2$, que coincide con el bigrama $\hat{P}(\text{duerme} \mid \text{perro}) = 1/2$. La coincidencia es un accidente del corpus: *perro* siempre viene precedido de *el*, así que el contexto adicional no aporta información alguna.

Más ilustrativo es el conteo de historiales. Los pares con conteo positivo son (**<s>**, el), (el, perro), (el, gato), (perro, ladra), (perro, duerme) y (gato, duerme): seis observados frente a $6^2 = 36$ posibles con seis tipos de palabra. Es decir, más del ochenta por ciento de la tabla está vacía en un corpus de tres oraciones.

6. Dispersión: por qué la estimación se rompe

Un modelo de n -gramas tiene del orden de $|\mathcal{V}|^{n-1}(|\mathcal{V}| - 1)$ parámetros libres. Con $|\mathcal{V}| = 10^4$ y $n = 3$ eso asciende a unos 10^{12} valores, cifra que ningún corpus cubre. La consecuencia es inmediata: en el conjunto de prueba aparecen n -gramas con conteo cero, la conjunta se anula por ser un producto y la log-verosimilitud se va a $-\infty$.

Dos limitaciones distintas que conviene no mezclar

El sesgo por el supuesto de Markov (sección 3) es error de *especificación* y no mejora con más datos. La dispersión es error de *estimación* y sí mejora con más datos, aunque nunca lo suficiente. El suavizado ataca la segunda, no la primera.

7. Fuga de masa: normalización local frente a global

Que cada renglón de la matriz sume 1 no garantiza que la conjunta sume 1 sobre $\mathcal{V}^*$. El siguiente par de ejemplos lo muestra sobre el modelo más pequeño posible.

Ejemplo 7.1 (Con fuga). Vocabulario de emisión $\{a, </s>\}$, historiales $\{<s>, a\}$, con

$$P(a \mid <s>) = 1, \quad P(a \mid a) = 1, \quad P(</s> \mid a) = 0.$$

Cada renglón suma 1: hay un único evento con masa en cada uno. Sin embargo, toda cadena finita $a^k </s>$ tiene probabilidad $1 \cdot 1^{k-1} \cdot 0 = 0$, de modo que

$$\sum_{s \in \mathcal{V}^*} P(s) = 0 \neq 1.$$

Toda la masa se fue a la cadena infinita $aaa \dots$, que no es elemento de $\mathcal{V}^*$.

Ejemplo 7.2 (Sin fuga). El mismo modelo con $P(a \mid a) = 0.9$ y $P(</s> \mid a) = 0.1$ asigna $P(a^k </s>) = 0.9^{k-1} \cdot 0.1$ para $k \geq 1$, y por serie geométrica

$$\sum_{k \geq 1} 0.9^{k-1} (0.1) = \frac{0.1}{1 - 0.9} = 1.$$

La diferencia con el caso anterior es que el ciclo tiene probabilidad de escape estrictamente positiva.

Observación. Punto a verificar, y lo señalo como incertidumbre real. La condición general que caracteriza cuándo un modelo de n -gramas es *estricto* (tight, es decir, cuando la conjunta suma 1 sobre $\mathcal{V}^*$) involucra el radio espectral de la matriz de transición restringida a los estados no terminales, y no la enuncio aquí porque no la tengo verificada con la precisión necesaria. Existe además la *intuición*, no verificada, de que un modelo estimado por máxima verosimilitud a partir de un corpus de oraciones completas resulta siempre estricto, ya que todo estado alcanzable tiene un camino observado hacia $</s>$; suena razonable y hay resultados análogos para gramáticas probabilísticas, pero no debe darse por cierto sin contrastarlo. El ejemplo con fuga de arriba fue construido a mano y no proviene de ninguna estimación por máxima verosimilitud.

8. Suavizado

El problema, en una línea: la máxima verosimilitud asigna cero a lo no visto, y el cero es letal porque la conjunta es un producto. La solución siempre tiene la misma forma, quitar masa a lo visto y dársela a lo no visto; las familias de métodos se distinguen en cuánta masa se quita y a dónde se manda.

8.1. Add- k (Laplace)

$$\hat{P}_{\text{add-}k}(v \mid u) = \frac{C(uv) + k}{C(u) + k|\mathcal{V}|}.$$

El término $k|\mathcal{V}|$ del denominador es exactamente lo que se necesita para compensar el k sumado a cada uno de los $|\mathcal{V}|$ numeradores; esa es la condición de normalización, y verificarla consiste en sumar sobre v . Con $k = 1$ se obtiene el suavizado de Laplace.

Sobre el corpus juguete, con $|\mathcal{V}| = 6$ y $k = 1$, resulta $\hat{P}(\text{perro} \mid \text{el}) = (2+1)/(3+6) = 1/3$ frente a $2/3$ de la máxima verosimilitud, es decir la mitad de la masa original; y $\hat{P}(\text{ladra} \mid \text{gato}) = (0+1)/(1+6) = 1/7$, que antes era cero. El defecto es visible en esos números: cuando $|\mathcal{V}|$ es grande, el término $k|\mathcal{V}|$ domina el denominador y la estimación se aplana. Add- k redistribuye demasiada masa, lo cual resulta aceptable en clasificación de texto pero es malo para modelado de lenguaje.

8.2. Descuento absoluto

Se resta una cantidad fija $d \in (0, 1)$ a cada conteo positivo:

$$\hat{P}_d(v \mid u) = \frac{\max\{C(uv) - d, 0\}}{C(u)}.$$

Esto ya no suma 1. La masa liberada en el contexto u es

$$\gamma(u) = \frac{d \cdot N_{1+}(u)}{C(u)}, \quad N_{1+}(u) = |\{v : C(uv) > 0\}|,$$

y es precisamente esa $\gamma(u)$ lo que los métodos siguientes reparten entre lo no visto, cada uno a su manera.

Observación. La justificación empírica del descuento fijo proviene de la observación de que el conteo esperado en un corpus de prueba de un bigrama que apareció r veces en entrenamiento es aproximadamente $r - 0.75$ para valores medianos de r , de donde el valor típico $d = 0.75$. El resultado es estándar (Church y Gale), pero la cifra conviene verificarla en el material del curso.

8.3. Back-off

Se recurre al orden menor *sólo* cuando el n -grama no se observó:

$$\hat{P}_{\text{bo}}(v \mid u) = \begin{cases} \frac{\max\{C(uv) - d, 0\}}{C(u)} & \text{si } C(uv) > 0, \\ \alpha(u) \hat{P}_{\text{bo}}(v) & \text{si } C(uv) = 0. \end{cases}$$

El coeficiente $\alpha(u)$ no se elige sino que se calcula: es la constante que hace que la masa $\gamma(u)$ liberada por el descuento se reparta exactamente entre los no vistos, en proporción a la distribución de orden menor, es decir

$$\alpha(u) = \frac{\gamma(u)}{\sum_{v: C(uv)=0} \hat{P}_{\text{bo}}(v)}.$$

8.4. Interpolación

Se mezclan los órdenes *siempre*, se haya visto o no el n -grama:

$$\hat{P}_{\text{int}}(w_i \mid w_{i-2}w_{i-1}) = \lambda_1 \hat{P}(w_i \mid w_{i-2}w_{i-1}) + \lambda_2 \hat{P}(w_i \mid w_{i-1}) + \lambda_3 \hat{P}(w_i), \quad \sum_j \lambda_j = 1.$$

Los λ_j se ajustan sobre un conjunto de desarrollo (held-out) y no sobre el entrenamiento, donde el óptimo sería $\lambda_1 = 1$, es decir volver a la máxima verosimilitud. Una variante estándar los hace depender del contexto, $\lambda_j(u)$, para confiar más en el orden alto cuando $C(u)$ es grande.

	Back-off	Interpolación
Cuándo usa el orden menor	sólo si $C(uv) = 0$	siempre
$\hat{P}$ de un n -grama visto	depende sólo del orden alto	mezcla los órdenes
Normalización	vía $\alpha(u)$ calculada	automática si $\sum_j \lambda_j = 1$

La distinción operativa

En interpolación, dos n -gramas vistos con el mismo conteo pueden recibir probabilidades distintas si sus órdenes menores difieren, porque el orden menor siempre participa. En back-off no ocurre: si el n -grama se vio, el orden menor no interviene en absoluto.

8.5. Kneser-Ney: la idea que lo distingue

El problema que resuelve puede enunciarse con un ejemplo. La palabra *Francisco* puede ser frecuente como unigrama y sin embargo aparecer casi siempre dentro de *San Francisco*. Al hacer back-off tras un contexto no visto, un unigrama basado en frecuencia le asignaría mucha masa, cuando es un mal candidato en contexto libre.

La corrección consiste en que la distribución de respaldo no mida frecuencia sino *versatilidad de contextos*:

$$P_{\text{cont}}(v) = \frac{|\{u : C(uv) > 0\}|}{|\{(u', v') : C(u'v') > 0\}|},$$

donde el numerador cuenta cuántos contextos distintos preceden a v y el denominador el número total de tipos de bigrama. Una palabra con frecuencia alta pero un único contexto queda penalizada. Kneser-Ney combina esta idea con descuento absoluto e interpolación, y es el mejor suavizado de n -gramas conocido.

Observación. Punto a verificar. La fórmula de P_{cont} se da con confianza razonable, pero la versión interpolada y modificada de Kneser-Ney, con descuentos distintos d_1, d_2, d_{3+} según el conteo, tiene detalles de normalización que conviene revisar directamente en J&M antes de usarla formalmente.

8.6. Dónde puede salir mal

El descuento absoluto con $d > 1$ aplicado sin el $\max\{\cdot, 0\}$ produce numeradores negativos para los n -gramas de conteo 1, es decir masa negativa. Y cualquier esquema en que $\alpha(u)$ o los λ_j se fijen a ojo en lugar de calcularse rompe la normalización sin que resulte evidente en el código. La verificación es siempre la misma: fijar un u , sumar sobre todo v y comprobar que da 1.

9. Perplejidad

9.1. Para qué sirve

Para comparar modelos de lenguaje entre sí sin ejecutarlos en ninguna tarea. Es la métrica de evaluación estándar: se entrenan dos modelos, se evalúan sobre el mismo texto de prueba, y el de menor perplejidad ajusta mejor.

9.2. Qué mide

Cuán sorprendido queda el modelo ante texto que no vio. Concretamente, el número efectivo de opciones que considera en cada posición.

- Perplejidad 100: el modelo duda entre unas 100 palabras en cada paso.
- Perplejidad 10: duda entre unas 10. Mejor modelo.
- Modelo uniforme sobre $|\mathcal{V}|$ palabras: perplejidad exactamente $|\mathcal{V}|$. Ese es el piso trivial.

9.3. Definición y forma de cálculo

Definición 9.1. La *perplejidad* (perplexity) de un texto de prueba $W = w_1 \cdots w_N$ bajo un modelo P es

$$\text{PP}(W) = P(w_1 \cdots w_N)^{-1/N} = \left(\prod_{i=1}^N P(w_i \mid \text{historial}) \right)^{-1/N}.$$

En la práctica se calcula en forma logarítmica para evitar desbordamiento por defecto (underflow):

$$\text{PP}(W) = \exp \left(-\frac{1}{N} \sum_{i=1}^N \ln P(w_i \mid \text{historial}) \right).$$

9.4. Relación con la entropía cruzada

Definiendo la entropía cruzada por token (cross-entropy) como

$$H(W) = -\frac{1}{N} \sum_{i=1}^N \log_2 P(w_i \mid \text{historial}),$$

se tiene $\text{PP}(W) = 2^{H(W)}$.

La base debe ser consistente

Si H se mide en bits (logaritmo base 2), la perplejidad es 2^H ; si en nats (base e), es e^H . La perplejidad resultante es la misma en ambos casos: lo que cambia es el número al que se llama entropía. Mezclar bases produce cifras que parecen plausibles y son incorrectas, y es de los errores más frecuentes.

9.5. Interpretación y baseline trivial

La perplejidad es el factor de ramificación promedio ponderado: el número efectivo de opciones que el modelo considera en cada posición. El caso de control lo fija: si el modelo es uniforme sobre $|\mathcal{V}|$ palabras, entonces $P(w_i \mid \cdot) = 1/|\mathcal{V}|$ para todo i y

$$\text{PP} = (|\mathcal{V}|^{-N})^{-1/N} = |\mathcal{V}|.$$

Es decir, **la perplejidad de un modelo uniforme es el tamaño del vocabulario**, y ése es el baseline trivial contra el cual debe compararse cualquier cifra reportada. Menor perplejidad indica mejor modelo.

9.6. Los detalles donde se rompe

Respecto a qué cuenta N : si $\langle /s \rangle$ se incluye en el producto, y debe incluirse porque forma parte de la probabilidad de la oración, entonces debe incluirse también en N ; incluirlo en uno y no en el otro sesga sistemáticamente la cifra. En cambio $\langle s \rangle$ normalmente no se cuenta en N , porque no se predice sino que condiciona.

Respecto a $\langle \text{UNK} \rangle$: dos modelos con vocabularios distintos no son comparables por perplejidad. Un vocabulario pequeño manda muchas palabras a $\langle \text{UNK} \rangle$, y $\langle \text{UNK} \rangle$ resulta fácil de predecir precisamente porque acumula masa, de modo que es posible bajar la perplejidad de forma arbitraria reduciendo el vocabulario. La comparación sólo tiene sentido con vocabulario idéntico y el mismo tratamiento de las palabras fuera de vocabulario.

Finalmente, la perplejidad es una métrica intrínseca: mide ajuste probabilístico al texto de prueba, no utilidad en ninguna tarea concreta. Suele correlacionar con el desempeño en traducción o reconocimiento de voz, pero no lo implica. Y si algún $P(w_i \mid \cdot)$ vale cero, la perplejidad es infinita; por eso perplejidad y suavizado son inseparables, y no puede evaluarse sobre datos reales un modelo estimado por máxima verosimilitud sin suavizar.

10. Resumen del esquema

Un modelo de lenguaje es una distribución sobre $\mathcal{V}^*$. La regla de la cadena la factoriza en condicionales sin pérdida alguna, y el orden de la factorización es una elección. El supuesto de Markov trunca el historial a $n - 1$ símbolos: es falso para el lenguaje natural, y no lo arreglan más datos porque se trata de sesgo de especificación, distinto del error de estimación por dispersión. La máxima verosimilitud estima las condicionales por frecuencias relativas, resultado que se deriva y no se postula, y asigna cero a todo lo no observado. El suavizado abandona deliberadamente ese criterio moviendo masa de lo visto a lo no visto, y las familias de métodos difieren en cuánta masa y hacia dónde. La perplejidad evalúa el resultado: es 2^H con H la entropía cruzada por token, y sólo resulta comparable bajo vocabulario y segmentación idénticos.

Quedan como puntos explícitamente pendientes de verificación contra el material del curso: la condición de estrictez del modelo, la constante del descuento absoluto y los detalles de normalización de Kneser-Ney modificado.