

Matemáticas para Computación

Dra. Hayde Peregrina Barreto

Dr. Luis Villaseñor Pineda

Otoño 2026 - Bryan Ezequiel Violante Arriaga

Índice

1. Introducción	2
2. Repaso	3
3. Relaciones y funciones	6
4. Algebras	8
5. Continuación (Estructuras algebraicas)	9
6. Matrices	12
7. Sistemas de ecuaciones lineales	17
8. Determinantes	21
9. Inversa de una matriz	27
10. Eigenvalores y eigenvectores	32
11. Descomposición en valores singulares (SVD)	41

1. Introducción

17 de agosto de 2026

Resumen rápido. En esta sesión vimos una intro... que es lo que se espera de nosotros en la materia, cómo se va a evaluar y qué temas se van a ver. Nos dijeron que no es tanto como para hacer demostraciones sino como para entender los conceptos y saber usar esas herramientas en la computación.

2. Repaso

19 de agosto de 2026

Resumen rápido. En esta clase iniciamos con el repaso de algunos conceptos matemáticos en los que se basa la materia y en general las mates para compu. Los conceptos que vimos son el de álgebra, conjuntos, subconjuntos, operaciones con conjuntos y producto cartesiano.

Álgebra

El álgebra es la parte de las matemáticas que estudia las operaciones, sus signos y las leyes que las rigen.

Conjuntos

Los conjuntos permiten agrupar elementos que comparten algo y operar entre esos grupos. Son la forma más básica de describir qué objetos estamos estudiando.

Definición 2.1 (Conjunto). Colección bien definida de objetos que comparten alguna característica. Puede ser finito o infinito.

Los elementos de un conjunto son distintos entre sí. Si al escribirlo se repite uno, cuenta una sola vez. Los enteros son el ejemplo de conjunto infinito.

Notación

Un conjunto se describe por comprensión dando la regla que cumplen sus elementos:

$$X = \{x \mid \text{regla que cumple } x\}$$

O por extensión listando sus elementos:

$$X = \{x_1, x_2, x_3, \dots, x_n\}$$

Los tres símbolos que se usan a cada rato:

- **Pertenencia** ($x \in X$): dice que x es uno de los elementos de X .
- **Cardinalidad** ($|X|$): el número de elementos que tiene el conjunto.
- **Universo** (U): todas las posibilidades sobre las que se define la regla. Sin fijar U , la regla no delimita nada.

Conjunto vacío e igualdad

El conjunto vacío $\emptyset$ no tiene elementos, su cardinalidad es 0 y es subconjunto de cualquier conjunto.

Dos conjuntos son iguales cuando lo son elemento a elemento.

Subconjuntos

$A \subseteq B$ cuando todo elemento de A está también en B . Todo conjunto es subconjunto de sí mismo, $A \subseteq A$.

El subconjunto es **propio**, $A \subset B$, cuando además $A \neq B$: la contención se cumple pero B tiene al menos un elemento que A no tiene.

Ejercicio clase

La Dra dejó un ejercicio de que así:

Sea

$$\mathcal{U} = \{1, 2, 3, 4, \{1, 2\}, \{3, 5\}, \{1, 2, 3, 4\}\} \quad A = \{1, 2, 3, 4\}$$

Determinar si lo siguiente es verdadero o falso:

- a) $|\mathcal{U}| = 7$ **Verdadero**, pq tiene 7 elementos distintos
- b) $A \subseteq \mathcal{U}$ **Verdadero**, pq todos los elementos de A están en $\mathcal{U}$
- c) $A \in \mathcal{U}$ **Verdadero**, pq A es un elemento de $\mathcal{U}$
- d) $|A| = 4$ **Verdadero**, pq tiene 4 elementos distintos

Conjunto potencia

Definición 2.2 (Conjunto potencia). El conjunto formado por todos los subconjuntos de A , incluidos $\emptyset$ y el propio A . Se escribe $\mathcal{P}(A)$.

Su cardinalidad es $|\mathcal{P}(A)| = 2^{|A|}$. De dónde sale el 2^n : armar un subconjunto es decidir, para cada uno de los n elementos, si entra o no entra. Son dos opciones independientes por elemento, así que salen $2 \times 2 \times \cdots \times 2 = 2^n$ combinaciones, y cada una da un subconjunto distinto.

Ejemplo 2.3. Con $A = \{1, 2\}$ hay $n = 2$ elementos y $2^2 = 4$ subconjuntos:

$$\mathcal{P}(A) = \{ \emptyset, \{1\}, \{2\}, \{1, 2\} \}$$

Operaciones con conjuntos

Todas las que vimos son **binarias**: toman dos operandos.

Cerradura

Si a y b pertenecen a los enteros y el resultado de operarlos también es un entero, la operación es **cerrada** en los enteros. La cerradura sirve para ponerle etiqueta y nombre al álgebra en la que se está trabajando.

Las cinco operaciones

Operación	Símbolo	Qué devuelve
Unión	$A \cup B$	Lo que está en A , en B o en ambos
Intersección	$A \cap B$	Lo que está en los dos a la vez
Diferencia	$A \setminus B$	Lo de A que no está en B
Diferencia simétrica	$A \triangle B$	Lo que está en uno de los dos, pero no en ambos
Complemento	A^c	Lo de U que no está en A

Tabla 1: Las cinco operaciones vistas en clase.

Producto cartesiano

Definición 2.4 (Producto cartesiano). $A \times B$ es el conjunto de todos los pares ordenados cuyo primer elemento sale de A y cuyo segundo sale de B :

$$A \times B = \{(a, b) \mid a \in A, b \in B\}$$

Se emparejan todos los elementos de A con todos los de B , así que la cardinalidad es $|A \times B| = |A| \cdot |B|$.

3. Relaciones y funciones

24 de agosto de 2026

Resumen rápido. En esta clase vimos un repaso de relaciones y funciones, también vimos una intro a las álgebras.

Relaciones

Definición 3.1 (Relación binaria). Una relación binaria R de un conjunto X en un conjunto Y es un subconjunto del producto cartesiano $X \times Y$.

Si $(x, y) \in R$, escribimos xRy para denotar que x está relacionada con y . Si $X = Y$ decimos que R es una relación binaria **sobre** X .

Como una relación es un subconjunto de $X \times Y$, todo lo de conjuntos aplica: $\emptyset$ es una relación, y hay $2^{|X| \cdot |Y|}$ relaciones distintas entre X y Y .

Dominio, codominio y rango

El **dominio** está formado por los elementos del primer conjunto del que estamos hablando, y el **codominio** por los del segundo. El **rango** o imagen son los elementos que sí se usan, o sea los que participan de forma efectiva:

$$\text{Dom}(R) = \{x \in X \mid \exists y \in Y, (x, y) \in R\} \quad \text{Ran}(R) = \{y \in Y \mid \exists x \in X, (x, y) \in R\}$$

La diferencia entre codominio y rango es que el codominio se declara y el rango se calcula: Y es lo que la relación podría alcanzar, $\text{Ran}(R)$ es lo que de verdad alcanza.

Ejemplo 3.2. Sean $X = \{1, 2, 3\}$ y $Y = \{a, b\}$, con $R = \{(1, a), (1, b), (3, a)\}$. Entonces $\text{Dom}(R) = \{1, 3\}$ y $\text{Ran}(R) = \{a, b\}$. El 2 no participa y el codominio sigue siendo todo Y .

Relación n-aria

Una relación n-aria es un subconjunto del producto cartesiano de n conjuntos $A_1 \times A_2 \times \cdots \times A_n$. Esos son los conjuntos dominio y n es el **grado** de la relación.

R consiste en un conjunto de n-tuplas $(a_1, a_2, a_3, \dots, a_n)$ tales que el i -ésimo elemento de la tupla proviene del conjunto A_i . La relación binaria es el caso $n = 2$.

Propiedades de las relaciones

Se definen sobre una relación R en un conjunto X .

- **Reflexividad:** para todo x , la tupla (x, x) está en la relación. Es decir, x se relaciona consigo mismo para todo $x \in X$.
- **Simetría:** para todo $x, y \in X$, si (x, y) está en la relación, entonces (y, x) también.
- **Antisimetría:** para todo $x, y \in X$, si (x, y) y (y, x) están en la relación, entonces $x = y$. Dicho al revés, que es más fácil de ver: los únicos pares que pueden ir y venir son los de un elemento consigo mismo.
- **Transitividad:** para todo $x, y, z \in X$, si xRy y yRz , entonces xRz .

Ojito...

Simetría y antisimetría no son opuestas, se pueden cumplir las dos a la vez. La igualdad es el caso: si $x = y$ entonces $y = x$ (simétrica), y si ambas se cumplen entonces $x = y$ (antisimétrica).

Funciones

Son un tipo especial de relaciones. Es una relación pero con la restricción de que cada elemento de A debe tener un elemento de salida, o sea que solo debe aparecer una vez en el dominio.

Definición 3.3 (Función). $f : A \rightarrow B$ es una relación de A en B tal que para cada $a \in A$ existe exactamente un $b \in B$ con $(a, b) \in f$.

Mapear es una función: un mapa es una forma de asociar objetos únicos a cada elemento de un conjunto dado.

Tipos de funciones

- **Inyectiva:** la relación se da 1 a 1, un elemento de A no se puede relacionar con dos de B . Formalmente, si $f(x) = f(y)$ entonces $x = y$.
- **Sobreyectiva:** todos los elementos de B participan, ninguno se queda solo. O sea, el rango es todo el codominio.
- **Biyectiva:** ambas, inyectiva y sobreyectiva. Rango igual a codominio, y cada elemento de B le toca a exactamente un elemento de A .

La biyección es la que importa porque es la única que se puede invertir: existe $f^{-1} : B \rightarrow A$ y también es función.

Dado todo lo que hemos visto hasta ahora, todo eso se define dentro de una estructura algebraica.

4. Algebras

24 de agosto de 2026

Estructura algebraica

Definición 4.1 (Estructura sobre un conjunto). Conjunto de funciones, reglas y restricciones que dan significado a una colección de objetos.

Se dice que hay una **composición** en un conjunto no vacío S si a cada par de elementos de S se le asigna, de cierta forma y de manera única, un elemento de S .

Aridad

De acuerdo al número de argumentos requeridos para que un operador pueda realizar el cálculo (aridad), las operaciones pueden ser:

- Nularias
- Unarias
- Binarias
- Ternarias
- N-arias

Las operaciones algebraicas básicas son la **adición** y la **multiplicación**.

Propiedades de una operación binaria

Sea $*$ una operación binaria sobre un conjunto S .

- **Cerradura:** $a * b$ sigue estando en S . En los naturales la suma es cerrada, pero la resta no lo es: $3 - 5$ ya no es natural.
- **Asociatividad:** $(a * b) * c = a * (b * c)$, o sea que el orden de agrupar no cambia el resultado.
- **Identidad:** existe $e \in S$ tal que $a * e = e * a = a$. El 0 para la suma, el 1 para el producto.
- **Conmutatividad:** $a * b = b * a$.
- **Distributividad:** relaciona dos operaciones, $a * (b + c) = (a * b) + (a * c)$.
- **Idempotencia:** $a * a = a$. La unión y la intersección de conjuntos la cumplen.

Idea clave

La cerradura es la que decide de qué álgebra estamos hablando. Es la misma idea que ya salió con los conjuntos: si la operación se sale del conjunto, el conjunto no alcanza para describir lo que se está haciendo.

5. Continuación (Estructuras algebraicas)

26 de agosto de 2026

Definición y para qué sirven

Definición 5.1 (Estructura algebraica). Un conjunto no vacío S es llamado estructura algebraica si al menos una composición, o más exactamente una n -tupla de composiciones, está definida dentro de ella.

Sirven para diferenciar qué elementos se están utilizando y qué operaciones son válidas entre ellos. Por ejemplo, si el conjunto S contiene a los enteros, no se puede aplicar un producto vectorial.

Una estructura algebraica está compuesta por un conjunto S y las operaciones que pueden aplicarse sobre S , que satisfacen ciertas propiedades:

- Operación cerrada o interna (clausura)
- Asociativa
- Conmutativa
- Elemento neutro
- Elemento inverso (simetría)
- Distributividad

El elemento inverso es el que no había salido antes: para cada $a \in S$ existe $a^{-1} \in S$ tal que $a * a^{-1} = e$, con e el neutro. En $(\mathbb{Z}, +)$ el inverso de 3 es -3 ; en $(\mathbb{Z}, \cdot)$ el 3 no tiene inverso, porque $1/3$ ya no es entero.

Estructuras con una operación

Magma

Hace referencia a un conjunto equipado con un operador binario. Es la estructura algebraica más básica: consta de un conjunto M y una única operación binaria cerrada, sin que se imponga ninguna otra propiedad.

Semigrupo

Es un conjunto no vacío en el cual está definida una operación binaria asociativa, $(S, *)$.

Monoide

Estructura algebraica formada por un conjunto no vacío S y una operación binaria asociativa que además tiene elemento neutro.

Ejemplo 5.2. $(\mathbb{N}, +)$ es asociativa y su elemento neutro es el 0, así que es un monoide.

$(\mathbb{N}, \cdot)$ es asociativa y su neutro es el 1, así que también es un monoide.

$(\mathbb{Z}^+, +)$ es asociativa pero no tiene neutro, porque el 0 no está en $\mathbb{Z}^+$, así que solo llega a semigrupo.

Grupo

Si S es un conjunto no vacío y $*$ una operación binaria en S , entonces $(S, *)$ es un grupo si cumple con ser asociativo, tener elemento neutro y tener inversos.

Idea clave

Dicho de otro modo, un grupo es un monoide en el que cada elemento tiene un inverso. Cada estructura de la lista es la anterior más una propiedad, y por eso el orden en que se presentan no es arbitrario.

Grupo abeliano o conmutativo

Es una estructura de tipo grupo que además cumple con ser conmutativa.

Estructuras con dos operaciones**Anillo**

Es una estructura algebraica formada por un conjunto no vacío S y dos operaciones internas, llamadas usualmente suma y producto, $(S, +, \cdot)$, que cumplen ciertas propiedades.

Respecto a la operación suma es cerrado, asociativo, tiene elemento neutro, tiene elemento inverso y es conmutativo. Respecto a la operación producto es cerrado, asociativo, distributivo y conmutativo.

Ojito...

Lo del producto conmutativo hay que revisarlo. En la tabla de abajo, que es la que dio el profesor, la conmutatividad del producto es justo lo que separa al anillo del anillo conmutativo: el anillo la tiene solo en la suma. Es probable que esa última propiedad de la lista corresponda al anillo conmutativo.

Tabla de todas las estructuras

Estructura	Cerr.	Asoc.	Neutro	Inv.	Conm.	Ejemplo
Magma	✓					$(\mathbb{Z}, -)$
Semigrupo	✓	✓				$(\mathbb{N}^+, +)$
Monoide	✓	✓	✓			$(\{0, 1\}, \wedge), (\Sigma^*, \cdot)$
Grupo	✓	✓	✓	✓		$(S_3, \circ), (GL_n, \cdot)$
Grupo abeliano	✓	✓	✓	✓	✓	$(\mathbb{Z}, +), (\{0, 1\}, \oplus)$

Tabla 2: Estructuras con una operación $(S, *)$.

Fuera de la cadena principal

Estructura	Definición	Nota
Cuasigrupo	Magma más división única	No requiere asociatividad
Loop	Cuasigrupo más neutro	Tampoco asociativo
Semirretícula	Semigrupo conmutativo e idempotente ($a * a = a$)	$(\{0, 1\}, \wedge)$ lo es

Tabla 3: Estructuras que no caen en la cadena de arriba.

Estructuras con dos operaciones**Notas sobre las tablas:**

- La distributividad es el único axioma que relaciona las dos operaciones entre sí.

Estructura	$(S, +)$	$(S, \cdot)$	Distrib.	Ejemplo
Semianillo	Monoide conm.	Monoide	✓	$(\mathbb{N}, +, \cdot)$, tropical $(\text{máx}, +)$
Anillo	Grupo abeliano	Semigrupo	✓	$2\mathbb{Z}$, los pares
Anillo con unidad	Grupo abeliano	Monoide	✓	$(M_n(\mathbb{R}), +, \cdot)$
Anillo conmutativo	Grupo abeliano	Monoide conm.	✓	$(\mathbb{Z}, +, \cdot)$, $(\mathbb{Z}_6, +, \cdot)$
Dominio entero	Grupo abeliano	Monoide conm., sin divisores de 0	✓	$(\mathbb{Z}, +, \cdot)$
Anillo de división	Grupo abeliano	$(S \setminus \{0\}, \cdot)$ grupo	✓	Cuaterniones $\mathbb{H}$
Campo	Grupo abeliano	$(S \setminus \{0\}, \cdot)$ grupo abeliano	✓	$\mathbb{R}, \mathbb{Q}, \mathbb{Z}_5$

Tabla 4: Estructuras con dos operaciones $(S, +, \cdot)$.

- En el semianillo, la absorción $0 \cdot a = 0$ hay que pedirla como axioma: sin inversos aditivos no se puede demostrar. En el anillo sí se demuestra.
- La definición de anillo que se usa aquí sigue la lámina 49 y a Grimaldi, o sea que **no** exige unidad. Muchos textos modernos sí la exigen, y al que no la tiene le llaman *rng*.
- Cuasigrupo y loop no van debajo de grupo. La jerarquía es una retícula, no una cadena.

6. Matrices

2 de septiembre de 2026

Resumen rápido. En esta clase vimos así bn rápido que son los arreglos y las matrices, con sus operaciones, propiedades y así

Arreglos y matrices

Un arreglo es una lista de listas donde la longitud de cada nivel es la misma. El tamaño de un arreglo d -dimensional se indica como $m \times n \times \cdots \times p$

El caso más simple es el arreglo de una dimensión, o sea un vector. Sus elementos se escriben con un solo índice, y su tamaño es n :

$$u = (u_1, u_2, \dots, u_n), \quad v = (4, -2, 7, 0) \quad \text{de tamaño } 4.$$

Un vector también se puede escribir acostado o parado, y para las operaciones con matrices la diferencia sí importa:

$$\underbrace{\begin{pmatrix} 4 & -2 & 7 & 0 \end{pmatrix}}_{\text{vector fila, } 1 \times 4} \quad \underbrace{\begin{pmatrix} 4 \\ -2 \\ 7 \\ 0 \end{pmatrix}}_{\text{vector columna, } 4 \times 1}$$

Al subir una dimensión, cada elemento del arreglo es a su vez un arreglo, y ahí aparece la matriz

Una matriz es un arreglo de arreglos, donde se tienen filas y columnas. El elemento en la fila i y la columna j se escribe a_{ij} :

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = \begin{pmatrix} 2 & -1 & 0 \\ 4 & 3 & 5 \\ 0 & 1 & 7 \end{pmatrix}.$$

El orden de una matriz $m \times n$ quiere decir que tiene m filas y n columnas. Cuando $m = n$ es una matriz cuadrada.

La **diagonal principal** son los elementos a_{ij} donde $i = j$, o sea 2, 3 y 7 en el ejemplo. La **diagonal secundaria** es la que va al revés, de la esquina superior derecha a la inferior izquierda: 0, 3 y 0.

Tipos de matrices

- **Matriz cero:** todos sus elementos son 0. Es el neutro de la suma.
- **Matriz diagonal:** $a_{ij} = 0$ para todo $i \neq j$, o sea que solo la diagonal principal puede ser distinta de cero.
- **Matriz identidad I_n :** diagonal con puros unos en la diagonal principal. Es el neutro del producto.
- **Triangular superior:** $a_{ij} = 0$ para $i > j$, todo lo de abajo de la diagonal es cero. **Triangular inferior:** al revés, $a_{ij} = 0$ para $i < j$.

Un ejemplo de cada uno, todos de orden 3×3 :

$$\begin{array}{ccc}
 \underbrace{\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}}_{\text{cero}} & \underbrace{\begin{pmatrix} 3 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 2 \end{pmatrix}}_{\text{diagonal}} & \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{I_3} \\
 \\
 \underbrace{\begin{pmatrix} 2 & 7 & 1 \\ 0 & 4 & 6 \\ 0 & 0 & 3 \end{pmatrix}}_{\text{triangular superior}} & & \underbrace{\begin{pmatrix} 2 & 0 & 0 \\ 7 & 4 & 0 \\ 1 & 6 & 3 \end{pmatrix}}_{\text{triangular inferior}}
 \end{array}$$

Ojito...

La identidad es un caso particular de matriz diagonal, y la diagonal es a la vez triangular superior e inferior. Los tipos no son categorías separadas, se encajan unos dentro de otros.

Transpuesta, simetría y antisimetría**Matriz transpuesta**

Definición 6.1 (Transpuesta). La transpuesta A^T de una matriz A de orden $m \times n$ es la matriz de orden $n \times m$ que se obtiene intercambiando filas por columnas, o sea $(A^T)_{ij} = a_{ji}$.

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}, \quad A^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}.$$

Propiedades, con k un escalar:

- $(A^T)^T = A$
- $(A + B)^T = A^T + B^T$
- $(kA)^T = kA^T$
- $(AB)^T = B^T A^T$

Ojito...

La del producto invierte el orden. No es $A^T B^T$, y de hecho ese producto muchas veces ni siquiera está definido, porque las dimensiones dejan de calzar.

Matriz simétrica

Definición 6.2 (Simétrica). A es simétrica si $A = A^T$, es decir $a_{ij} = a_{ji}$ para todo i, j . Tiene que ser cuadrada, y se ve como un espejo respecto a la diagonal principal.

Matriz antisimétrica

Definición 6.3 (Antisimétrica). A es antisimétrica si $A = -A^T$, es decir $a_{ij} = -a_{ji}$.

$$\underbrace{\begin{pmatrix} 1 & 2 & 0 \\ 2 & 3 & 5 \\ 0 & 5 & 4 \end{pmatrix}}_{\text{simétrica}} \quad \underbrace{\begin{pmatrix} 0 & 2 & -1 \\ -2 & 0 & 5 \\ 1 & -5 & 0 \end{pmatrix}}_{\text{antisimétrica}}$$

Idea clave

En una antisimétrica la diagonal principal siempre es cero. Poniendo $i = j$ en la definición queda $a_{ii} = -a_{ii}$, y el único número que cumple eso es el cero.

Operaciones con matrices

Dos matrices son iguales si lo son elemento a elemento, o sea $a_{ij} = b_{ij}$ para todos los índices. Eso exige que sean del mismo orden.

Suma y producto por escalar

La suma se hace elemento a elemento, $(A + B)_{ij} = a_{ij} + b_{ij}$, y solo está definida entre matrices del mismo orden. El producto por un escalar multiplica cada entrada, $(kA)_{ij} = k a_{ij}$.

Propiedades:

- $A + B = B + A$, conmutativa
- $(A + B) + C = A + (B + C)$, asociativa
- $A + 0 = A$, la matriz cero es el neutro
- $A + (-A) = 0$, cada matriz tiene inverso aditivo
- $k(A + B) = kA + kB$ y $(k + l)A = kA + lA$, distributivas

Producto escalar o producto punto entre vectores

Definición 6.4 (Producto punto). Para dos vectores $u, v \in \mathbb{R}^n$,

$$u \cdot v = \sum_{i=1}^n u_i v_i = u_1 v_1 + u_2 v_2 + \cdots + u_n v_n.$$

El resultado es un escalar, no un vector.

Propiedades:

- $u \cdot v = v \cdot u$, conmutativo
- $u \cdot (v + w) = u \cdot v + u \cdot w$, distributivo
- $k(u \cdot v) = (ku) \cdot v = u \cdot (kv)$
- $u \cdot u \geq 0$, y vale 0 solo si u es el vector cero

Multiplicación de matrices

Definición 6.5 (Producto de matrices). Si A es de orden $m \times p$ y B de orden $p \times n$, entonces AB es de orden $m \times n$ y

$$(AB)_{ij} = \sum_{k=1}^p a_{ik} b_{kj},$$

o sea el producto punto de la fila i de A con la columna j de B .

Ojito...

El producto solo está definido si el número de columnas de A coincide con el número de filas de B . Ese p compartido es la condición que hay que revisar antes de multiplicar.

Propiedades:

- $(AB)C = A(BC)$, asociativa
- $A(B + C) = AB + AC$, distributiva
- $AI = IA = A$, la identidad es el neutro
- $AB \neq BA$ en general, **no** es conmutativa

Idea clave

Con la suma y el producto, las matrices cuadradas de orden n forman un anillo, pero no un anillo conmutativo, porque el producto no conmuta. Es el ejemplo que faltaba de la tabla de la clase pasada.

Multiplicación por bloques

Manipular matrices de dimensiones grandes es un proceso complejo para las computadoras. Conviene entonces manejar las matrices como bloques de submatrices más pequeñas.

La idea es partir la matriz con líneas horizontales y verticales:

$$A = \left(\begin{array}{cc|cc} 1 & 2 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ \hline 0 & 0 & 5 & 6 \\ 0 & 0 & 7 & 8 \end{array} \right) = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix},$$

donde cada A_{ij} es una submatriz de 2×2 . Si B se particiona de forma compatible, el producto se calcula con la misma fórmula de siempre, pero tratando cada bloque como si fuera una entrada:

$$AB = \begin{pmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{pmatrix}.$$

Ojito...

Compatible quiere decir que los cortes de columnas de A tienen que caer en los mismos lugares que los cortes de filas de B . Si no, los productos de bloques no están definidos.

Idea clave

Sirve porque cada bloque cabe en la memoria rápida de la máquina, así que se multiplica sin ir y venir a memoria principal a cada rato. También permite repartir los bloques entre varios procesadores, ya que cada uno se calcula por separado.

7. Sistemas de ecuaciones lineales

9 de septiembre de 2026

Resumen rápido. Por qué la linealidad es tan útil, cómo se junta un montón de ecuaciones lineales en un sistema, y las tres formas de resolverlo: eliminación, matriz aumentada con Gauss y con Gauss-Jordan. Cierra con el rango, que es lo que dice de un vistazo si un sistema tiene solución y cuántas.

Qué quiere decir lineal

Definición 7.1 (Expresión lineal). Una expresión es lineal respecto de sus variables cuando estas aparecen únicamente en **primer grado**, **no se multiplican entre sí**, y los cambios en las variables producen cambios de **magnitud constante** en el resultado.

Muchos fenómenos naturales se comportan así, y por eso el modelo lineal aparece en todos lados: llenar un tanque a flujo constante, moverse a velocidad constante, consumir recursos a tasa fija. La forma que se ve en la escuela es $y = mx + b$, y la **forma estándar** de la ecuación lineal en dos variables es

$$ax + by = c, \quad a, b, c \in \mathbb{R}.$$

Su gráfica es una recta: todo punto (x, y) de esa recta satisface la ecuación. Con una variable más,

$$ax + by + cz = d$$

es la ecuación de un **plano** en el espacio tridimensional.

Ejemplo 7.2. En una imagen, el color de cada píxel son sus cantidades de rojo, verde y azul, así que se puede tomar $x = R$, $y = G$, $z = B$. Una clasificación sencilla por color separa objeto de fondo con

$$2R - G + B - 100 \begin{cases} > 0 & \text{es objeto} \\ = 0 & \text{es el plano que define la frontera} \\ < 0 & \text{es fondo} \end{cases}$$

El plano parte el espacio RGB en dos, y de qué lado cae el píxel decide su clase.

Sistemas de ecuaciones lineales

Varias ecuaciones lineales sobre las mismas variables forman un sistema. En general, con m ecuaciones y n incógnitas:

$$\begin{array}{ccccccc} a_{11}x_1 & + & a_{12}x_2 & + \cdots + & a_{1n}x_n & = & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & + \cdots + & a_{2n}x_n & = & b_2 \\ & & & & \vdots & & \\ a_{m1}x_1 & + & a_{m2}x_2 & + \cdots + & a_{mn}x_n & = & b_m \end{array}$$

Los a_{ij} son los **coeficientes** de las incógnitas y los b_i las **constantes** del sistema.

Definición 7.3 (Solución, consistencia). Una solución es un conjunto de n números $x_1, \dots, x_n$ que satisface *cada una* de las ecuaciones. El sistema es **consistente** si tiene al menos una solución, e **inconsistente** si no tiene ninguna.

Definición 7.4 (Homogéneo). Si todas las constantes son $b_i = 0$ el sistema es **homogéneo**. Si al menos una es distinta de cero, es **no homogéneo**.

Con dos ecuaciones y dos incógnitas cada ecuación es una recta, y resolver el sistema es buscar dónde se cruzan. Solo hay tres desenlaces:

Geometría	Soluciones	Sistema
Se cruzan en un punto	Una única	Consistente
Son paralelas	Ninguna	Inconsistente
Son la misma recta	Infinitas	Consistente

Idea clave

Que haya solo tres casos no es casualidad del plano: vale para cualquier m y n . Un sistema lineal nunca tiene, digamos, dos soluciones o cinco. O ninguna, o una, o infinitas.

Ejemplo 7.5. Dos especies de insectos comparten recipiente. Cada individuo de la especie 1 consume 5 unidades del alimento AL1 y 3 del AL2; cada uno de la especie 2 consume 2 del AL1 y 4 del AL2. Cada día se suministran 900 de AL1 y 960 de AL2. Con x y y el número de individuos de cada especie:

$$\begin{aligned} 5x + 2y &= 900 \\ 3x + 4y &= 960 \end{aligned}$$

Contar insectos a mano es imposible, pero el consumo sí se mide, y de ahí sale el sistema.

Resolución por operaciones elementales

La idea es transformar el sistema en otro **equivalente**, o sea con las mismas soluciones, pero más simple. Hay tres operaciones permitidas:

Notación	Operación
R_{ij}	Intercambiar los renglones i y j
cR_i	Multiplicar el renglón i por una constante $c \neq 0$
$cR_i + R_j$	Multiplicar el renglón i por $c \neq 0$ y sumarlo al renglón j

La matriz aumentada

Se puede trabajar sobre las ecuaciones, pero es más cómodo tirar las variables y quedarse solo con los números, en la **matriz aumentada** del sistema:

$$(A \mid B) = \left(\begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & & & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} & b_m \end{array} \right)$$

Eliminación gaussiana	Lleva a forma escalonada
Gauss-Jordan	Sigue hasta forma escalonada reducida

Una matriz está en forma **escalonada** si cumple:

- I. El primer elemento distinto de 0 de cada renglón no nulo es un 1.
- II. Ese primer 1 aparece a la derecha del del renglón anterior.
- III. Los renglones de puros ceros quedan hasta abajo.

Y es **escalonada reducida** si además cumple:

- IV. En cada columna que contiene un 1 pivote, los demás elementos son 0.

Ejemplo 7.6. Resolviendo por Gauss el sistema $2x_1 + 6x_2 + x_3 = 7$, $x_1 + 2x_2 - x_3 = -1$, $5x_1 + 7x_2 - 4x_3 = 9$:

$$\left(\begin{array}{ccc|c} 2 & 6 & 1 & 7 \\ 1 & 2 & -1 & -1 \\ 5 & 7 & -4 & 9 \end{array} \right) \rightarrow \left(\begin{array}{ccc|c} 1 & 2 & -1 & -1 \\ 0 & 1 & \frac{3}{2} & \frac{9}{2} \\ 0 & 0 & 1 & 5 \end{array} \right) \rightarrow \left(\begin{array}{ccc|c} 1 & 0 & 0 & 10 \\ 0 & 1 & 0 & -3 \\ 0 & 0 & 1 & 5 \end{array} \right)$$

con R_{12} , luego $-2R_1 + R_2$ y $-5R_1 + R_3$, después $\frac{1}{2}R_2$, $3R_2 + R_3$ y $\frac{2}{11}R_3$. La matriz de en medio ya está escalonada y permite sustitución hacia atrás; la última es la reducida y da la solución directo: $x_1 = 10$, $x_2 = -3$, $x_3 = 5$.

Idea clave

Gauss-Jordan cuesta más operaciones pero no requiere sustitución hacia atrás: la solución se lee inspeccionando la matriz final.

Cómo leer la matriz final

Qué se ve	Qué significa
Pivotes = variables	Solución única
Pivotes < variables	Infinitas soluciones
Un renglón $[0 \ 0 \ \dots \ 0 \mid b \neq 0]$	Sin solución

Los dos primeros casos valen *siempre y cuando* no aparezca la contradicción del tercero. Un renglón de puros ceros a la izquierda con algo distinto de cero a la derecha dice $0 = b$, que nada satisface.

Cuando hay menos pivotes que variables, las que no tienen pivote son **variables libres**: se les asigna un parámetro t arbitrario y las demás quedan en términos de él. Como t recorre todos los reales, salen infinitas soluciones.

Sistemas homogéneos

Un sistema homogéneo **siempre es consistente**, porque $x_1 = x_2 = \dots = x_n = 0$ satisface todas las ecuaciones. Esa es la **solución trivial**.

Idea clave

La pregunta interesante no es si tiene solución, sino si tiene soluciones *no* triviales. Las tiene si el número m de ecuaciones es menor que el número n de incógnitas: faltan restricciones para clavar el origen como única respuesta.

Forma matricial y combinación lineal

Todo sistema se escribe como $AX = B$, con A la matriz de coeficientes, X el vector de incógnitas y B el de constantes. Esta forma es la que se encuentra en los algoritmos.

Si las columnas de A son $c_1, \dots, c_n$, entonces

$$AX = x_1c_1 + x_2c_2 + \dots + x_nc_n.$$

Idea clave

O sea que multiplicar A por un vector es tomar una **combinación lineal de las columnas** de A , con las incógnitas como coeficientes. Y resolver $AX = B$ es preguntar: ¿con qué pesos hay que combinar las columnas de A para producir exactamente B ? Si B no se puede armar así, el sistema es inconsistente.

Rango de una matriz

A los renglones de A se les llama vectores renglón y a sus columnas vectores columna. Como vectores, un conjunto de ellos puede ser linealmente independiente o dependiente.

Definición 7.7 (Dependencia lineal). Un conjunto de vectores es linealmente **dependiente** si alguno se puede escribir como combinación lineal de los demás. Si ninguno se puede, es linealmente **independiente**. Con dos vectores basta ver si son proporcionales: $u_1 = (3, 5)$ y $u_2 = (9, 15)$ son dependientes porque $u_2 = 3u_1$.

Definición 7.8 (Rango). El rango de una matriz A de $m \times n$, escrito $\text{Ran}(A)$, es el número máximo de vectores renglón o columna linealmente independientes.

Determinarlo a ojo es difícil, pero hay un atajo: si A es equivalente por renglones a una matriz escalonada B , entonces $\text{Ran}(A)$ es el número de renglones de B distintos de cero. Los renglones no nulos de B forman además una base del espacio de renglones de A .

Rango y sistemas

Teorema 7.9 (Consistencia de $AX = B$). *Un sistema lineal $AX = B$ es consistente si y solo si el rango de la matriz de coeficientes es igual al de la matriz aumentada:*

$$\text{Ran}(A) = \text{Ran}(A \mid B).$$

Teorema 7.10 (Número de parámetros). *Si el sistema $AX = B$ con n incógnitas es consistente y $r = \text{Ran}(A)$, entonces la solución contiene $n - r$ parámetros.*

Idea clave

Los dos teoremas juntos contestan todo de un golpe. Se calcula $\text{Ran}(A)$ y $\text{Ran}(A \mid B)$: si difieren no hay solución; si coinciden, $n - r$ dice cuántos parámetros libres quedan. Con $n - r = 0$ la solución es única, y con $n - r > 0$ hay infinitas. Es la tabla de arriba, dicha con un solo número.

Para qué sirve todo esto

La dependencia lineal sirve para generar datos del mismo tipo, por ejemplo muestras sintéticas o aumento de datos: si sé que un vector es combinación de otros, puedo fabricar más. En espectroscopia, los espectros estelares de un mismo tipo de la clasificación de Harvard son muy parecidos entre sí, y esa redundancia es justamente dependencia lineal.

La independencia lineal sirve para lo contrario, comprimir. En sensado comprimido una señal se descompone sobre una base linealmente independiente, y basta transmitir los coeficientes de esa combinación. Si transmisor y receptor comparten la base, nunca hace falta mandar la señal completa.

8. Determinantes

14 de septiembre de 2026

Resumen rápido. El determinante le asigna a cada matriz cuadrada un número que dice si es invertible. Se define con tres reglas, de ellas salen todas las demás propiedades, y hay tres formas de calcularlo: eliminación gaussiana, la fórmula grande con permutaciones y la expansión por cofactores. Dan el mismo número; lo que cambia es el costo. Sigue el capítulo 5 de Strang, *Introduction to Linear Algebra*.

Qué es y para qué sirve

Definición 8.1 (Determinante). Función que toma una matriz cuadrada A de $n \times n$ y devuelve un número, $\det A$ o $|A|$. Su propiedad central es

$$A^{-1} \text{ existe} \iff \det A \neq 0.$$

Para 2×2 la fórmula es directa:

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc.$$

Si $ad - bc = 0$, los renglones (a, b) y (c, d) son proporcionales, o sea linealmente dependientes, y la matriz no se puede invertir. Es la misma pregunta del rango, contestada con un solo número.

Se usa para saber si una matriz es invertible, para resolver sistemas $AX = B$ (si $\det A \neq 0$ la solución es única), para el jacobiano en un cambio de variables de una integral, y en visión por computadora y gráficos 3D, donde las transformaciones son matrices.

Idea clave

Geoméricamente, $|\det A|$ es el área del paralelogramo que forman los renglones de A (el volumen en 3×3). El signo dice si la transformación voltea la orientación. Por eso $\det A = 0$ es singular: los renglones se aplastan sobre una recta y el área es cero, ya no hay forma de deshacer eso.

Las tres reglas que lo definen

La fórmula $ad - bc$ no escala a n grande. Strang no define el determinante con una fórmula sino con tres propiedades; cualquier función que las cumpla es el determinante.

Regla 1. $\det I = 1$. Es la normalización: sin ella, $2 \det$ también cumpliría las otras dos reglas.

Regla 2. Intercambiar dos renglones cambia el signo.

$$\begin{vmatrix} 1 & 2 \\ 3 & 4 \end{vmatrix} = 4 - 6 = -2 \quad \begin{vmatrix} 3 & 4 \\ 1 & 2 \end{vmatrix} = 6 - 4 = 2$$

En consecuencia, una matriz de permutación P (la identidad con los renglones reordenados) tiene $\det P = +1$ si se llega a ella con un número par de intercambios y $\det P = -1$ si es impar.

Regla 3. Es lineal en cada renglón por separado, con los demás renglones fijos:

$$\begin{vmatrix} ta & tb \\ c & d \end{vmatrix} = t \begin{vmatrix} a & b \\ c & d \end{vmatrix} \quad \begin{vmatrix} a+a' & b+b' \\ c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} + \begin{vmatrix} a' & b' \\ c & d \end{vmatrix}$$

Ojito...

Lineal renglón por renglón no es lineal en toda la matriz. $\det(A + B) \neq \det A + \det B$ en general, y $\det(tA) = t^n \det A$, no $t \det A$: multiplicar la matriz entera por t escala los n renglones, y cada uno saca su propia t . Por ejemplo $\det(2I_3) = 2^3 = 8$.

Lo que se deduce de las tres reglas

Cada propiedad siguiente sale de las anteriores; no hay que memorizarlas sueltas.

Regla 4. Dos renglones iguales dan cero. Al intercambiarlos la matriz no cambia, pero la regla 2 dice que el signo sí. Entonces $D = -D$, y eso solo lo cumple $D = 0$.

$$\begin{vmatrix} 2 & 7 \\ 2 & 7 \end{vmatrix} = 14 - 14 = 0$$

Regla 5. Restar un múltiplo de un renglón a otro no cambia el determinante. Por la regla 3 el determinante se parte en dos, y el segundo pedazo tiene dos renglones iguales:

$$\begin{vmatrix} a & b \\ c - \ell a & d - \ell b \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} - \underbrace{\ell \begin{vmatrix} a & b \\ a & b \end{vmatrix}}_0 = \begin{vmatrix} a & b \\ c & d \end{vmatrix}$$

Esta es la que hace funcionar a la eliminación: sus pasos no mueven el determinante.

$$\begin{vmatrix} 1 & 2 \\ 3 & 7 \end{vmatrix} = 7 - 6 = 1 \xrightarrow{R_2 - 3R_1} \begin{vmatrix} 1 & 2 \\ 0 & 1 \end{vmatrix} = 1 - 0 = 1$$

Regla 6. Un renglón de ceros da cero. Ese renglón es 0 veces sí mismo; la regla 3 con $t = 0$ saca el cero afuera.

Regla 7. Si A es triangular, $\det A$ es el producto de la diagonal.

$$\begin{vmatrix} 2 & 7 & 1 \\ 0 & 3 & 5 \\ 0 & 0 & 4 \end{vmatrix} = (2)(3)(4) = 24$$

Por qué: si la diagonal no tiene ceros, con la regla 5 se limpia todo lo que está arriba de ella sin cambiar el determinante, queda $\text{diag}(d_1, \dots, d_n)$, la regla 3 saca cada d_i afuera y lo que queda es I , que vale 1. Si algún $d_i = 0$, la eliminación produce un renglón de ceros y el determinante es 0, que también es el producto de la diagonal.

Regla 8. $\det A = 0$ si y solo si A es singular. La eliminación lleva A a una triangular U usando solo la regla 5 (no cambia nada) y la regla 2 (cambia el signo). Entonces

$$\det A = \pm \det U = \pm d_1 d_2 \cdots d_n = \pm (\text{producto de los pivotes}).$$

Si A es singular, falta un pivote, aparece un cero en la diagonal y el producto es 0. Si es invertible, los n pivotes son distintos de cero y el producto también.

$$\begin{vmatrix} 1 & 2 \\ 2 & 4 \end{vmatrix} \xrightarrow{R_2 - 2R_1} \begin{vmatrix} 1 & 2 \\ 0 & 0 \end{vmatrix} = 0$$

Regla 9. $\det(AB) = (\det A)(\det B)$.

$$\underbrace{\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}}_{\det=-2} \underbrace{\begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix}}_{\det=6} = \underbrace{\begin{pmatrix} 4 & 6 \\ 10 & 12 \end{pmatrix}}_{\det=48-60=-12}$$

Con $B = A^{-1}$ queda $(\det A)(\det A^{-1}) = \det I = 1$, así que $\det A^{-1} = 1/\det A$. Ahí se ve otra vez que si $\det A = 0$ no hay inversa: no se puede dividir entre cero.

Regla 10. $\det A^T = \det A$.

$$\begin{vmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 1 & 0 & 6 \end{vmatrix} = 22 \qquad \begin{vmatrix} 1 & 0 & 1 \\ 2 & 4 & 0 \\ 3 & 5 & 6 \end{vmatrix} = 22$$

Idea clave

La regla 10 duplica todo lo anterior: lo que vale para renglones vale para columnas. Intercambiar dos columnas cambia el signo, una columna de ceros da cero, y más adelante se puede expandir por cofactores tanto por renglón como por columna.

Método 1: eliminación gaussiana

Es el método práctico. Se triangula, se multiplican los pivotes y se corrige el signo según cuántos intercambios hubo. En forma matricial la eliminación es $PA = LU$, y por la regla 9

$$(\det P)(\det A) = (\det L)(\det U) \implies \det A = \pm d_1 \cdots d_n,$$

porque $\det L = 1$ (L es triangular con unos en la diagonal), $\det U$ es el producto de los pivotes por la regla 7, y $\det P = \pm 1$ según la paridad de los intercambios. Cuesta del orden de $n^3/3$ operaciones.

Ejemplo 8.2. Calcular el determinante de $A = \begin{pmatrix} 0 & 1 & 2 \\ 1 & 2 & 3 \\ 2 & 1 & 1 \end{pmatrix}$.

Como $a_{11} = 0$ no sirve de pivote, primero se intercambian los renglones 1 y 2:

$$\begin{pmatrix} 0 & 1 & 2 \\ 1 & 2 & 3 \\ 2 & 1 & 1 \end{pmatrix} \xrightarrow{R_1 \leftrightarrow R_2} \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 2 & 1 & 1 \end{pmatrix} \xrightarrow{R_3 - 2R_1} \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & -3 & -5 \end{pmatrix} \xrightarrow{R_3 + 3R_2} \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{pmatrix}$$

Los pivotes son 1, 1, 1 y hubo un intercambio, número impar:

$$\det A = -(1)(1)(1) = -1.$$

Las tres matrices de $PA = LU$ ya estaban en la cadena: P es el intercambio $R_1 \leftrightarrow R_2$, L guarda los multiplicadores en el lugar donde se usaron y U es la última matriz.

$$\underbrace{\begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{P, \det=-1} \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & -3 & 1 \end{pmatrix}}_{L, \det=1} \underbrace{\begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{pmatrix}}_{U, \det=1}$$

De $(\det P)(\det A) = (\det L)(\det U)$ sale $(-1)\det A = 1$, o sea $\det A = -1$, igual que arriba.

Ojito...

L guarda lo que se *resta*. El paso $R_3 + 3R_2$ es $R_3 - (-3)R_2$, así que en L va -3 , no $+3$. El error no afecta al determinante, porque la diagonal de L sigue siendo de unos, pero sí rompe la factorización $LU = PA$.

Método 2: la fórmula grande

Sale de aplicar la regla 3 hasta el final: cada renglón se parte en una suma de renglones con una sola entrada distinta de cero. En 2×2 :

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & 0 \\ c & d \end{vmatrix} + \begin{vmatrix} 0 & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & 0 \\ 0 & d \end{vmatrix} + \begin{vmatrix} 0 & b \\ c & 0 \end{vmatrix} = ad \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} + bc \begin{vmatrix} 0 & 1 \\ 1 & 0 \end{vmatrix} = ad - bc.$$

En el segundo paso se tiraron los pedazos que tienen dos entradas en la misma columna, porque esos tienen una columna de ceros y valen 0. Lo que sobrevive son matrices de permutación, y cada una aporta el signo ± 1 .

En 3×3 sobreviven $3! = 6$ términos, uno por cada forma de escoger una entrada por renglón sin repetir columna:

$$\det A = \underbrace{a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32}}_{0 \text{ o } 2 \text{ intercambios: } +} \underbrace{-a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} - a_{13}a_{22}a_{31}}_{1 \text{ intercambio: } -}$$

El signo de cada término es el determinante de la permutación de sus columnas. Por ejemplo $a_{12}a_{23}a_{31}$ toma las columnas $(2, 3, 1)$; para regresar a $(1, 2, 3)$ hacen falta dos intercambios, así que va con $+$.

Definición 8.3 (Fórmula grande).

$$\det A = \sum_{\text{todas las } P} (\det P) a_{1\alpha} a_{2\beta} \cdots a_{n\omega},$$

donde $(\alpha, \beta, \dots, \omega)$ recorre los $n!$ ordenamientos de $(1, \dots, n)$ y $\det P = \pm 1$ según la paridad.

Si U es triangular, todo término que toma una entrada de abajo de la diagonal vale cero, y el único que sobrevive es $u_{11}u_{22} \cdots u_{nn}$. Es la regla 7 otra vez.

Por qué no se usa para calcular

n	términos $n!$	eliminación $\approx n^3/3$
3	6	9
5	120	42
10	3 628 800	333
20	2.4×10^{18}	2 667

Ojito...

El truco de las diagonales (Sarrus) solo sirve para $n = 3$. Con $n = 4$ da 8 productos y la fórmula grande pide $4! = 24$. Usarlo en 4×4 da un número equivocado.

Método 3: expansión por cofactores

Reduce un determinante de orden n a varios de orden $n - 1$. Sale de agrupar la fórmula grande según la entrada del primer renglón:

$$\det A = a_{11}(a_{22}a_{33} - a_{23}a_{32}) + a_{12}(a_{23}a_{31} - a_{21}a_{33}) + a_{13}(a_{21}a_{32} - a_{22}a_{31}).$$

Cada paréntesis es el determinante de 2×2 que queda al tachar el renglón 1 y la columna de esa entrada, con un signo. El de en medio viene al revés: $a_{23}a_{31} - a_{21}a_{33} = -(a_{21}a_{33} - a_{23}a_{31})$.

Definición 8.4 (Menor y cofactor). El **menor** M_{ij} es la submatriz de $(n - 1) \times (n - 1)$ que queda al tachar el renglón i y la columna j . El **cofactor** es

$$C_{ij} = (-1)^{i+j} \det M_{ij}.$$

El signo $(-1)^{i+j}$ sigue un tablero de ajedrez que arranca con $+$ en la esquina:

$$\begin{pmatrix} + & - & + & - \\ - & + & - & + \\ + & - & + & - \\ - & + & - & + \end{pmatrix}$$

La expansión se puede hacer por cualquier renglón i o, gracias a la regla 10, por cualquier columna j :

$$\det A = a_{i1}C_{i1} + \cdots + a_{in}C_{in} \quad \det A = a_{1j}C_{1j} + \cdots + a_{nj}C_{nj}.$$

Es recursiva: cada menor se vuelve a expandir hasta llegar a $\det[a] = a$, o a un 2×2 .

Idea clave

Conviene expandir por el renglón o la columna con más ceros. Cada $a_{ij} = 0$ anula su término completo, y ese menor ya no se calcula. En una matriz llena el costo es $n!$ igual que la fórmula grande; en una dispersa es muchísimo menos.

Cómo elegir el método

Método	Costo	Cuándo usarlo
Eliminación gaussiana	$\sim n^3/3$	Matriz numérica y general
Fórmula grande	$n!$	$n \leq 3$, o para demostrar propiedades
Cofactores	$n!$ en el peor caso	Muchos ceros, de banda o simbólica

Eliminación para calcular, cofactores cuando hay muchos ceros y la fórmula grande para demostrar.

Ejercicios

Ejemplo 8.5 (Ejercicio 1). $A = \begin{pmatrix} 3 & 5 \\ 2 & 4 \end{pmatrix}$. Con la fórmula de 2×2 :

$$\det A = (3)(4) - (5)(2) = 12 - 10 = 2.$$

Por eliminación sale lo mismo: $R_2 - \frac{2}{3}R_1$ deja el segundo pivote en $4 - \frac{10}{3} = \frac{2}{3}$, sin intercambios, y $(3)(\frac{2}{3}) = 2$.

Resultado

$\det A = 2$. Es distinto de cero, así que A es invertible.

Ejemplo 8.6 (Ejercicio 2). $A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 1 & 0 & 6 \end{pmatrix}$. La columna 1 tiene un cero, así que se expande por ella.

Solo quedan los términos de $a_{11} = 1$ y $a_{31} = 1$, ambos con signo $+$ en el tablero:

$$\begin{aligned} \det A &= 1 \cdot \begin{vmatrix} 4 & 5 \\ 0 & 6 \end{vmatrix} + 1 \cdot \begin{vmatrix} 2 & 3 \\ 4 & 5 \end{vmatrix} \\ &= (24 - 0) + (10 - 12) \\ &= 24 - 2 = 22. \end{aligned}$$

Por eliminación: $R_3 - R_1$ da $(0, -2, 3)$, y $R_3 + \frac{1}{2}R_2$ da $(0, 0, \frac{11}{2})$. Pivotes $1, 4, \frac{11}{2}$, sin intercambios: $(1)(4)(\frac{11}{2}) = 22$.

Resultado

$\det A = 22$.

Ejemplo 8.7 (Ejercicio 67).

$$B = \begin{pmatrix} 0 & 2 & 3 & 0 \\ 2 & 0 & 0 & 1 \\ 1 & 4 & 2 & 0 \\ 0 & 1 & 0 & 4 \end{pmatrix}$$

La columna 3 tiene dos ceros; solo sobreviven $b_{13} = 3$ y $b_{33} = 2$. En el tablero, las posiciones $(1, 3)$ y $(3, 3)$ llevan $+$ porque $1 + 3$ y $3 + 3$ son pares:

$$\det B = 3 \det M_{13} + 2 \det M_{33}.$$

Tachando renglón 1 y columna 3, y expandiendo por el renglón 1:

$$\det M_{13} = \begin{vmatrix} 2 & 0 & 1 \\ 1 & 4 & 0 \\ 0 & 1 & 4 \end{vmatrix} = 2(16 - 0) - 0 + 1(1 - 0) = 33.$$

Tachando renglón 3 y columna 3, y expandiendo por el renglón 1, donde solo sobrevive el 2 en la posición $(1, 2)$, que lleva $-$:

$$\det M_{33} = \begin{vmatrix} 0 & 2 & 0 \\ 2 & 0 & 1 \\ 0 & 1 & 4 \end{vmatrix} = -2(8 - 0) = -16.$$

Juntando:

$$\det B = 3(33) + 2(-16) = 99 - 32 = 67.$$

Resultado

$\det B = 67$.

9. Inversa de una matriz

21 de septiembre de 2026

Resumen rápido. Qué es la inversa, cuándo existe y sus propiedades. Tres formas de calcularla: Gauss-Jordan sobre $(A \mid I)$, la fórmula de la adjunta con cofactores, y la factorización LU resolviendo un sistema por columna. Cierra con su uso para resolver $AX = B$ y por qué en la práctica casi nunca se calcula explícitamente.

Definición y cuándo existe

Definición 9.1 (Matriz inversa). Una matriz cuadrada A de $n \times n$ es **invertible** (o no singular) si existe una matriz A^{-1} de $n \times n$ tal que

$$AA^{-1} = I_n \quad \text{y} \quad A^{-1}A = I_n.$$

Es el inverso del producto en el sentido de la clase de estructuras algebraicas: I es el neutro y A^{-1} es lo que, operado con A , regresa al neutro. La diferencia con los números es que aquí no basta con $A \neq 0$.

Teorema 9.2 (Existencia). A^{-1} existe si y solo si $\det A \neq 0$.

Es la regla 8 de determinantes vista desde el otro lado: si $\det A = 0$, las columnas de A son linealmente dependientes, falta un pivote y A es singular. En términos de rango, A es invertible exactamente cuando $\text{Ran}(A) = n$.

Ojito...

Una matriz no cuadrada nunca tiene inversa en este sentido. Si A es de $m \times n$ con $m \neq n$, los productos AA^{-1} y $A^{-1}A$ ni siquiera son del mismo tamaño, así que no pueden ser las dos la identidad.

Propiedades

Con A y B invertibles de $n \times n$:

1. **Unicidad.** Si X y Y son inversas de A , entonces $X = XI = X(AY) = (XA)Y = IY = Y$. Por eso se puede hablar de *la* inversa.
2. **Inversa del producto.** $(AB)^{-1} = B^{-1}A^{-1}$. Basta comprobarlo:

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AA^{-1} = I.$$

3. **Inversa de la transpuesta.** $(A^T)^{-1} = (A^{-1})^T$. Transponiendo $AA^{-1} = I$ queda $(A^{-1})^T A^T = I$, por la regla del producto transpuesto.
4. **Determinante de la inversa.** $\det A^{-1} = 1/\det A$. Sale de la regla 9: $(\det A)(\det A^{-1}) = \det I = 1$.

Ojito...

En la del producto el orden se invierte, igual que con la transpuesta. La idea es la de ponerse y quitarse los calcetines y los zapatos: lo último que se aplicó es lo primero que se deshace. $A^{-1}B^{-1}$ en general **no** es la inversa de AB , porque el producto de matrices no conmuta.

Método 1: Gauss-Jordan

Se arma la matriz aumentada $(A \mid I_n)$ y se aplican operaciones elementales de renglón hasta que el bloque izquierdo sea la identidad. Lo que queda a la derecha es la inversa:

$$(A \mid I_n) \xrightarrow{\text{Gauss-Jordan}} (I_n \mid A^{-1}).$$

Si en el camino aparece un renglón de ceros en el bloque izquierdo, A es singular y se detiene todo: no hay inversa.

Idea clave

Por qué funciona: cada operación elemental es multiplicar por la izquierda por una matriz elemental E_k . Si $E_m \cdots E_2 E_1 A = I$, entonces el producto $E_m \cdots E_1$ es A^{-1} . Al bloque derecho se le aplican las mismas operaciones, así que termina valiendo $E_m \cdots E_1 I = A^{-1}$. El bloque de la derecha nada más va guardando el registro de lo que se le hizo a A .

Ejemplo 9.3. Invertir $A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$.

$$\left(\begin{array}{ccc|ccc} 1 & 2 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 0 & 1 & 0 \\ 5 & 6 & 0 & 0 & 0 & 1 \end{array} \right) \xrightarrow{R_3 - 5R_1} \left(\begin{array}{ccc|ccc} 1 & 2 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 0 & 1 & 0 \\ 0 & -4 & -15 & -5 & 0 & 1 \end{array} \right)$$

Con el segundo pivote se limpia su columna arriba y abajo, $R_3 + 4R_2$ y $R_1 - 2R_2$:

$$\left(\begin{array}{ccc|ccc} 1 & 0 & -5 & 1 & -2 & 0 \\ 0 & 1 & 4 & 0 & 1 & 0 \\ 0 & 0 & 1 & -5 & 4 & 1 \end{array} \right)$$

El tercer pivote ya es 1. Se limpia su columna con $R_1 + 5R_3$ y $R_2 - 4R_3$:

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & -24 & 18 & 5 \\ 0 & 1 & 0 & 20 & -15 & -4 \\ 0 & 0 & 1 & -5 & 4 & 1 \end{array} \right) \implies A^{-1} = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}.$$

Idea clave

Que la inversa salga con puros enteros no es suerte: aquí $\det A = 1$, y en la fórmula de la adjunta de abajo se divide entre $\det A$. Si el determinante fuera 3, casi seguro aparecerían tercios.

Método 2: la matriz adjunta

Definición 9.4 (Adjunta). Sea C la matriz de cofactores de A , con $C_{ij} = (-1)^{i+j} \det M_{ij}$ como en la clase de determinantes. La **adjunta** es su transpuesta, $\text{Adj}(A) = C^T$. Si $\det A \neq 0$,

$$A^{-1} = \frac{1}{\det A} \text{Adj}(A).$$

Por qué funciona: la entrada (i, j) de $A \cdot \text{Adj}(A)$ es $a_{i1}C_{j1} + \cdots + a_{in}C_{jn}$, el renglón i de A contra los cofactores del renglón j .

- Si $i = j$, es la expansión por cofactores del renglón i , o sea $\det A$.
- Si $i \neq j$, es la expansión de una matriz en la que el renglón j se reemplazó por el renglón i . Esa matriz tiene dos renglones iguales y su determinante es 0 (regla 4).

Entonces $A \cdot \text{Adj}(A) = (\det A) I$, y dividiendo entre $\det A$ queda la fórmula.

Ojito...

La transpuesta es lo que más se olvida. El cofactor C_{ij} va en la posición (j, i) de la adjunta, no en la (i, j) . Si se omite la transpuesta, la matriz sale mal y la comprobación $AA^{-1} = I$ falla.

El procedimiento es: calcular $\det A$ y revisar que no sea cero, calcular los n^2 cofactores, transponer y dividir entre $\det A$.

Ejemplo 9.5. Invertir $A = \begin{pmatrix} 4 & 7 \\ 2 & 6 \end{pmatrix}$.

Determinante. $\det A = (4)(6) - (7)(2) = 24 - 14 = 10$. Como es distinto de cero, la inversa existe.

Cofactores. En 2×2 cada menor es una sola entrada, la que queda al tachar renglón y columna. Con el tablero $\begin{pmatrix} + & - \\ - & + \end{pmatrix}$:

$$C_{11} = +6, \quad C_{12} = -2, \quad C_{21} = -7, \quad C_{22} = +4.$$

Adjunta e inversa.

$$C = \begin{pmatrix} 6 & -2 \\ -7 & 4 \end{pmatrix} \Rightarrow \text{Adj}(A) = C^T = \begin{pmatrix} 6 & -7 \\ -2 & 4 \end{pmatrix} \Rightarrow A^{-1} = \frac{1}{10} \begin{pmatrix} 6 & -7 \\ -2 & 4 \end{pmatrix} = \begin{pmatrix} \frac{3}{5} & -\frac{7}{10} \\ -\frac{1}{5} & \frac{2}{5} \end{pmatrix}.$$

Comprobación.

$$AA^{-1} = \frac{1}{10} \begin{pmatrix} 4 & 7 \\ 2 & 6 \end{pmatrix} \begin{pmatrix} 6 & -7 \\ -2 & 4 \end{pmatrix} = \frac{1}{10} \begin{pmatrix} 24 - 14 & -28 + 28 \\ 12 - 12 & -14 + 24 \end{pmatrix} = \frac{1}{10} \begin{pmatrix} 10 & 0 \\ 0 & 10 \end{pmatrix} = I_2.$$

Idea clave

En 2×2 la adjunta se escribe de memoria: se intercambian las entradas de la diagonal y se les cambia el signo a las otras dos.

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Sirve para matrices chicas y para explicar la relación entre determinante, cofactores e inversa. Para n grande hay que calcular n^2 determinantes de orden $n - 1$, y eso ya no conviene.

Método 3: factorización LU

Definición 9.6 (Factorización LU). Escribir $A = LU$, con L triangular inferior con unos en la diagonal y U triangular superior. U es la matriz que deja la eliminación gaussiana y L guarda los multiplicadores m_{ij} debajo de la diagonal, cada uno en la posición donde se usó.

Aquí se supone que la eliminación no necesita intercambiar renglones. Si los necesita, la factorización es $PA = LU$, como en la clase de determinantes.

La inversa $X = A^{-1}$ cumple $AX = I$, que es n sistemas, uno por columna: $Ax_k = e_k$, con e_k la columna k de la identidad. Con $A = LU$, cada sistema se parte en dos triangulares:

$$Ly_k = e_k \quad (\text{sustitución hacia adelante}), \quad Ux_k = y_k \quad (\text{sustitución hacia atrás}).$$

Las x_k son las columnas de A^{-1} .

Idea clave

La gracia es que la factorización se hace **una sola vez**, con costo $\sim n^3/3$. Cada sistema triangular después cuesta solo $\sim n^2$. Con muchos lados derechos, sean las columnas de I o muchos vectores b distintos, se reutilizan L y U y no se vuelve a eliminar.

Ejemplo 9.7. Factorizar e invertir $A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix}$.

Eliminación. El primer pivote es 2, con multiplicadores $m_{21} = 4/2 = 2$ y $m_{31} = 8/2 = 4$. Después el segundo pivote es 1, con $m_{32} = 3/1 = 3$:

$$A \xrightarrow{R_2-2R_1, R_3-4R_1} \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 3 & 5 \end{pmatrix} \xrightarrow{R_3-3R_2} \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix} = U, \quad L = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}.$$

De paso, $\det A = \det U = (2)(1)(2) = 4 \neq 0$, así que la inversa existe.

Columna 1. $Ly_1 = e_1$ se resuelve de arriba hacia abajo, y $Ux_1 = y_1$ de abajo hacia arriba:

$$\begin{aligned} y_{11} &= 1, & 2x_{31} &= 2 \implies x_{31} = 1, \\ 2(1) + y_{21} &= 0 \implies y_{21} = -2, & x_{21} + 1 &= -2 \implies x_{21} = -3, \\ 4(1) + 3(-2) + y_{31} &= 0 \implies y_{31} = 2, & 2x_{11} - 3 + 1 &= 1 \implies x_{11} = \frac{3}{2}. \end{aligned}$$

Columnas 2 y 3. El mismo procedimiento con e_2 y e_3 da

$$y_2 = \begin{pmatrix} 0 \\ 1 \\ -3 \end{pmatrix} \rightarrow x_2 = \begin{pmatrix} -\frac{1}{2} \\ \frac{5}{2} \\ -\frac{3}{2} \end{pmatrix}, \quad y_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \rightarrow x_3 = \begin{pmatrix} 0 \\ -\frac{1}{2} \\ \frac{1}{2} \end{pmatrix}.$$

Por ejemplo, en $Ux_2 = y_2$ se despeja primero $2x_{32} = -3$, luego $x_{22} = 1 - x_{32} = \frac{5}{2}$, y al final $2x_{12} = 0 - x_{22} - x_{32} = -1$.

Inversa. Se juntan las tres columnas:

$$A^{-1} = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} & -\frac{1}{2} & 0 \\ -3 & \frac{5}{2} & -\frac{1}{2} \\ 1 & -\frac{3}{2} & \frac{1}{2} \end{pmatrix}.$$

Ojito...

Aquí los multiplicadores entran a L con su signo tal cual porque todas las operaciones fueron de la forma $R_i - m_{ij}R_j$. Si una flecha dice $R_i + 3R_j$, en L va -3 . Es la misma trampa de la clase de determinantes.

Resolver sistemas con la inversa

Si A es invertible, el sistema $AX = B$ tiene solución única, y se obtiene multiplicando ambos lados por A^{-1} por la izquierda:

$$AX = B \implies A^{-1}AX = A^{-1}B \implies X = A^{-1}B.$$

Ejemplo 9.8. Resolver $4x + 7y = 1$, $2x + 6y = 0$. La matriz de coeficientes es la del método 2, cuya inversa ya se tiene:

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} \frac{3}{5} & -\frac{7}{10} \\ -\frac{1}{5} & \frac{2}{5} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{3}{5}(1) - \frac{7}{10}(0) \\ -\frac{1}{5}(1) + \frac{2}{5}(0) \end{pmatrix} = \begin{pmatrix} \frac{3}{5} \\ -\frac{1}{5} \end{pmatrix}.$$

Sustituyendo: $4(\frac{3}{5}) + 7(-\frac{1}{5}) = \frac{12-7}{5} = 1$ y $2(\frac{3}{5}) + 6(-\frac{1}{5}) = \frac{6-6}{5} = 0$. Satisface las dos ecuaciones.

Resultado

$$x = \frac{3}{5}, y = -\frac{1}{5}.$$

Ojito...

$X = A^{-1}B$ es la forma de escribir la solución, no la forma de calcularla. En software numérico casi nunca se calcula A^{-1} : se factoriza $A = LU$ y se resuelven los dos sistemas triangulares con B directamente. Sale más barato, porque calcular la inversa equivale a resolver n sistemas en vez de uno, y además acumula menos error de redondeo.

Cómo elegir el método

Método	Costo	Cuándo usarlo
Gauss-Jordan	$\sim n^3$	A mano, cualquier tamaño chico o mediano
Adjunta	n^2 determinantes	2×2 , 3×3 o simbólica
LU	$\sim n^3/3$, luego $\sim n^2$ por columna	Muchos lados derechos, cómputo

Donde aparece: análisis de circuitos y redes eléctricas, transformaciones geométricas en gráficos por computadora (deshacer una rotación o un escalamiento es aplicar la inversa) y el modelo de entrada-salida de Leontief en economía. Ahí A dice cuánto consume cada sector de los demás para producir una unidad y d es la demanda externa; la producción que hace falta es $(I - A)^{-1}d$.

10. Eigenvalores y eigenvectores

28 de septiembre de 2026

Resumen rápido. Qué es un eigenvector: una dirección que la matriz no gira, solo estira, encoge o voltea. Cómo se calculan con el polinomio característico $\det(A - \lambda I) = 0$ y luego resolviendo un sistema homogéneo por cada eigenvalor. Multiplicidad algebraica y geométrica, propiedades que conectan con determinante, traza e inversa, diagonalización $A = PDP^{-1}$ para sacar potencias, el método de la potencia y dónde aparece todo esto en computación.

La idea: direcciones que la matriz no gira

Una matriz A de $n \times n$ es una transformación: toma un vector v y regresa otro vector Av . En general Av apunta hacia otro lado, la matriz gira y estira al mismo tiempo. Pero casi siempre hay algunas direcciones especiales en las que A no gira nada: el vector sale sobre la misma recta por el origen, nada más más largo, más corto o al revés.

Definición 10.1 (Eigenvalor y eigenvector). Sea A de $n \times n$. Un escalar λ es un **eigenvalor** (o valor propio) de A si existe un vector $v \neq 0$ tal que

$$Av = \lambda v.$$

Ese v es un **eigenvector** (o vector propio) asociado a λ . Al par (λ, v) se le llama eigenpar.

El prefijo *eigen* viene del alemán y quiere decir “propio”: son los valores y vectores propios de la matriz, los que dicen cómo actúa ella en particular.

- $\lambda > 1$: en esa dirección A estira.
- $0 < \lambda < 1$: encoge.
- $\lambda < 0$: voltea el sentido, y además estira o encoge según $|\lambda|$.
- $\lambda = 0$: aplasta esa dirección al origen, $Av = 0$.

Ojito...

El vector cero queda excluido a propósito. $A \cdot 0 = \lambda \cdot 0$ se cumple para cualquier λ , así que si se permitiera, todo número sería eigenvalor y la definición no diría nada. El eigenvalor $\lambda = 0$ sí está permitido; el eigenvector cero, no.

Ejemplo 10.2. Comprobar si $u = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ y $w = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ son eigenvectores de $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$.

$$Au = \begin{pmatrix} 4+1 \\ 2+3 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \end{pmatrix} = 5 \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad Aw = \begin{pmatrix} 4 \\ 2 \end{pmatrix}.$$

Au es $5u$, así que u es eigenvector con eigenvalor 5. $Aw = (4, 2)$ no es múltiplo de $(1, 0)$, porque ningún λ hace $\lambda \cdot 0 = 2$. Entonces w no es eigenvector: A lo gira.

Si v es eigenvector, cualquier múltiplo cv con $c \neq 0$ también lo es, porque $A(cv) = cAv = c\lambda v = \lambda(cv)$. Por eso no se habla de *el* eigenvector sino de una dirección. En el ejemplo, $(2, 2)$ y $(-7, -7)$ son igual de válidos que $(1, 1)$.

Ejemplo 10.3 (Tres transformaciones del plano). **Escalamiento.** $A = \begin{pmatrix} 3 & 0 \\ 0 & \frac{1}{2} \end{pmatrix}$ estira el eje x al triple y encoge el eje y a la mitad. Los eigenvectores son los ejes: $(1, 0)$ con $\lambda = 3$ y $(0, 1)$ con $\lambda = \frac{1}{2}$. En una matriz diagonal los eigenvalores se leen directo en la diagonal.

Reflexión sobre la recta $y = x$. $A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ intercambia las coordenadas. Lo que está sobre la recta no se mueve: $A(1, 1) = (1, 1)$, eigenvalor 1. Lo que está sobre la recta perpendicular se voltea: $A(1, -1) = (-1, 1) = -(1, -1)$, eigenvalor -1 .

Rotación de 90° . $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ gira todo vector un cuarto de vuelta. Ninguna dirección del plano sale sobre sí misma, así que no hay eigenvectores reales. Más abajo se ve que sus eigenvalores son complejos, $\pm i$.

El polinomio característico

La definición no dice cómo encontrar λ , porque tiene dos incógnitas multiplicándose, λ y v . El truco es pasar todo de un lado:

$$Av = \lambda v \iff Av - \lambda Iv = 0 \iff (A - \lambda I)v = 0.$$

Hace falta el I porque $A - \lambda$ no tiene sentido: no se le resta un número a una matriz. $\lambda v = \lambda Iv$ sí.

Lo que queda es un **sistema homogéneo** con matriz $A - \lambda I$. De la clase de sistemas, un homogéneo siempre tiene la solución trivial $v = 0$, y tiene otras soluciones exactamente cuando la matriz es singular. De la clase de inversa, singular es lo mismo que determinante cero. Entonces:

$$\lambda \text{ es eigenvalor de } A \iff (A - \lambda I)v = 0 \text{ tiene solución } v \neq 0 \iff \det(A - \lambda I) = 0.$$

Con eso la v desaparece y queda una ecuación solo en λ .

Definición 10.4 (Polinomio y ecuación característica). El **polinomio característico** de A es $p(\lambda) = \det(A - \lambda I)$. Es un polinomio de grado n en λ . La **ecuación característica** es $p(\lambda) = 0$, y sus raíces son los eigenvalores de A .

Idea clave

Todo el tema descansa en una cadena de tres clases: eigenvalor $\rightarrow$ sistema homogéneo con solución no trivial $\rightarrow$ matriz singular $\rightarrow$ determinante cero. Si se entiende esa cadena, el procedimiento sale solo.

Como p tiene grado n , una matriz de $n \times n$ tiene a lo más n eigenvalores distintos. Contando repeticiones y admitiendo raíces complejas, tiene exactamente n , por el teorema fundamental del álgebra.

El procedimiento completo es:

1. Calcular $p(\lambda) = \det(A - \lambda I)$: restar λ a cada entrada de la diagonal y sacar el determinante con cualquiera de los métodos de la clase de determinantes.
2. Resolver $p(\lambda) = 0$. Las raíces son los eigenvalores.
3. Para cada eigenvalor λ_i , resolver el sistema homogéneo $(A - \lambda_i I)v = 0$ por eliminación gaussiana. Sus soluciones no nulas son los eigenvectores.

Idea clave

En 2×2 el polinomio se escribe de memoria:

$$\det \begin{pmatrix} a - \lambda & b \\ c & d - \lambda \end{pmatrix} = (a - \lambda)(d - \lambda) - bc = \lambda^2 - (a + d)\lambda + (ad - bc).$$

El coeficiente de λ es menos la **traza** $\text{tr}(A) = a + d$, la suma de la diagonal, y el término independiente es $\det A$. O sea $p(\lambda) = \lambda^2 - \text{tr}(A)\lambda + \det A$.

Ejemplo completo en 2×2

Ejemplo 10.5. Encontrar eigenvalores y eigenvectores de $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$.

Polinomio. $\text{tr}(A) = 7$ y $\det A = 12 - 2 = 10$, así que

$$p(\lambda) = \lambda^2 - 7\lambda + 10 = (\lambda - 5)(\lambda - 2).$$

Los eigenvalores son $\lambda_1 = 5$ y $\lambda_2 = 2$.

Eigenvector para $\lambda_1 = 5$. Se resta 5 en la diagonal y se escalona:

$$A - 5I = \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix} \xrightarrow{R_2 + 2R_1} \begin{pmatrix} -1 & 1 \\ 0 & 0 \end{pmatrix}.$$

Queda una sola ecuación, $-x + y = 0$, o sea $y = x$. Con $x = t$ libre, $v = t(1, 1)$. Se toma $v_1 = (1, 1)$.

Eigenvector para $\lambda_2 = 2$.

$$A - 2I = \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix} \xrightarrow{R_2 - R_1} \begin{pmatrix} 2 & 1 \\ 0 & 0 \end{pmatrix}.$$

Queda $2x + y = 0$, o sea $y = -2x$. Con $x = t$, $v = t(1, -2)$. Se toma $v_2 = (1, -2)$.

Comprobación.

$$Av_1 = \begin{pmatrix} 4+1 \\ 2+3 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \end{pmatrix} = 5v_1, \quad Av_2 = \begin{pmatrix} 4-2 \\ 2-6 \end{pmatrix} = \begin{pmatrix} 2 \\ -4 \end{pmatrix} = 2v_2.$$

Resultado

$\lambda_1 = 5$ con $v_1 = (1, 1)$, y $\lambda_2 = 2$ con $v_2 = (1, -2)$.

Ojito...

Al escalonar $A - \lambda I$ **siempre** tiene que aparecer al menos un renglón de ceros. Si sale con pivote en todas las columnas, la única solución es $v = 0$, y eso quiere decir que el λ está mal: se equivocó uno al factorizar p o al restar en la diagonal. Es una comprobación gratis a media cuenta.

Ejemplo en 3×3 y eigenespacios

Definición 10.6 (Eigenespacio). Para un eigenvalor λ , el **eigenespacio** E_λ es el conjunto de todas las soluciones de $(A - \lambda I)v = 0$: los eigenvectores de λ más el vector cero. Es el espacio nulo de $A - \lambda I$.

Por el teorema de rango de la clase de sistemas, la dimensión de E_λ es el número de variables libres, $n - \text{Ran}(A - \lambda I)$. Puede ser una recta, un plano o algo más grande.

Ejemplo 10.7. Encontrar eigenvalores y eigespacios de $A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$.

Polinomio. Para aligerar la cuenta se escribe $\mu = 2 - \lambda$ en la diagonal y se expande por el primer renglón:

$$\begin{aligned} \det \begin{pmatrix} \mu & 1 & 1 \\ 1 & \mu & 1 \\ 1 & 1 & \mu \end{pmatrix} &= \mu(\mu^2 - 1) - 1(\mu - 1) + 1(1 - \mu) \\ &= \mu^3 - 3\mu + 2 = (\mu - 1)^2(\mu + 2). \end{aligned}$$

Regresando a λ : $\mu - 1 = 1 - \lambda$ y $\mu + 2 = 4 - \lambda$, entonces

$$p(\lambda) = (1 - \lambda)^2(4 - \lambda).$$

Los eigenvalores son $\lambda = 4$ y $\lambda = 1$, este último como raíz doble.

Eigespacio de $\lambda = 4$.

$$A - 4I = \begin{pmatrix} -2 & 1 & 1 \\ 1 & -2 & 1 \\ 1 & 1 & -2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{pmatrix}.$$

Dos pivotes, una variable libre: $x = z$, $y = z$. Con $z = t$, E_4 es la recta generada por $(1, 1, 1)$.

Eigespacio de $\lambda = 1$.

$$A - I = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \xrightarrow{R_2 - R_1, R_3 - R_1} \begin{pmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

Un pivote, dos variables libres. La ecuación es $x + y + z = 0$, así que con $y = s$ y $z = t$:

$$v = \begin{pmatrix} -s - t \\ s \\ t \end{pmatrix} = s \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} + t \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}.$$

E_1 es un plano, el que es perpendicular a $(1, 1, 1)$.

Comprobación. $A(1, 1, 1) = (4, 4, 4)$ y $A(-1, 1, 0) = (-2 + 1, -1 + 2, -1 + 1) = (-1, 1, 0)$.

Resultado

$\lambda = 4$ con $E_4 = \text{gen}\{(1, 1, 1)\}$, y $\lambda = 1$ con $E_1 = \text{gen}\{(-1, 1, 0), (-1, 0, 1)\}$.

Idea clave

Para 3×3 en adelante, factorizar p es lo difícil. Dos atajos: si la matriz tiene un patrón, como aquí la diagonal repetida, conviene un cambio de variable; y si hay que adivinar raíces enteras, solo pueden ser divisores del término independiente, que es $\det A$.

Multiplicidad algebraica y geométrica

Una raíz repetida de p puede dar un eigenspacio grande, como en el ejemplo anterior, o uno chico. Para distinguir se usan dos números.

Definición 10.8 (Multiplicidades). Sea λ un eigenvalor de A .

- Su **multiplicidad algebraica** es cuántas veces aparece λ como raíz de p .
- Su **multiplicidad geométrica** es la dimensión de E_λ , o sea cuántos eigenvectores linealmente independientes tiene.

Siempre se cumple $1 \leq \text{geométrica} \leq \text{algebraica}$.

En el ejemplo de 3×3 , $\lambda = 1$ tiene algebraica 2 y geométrica 2: la raíz doble trajo un plano entero de eigenvectores. No siempre pasa.

Ejemplo 10.9 (Matriz defectuosa). Sea $A = \begin{pmatrix} 3 & 1 \\ 0 & 3 \end{pmatrix}$. Es triangular, así que $p(\lambda) = (3 - \lambda)^2$ y el único eigenvalor es $\lambda = 3$, con multiplicidad algebraica 2.

$$A - 3I = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

Ya está escalonada, con un pivote. La ecuación es $y = 0$ y x queda libre: $E_3 = \text{gen}\{(1, 0)\}$, una recta. Multiplicidad geométrica 1.

Geoméricamente, A estira todo por 3 y además desliza en horizontal: el eje x se queda en su lugar, pero cualquier vector con $y \neq 0$ se ladea. Solo sobrevive una dirección.

Cuando la geométrica es menor que la algebraica se dice que la matriz es **defectuosa**: le faltan eigenvectores. Eso importa en la diagonalización, más abajo.

Eigenvalores complejos

Ejemplo 10.10. Para la rotación $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ se tiene $\text{tr}(A) = 0$ y $\det A = 0 - (-1) = 1$, así que

$$p(\lambda) = \lambda^2 + 1 = 0 \implies \lambda = \pm i.$$

Para $\lambda = i$:

$$A - iI = \begin{pmatrix} -i & -1 \\ 1 & -i \end{pmatrix}.$$

El primer renglón da $-ix - y = 0$, o sea $y = -ix$, y el segundo es el mismo multiplicado por i . Con $x = 1$, $v = (1, -i)$. Para $\lambda = -i$ sale el conjugado, $v = (1, i)$.

Ojito...

Una matriz con entradas reales puede tener eigenvalores complejos, y cuando los tiene vienen en pares conjugados $a \pm bi$. En la práctica casi siempre indican una rotación escondida en la transformación. En 2×2 se detectan antes de factorizar: si el discriminante $\text{tr}(A)^2 - 4 \det A$ es negativo, las raíces son complejas. Aquí da $0 - 4 = -4$.

Propiedades

Sean $\lambda_1, \dots, \lambda_n$ los eigenvalores de A , contados con su multiplicidad algebraica.

1. Suma y producto.

$$\lambda_1 + \dots + \lambda_n = \text{tr}(A), \quad \lambda_1 \cdots \lambda_n = \det A.$$

Salen de comparar coeficientes de $p(\lambda)$ con su forma factorizada $(\lambda_1 - \lambda) \cdots (\lambda_n - \lambda)$; evaluando en $\lambda = 0$ queda $p(0) = \det A = \lambda_1 \cdots \lambda_n$. En el ejemplo de 3×3 : $4 + 1 + 1 = 6 = 2 + 2 + 2$ y $4 \cdot 1 \cdot 1 = 4 = \det A$.

2. **Singularidad.** A es invertible si y solo si 0 no es eigenvalor. Es la propiedad anterior: el determinante es el producto de los eigenvalores y se anula justo cuando uno de ellos es cero.

3. **Triangulares.** Si A es triangular (o diagonal), sus eigenvalores son las entradas de la diagonal, porque $A - \lambda I$ también es triangular y su determinante es el producto $(a_{11} - \lambda) \cdots (a_{nn} - \lambda)$.

4. **Potencias.** Si $Av = \lambda v$, entonces $A^k v = \lambda^k v$. Se aplica A una vez más: $A^2 v = A(\lambda v) = \lambda Av = \lambda^2 v$, y así sucesivamente. Mismo eigenvector, eigenvalor elevado a la k .

5. **Inversa.** Si A es invertible y $Av = \lambda v$, entonces $A^{-1}v = \frac{1}{\lambda}v$. Se multiplica $Av = \lambda v$ por A^{-1} y se divide entre λ , que no es cero por la propiedad 2.

6. **Transpuesta.** A y A^T tienen los mismos eigenvalores, porque $\det(A^T - \lambda I) = \det((A - \lambda I)^T) = \det(A - \lambda I)$. Los eigenvectores en general son distintos.

7. **Independencia.** Eigenvectores de eigenvalores distintos son linealmente independientes. Con n eigenvalores distintos hay n eigenvectores independientes.

8. **Simétricas.** Si A es real y simétrica, todos sus eigenvalores son reales y los eigenvectores de eigenvalores distintos son ortogonales. El ejemplo de 3×3 lo muestra: $(1, 1, 1) \cdot (-1, 1, 0) = 0$.

Idea clave

Las propiedades 1 y 3 sirven para revisar la cuenta sin volver a hacerla. Si la suma de los eigenvalores que salieron no da la traza, algo está mal antes de siquiera buscar eigenvectores.

Ojito...

Los eigenvalores **no** se conservan con operaciones elementales de renglón. Escalonar A primero y luego leer la diagonal da cualquier cosa. La propiedad 3 aplica a una matriz que ya es triangular de origen, no a una que se triangularizó con Gauss. Se escalona $A - \lambda I$, nunca A .

Diagonalización

Supóngase que A de $n \times n$ tiene n eigenvectores linealmente independientes $v_1, \dots, v_n$ con eigenvalores $\lambda_1, \dots, \lambda_n$. Se ponen como columnas de una matriz P y los eigenvalores en una diagonal D , en el mismo orden:

$$P = \begin{pmatrix} v_1 & v_2 & \cdots & v_n \end{pmatrix}, \quad D = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix}.$$

Por la multiplicación por bloques, AP tiene columnas Av_i , y PD tiene columnas $\lambda_i v_i$. Son iguales, así que $AP = PD$. Como las columnas de P son independientes, P es invertible, y

$$A = PDP^{-1}.$$

Definición 10.11 (Matriz diagonalizable). A es **diagonalizable** si existe P invertible y D diagonal con $A = PDP^{-1}$. Esto pasa si y solo si A tiene n eigenvectores linealmente independientes, es decir, si la multiplicidad geométrica de cada eigenvalor es igual a la algebraica.

- Con n eigenvalores distintos, siempre es diagonalizable (propiedad 7).
- Toda matriz real simétrica es diagonalizable.
- La matriz defectuosa $\begin{pmatrix} 3 & 1 \\ 0 & 3 \end{pmatrix}$ no lo es: solo tiene un eigenvector independiente y P no se puede armar.

Idea clave

Diagonalizar es cambiar de coordenadas. P^{-1} traduce un vector a coordenadas de eigenvectores, D estira cada coordenada por su eigenvalor sin mezclar nada, y P regresa a las coordenadas originales. En la base de eigenvectores la matriz más enredada se vuelve un escalamiento por ejes.

Para lo que más sirve es para las potencias. Al multiplicar $A^k = (PDP^{-1})(PDP^{-1}) \cdots (PDP^{-1})$ los $P^{-1}P$ de en medio se cancelan y queda

$$A^k = PD^k P^{-1}, \quad D^k = \begin{pmatrix} \lambda_1^k & & \\ & \ddots & \\ & & \lambda_n^k \end{pmatrix}.$$

Elevar una diagonal es elevar cada entrada. En vez de $k-1$ productos de matrices, bastan dos.

Ejemplo 10.12. Diagonalizar $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$ y dar una fórmula para A^k .

P y D . Con los eigenpares del ejemplo de 2×2 , $(5, (1, 1))$ y $(2, (1, -2))$:

$$P = \begin{pmatrix} 1 & 1 \\ 1 & -2 \end{pmatrix}, \quad D = \begin{pmatrix} 5 & 0 \\ 0 & 2 \end{pmatrix}.$$

P^{-1} . Con la fórmula de 2×2 de la clase de inversa, $\det P = -2 - 1 = -3$:

$$P^{-1} = \frac{1}{-3} \begin{pmatrix} -2 & -1 \\ -1 & 1 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} 2 & 1 \\ 1 & -1 \end{pmatrix}.$$

A^k . Primero PD^k , que multiplica cada columna de P por su eigenvalor a la k :

$$PD^k = \begin{pmatrix} 5^k & 2^k \\ 5^k & -2 \cdot 2^k \end{pmatrix}, \quad A^k = PD^k P^{-1} = \frac{1}{3} \begin{pmatrix} 2 \cdot 5^k + 2^k & 5^k - 2^k \\ 2 \cdot 5^k - 2 \cdot 2^k & 5^k + 2 \cdot 2^k \end{pmatrix}.$$

Comprobación. Con $k = 1$ sale $\frac{1}{3} \begin{pmatrix} 12 & 3 \\ 6 & 9 \end{pmatrix} = A$. Con $k = 2$ la fórmula da $\frac{1}{3} \begin{pmatrix} 54 & 21 \\ 42 & 33 \end{pmatrix} = \begin{pmatrix} 18 & 7 \\ 14 & 11 \end{pmatrix}$, y directo

$$A^2 = \begin{pmatrix} 16 + 2 & 4 + 3 \\ 8 + 6 & 2 + 9 \end{pmatrix} = \begin{pmatrix} 18 & 7 \\ 14 & 11 \end{pmatrix}.$$

Resultado

$$A^k = \frac{1}{3} \begin{pmatrix} 2 \cdot 5^k + 2^k & 5^k - 2^k \\ 2 \cdot 5^k - 2 \cdot 2^k & 5^k + 2 \cdot 2^k \end{pmatrix}.$$

Idea clave

La fórmula dice algo más: cuando k crece, 5^k le gana por mucho a 2^k , y A^k se parece cada vez más a $\frac{5^k}{3} \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix}$. A la larga manda el eigenvalor más grande en valor absoluto. En eso se basa el método de la siguiente sección.

Ojito...

El orden importa: la columna i de P tiene que ser el eigenvector de la entrada i de D . Si se ponen los eigenvalores en un orden y los eigenvectores en otro, PDP^{-1} ya no da A .

Método de la potencia

Para matrices grandes nadie calcula $p(\lambda)$: el polinomio de una matriz de 1000×1000 tiene grado 1000, y encontrar sus raíces es numéricamente inestable. Cuando solo interesa el eigenvalor dominante, el de mayor valor absoluto, hay un método iterativo muy simple.

Se parte de un vector x_0 cualquiera y se repite

$$x_{k+1} = \frac{Ax_k}{c_k},$$

donde c_k es la entrada de mayor valor absoluto de Ax_k . Dividir entre c_k solo sirve para que los números no crezcan sin control. Si hay un eigenvalor dominante λ_1 , x_k tiende a su eigenvector y c_k tiende a λ_1 .

Idea clave

Por qué funciona: x_0 se escribe como combinación de eigenvectores, $x_0 = a_1v_1 + a_2v_2 + \dots$. Aplicar A k veces da $a_1\lambda_1^k v_1 + a_2\lambda_2^k v_2 + \dots$, y como $|\lambda_1|$ es el más grande, el primer término aplasta a los demás. El error baja en cada paso por un factor $|\lambda_2/\lambda_1|$.

Ejemplo 10.13. Aplicar el método a $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$ con $x_0 = (1, 0)$.

$Ax_0 = (4, 2),$	$c_0 = 4,$	$x_1 = (1, 0.5),$
$Ax_1 = (4.5, 3.5),$	$c_1 = 4.5,$	$x_2 = (1, 0.778),$
$Ax_2 = (4.778, 4.333),$	$c_2 = 4.778,$	$x_3 = (1, 0.907),$
$Ax_3 = (4.907, 4.721),$	$c_3 = 4.907,$	$x_4 = (1, 0.962).$

x_k se acerca a $(1, 1)$ y c_k a 5, que es el eigenpar dominante ya conocido. La distancia de la segunda coordenada a 1 va 0.5, 0.222, 0.093, 0.038: se multiplica cada vez por $\approx 0.4 = 2/5 = \lambda_2/\lambda_1$, como predice la teoría.

Ojito...

Si $|\lambda_2|$ está muy cerca de $|\lambda_1|$, el factor se acerca a 1 y la convergencia es lentísima. Si hay dos eigenvalores dominantes de igual magnitud, por ejemplo 3 y -3 , el método oscila y no converge.

Para qué sirve en computación

Ejemplo 10.14 (Cadena de Markov). Un modelo de clima con dos estados: si hoy hay sol, mañana hay sol con probabilidad 0.9; si hoy llueve, mañana hay sol con probabilidad 0.5. Con el vector de probabilidades $x = (\text{sol}, \text{lluvia})$, un día después se tiene $x' = Mx$ con

$$M = \begin{pmatrix} 0.9 & 0.5 \\ 0.1 & 0.5 \end{pmatrix}.$$

Cada columna suma 1 porque es una distribución de probabilidad. La pregunta es qué proporción de días soleados hay a la larga, o sea un x que ya no cambie: $Mx = x$. Es un eigenvector con $\lambda = 1$.

Eigenvalores. $\text{tr}(M) = 1.4$ y $\det M = 0.45 - 0.05 = 0.4$, así que $p(\lambda) = \lambda^2 - 1.4\lambda + 0.4 = (\lambda - 1)(\lambda - 0.4)$.

Eigenvector para $\lambda = 1$.

$$M - I = \begin{pmatrix} -0.1 & 0.5 \\ 0.1 & -0.5 \end{pmatrix} \xrightarrow{R_2 + R_1} \begin{pmatrix} -0.1 & 0.5 \\ 0 & 0 \end{pmatrix} \implies x = 5y.$$

Como es una distribución, se normaliza para que sume 1: $5y + y = 1$, $y = \frac{1}{6}$.

Resultado

A la larga, $\frac{5}{6}$ de los días hay sol y $\frac{1}{6}$ llueve, sin importar cómo esté el clima hoy. El otro eigenvalor, 0.4, dice qué tan rápido se olvida la condición inicial: la diferencia se multiplica por 0.4 cada día.

Donde más aparece:

- **PageRank.** La web es una cadena de Markov gigante: cada página reparte su probabilidad entre las páginas a las que enlaza. La importancia de cada página es la entrada correspondiente del eigenvector con $\lambda = 1$, y se calcula con el método de la potencia porque la matriz tiene miles de millones de renglones.
- **Análisis de componentes principales (PCA).** Se toma la matriz de covarianza de los datos, que es simétrica. Sus eigenvectores son las direcciones de mayor varianza y sus eigenvalores dicen cuánta varianza explica cada una. Reducir dimensión es quedarse con los eigenvectores de los eigenvalores más grandes.
- **Estabilidad de sistemas dinámicos.** En $x_{k+1} = Ax_k$, si todos los eigenvalores cumplen $|\lambda| < 1$, el sistema se apaga hacia cero; si alguno tiene $|\lambda| > 1$, explota. Lo mismo decide si el gradiente de una red recurrente se desvanece o se dispara.
- **Grafos.** Los eigenvalores de la matriz de adyacencia o de la laplaciana dicen si el grafo es conexo, cuántas componentes tiene y cómo partirlo en comunidades (agrupamiento espectral).

11. Descomposición en valores singulares (SVD) 30 de septiembre de 2026

Resumen rápido. Exposición de Erick Rodríguez y Osvaldo Cornelio. La SVD escribe *cualquier* matriz, cuadrada o no, como $A = U\Sigma V^T$: una rotación, un estiramiento por ejes y otra rotación. Se saca con los eigenvalores y eigenvectores de $A^T A$, así que es la continuación directa de la clase anterior. Se vio la definición, las propiedades, la interpretación geométrica, un ejemplo completo de 3×2 y aplicaciones: compresión de imágenes, indexación semántica y sistemas de recomendación.

Por qué hace falta

La diagonalización $A = PDP^{-1}$ de la clase anterior es muy útil, pero tiene tres limitaciones:

1. Solo aplica a matrices **cuadradas**. Una tabla de datos con 1000 usuarios y 50 películas es de 1000×50 y ni siquiera tiene eigenvalores.
2. No toda cuadrada es diagonalizable: las defectuosas no lo son.
3. Aunque exista, P en general no es ortogonal, y los eigenvalores pueden salir negativos o complejos.

La SVD resuelve las tres: existe para toda matriz real de $m \times n$, las dos matrices de los lados son ortogonales y los números de en medio son reales y no negativos.

Matrices ortogonales

Antes de la definición hace falta un concepto.

Definición 11.1 (Matriz ortogonal). Una matriz cuadrada Q es **ortogonal** si $Q^T Q = Q Q^T = I$, o sea si $Q^{-1} = Q^T$. Equivalentemente, sus columnas son **ortonormales**: cada una mide 1 y cualesquiera dos distintas son perpendiculares,

$$q_i \cdot q_j = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}.$$

La entrada (i, j) de $Q^T Q$ es justo $q_i \cdot q_j$, por eso las dos formas de decirlo son la misma. Lo importante de una ortogonal es que **no cambia longitudes ni ángulos**:

$$\|Qx\|^2 = (Qx)^T (Qx) = x^T Q^T Q x = x^T x = \|x\|^2.$$

Geométricamente es una rotación o una reflexión. A esto se le llama invariancia isométrica.

Ejemplo 11.2. La rotación por un ángulo θ , $Q = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$, es ortogonal: cada columna cumple $\cos^2 \theta + \sin^2 \theta = 1$, y el producto punto entre ellas es $-\cos \theta \sin \theta + \sin \theta \cos \theta = 0$.

Idea clave

Invertir una ortogonal es gratis: basta transponerla. Por eso, cuando aparece una en una factorización, deshacerla no cuesta nada ni acumula error numérico.

Definición

Definición 11.3 (Descomposición en valores singulares). Toda matriz real A de $m \times n$ se puede escribir como

$$A = U\Sigma V^T,$$

donde

- U es de $m \times m$ y ortogonal. Sus columnas $u_1, \dots, u_m$ son los **vectores singulares izquierdos**.
- Σ es de $m \times n$, con ceros fuera de la diagonal principal. En la diagonal van los **valores singulares** $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$.
- V es de $n \times n$ y ortogonal. Sus columnas $v_1, \dots, v_n$, que son los renglones de V^T , son los **vectores singulares derechos**.

Ojito...

En las láminas de la exposición las cuatro matrices aparecían como de $m \times m$. Las dimensiones correctas son las de arriba, y se revisan con la regla del producto: $(m \times m)(m \times n)(n \times n) = m \times n$. U tiene el tamaño de los renglones de A , V el de sus columnas, y Σ el mismo tamaño que A .

Cuando A no es cuadrada, Σ tampoco. Por ejemplo, con $m = 3$ y $n = 2$ solo hay dos valores singulares y sobra un renglón de ceros:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix}.$$

En general hay $\min(m, n)$ valores singulares.

De dónde sale: la matriz $A^T A$

La idea es convertir el problema de una matriz rectangular en uno de eigenvalores de una matriz cuadrada y simétrica. Si $A = U\Sigma V^T$, entonces

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T \Sigma)V^T.$$

$\Sigma^T \Sigma$ es diagonal de $n \times n$ con entradas σ_i^2 . Eso es una diagonalización de $A^T A$ con $P = V$. Así que:

- Las columnas de V son eigenvectores de $A^T A$.
- Los eigenvalores de $A^T A$ son los σ_i^2 , y por eso $\sigma_i = \sqrt{\lambda_i}$.

Que esto siempre se pueda hacer depende de dos hechos sobre $A^T A$:

1. **Es simétrica**, porque $(A^T A)^T = A^T (A^T)^T = A^T A$. Por la propiedad 8 de la clase anterior, sus eigenvalores son reales, se puede diagonalizar y sus eigenvectores se pueden escoger ortonormales. Eso da una V ortogonal.
2. **Sus eigenvalores son ≥ 0** . Si $A^T A v = \lambda v$ con $\|v\| = 1$,

$$\lambda = \lambda v^T v = v^T A^T A v = (Av)^T (Av) = \|Av\|^2 \geq 0.$$

Por eso la raíz cuadrada siempre existe y los σ_i son reales y no negativos.

Falta U . Para cada $\sigma_i \neq 0$ se define

$$u_i = \frac{Av_i}{\sigma_i}.$$

Estos vectores salen ortonormales solos:

$$u_i \cdot u_j = \frac{(Av_i)^T (Av_j)}{\sigma_i \sigma_j} = \frac{v_i^T (A^T A v_j)}{\sigma_i \sigma_j} = \frac{\sigma_j^2 v_i \cdot v_j}{\sigma_i \sigma_j} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}.$$

Despejando, $Av_i = \sigma_i u_i$ para cada i . Juntando todas las columnas, $AV = U\Sigma$, y como $V^{-1} = V^T$, queda $A = U\Sigma V^T$.

Idea clave

La relación $Av_i = \sigma_i u_i$ es el corazón de la SVD. Se parece a $Av = \lambda v$, pero con dos vectores distintos: A manda la dirección v_i del espacio de entrada a la dirección u_i del espacio de salida, multiplicada por σ_i . Con una matriz rectangular no puede ser el mismo vector, porque v_i vive en $\mathbb{R}^n$ y u_i en $\mathbb{R}^m$.

Si $m > n$, o si hay valores singulares cero, las fórmulas anteriores no alcanzan para llenar las m columnas de U . Las que faltan se completan con cualquier conjunto de vectores ortonormales perpendiculares a los que ya se tienen. No afectan el producto, porque en Σ multiplican a renglones de ceros.

Procedimiento

1. Calcular $A^T A$, de $n \times n$.
2. Sacar sus eigenvalores con $\det(A^T A - \lambda I) = 0$ y ordenarlos de mayor a menor.
3. Valores singulares: $\sigma_i = \sqrt{\lambda_i}$. Armar Σ del tamaño de A con ellos en la diagonal.
4. Para cada λ_i , resolver $(A^T A - \lambda_i I)v = 0$ y **normalizar** el eigenvector, $v_i = v / \|v\|$. Las v_i son las columnas de V .
5. Para cada $\sigma_i \neq 0$, calcular $u_i = Av_i / \sigma_i$.
6. Si faltan columnas de U , completarlas con vectores ortonormales perpendiculares a los anteriores.

Ojito...

Tentación: sacar U por separado como eigenvectores de AA^T , que también funciona en teoría. El problema es el signo: cada eigenvector se puede tomar como v o $-v$, y si U y V se escogen por separado, puede salir un u_i con el signo equivocado y $U\Sigma V^T$ ya no da A . Con $u_i = Av_i / \sigma_i$ el signo queda amarrado a v_i y no hay forma de fallar.

Idea clave

Conviene usar $A^T A$ o AA^T según cuál sea más chica. Si A es de 3×2 , $A^T A$ es de 2×2 y AA^T de 3×3 . Las dos tienen los mismos eigenvalores distintos de cero; la grande solo agrega ceros.

Ejemplo completo

Ejemplo 11.4. Calcular la SVD de $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$, de 3×2 .

Paso 1: $A^T A$.

$$A^T A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1+0+1 & 0+0+1 \\ 0+0+1 & 0+1+1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Sale simétrica, como tiene que ser.

Paso 2: eigenvalores. Con el atajo de 2×2 , traza 4 y determinante 3:

$$\det(A^T A - \lambda I) = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 3)(\lambda - 1).$$

Ordenados: $\lambda_1 = 3$, $\lambda_2 = 1$.

Paso 3: valores singulares y Σ . $\sigma_1 = \sqrt{3} \approx 1.732$ y $\sigma_2 = \sqrt{1} = 1$. Como A es de 3×2 , Σ también:

$$\Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

Paso 4: V . Para $\lambda_1 = 3$:

$$A^T A - 3I = \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \xrightarrow{R_2+R_1} \begin{pmatrix} -1 & 1 \\ 0 & 0 \end{pmatrix} \Rightarrow y = x \Rightarrow v = (1, 1).$$

Su norma es $\sqrt{1^2 + 1^2} = \sqrt{2}$, así que $v_1 = \frac{1}{\sqrt{2}}(1, 1)$. Para $\lambda_2 = 1$:

$$A^T A - I = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \xrightarrow{R_2-R_1} \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix} \Rightarrow y = -x \Rightarrow v = (1, -1),$$

y normalizado $v_2 = \frac{1}{\sqrt{2}}(1, -1)$. Entonces

$$V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad V^T = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}.$$

Aquí $V = V^T$ porque V salió simétrica, pero eso es casualidad de este ejemplo.

Paso 5: u_1 y u_2 .

$$Av_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix} \Rightarrow u_1 = \frac{Av_1}{\sqrt{3}} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix},$$

$$Av_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} \Rightarrow u_2 = \frac{Av_2}{1} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}.$$

La tercera entrada de u_1 es $\frac{2}{\sqrt{6}}$, que en las láminas aparece como $\sqrt{2/3}$; es el mismo número.

Paso 6: completar u_3 . U debe ser de 3×3 y solo hay dos columnas. Se busca $u_3 = (x, y, z)$ perpendicular a las dos:

$$u_2 \cdot u_3 = 0 \Rightarrow \frac{1}{\sqrt{2}}(x - y) = 0 \Rightarrow y = x,$$

$$u_1 \cdot u_3 = 0 \Rightarrow \frac{1}{\sqrt{6}}(x + y + 2z) = 0 \Rightarrow 2x + 2z = 0 \Rightarrow z = -x.$$

Con $x = 1$ queda $w = (1, 1, -1)$, de norma $\sqrt{3}$, así que $u_3 = \frac{1}{\sqrt{3}}(1, 1, -1)$.

Resultado

$$A = \underbrace{\begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \end{pmatrix}}_U \underbrace{\begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}}_{\Sigma} \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix}}_{V^T}$$

Comprobación. $U\Sigma$ solo usa las dos primeras columnas de U , multiplicadas por σ_1 y σ_2 ; la tercera choca con el renglón de ceros:

$$U\Sigma = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \sqrt{2} & 0 \end{pmatrix}, \quad U\Sigma V^T = \begin{pmatrix} \frac{1}{2} + \frac{1}{2} & \frac{1}{2} - \frac{1}{2} \\ \frac{1}{2} - \frac{1}{2} & \frac{1}{2} + \frac{1}{2} \\ 1 + 0 & 1 - 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = A.$$

Idea clave

Hay un atajo para u_3 . Las columnas de U que sobran son perpendiculares a todo lo que A puede producir, o sea a las columnas de A . Eso equivale a resolver $A^T u = 0$: aquí $x + z = 0$ y $y + z = 0$, que da $(1, 1, -1)$ directo, sin pasar por u_1 y u_2 .


Interpretación geométrica

Leyendo $Ax = U\Sigma V^T x$ de derecha a izquierda, A hace tres cosas en orden:

1. V^T **rota** (o refleja) el espacio de entrada, llevando los v_i a los ejes coordenados.
2. Σ **estira** cada eje por su σ_i . Si $m \neq n$, además agrega o quita dimensiones.
3. U **rota** el resultado hasta dejar los ejes sobre los u_i .

Las rotaciones no deforman nada, así que toda la deformación de A está en Σ . Por eso A convierte el círculo unitario en una elipse cuyos semiejes miden σ_1 y σ_2 y apuntan en las direcciones u_1 y u_2 .

Ejemplo 11.5 (El ejemplo gráfico de la exposición). $A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$ tiene traza 5 y determinante 5, así que sus eigenvalores son $\frac{5 \pm \sqrt{5}}{2}$, o sea 3.62 y 1.38. Como es simétrica y sus eigenvalores son positivos, su SVD coincide con su diagonalización: $\sigma_1 = 3.62$, $\sigma_2 = 1.38$, y $U = V$ con columnas $(0.85, 0.53)$ y $(-0.53, 0.85)$, salvo signos.



El vector v_1 sale estirado 3.62 veces y v_2 solo 1.38. Cualquier otro vector del círculo termina en algún punto de la elipse entre esos dos extremos.

Ojito...

Que SVD y diagonalización coincidan es exclusivo de las matrices simétricas con eigenvalores ≥ 0 . Si A es simétrica pero tiene un eigenvalor negativo, $\sigma = |\lambda|$ y el signo se pasa a u o a v . Si A no es simétrica, los eigenvalores y los valores singulares en general no tienen nada que ver.

Propiedades

1. **Ortogonalidad.** $U^T U = U U^T = I_m$ y $V^T V = V V^T = I_n$, o sea $U^{-1} = U^T$ y $V^{-1} = V^T$.
2. **No negatividad y orden.** $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$. Los σ_i son únicos; U y V no, porque cada par (u_i, v_i) se puede cambiar por $(-u_i, -v_i)$.
3. **Rango.** El rango de A es el número de valores singulares distintos de cero. Es la forma más confiable de calcularlo en computadora: en vez de preguntar si un pivote es exactamente cero, se ve qué σ_i son despreciables.
4. **Norma.** σ_1 es lo más que A puede estirar un vector unitario, $\sigma_1 = \max_{\|x\|=1} \|Ax\|$. Es el semieje mayor de la elipse.
5. **Energía.** La suma de los cuadrados de todas las entradas de A es igual a la suma de los σ_i^2 :

$$\sum_{i,j} a_{ij}^2 = \sigma_1^2 + \sigma_2^2 + \dots$$

En el ejemplo, A tiene cuatro unos, así que da 4, y $\sigma_1^2 + \sigma_2^2 = 3 + 1 = 4$. Cada σ_i^2 dice qué parte de la “energía” de la matriz carga su dirección.

6. **Determinante.** Si A es cuadrada, $|\det A| = \sigma_1 \sigma_2 \dots \sigma_n$, porque $\det U$ y $\det V$ valen ± 1 .

SVD como suma y SVD truncada

Multiplicando $U \Sigma V^T$ por bloques, columna de U por renglón de V^T , la SVD se puede escribir como suma de matrices de rango 1:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_r u_r v_r^T,$$

donde r es el rango. Cada término $u_i v_i^T$ es una matriz de $m \times n$ hecha con un solo vector columna por un solo vector renglón, y va pesado por σ_i . Como los σ_i vienen ordenados, los primeros términos son los que más pesan.

Definición 11.6 (SVD truncada). Quedarse con los primeros k términos,

$$A_k = \sigma_1 u_1 v_1^T + \dots + \sigma_k u_k v_k^T,$$

da la mejor aproximación de rango k de A (teorema de Eckart-Young): ninguna otra matriz de rango k queda más cerca. El error cometido es $\sigma_{k+1}^2 + \dots + \sigma_r^2$ en energía.

Ejemplo 11.7. La mejor aproximación de rango 1 de $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ es

$$A_1 = \sigma_1 u_1 v_1^T = \sqrt{3} \cdot \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 2 & 2 \end{pmatrix},$$

porque $\sqrt{3}/(\sqrt{6}\sqrt{2}) = \sqrt{3}/\sqrt{12} = 1/2$. Lo que se tira es

$$A - A_1 = \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \\ 0 & 0 \end{pmatrix} = \sigma_2 u_2 v_2^T,$$

cuya energía es $4 \cdot \frac{1}{4} = 1 = \sigma_2^2$. Se conserva 3/4 de la energía con la mitad de los términos.

Idea clave

Así funciona la compresión con SVD. Guardar A_k requiere k valores singulares, k vectores de tamaño m y k de tamaño n : en total $k(m+n+1)$ números en vez de mn . Una imagen en escala de grises de 1000×1000 con $k = 50$ ocupa $50 \cdot 2001 = 100\,050$ números en lugar de $1\,000\,000$, alrededor del 10 %. En las imágenes reales los σ_i caen rápido, así que con k chico casi no se nota la diferencia.

Pseudoinversa

Una matriz rectangular no tiene inversa, pero con la SVD se define lo más parecido. Si Σ^+ es la matriz de $n \times m$ que tiene $1/\sigma_i$ en la diagonal (solo para los $\sigma_i \neq 0$), la **pseudoinversa** es

$$A^+ = V\Sigma^+U^T = \frac{1}{\sigma_1}v_1u_1^T + \cdots + \frac{1}{\sigma_r}v_ru_r^T.$$

Deshace a A en todas las direcciones donde A no destruyó información.

Ejemplo 11.8. Para la A de 3×2 del ejemplo completo:

$$A^+ = \frac{1}{\sqrt{3}}v_1u_1^T + v_2u_2^T = \frac{1}{6}\begin{pmatrix} 1 & 1 & 2 \\ 1 & 1 & 2 \end{pmatrix} + \frac{1}{2}\begin{pmatrix} 1 & -1 & 0 \\ -1 & 1 & 0 \end{pmatrix} = \frac{1}{3}\begin{pmatrix} 2 & -1 & 1 \\ -1 & 2 & 1 \end{pmatrix}.$$

Se comprueba que $A^+A = I_2$: el primer renglón de A^+ contra las columnas de A da $\frac{1}{3}(2+0+1) = 1$ y $\frac{1}{3}(0-1+1) = 0$.

Su uso principal es resolver sistemas $Ax = b$ que no tienen solución, como los que salen de ajustar una recta a muchos puntos con ruido. $x = A^+b$ es la solución de **mínimos cuadrados**: la que hace $\|Ax - b\|$ lo más chico posible.

Para qué sirve en computación

- **Compresión de imágenes.** Una imagen es una matriz de intensidades. La SVD truncada se queda con las k direcciones de más energía. Además de comprimir, quita ruido: el ruido se reparte entre muchos σ_i chicos, que son justo los que se tiran.
- **Indexación semántica latente (LSI).** Se arma una matriz término-documento, con un renglón por palabra y una columna por documento. Su SVD truncada agrupa palabras que aparecen en contextos parecidos: “coche” y “automóvil” quedan cerca en el espacio de los primeros v_i aunque nunca aparezcan en el mismo documento. Un buscador así encuentra documentos por concepto y no solo por palabra exacta.
- **Sistemas de recomendación.** La matriz usuario-película tiene casi todas sus entradas vacías. Se aproxima con una factorización de rango bajo; los k factores son “gustos ocultos” (acción, comedia, películas de autor) que nadie definió a mano. Las entradas vacías de la aproximación son las calificaciones predichas.

- **PCA.** Si X son los datos centrados, un renglón por muestra, los v_i de su SVD son las componentes principales, y $\sigma_i^2/(N-1)$ es la varianza que explica cada una. Es el mismo PCA de la clase anterior, solo que sin formar la matriz de covarianza, lo cual es más estable numéricamente.