Matemáticas para Computación

Dra. Hayde Peregrina Barreto
Dr. Luis Villaseñor Pineda

Otoño 2026 - Bryan Ezequiel Violante Arriaga

Índice

1. Introducción **2**

2. Repaso **3**

3. Relaciones y funciones **6**

4. Algebras **8**

5. Continuación (Estructuras algebraicas) **9**

6. Matrices **12**

7. Sistemas de ecuaciones lineales **17**

8. Determinantes **21**

9. Inversa de una matriz **27**

10. Eigenvalores y eigenvectores **32**

11. Descomposición en valores singulares (SVD) **41**

12. Introducción a la estadística **49**

13. Estadística descriptiva: datos, variables y escalas **53**

14. Variables aleatorias y distribuciones **60**

15. Distribuciones conjuntas **68**

16. Centro, dispersión y forma **73**

17. Gráficas de distribuciones y modelos importantes **81**

18. IID, error estándar y teoremas de muestreo **94**

1. Introducción

17 de agosto de 2026

Resumen rápido. En esta sesión vimos una intro... que es lo que se espera de nosotros en la materia, cómo se va a evaluar y qué temas se van a ver. Nos dijeron que no es tanto como para hacer demostraciones sino como para entender los conceptos y saber usar esas herramientas en la computación.

2. Repaso

19 de agosto de 2026

Resumen rápido. En esta clase iniciamos con el repaso de algunos conceptos matemáticos en los que se basa la materia y en general las mates para compu. Los conceptos que vimos son el de algebra, conjuntos, subconjuntos, operaciones con conjuntos y producto cartesiano.

Álgebra

El álgebra es la parte de las matemáticas que estudia las operaciones, sus signos y las leyes que las rigen.

Conjuntos

Los conjuntos permiten agrupar elementos que comparten algo y operar entre esos grupos. Son la forma más básica de describir qué objetos estamos estudiando.

Definición 2.1 (Conjunto)**.** Colección bien definida de objetos que comparten alguna característica. Puede ser finito o infinito.

Los elementos de un conjunto son distintos entre sí. Si al escribirlo se repite uno, cuenta una sola vez. Los enteros son el ejemplo de conjunto infinito.

Notación

Un conjunto se describe por comprensión dando la regla que cumplen sus elementos:

$$X = \{x \mid \text{regla que cumple } x\}$$

O por extensión listando sus elementos:

$$X = \{x_1, x_2, x_3, \ldots, x_n\}$$

Los tres símbolos que se usan a cada rato:

- **Pertenencia** ($x \in X$): dice que x es uno de los elementos de X.
- **Cardinalidad** ($|X|$): el número de elementos que tiene el conjunto.
- **Universo** (U): todas las posibilidades sobre las que se define la regla. Sin fijar U, la regla no delimita nada.

Conjunto vacío e igualdad

El conjunto vacío $\emptyset$ no tiene elementos, su cardinalidad es 0 y es subconjunto de cualquier conjunto.

Dos conjuntos son iguales cuando lo son elemento a elemento.

Subconjuntos

$A \subseteq B$ cuando todo elemento de A está también en B. Todo conjunto es subconjunto de sí mismo, $A \subseteq A$.

El subconjunto es **propio**, $A \subset B$, cuando además $A \neq B$: la contención se cumple pero B tiene al menos un elemento que A no tiene.

Ejercicio clase

La Dra dejo un ejercicio de que así:

Sea

$$\mathcal{U} = \{1, 2, 3, 4, \{1, 2\}, \{3, 5\}, \{1, 2, 3, 4\}\} \qquad A = \{1, 2, 3, 4\}$$

Determinar si lo siguiente es verdadero o falso:

a) $|\mathcal{U}| = 7$ **Verdadero**, pq tiene 7 elementos distintos

b) $A \subseteq \mathcal{U}$ **Verdadero**, pq todos los elementos de A están en $\mathcal{U}$

c) $A \in \mathcal{U}$ **Verdadero**, pq A es un elemento de $\mathcal{U}$

d) $|A| = 4$ **Verdadero**, pq tiene 4 elementos distintos

Conjunto potencia

Definición 2.2 (Conjunto potencia)**.** El conjunto formado por todos los subconjuntos de A, incluidos $\emptyset$ y el propio A. Se escribe $\mathcal{P}(A)$.

Su cardinalidad es $|\mathcal{P}(A)| = 2^{|A|}$. De dónde sale el 2^n: armar un subconjunto es decidir, para cada uno de los n elementos, si entra o no entra. Son dos opciones independientes por elemento, así que salen $2 \times 2 \times \cdots \times 2 = 2^n$ combinaciones, y cada una da un subconjunto distinto.

Ejemplo 2.3. Con $A = \{1, 2\}$ hay $n = 2$ elementos y $2^2 = 4$ subconjuntos:

$$\mathcal{P}(A) = \{\ \emptyset,\ \{1\},\ \{2\},\ \{1, 2\}\ \}$$

Operaciones con conjuntos

Todas las que vimos son **binarias**: toman dos operandos.

Cerradura

Si a y b pertenecen a los enteros y el resultado de operarlos también es un entero, la operación es **cerrada** en los enteros. La cerradura sirve para ponerle etiqueta y nombre al álgebra en la que se está trabajando.

Las cinco operaciones

Operación	Símbolo	Qué devuelve
Unión	$A \cup B$	Lo que está en A, en B o en ambos
Intersección	$A \cap B$	Lo que está en los dos a la vez
Diferencia	$A \setminus B$	Lo de A que no está en B
Diferencia simétrica	$A \triangle B$	Lo que está en uno de los dos, pero no en ambos
Complemento	A^c	Lo de U que no está en A

Tabla 1: Las cinco operaciones vistas en clase.

Producto cartesiano

Definición 2.4 (Producto cartesiano)**.** $A \times B$ es el conjunto de todos los pares ordenados cuyo primer elemento sale de A y cuyo segundo sale de B:

$$A \times B = \{(a, b) \mid a \in A,\ b \in B\}$$

Se emparejan todos los elementos de A con todos los de B, así que la cardinalidad es $|A \times B| = |A| \cdot |B|$.

3. Relaciones y funciones

24 de agosto de 2026

Resumen rápido. En esta clase vimos un repaso de relaciones y funciones, tambien vimos una intro a las álgebras.

Relaciones

Definición 3.1 (Relación binaria)**.** Una relación binaria R de un conjunto X en un conjunto Y es un subconjunto del producto cartesiano $X \times Y$.

Si $(x, y) \in R$, escribimos xRy para denotar que x está relacionada con y. Si $X = Y$ decimos que R es una relación binaria **sobre** X.

Como una relación es un subconjunto de $X \times Y$, todo lo de conjuntos aplica: $\emptyset$ es una relación, y hay $2^{|X|\cdot|Y|}$ relaciones distintas entre X y Y.

Dominio, codominio y rango

El **dominio** está formado por los elementos del primer conjunto del que estamos hablando, y el **codominio** por los del segundo. El **rango** o imagen son los elementos que sí se usan, o sea los que participan de forma efectiva:

$$\mathrm{Dom}(R) = \{x \in X \mid \exists\, y \in Y,\ (x, y) \in R\} \qquad \mathrm{Ran}(R) = \{y \in Y \mid \exists\, x \in X,\ (x, y) \in R\}$$

La diferencia entre codominio y rango es que el codominio se declara y el rango se calcula: Y es lo que la relación podría alcanzar, $\mathrm{Ran}(R)$ es lo que de verdad alcanza.

Ejemplo 3.2. Sean $X = \{1, 2, 3\}$ y $Y = \{a, b\}$, con $R = \{(1, a),\ (1, b),\ (3, a)\}$. Entonces $\mathrm{Dom}(R) = \{1, 3\}$ y $\mathrm{Ran}(R) = \{a, b\}$. El 2 no participa y el codominio sigue siendo todo Y.

Relación n-aria

Una relación n-aria es un subconjunto del producto cartesiano de n conjuntos $A_1 \times A_2 \times \cdots \times A_n$. Esos son los conjuntos dominio y n es el **grado** de la relación.

R consiste en un conjunto de n-tuplas $(a_1, a_2, a_3, \ldots, a_n)$ tales que el i-ésimo elemento de la tupla proviene del conjunto A_i. La relación binaria es el caso $n = 2$.

Propiedades de las relaciones

Se definen sobre una relación R en un conjunto X.

- **Reflexividad**: para todo x, la tupla (x, x) está en la relación. Es decir, x se relaciona consigo mismo para todo $x \in X$.
- **Simetría**: para todo $x, y \in X$, si (x, y) está en la relación, entonces (y, x) también.
- **Antisimetría**: para todo $x, y \in X$, si (x, y) y (y, x) están en la relación, entonces $x = y$. Dicho al revés, que es más fácil de ver: los únicos pares que pueden ir y venir son los de un elemento consigo mismo.
- **Transitividad**: para todo $x, y, z \in X$, si xRy y yRz, entonces xRz.

Ojito...

Simetría y antisimetría no son opuestas, se pueden cumplir las dos a la vez. La igualdad es el caso: si $x = y$ entonces $y = x$ (simétrica), y si ambas se cumplen entonces $x = y$ (antisimétrica).

Funciones

Son un tipo especial de relaciones. Es una relación pero con la restricción de que cada elemento de A debe tener un elemento de salida, o sea que solo debe aparecer una vez en el dominio.

Definición 3.3 (Función)**.** $f : A \to B$ es una relación de A en B tal que para cada $a \in A$ existe exactamente un $b \in B$ con $(a, b) \in f$.

Mapear es una función: un mapa es una forma de asociar objetos únicos a cada elemento de un conjunto dado.

Tipos de funciones

- **Inyectiva**: la relación se da 1 a 1, un elemento de A no se puede relacionar con dos de B. Formalmente, si $f(x) = f(y)$ entonces $x = y$.
- **Sobreyectiva**: todos los elementos de B participan, ninguno se queda solo. O sea, el rango es todo el codominio.
- **Biyectiva**: ambas, inyectiva y sobreyectiva. Rango igual a codominio, y cada elemento de B le toca a exactamente un elemento de A.

La biyección es la que importa porque es la única que se puede invertir: existe $f^{-1} : B \to A$ y también es función.

Dado todo lo que hemos visto hasta ahora, todo eso se define dentro de una estructura algebraica.

4. Algebras

24 de agosto de 2026

Estructura algebraica

Definición 4.1 (Estructura sobre un conjunto)**.** Conjunto de funciones, reglas y restricciones que dan significado a una colección de objetos.

Se dice que hay una **composición** en un conjunto no vacío S si a cada par de elementos de S se le asigna, de cierta forma y de manera única, un elemento de S.

Aridad

De acuerdo al número de argumentos requeridos para que un operador pueda realizar el cálculo (aridad), las operaciones pueden ser:

- Nularias
- Unarias
- Binarias
- Ternarias
- N-arias

Las operaciones algebraicas básicas son la **adición** y la **multiplicación**.

Propiedades de una operación binaria

Sea $*$ una operación binaria sobre un conjunto S.

- **Cerradura**: $a * b$ sigue estando en S. En los naturales la suma es cerrada, pero la resta no lo es: $3 - 5$ ya no es natural.
- **Asociatividad**: $(a * b) * c = a * (b * c)$, o sea que el orden de agrupar no cambia el resultado.
- **Identidad**: existe $e \in S$ tal que $a * e = e * a = a$. El 0 para la suma, el 1 para el producto.
- **Conmutatividad**: $a * b = b * a$.
- **Distributividad**: relaciona dos operaciones, $a * (b + c) = (a * b) + (a * c)$.
- **Idempotencia**: $a * a = a$. La unión y la intersección de conjuntos la cumplen.

Idea clave

La cerradura es la que decide de qué álgebra estamos hablando. Es la misma idea que ya salió con los conjuntos: si la operación se sale del conjunto, el conjunto no alcanza para describir lo que se está haciendo.

5. Continuación (Estructuras algebraicas)

26 de agosto de 2026

Definición y para qué sirven

Definición 5.1 (Estructura algebraica)**.** Un conjunto no vacío S es llamado estructura algebraica si al menos una composición, o más exactamente una n-tupla de composiciones, está definida dentro de ella.

Sirven para diferenciar qué elementos se están utilizando y qué operaciones son válidas entre ellos. Por ejemplo, si el conjunto S contiene a los enteros, no se puede aplicar un producto vectorial.

Una estructura algebraica está compuesta por un conjunto S y las operaciones que pueden aplicarse sobre S, que satisfacen ciertas propiedades:

- Operación cerrada o interna (clausura)
- Asociativa
- Conmutativa
- Elemento neutro
- Elemento inverso (simetría)
- Distributividad

El elemento inverso es el que no había salido antes: para cada $a \in S$ existe $a^{-1} \in S$ tal que $a * a^{-1} = e$, con e el neutro. En $(\mathbb{Z}, +)$ el inverso de 3 es -3; en $(\mathbb{Z}, \cdot)$ el 3 no tiene inverso, porque $1/3$ ya no es entero.

Estructuras con una operación

Magma

Hace referencia a un conjunto equipado con un operador binario. Es la estructura algebraica más básica: consta de un conjunto M y una única operación binaria cerrada, sin que se imponga ninguna otra propiedad.

Semigrupo

Es un conjunto no vacío en el cual está definida una operación binaria asociativa, $(S, *)$.

Monoide

Estructura algebraica formada por un conjunto no vacío S y una operación binaria asociativa que además tiene elemento neutro.

Ejemplo 5.2. $(\mathbb{N}, +)$ es asociativa y su elemento neutro es el 0, así que es un monoide.

$(\mathbb{N}, \cdot)$ es asociativa y su neutro es el 1, así que también es un monoide.

$(\mathbb{Z}^+, +)$ es asociativa pero no tiene neutro, porque el 0 no está en $\mathbb{Z}^+$, así que solo llega a semigrupo.

Grupo

Si S es un conjunto no vacío y $*$ una operación binaria en S, entonces $(S, *)$ es un grupo si cumple con ser asociativo, tener elemento neutro y tener inversos.

Idea clave

Dicho de otro modo, un grupo es un monoide en el que cada elemento tiene un inverso. Cada estructura de la lista es la anterior más una propiedad, y por eso el orden en que se presentan no es arbitrario.

Grupo abeliano o conmutativo

Es una estructura de tipo grupo que además cumple con ser conmutativa.

Estructuras con dos operaciones

Anillo

Es una estructura algebraica formada por un conjunto no vacío S y dos operaciones internas, llamadas usualmente suma y producto, $(S, +, \cdot)$, que cumplen ciertas propiedades.

Respecto a la operación suma es cerrado, asociativo, tiene elemento neutro, tiene elemento inverso y es conmutativo. Respecto a la operación producto es cerrado, asociativo, distributivo y conmutativo.

Ojito...

Lo del producto conmutativo hay que revisarlo. En la tabla de abajo, que es la que dio el profesor, la conmutatividad del producto es justo lo que separa al anillo del anillo conmutativo: el anillo la tiene solo en la suma. Es probable que esa última propiedad de la lista corresponda al anillo conmutativo.

Tabla de todas las estructuras

Estructura	Cerr.	Asoc.	Neutro	Inv.	Conm.	Ejemplo
Magma	✓					$(\mathbb{Z}, -)$
Semigrupo	✓	✓				$(\mathbb{N}^+, +)$
Monoide	✓	✓	✓			$(\{0,1\}, \wedge)$, $(\Sigma^*, \cdot)$
Grupo	✓	✓	✓	✓		$(S_3, \circ)$, $(GL_n, \cdot)$
Grupo abeliano	✓	✓	✓	✓	✓	$(\mathbb{Z}, +)$, $(\{0,1\}, \oplus)$

Tabla 2: Estructuras con una operación $(S, *)$.

Fuera de la cadena principal

Estructura	Definición	Nota
Cuasigrupo	Magma más división única	**No** requiere asociatividad
Loop	Cuasigrupo más neutro	Tampoco asociativo
Semirretícula	Semigrupo conmutativo e idempotente ($a * a = a$)	$(\{0,1\}, \wedge)$ lo es

Tabla 3: Estructuras que no caen en la cadena de arriba.

Estructuras con dos operaciones

Notas sobre las tablas:

- La distributividad es el único axioma que relaciona las dos operaciones entre sí.

Estructura	$(S,+)$	$(S,\cdot)$	**Distrib.**	**Ejemplo**
Semianillo	Monoide conm.	Monoide	✓	$(\mathbb{N},+,\cdot)$, tropical $(\max,+)$
Anillo	Grupo abeliano	Semigrupo	✓	$2\mathbb{Z}$, los pares
Anillo con unidad	Grupo abeliano	Monoide	✓	$(M_n(\mathbb{R}),+,\cdot)$
Anillo conmutativo	Grupo abeliano	Monoide conm.	✓	$(\mathbb{Z},+,\cdot)$, $(\mathbb{Z}_6,+,\cdot)$
Dominio entero	Grupo abeliano	Monoide conm., sin divisores de 0	✓	$(\mathbb{Z},+,\cdot)$
Anillo de división	Grupo abeliano	$(S\setminus\{0\},\cdot)$ grupo	✓	Cuaterniones $\mathbb{H}$
Campo	Grupo abeliano	$(S\setminus\{0\},\cdot)$ grupo abeliano	✓	$\mathbb{R}$, $\mathbb{Q}$, $\mathbb{Z}_5$

Tabla 4: Estructuras con dos operaciones $(S,+,\cdot)$.

- En el semianillo, la absorción $0\cdot a=0$ hay que pedirla como axioma: sin inversos aditivos no se puede demostrar. En el anillo sí se demuestra.
- La definición de anillo que se usa aquí sigue la lámina 49 y a Grimaldi, o sea que **no** exige unidad. Muchos textos modernos sí la exigen, y al que no la tiene le llaman *rng*.
- Cuasigrupo y loop no van debajo de grupo. La jerarquía es una retícula, no una cadena.

6. Matrices

2 de septiembre de 2026

Resumen rápido. En esta clase vimos asi bn rapido que son los arreglos y las matrices, con sus operaciones, propiedades y asi

Arreglos y matrices

Un arreglo es una lista de listas donde la longitud de cada nivel es la misma. El tamaño de un arreglo d-dimensional se indica como $m \times n \times \cdots \times p$

El caso más simple es el arreglo de una dimensión, o sea un vector. Sus elementos se escriben con un solo índice, y su tamaño es n:

$$u = (u_1,\, u_2,\, \ldots,\, u_n), \qquad v = (4,\, -2,\, 7,\, 0) \quad \text{de tamaño } 4.$$

Un vector también se puede escribir acostado o parado, y para las operaciones con matrices la diferencia sí importa:

$$\underbrace{\begin{pmatrix} 4 & -2 & 7 & 0 \end{pmatrix}}_{\text{vector fila, } 1\times 4} \qquad \underbrace{\begin{pmatrix} 4 \\ -2 \\ 7 \\ 0 \end{pmatrix}}_{\text{vector columna, } 4\times 1}$$

Al subir una dimensión, cada elemento del arreglo es a su vez un arreglo, y ahí aparece la matriz

Una matriz es un arreglo de arreglos, donde se tienen filas y columnas. El elemento en la fila i y la columna j se escribe a_{ij}:

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = \begin{pmatrix} 2 & -1 & 0 \\ 4 & 3 & 5 \\ 0 & 1 & 7 \end{pmatrix}.$$

El orden de una matriz $m \times n$ quiere decir que tiene m filas y n columnas. Cuando $m = n$ es una matriz cuadrada.

La **diagonal principal** son los elementos a_{ij} donde $i = j$, o sea 2, 3 y 7 en el ejemplo. La **diagonal secundaria** es la que va al revés, de la esquina superior derecha a la inferior izquierda: 0, 3 y 0.

Tipos de matrices

- **Matriz cero**: todos sus elementos son 0. Es el neutro de la suma.
- **Matriz diagonal**: $a_{ij} = 0$ para todo $i \neq j$, o sea que solo la diagonal principal puede ser distinta de cero.
- **Matriz identidad** I_n: diagonal con puros unos en la diagonal principal. Es el neutro del producto.
- **Triangular superior**: $a_{ij} = 0$ para $i > j$, todo lo de abajo de la diagonal es cero. **Triangular inferior**: al revés, $a_{ij} = 0$ para $i < j$.

Un ejemplo de cada uno, todos de orden 3×3:

$$\underbrace{\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}}_{\text{cero}} \qquad \underbrace{\begin{pmatrix} 3 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 2 \end{pmatrix}}_{\text{diagonal}} \qquad \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{I_3}$$

$$\underbrace{\begin{pmatrix} 2 & 7 & 1 \\ 0 & 4 & 6 \\ 0 & 0 & 3 \end{pmatrix}}_{\text{triangular superior}} \qquad \underbrace{\begin{pmatrix} 2 & 0 & 0 \\ 7 & 4 & 0 \\ 1 & 6 & 3 \end{pmatrix}}_{\text{triangular inferior}}$$

Ojito...

La identidad es un caso particular de matriz diagonal, y la diagonal es a la vez triangular superior e inferior. Los tipos no son categorías separadas, se encajan unos dentro de otros.

Transpuesta, simetría y antisimetría

Matriz transpuesta

Definición 6.1 (Transpuesta)**.** La transpuesta A^T de una matriz A de orden $m \times n$ es la matriz de orden $n \times m$ que se obtiene intercambiando filas por columnas, o sea $(A^T)_{ij} = a_{ji}$.

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}, \qquad A^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}.$$

Propiedades, con k un escalar:

- $(A^T)^T = A$
- $(A + B)^T = A^T + B^T$
- $(k\,A)^T = k\,A^T$
- $(A\,B)^T = B^T A^T$

Ojito...

La del producto invierte el orden. No es $A^T B^T$, y de hecho ese producto muchas veces ni siquiera está definido, porque las dimensiones dejan de calzar.

Matriz simétrica

Definición 6.2 (Simétrica)**.** A es simétrica si $A = A^T$, es decir $a_{ij} = a_{ji}$ para todo i, j. Tiene que ser cuadrada, y se ve como un espejo respecto a la diagonal principal.

Matriz antisimétrica

Definición 6.3 (Antisimétrica)**.** A es antisimétrica si $A = -A^T$, es decir $a_{ij} = -a_{ji}$.

$$\underbrace{\begin{pmatrix} 1 & 2 & 0 \\ 2 & 3 & 5 \\ 0 & 5 & 4 \end{pmatrix}}_{\text{simétrica}} \qquad \underbrace{\begin{pmatrix} 0 & 2 & -1 \\ -2 & 0 & 5 \\ 1 & -5 & 0 \end{pmatrix}}_{\text{antisimétrica}}$$

Idea clave

En una antisimétrica la diagonal principal siempre es cero. Poniendo $i = j$ en la definición queda $a_{ii} = -a_{ii}$, y el único número que cumple eso es el cero.

Operaciones con matrices

Dos matrices son iguales si lo son elemento a elemento, o sea $a_{ij} = b_{ij}$ para todos los índices. Eso exige que sean del mismo orden.

Suma y producto por escalar

La suma se hace elemento a elemento, $(A + B)_{ij} = a_{ij} + b_{ij}$, y solo está definida entre matrices del mismo orden. El producto por un escalar multiplica cada entrada, $(kA)_{ij} = k\, a_{ij}$.

Propiedades:

- $A + B = B + A$, conmutativa
- $(A + B) + C = A + (B + C)$, asociativa
- $A + 0 = A$, la matriz cero es el neutro
- $A + (-A) = 0$, cada matriz tiene inverso aditivo
- $k(A + B) = kA + kB$ y $(k + l)A = kA + lA$, distributivas

Producto escalar o producto punto entre vectores

Definición 6.4 (Producto punto)**.** Para dos vectores $u, v \in \mathbb{R}^n$,

$$u \cdot v = \sum_{i=1}^{n} u_i\, v_i = u_1 v_1 + u_2 v_2 + \cdots + u_n v_n.$$

El resultado es un escalar, no un vector.

Propiedades:

- $u \cdot v = v \cdot u$, conmutativo
- $u \cdot (v + w) = u \cdot v + u \cdot w$, distributivo
- $k(u \cdot v) = (k\, u) \cdot v = u \cdot (k\, v)$
- $u \cdot u \geq 0$, y vale 0 solo si u es el vector cero

Multiplicación de matrices

Definición 6.5 (Producto de matrices)**.** Si A es de orden $m \times p$ y B de orden $p \times n$, entonces AB es de orden $m \times n$ y

$$(AB)_{ij} = \sum_{k=1}^{p} a_{ik}\, b_{kj},$$

o sea el producto punto de la fila i de A con la columna j de B.

Ojito...

El producto solo está definido si el número de columnas de A coincide con el número de filas de B. Ese p compartido es la condición que hay que revisar antes de multiplicar.

Propiedades:

- $(AB)C = A(BC)$, asociativa
- $A(B + C) = AB + AC$, distributiva
- $A\,I = I\,A = A$, la identidad es el neutro
- $AB \neq BA$ en general, **no** es conmutativa

Idea clave

Con la suma y el producto, las matrices cuadradas de orden n forman un anillo, pero no un anillo conmutativo, porque el producto no conmuta. Es el ejemplo que faltaba de la tabla de la clase pasada.

Multiplicación por bloques

Manipular matrices de dimensiones grandes es un proceso complejo para las computadoras. Conviene entonces manejar las matrices como bloques de submatrices más pequeñas.

La idea es partir la matriz con líneas horizontales y verticales:

$$A = \left(\begin{array}{cc|cc} 1 & 2 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ \hline 0 & 0 & 5 & 6 \\ 0 & 0 & 7 & 8 \end{array}\right) = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix},$$

donde cada A_{ij} es una submatriz de 2×2. Si B se particiona de forma compatible, el producto se calcula con la misma fórmula de siempre, pero tratando cada bloque como si fuera una entrada:

$$AB = \begin{pmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{pmatrix}.$$

Ojito...

Compatible quiere decir que los cortes de columnas de A tienen que caer en los mismos lugares que los cortes de filas de B. Si no, los productos de bloques no están definidos.

Idea clave

Sirve porque cada bloque cabe en la memoria rápida de la máquina, así que se multiplica sin ir y venir a memoria principal a cada rato. También permite repartir los bloques entre varios procesadores, ya que cada uno se calcula por separado.

7. Sistemas de ecuaciones lineales

9 de septiembre de 2026

Resumen rápido. Por qué la linealidad es tan útil, cómo se junta un montón de ecuaciones lineales en un sistema, y las tres formas de resolverlo: eliminación, matriz aumentada con Gauss y con Gauss-Jordan. Cierra con el rango, que es lo que dice de un vistazo si un sistema tiene solución y cuántas.

Qué quiere decir lineal

Definición 7.1 (Expresión lineal)**.** Una expresión es lineal respecto de sus variables cuando estas aparecen únicamente en **primer grado**, **no se multiplican entre sí**, y los cambios en las variables producen cambios de **magnitud constante** en el resultado.

Muchos fenómenos naturales se comportan así, y por eso el modelo lineal aparece en todos lados: llenar un tanque a flujo constante, moverse a velocidad constante, consumir recursos a tasa fija. La forma que se ve en la escuela es $y = mx + b$, y la **forma estándar** de la ecuación lineal en dos variables es

$$ax + by = c, \qquad a, b, c \in \mathbb{R}.$$

Su gráfica es una recta: todo punto (x, y) de esa recta satisface la ecuación. Con una variable más,

$$ax + by + cz = d$$

es la ecuación de un **plano** en el espacio tridimensional.

Ejemplo 7.2. En una imagen, el color de cada píxel son sus cantidades de rojo, verde y azul, así que se puede tomar $x = R$, $y = G$, $z = B$. Una clasificación sencilla por color separa objeto de fondo con

$$2R - G + B - 100 \begin{cases} > 0 & \text{es objeto} \\ = 0 & \text{es el plano que define la frontera} \\ < 0 & \text{es fondo} \end{cases}$$

El plano parte el espacio RGB en dos, y de qué lado cae el píxel decide su clase.

Sistemas de ecuaciones lineales

Varias ecuaciones lineales sobre las mismas variables forman un sistema. En general, con m ecuaciones y n incógnitas:

$$\begin{array}{ccccccccc} a_{11}x_1 & + & a_{12}x_2 & + \cdots + & a_{1n}x_n & = & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & + \cdots + & a_{2n}x_n & = & b_2 \\ & & & \vdots & & & \\ a_{m1}x_1 & + & a_{m2}x_2 & + \cdots + & a_{mn}x_n & = & b_m \end{array}$$

Los a_{ij} son los **coeficientes** de las incógnitas y los b_i las **constantes** del sistema.

Definición 7.3 (Solución, consistencia)**.** Una solución es un conjunto de n números $x_1, \ldots, x_n$ que satisface *cada una* de las ecuaciones. El sistema es **consistente** si tiene al menos una solución, e **inconsistente** si no tiene ninguna.

Definición 7.4 (Homogéneo)**.** Si todas las constantes son $b_i = 0$ el sistema es **homogéneo**. Si al menos una es distinta de cero, es **no homogéneo**.

Con dos ecuaciones y dos incógnitas cada ecuación es una recta, y resolver el sistema es buscar dónde se cruzan. Solo hay tres desenlaces:

Geometría	Soluciones	Sistema
Se cruzan en un punto	Una única	Consistente
Son paralelas	Ninguna	Inconsistente
Son la misma recta	Infinitas	Consistente

Idea clave

Que haya solo tres casos no es casualidad del plano: vale para cualquier m y n. Un sistema lineal nunca tiene, digamos, dos soluciones o cinco. O ninguna, o una, o infinitas.

Ejemplo 7.5. Dos especies de insectos comparten recipiente. Cada individuo de la especie 1 consume 5 unidades del alimento AL1 y 3 del AL2; cada uno de la especie 2 consume 2 del AL1 y 4 del AL2. Cada día se suministran 900 de AL1 y 960 de AL2. Con x y y el número de individuos de cada especie:

$$\begin{aligned} 5x &+ 2y = 900 \\ 3x &+ 4y = 960 \end{aligned}$$

Contar insectos a mano es imposible, pero el consumo sí se mide, y de ahí sale el sistema.

Resolución por operaciones elementales

La idea es transformar el sistema en otro **equivalente**, o sea con las mismas soluciones, pero más simple. Hay tres operaciones permitidas:

Notación	Operación
R_{ij}	Intercambiar los renglones i y j
cR_i	Multiplicar el renglón i por una constante $c \neq 0$
$cR_i + R_j$	Multiplicar el renglón i por $c \neq 0$ y sumarlo al renglón j

La matriz aumentada

Se puede trabajar sobre las ecuaciones, pero es más cómodo tirar las variables y quedarse solo con los números, en la **matriz aumentada** del sistema:

$$(A \mid B) = \left(\begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & & & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} & b_m \end{array}\right)$$

Eliminación gaussiana	Lleva a forma **escalonada**
Gauss-Jordan	Sigue hasta forma **escalonada reducida**

Una matriz está en forma **escalonada** si cumple:

I. El primer elemento distinto de 0 de cada renglón no nulo es un 1.

II. Ese primer 1 aparece a la derecha del del renglón anterior.

III. Los renglones de puros ceros quedan hasta abajo.

Y es **escalonada reducida** si además cumple:

IV. En cada columna que contiene un 1 pivote, los demás elementos son 0.

Ejemplo 7.6. Resolviendo por Gauss el sistema $2x_1+6x_2+x_3 = 7$, $x_1+2x_2-x_3 = -1$, $5x_1+7x_2-4x_3 = 9$:

$$\left(\begin{array}{ccc|c} 2 & 6 & 1 & 7 \\ 1 & 2 & -1 & -1 \\ 5 & 7 & -4 & 9 \end{array}\right) \longrightarrow \left(\begin{array}{ccc|c} 1 & 2 & -1 & -1 \\ 0 & 1 & \frac{3}{2} & \frac{9}{2} \\ 0 & 0 & 1 & 5 \end{array}\right) \longrightarrow \left(\begin{array}{ccc|c} 1 & 0 & 0 & 10 \\ 0 & 1 & 0 & -3 \\ 0 & 0 & 1 & 5 \end{array}\right)$$

con R_{12}, luego $-2R_1 + R_2$ y $-5R_1 + R_3$, después $\frac{1}{2}R_2$, $3R_2 + R_3$ y $\frac{2}{11}R_3$. La matriz de en medio ya está escalonada y permite sustitución hacia atrás; la última es la reducida y da la solución directo: $x_1 = 10$, $x_2 = -3$, $x_3 = 5$.

Idea clave

Gauss-Jordan cuesta más operaciones pero no requiere sustitución hacia atrás: la solución se lee inspeccionando la matriz final.

Cómo leer la matriz final

Qué se ve	Qué significa
Pivotes = variables	Solución única
Pivotes < variables	Infinitas soluciones
Un renglón $[\,0\;0\cdots0 \mid b \neq 0\,]$	Sin solución

Los dos primeros casos valen *siempre y cuando* no aparezca la contradicción del tercero. Un renglón de puros ceros a la izquierda con algo distinto de cero a la derecha dice $0 = b$, que nada satisface.

Cuando hay menos pivotes que variables, las que no tienen pivote son **variables libres**: se les asigna un parámetro t arbitrario y las demás quedan en términos de él. Como t recorre todos los reales, salen infinitas soluciones.

Sistemas homogéneos

Un sistema homogéneo **siempre es consistente**, porque $x_1 = x_2 = \cdots = x_n = 0$ satisface todas las ecuaciones. Esa es la **solución trivial**.

Idea clave

La pregunta interesante no es si tiene solución, sino si tiene soluciones *no* triviales. Las tiene si el número m de ecuaciones es menor que el número n de incógnitas: faltan restricciones para clavar el origen como única respuesta.

Forma matricial y combinación lineal

Todo sistema se escribe como $AX = B$, con A la matriz de coeficientes, X el vector de incógnitas y B el de constantes. Esta forma es la que se encuentra en los algoritmos.

Si las columnas de A son $c_1, \ldots, c_n$, entonces

$$AX = x_1c_1 + x_2c_2 + \cdots + x_nc_n.$$

Idea clave

O sea que multiplicar A por un vector es tomar una **combinación lineal de las columnas** de A, con las incógnitas como coeficientes. Y resolver $AX = B$ es preguntar: ¿con qué pesos hay que combinar las columnas de A para producir exactamente B? Si B no se puede armar así, el sistema es inconsistente.

Rango de una matriz

A los renglones de A se les llama vectores renglón y a sus columnas vectores columna. Como vectores, un conjunto de ellos puede ser linealmente independiente o dependiente.

Definición 7.7 (Dependencia lineal)**.** Un conjunto de vectores es linealmente **dependiente** si alguno se puede escribir como combinación lineal de los demás. Si ninguno se puede, es linealmente **independiente**. Con dos vectores basta ver si son proporcionales: $u_1 = (3, 5)$ y $u_2 = (9, 15)$ son dependientes porque $u_2 = 3u_1$.

Definición 7.8 (Rango)**.** El rango de una matriz A de $m \times n$, escrito $\text{Ran}(A)$, es el número máximo de vectores renglón o columna linealmente independientes.

Determinarlo a ojo es difícil, pero hay un atajo: si A es equivalente por renglones a una matriz escalonada B, entonces $\text{Ran}(A)$ es el número de renglones de B distintos de cero. Los renglones no nulos de B forman además una base del espacio de renglones de A.

Rango y sistemas

Teorema 7.9 (Consistencia de $AX = B$)**.** *Un sistema lineal $AX = B$ es consistente si y solo si el rango de la matriz de coeficientes es igual al de la matriz aumentada:*

$$\text{Ran}(A) = \text{Ran}(A \mid B).$$

Teorema 7.10 (Número de parámetros)**.** *Si el sistema $AX = B$ con n incógnitas es consistente y $r = \text{Ran}(A)$, entonces la solución contiene $n - r$ parámetros.*

Idea clave

Los dos teoremas juntos contestan todo de un golpe. Se calcula $\text{Ran}(A)$ y $\text{Ran}(A \mid B)$: si difieren no hay solución; si coinciden, $n - r$ dice cuántos parámetros libres quedan. Con $n - r = 0$ la solución es única, y con $n - r > 0$ hay infinitas. Es la tabla de arriba, dicha con un solo número.

Para qué sirve todo esto

La dependencia lineal sirve para generar datos del mismo tipo, por ejemplo muestras sintéticas o aumento de datos: si sé que un vector es combinación de otros, puedo fabricar más. En espectroscopia, los espectros estelares de un mismo tipo de la clasificación de Harvard son muy parecidos entre sí, y esa redundancia es justamente dependencia lineal.

La independencia lineal sirve para lo contrario, comprimir. En sensado comprimido una señal se descompone sobre una base linealmente independiente, y basta transmitir los coeficientes de esa combinación. Si transmisor y receptor comparten la base, nunca hace falta mandar la señal completa.

8. Determinantes

14 de septiembre de 2026

Resumen rápido. El determinante le asigna a cada matriz cuadrada un número que dice si es invertible. Se define con tres reglas, de ellas salen todas las demás propiedades, y hay tres formas de calcularlo: eliminación gaussiana, la fórmula grande con permutaciones y la expansión por cofactores. Dan el mismo número; lo que cambia es el costo. Sigue el capítulo 5 de Strang, *Introduction to Linear Algebra*.

Qué es y para qué sirve

Definición 8.1 (Determinante)**.** Función que toma una matriz cuadrada A de $n \times n$ y devuelve un número, $\det A$ o $|A|$. Su propiedad central es

$$A^{-1} \text{ existe} \iff \det A \neq 0.$$

Para 2×2 la fórmula es directa:

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc.$$

Si $ad - bc = 0$, los renglones (a, b) y (c, d) son proporcionales, o sea linealmente dependientes, y la matriz no se puede invertir. Es la misma pregunta del rango, contestada con un solo número.

Se usa para saber si una matriz es invertible, para resolver sistemas $AX = B$ (si $\det A \neq 0$ la solución es única), para el jacobiano en un cambio de variables de una integral, y en visión por computadora y gráficos 3D, donde las transformaciones son matrices.

Idea clave

Geométricamente, $|\det A|$ es el área del paralelogramo que forman los renglones de A (el volumen en 3×3). El signo dice si la transformación voltea la orientación. Por eso $\det A = 0$ es singular: los renglones se aplastan sobre una recta y el área es cero, ya no hay forma de deshacer eso.

Las tres reglas que lo definen

La fórmula $ad - bc$ no escala a n grande. Strang no define el determinante con una fórmula sino con tres propiedades; cualquier función que las cumpla es el determinante.

Regla 1. $\det I = 1$. Es la normalización: sin ella, $2\det$ también cumpliría las otras dos reglas.

Regla 2. Intercambiar dos renglones cambia el signo.

$$\begin{vmatrix} 1 & 2 \\ 3 & 4 \end{vmatrix} = 4 - 6 = -2 \qquad \begin{vmatrix} 3 & 4 \\ 1 & 2 \end{vmatrix} = 6 - 4 = 2$$

En consecuencia, una matriz de permutación P (la identidad con los renglones reordenados) tiene $\det P = +1$ si se llega a ella con un número par de intercambios y $\det P = -1$ si es impar.

Regla 3. Es lineal en cada renglón por separado, con los demás renglones fijos:

$$\begin{vmatrix} ta & tb \\ c & d \end{vmatrix} = t \begin{vmatrix} a & b \\ c & d \end{vmatrix} \qquad \begin{vmatrix} a + a' & b + b' \\ c & d \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} + \begin{vmatrix} a' & b' \\ c & d \end{vmatrix}$$

Ojito...

Lineal renglón por renglón no es lineal en toda la matriz. $\det(A+B) \neq \det A + \det B$ en general, y $\det(tA) = t^n \det A$, no $t \det A$: multiplicar la matriz entera por t escala los n renglones, y cada uno saca su propia t. Por ejemplo $\det(2I_3) = 2^3 = 8$.

Lo que se deduce de las tres reglas

Cada propiedad siguiente sale de las anteriores; no hay que memorizarlas sueltas.

Regla 4. Dos renglones iguales dan cero. Al intercambiarlos la matriz no cambia, pero la regla 2 dice que el signo sí. Entonces $D = -D$, y eso solo lo cumple $D = 0$.

$$\begin{vmatrix} 2 & 7 \\ 2 & 7 \end{vmatrix} = 14 - 14 = 0$$

Regla 5. Restar un múltiplo de un renglón a otro no cambia el determinante. Por la regla 3 el determinante se parte en dos, y el segundo pedazo tiene dos renglones iguales:

$$\begin{vmatrix} a & b \\ c - \ell a & d - \ell b \end{vmatrix} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} - \ell \underbrace{\begin{vmatrix} a & b \\ a & b \end{vmatrix}}_{0} = \begin{vmatrix} a & b \\ c & d \end{vmatrix}$$

Esta es la que hace funcionar a la eliminación: sus pasos no mueven el determinante.

$$\begin{vmatrix} 1 & 2 \\ 3 & 7 \end{vmatrix} = 7 - 6 = 1 \xrightarrow{R_2 - 3R_1} \begin{vmatrix} 1 & 2 \\ 0 & 1 \end{vmatrix} = 1 - 0 = 1$$

Regla 6. Un renglón de ceros da cero. Ese renglón es 0 veces sí mismo; la regla 3 con $t = 0$ saca el cero afuera.

Regla 7. Si A es triangular, $\det A$ es el producto de la diagonal.

$$\begin{vmatrix} 2 & 7 & 1 \\ 0 & 3 & 5 \\ 0 & 0 & 4 \end{vmatrix} = (2)(3)(4) = 24$$

Por qué: si la diagonal no tiene ceros, con la regla 5 se limpia todo lo que está arriba de ella sin cambiar el determinante, queda $\operatorname{diag}(d_1, \ldots, d_n)$, la regla 3 saca cada d_i afuera y lo que queda es I, que vale 1. Si algún $d_i = 0$, la eliminación produce un renglón de ceros y el determinante es 0, que también es el producto de la diagonal.

Regla 8. $\det A = 0$ si y solo si A es singular. La eliminación lleva A a una triangular U usando solo la regla 5 (no cambia nada) y la regla 2 (cambia el signo). Entonces

$$\det A = \pm \det U = \pm\, d_1 d_2 \cdots d_n = \pm(\text{producto de los pivotes}).$$

Si A es singular, falta un pivote, aparece un cero en la diagonal y el producto es 0. Si es invertible, los n pivotes son distintos de cero y el producto también.

$$\begin{vmatrix} 1 & 2 \\ 2 & 4 \end{vmatrix} \xrightarrow{R_2 - 2R_1} \begin{vmatrix} 1 & 2 \\ 0 & 0 \end{vmatrix} = 0$$

Regla 9. $\det(AB) = (\det A)(\det B)$**.**

$$\underbrace{\begin{pmatrix}1 & 2\\ 3 & 4\end{pmatrix}}_{\det=-2}\underbrace{\begin{pmatrix}2 & 0\\ 1 & 3\end{pmatrix}}_{\det=6} = \underbrace{\begin{pmatrix}4 & 6\\ 10 & 12\end{pmatrix}}_{\det=48-60=-12}$$

Con $B = A^{-1}$ queda $(\det A)(\det A^{-1}) = \det I = 1$, así que $\det A^{-1} = 1/\det A$. Ahí se ve otra vez que si $\det A = 0$ no hay inversa: no se puede dividir entre cero.

Regla 10. $\det A^T = \det A$**.**

$$\begin{vmatrix}1 & 2 & 3\\ 0 & 4 & 5\\ 1 & 0 & 6\end{vmatrix} = 22 \qquad \begin{vmatrix}1 & 0 & 1\\ 2 & 4 & 0\\ 3 & 5 & 6\end{vmatrix} = 22$$

Idea clave

La regla 10 duplica todo lo anterior: lo que vale para renglones vale para columnas. Intercambiar dos columnas cambia el signo, una columna de ceros da cero, y más adelante se puede expandir por cofactores tanto por renglón como por columna.

Método 1: eliminación gaussiana

Es el método práctico. Se triangula, se multiplican los pivotes y se corrige el signo según cuántos intercambios hubo. En forma matricial la eliminación es $PA = LU$, y por la regla 9

$$(\det P)(\det A) = (\det L)(\det U) \implies \det A = \pm\, d_1 \cdots d_n,$$

porque $\det L = 1$ (L es triangular con unos en la diagonal), $\det U$ es el producto de los pivotes por la regla 7, y $\det P = \pm 1$ según la paridad de los intercambios. Cuesta del orden de $n^3/3$ operaciones.

Ejemplo 8.2. Calcular el determinante de $A = \begin{pmatrix}0 & 1 & 2\\ 1 & 2 & 3\\ 2 & 1 & 1\end{pmatrix}$.

Como $a_{11} = 0$ no sirve de pivote, primero se intercambian los renglones 1 y 2:

$$\begin{pmatrix}0 & 1 & 2\\ 1 & 2 & 3\\ 2 & 1 & 1\end{pmatrix} \xrightarrow{R_1 \leftrightarrow R_2} \begin{pmatrix}1 & 2 & 3\\ 0 & 1 & 2\\ 2 & 1 & 1\end{pmatrix} \xrightarrow{R_3 - 2R_1} \begin{pmatrix}1 & 2 & 3\\ 0 & 1 & 2\\ 0 & -3 & -5\end{pmatrix} \xrightarrow{R_3 + 3R_2} \begin{pmatrix}1 & 2 & 3\\ 0 & 1 & 2\\ 0 & 0 & 1\end{pmatrix}$$

Los pivotes son $1, 1, 1$ y hubo un intercambio, número impar:

$$\det A = -(1)(1)(1) = -1.$$

Las tres matrices de $PA = LU$ ya estaban en la cadena: P es el intercambio $R_1 \leftrightarrow R_2$, L guarda los multiplicadores en el lugar donde se usaron y U es la última matriz.

$$\underbrace{\begin{pmatrix}0 & 1 & 0\\ 1 & 0 & 0\\ 0 & 0 & 1\end{pmatrix}}_{P,\ \det=-1} \quad \underbrace{\begin{pmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ 2 & -3 & 1\end{pmatrix}}_{L,\ \det=1} \quad \underbrace{\begin{pmatrix}1 & 2 & 3\\ 0 & 1 & 2\\ 0 & 0 & 1\end{pmatrix}}_{U,\ \det=1}$$

De $(\det P)(\det A) = (\det L)(\det U)$ sale $(-1)\det A = 1$, o sea $\det A = -1$, igual que arriba.

Ojito...

L guarda lo que se *resta*. El paso $R_3 + 3R_2$ es $R_3 - (-3)R_2$, así que en L va -3, no $+3$. El error no afecta al determinante, porque la diagonal de L sigue siendo de unos, pero sí rompe la factorización $LU = PA$.

Método 2: la fórmula grande

Sale de aplicar la regla 3 hasta el final: cada renglón se parte en una suma de renglones con una sola entrada distinta de cero. En 2×2:

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & 0 \\ c & d \end{vmatrix} + \begin{vmatrix} 0 & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & 0 \\ 0 & d \end{vmatrix} + \begin{vmatrix} 0 & b \\ c & 0 \end{vmatrix} = ad \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} + bc \begin{vmatrix} 0 & 1 \\ 1 & 0 \end{vmatrix} = ad - bc.$$

En el segundo paso se tiraron los pedazos que tienen dos entradas en la misma columna, porque esos tienen una columna de ceros y valen 0. Lo que sobrevive son matrices de permutación, y cada una aporta el signo ± 1.

En 3×3 sobreviven $3! = 6$ términos, uno por cada forma de escoger una entrada por renglón sin repetir columna:

$$\det A = \underbrace{a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32}}_{\text{0 o 2 intercambios: } +} \underbrace{-a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} - a_{13}a_{22}a_{31}}_{\text{1 intercambio: } -}$$

El signo de cada término es el determinante de la permutación de sus columnas. Por ejemplo $a_{12}a_{23}a_{31}$ toma las columnas $(2, 3, 1)$; para regresar a $(1, 2, 3)$ hacen falta dos intercambios, así que va con $+$.

Definición 8.3 (Fórmula grande)**.**

$$\det A = \sum_{\text{todas las } P} (\det P)\, a_{1\alpha}\, a_{2\beta} \cdots a_{n\omega},$$

donde $(\alpha, \beta, \ldots, \omega)$ recorre los $n!$ ordenamientos de $(1, \ldots, n)$ y $\det P = \pm 1$ según la paridad.

Si U es triangular, todo término que toma una entrada de abajo de la diagonal vale cero, y el único que sobrevive es $u_{11}u_{22}\cdots u_{nn}$. Es la regla 7 otra vez.

Por qué no se usa para calcular

n	**términos** $n!$	**eliminación** $\approx n^3/3$
3	6	9
5	120	42
10	3 628 800	333
20	2.4×10^{18}	2 667

Ojito...

El truco de las diagonales (Sarrus) solo sirve para $n = 3$. Con $n = 4$ da 8 productos y la fórmula grande pide $4! = 24$. Usarlo en 4×4 da un número equivocado.

Método 3: expansión por cofactores

Reduce un determinante de orden n a varios de orden $n-1$. Sale de agrupar la fórmula grande según la entrada del primer renglón:

$$\det A = a_{11}(a_{22}a_{33} - a_{23}a_{32}) + a_{12}(a_{23}a_{31} - a_{21}a_{33}) + a_{13}(a_{21}a_{32} - a_{22}a_{31}).$$

Cada paréntesis es el determinante de 2×2 que queda al tachar el renglón 1 y la columna de esa entrada, con un signo. El de en medio viene al revés: $a_{23}a_{31} - a_{21}a_{33} = -(a_{21}a_{33} - a_{23}a_{31})$.

Definición 8.4 (Menor y cofactor)**.** El **menor** M_{ij} es la submatriz de $(n-1) \times (n-1)$ que queda al tachar el renglón i y la columna j. El **cofactor** es

$$C_{ij} = (-1)^{i+j} \det M_{ij}.$$

El signo $(-1)^{i+j}$ sigue un tablero de ajedrez que arranca con $+$ en la esquina:

$$\begin{pmatrix} + & - & + & - \\ - & + & - & + \\ + & - & + & - \\ - & + & - & + \end{pmatrix}$$

La expansión se puede hacer por cualquier renglón i o, gracias a la regla 10, por cualquier columna j:

$$\det A = a_{i1}C_{i1} + \cdots + a_{in}C_{in} \qquad \det A = a_{1j}C_{1j} + \cdots + a_{nj}C_{nj}.$$

Es recursiva: cada menor se vuelve a expandir hasta llegar a $\det[a] = a$, o a un 2×2.

Idea clave

Conviene expandir por el renglón o la columna con más ceros. Cada $a_{ij} = 0$ anula su término completo, y ese menor ya no se calcula. En una matriz llena el costo es $n!$ igual que la fórmula grande; en una dispersa es muchísimo menos.

Cómo elegir el método

Método	Costo	Cuándo usarlo
Eliminación gaussiana	$\sim n^3/3$	Matriz numérica y general
Fórmula grande	$n!$	$n \leq 3$, o para demostrar propiedades
Cofactores	$n!$ en el peor caso	Muchos ceros, de banda o simbólica

Eliminación para calcular, cofactores cuando hay muchos ceros y la fórmula grande para demostrar.

Ejercicios

Ejemplo 8.5 (Ejercicio 1)**.** $A = \begin{pmatrix} 3 & 5 \\ 2 & 4 \end{pmatrix}$. Con la fórmula de 2×2:

$$\det A = (3)(4) - (5)(2) = 12 - 10 = 2.$$

Por eliminación sale lo mismo: $R_2 - \frac{2}{3}R_1$ deja el segundo pivote en $4 - \frac{10}{3} = \frac{2}{3}$, sin intercambios, y $(3)(\frac{2}{3}) = 2$.

Resultado

$\det A = 2$. Es distinto de cero, así que A es invertible.

Ejemplo 8.6 (Ejercicio 2)**.** $A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 1 & 0 & 6 \end{pmatrix}$. La columna 1 tiene un cero, así que se expande por ella. Solo quedan los términos de $a_{11} = 1$ y $a_{31} = 1$, ambos con signo $+$ en el tablero:

$$\begin{aligned} \det A &= 1 \cdot \begin{vmatrix} 4 & 5 \\ 0 & 6 \end{vmatrix} + 1 \cdot \begin{vmatrix} 2 & 3 \\ 4 & 5 \end{vmatrix} \\ &= (24 - 0) + (10 - 12) \\ &= 24 - 2 = 22. \end{aligned}$$

Por eliminación: $R_3 - R_1$ da $(0, -2, 3)$, y $R_3 + \frac{1}{2}R_2$ da $(0, 0, \frac{11}{2})$. Pivotes $1, 4, \frac{11}{2}$, sin intercambios: $(1)(4)(\frac{11}{2}) = 22$.

Resultado

$\det A = 22$.

Ejemplo 8.7 (Ejercicio 67)**.**

$$B = \begin{pmatrix} 0 & 2 & 3 & 0 \\ 2 & 0 & 0 & 1 \\ 1 & 4 & 2 & 0 \\ 0 & 1 & 0 & 4 \end{pmatrix}$$

La columna 3 tiene dos ceros; solo sobreviven $b_{13} = 3$ y $b_{33} = 2$. En el tablero, las posiciones $(1, 3)$ y $(3, 3)$ llevan $+$ porque $1 + 3$ y $3 + 3$ son pares:

$$\det B = 3 \det M_{13} + 2 \det M_{33}.$$

Tachando renglón 1 y columna 3, y expandiendo por el renglón 1:

$$\det M_{13} = \begin{vmatrix} 2 & 0 & 1 \\ 1 & 4 & 0 \\ 0 & 1 & 4 \end{vmatrix} = 2(16 - 0) - 0 + 1(1 - 0) = 33.$$

Tachando renglón 3 y columna 3, y expandiendo por el renglón 1, donde solo sobrevive el 2 en la posición $(1, 2)$, que lleva $-$:

$$\det M_{33} = \begin{vmatrix} 0 & 2 & 0 \\ 2 & 0 & 1 \\ 0 & 1 & 4 \end{vmatrix} = -2(8 - 0) = -16.$$

Juntando:

$$\det B = 3(33) + 2(-16) = 99 - 32 = 67.$$

Resultado

$\det B = 67$.

9. Inversa de una matriz

21 de septiembre de 2026

Resumen rápido. Qué es la inversa, cuándo existe y sus propiedades. Tres formas de calcularla: Gauss-Jordan sobre $(A \mid I)$, la fórmula de la adjunta con cofactores, y la factorización LU resolviendo un sistema por columna. Cierra con su uso para resolver $AX = B$ y por qué en la práctica casi nunca se calcula explícitamente.

Definición y cuándo existe

Definición 9.1 (Matriz inversa)**.** Una matriz cuadrada A de $n \times n$ es **invertible** (o no singular) si existe una matriz A^{-1} de $n \times n$ tal que

$$AA^{-1} = I_n \qquad \text{y} \qquad A^{-1}A = I_n.$$

Es el inverso del producto en el sentido de la clase de estructuras algebraicas: I es el neutro y A^{-1} es lo que, operado con A, regresa al neutro. La diferencia con los números es que aquí no basta con $A \neq 0$.

Teorema 9.2 (Existencia)**.** *A^{-1} existe si y solo si* $\det A \neq 0$.

Es la regla 8 de determinantes vista desde el otro lado: si $\det A = 0$, las columnas de A son linealmente dependientes, falta un pivote y A es singular. En términos de rango, A es invertible exactamente cuando $\operatorname{Ran}(A) = n$.

Ojito...

Una matriz no cuadrada nunca tiene inversa en este sentido. Si A es de $m \times n$ con $m \neq n$, los productos AA^{-1} y $A^{-1}A$ ni siquiera son del mismo tamaño, así que no pueden ser las dos la identidad.

Propiedades

Con A y B invertibles de $n \times n$:

1. **Unicidad.** Si X y Y son inversas de A, entonces $X = XI = X(AY) = (XA)Y = IY = Y$. Por eso se puede hablar de *la* inversa.
2. **Inversa del producto.** $(AB)^{-1} = B^{-1}A^{-1}$. Basta comprobarlo:
$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AA^{-1} = I.$$
3. **Inversa de la transpuesta.** $(A^T)^{-1} = (A^{-1})^T$. Transponiendo $AA^{-1} = I$ queda $(A^{-1})^T A^T = I$, por la regla del producto transpuesto.
4. **Determinante de la inversa.** $\det A^{-1} = 1/\det A$. Sale de la regla 9: $(\det A)(\det A^{-1}) = \det I = 1$.

Ojito...

En la del producto el orden se invierte, igual que con la transpuesta. La idea es la de ponerse y quitarse los calcetines y los zapatos: lo último que se aplicó es lo primero que se deshace. $A^{-1}B^{-1}$ en general **no** es la inversa de AB, porque el producto de matrices no conmuta.

Método 1: Gauss-Jordan

Se arma la matriz aumentada $(A \mid I_n)$ y se aplican operaciones elementales de renglón hasta que el bloque izquierdo sea la identidad. Lo que queda a la derecha es la inversa:

$$(A \mid I_n) \xrightarrow{\text{Gauss-Jordan}} (I_n \mid A^{-1}).$$

Si en el camino aparece un renglón de ceros en el bloque izquierdo, A es singular y se detiene todo: no hay inversa.

Idea clave

Por qué funciona: cada operación elemental es multiplicar por la izquierda por una matriz elemental E_k. Si $E_m \cdots E_2 E_1 A = I$, entonces el producto $E_m \cdots E_1$ *es* A^{-1}. Al bloque derecho se le aplican las mismas operaciones, así que termina valiendo $E_m \cdots E_1 I = A^{-1}$. El bloque de la derecha nada más va guardando el registro de lo que se le hizo a A.

Ejemplo 9.3. Invertir $A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$.

$$\left(\begin{array}{ccc|ccc} 1 & 2 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 0 & 1 & 0 \\ 5 & 6 & 0 & 0 & 0 & 1 \end{array}\right) \xrightarrow{R_3 - 5R_1} \left(\begin{array}{ccc|ccc} 1 & 2 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 0 & 1 & 0 \\ 0 & -4 & -15 & -5 & 0 & 1 \end{array}\right)$$

Con el segundo pivote se limpia su columna arriba y abajo, $R_3 + 4R_2$ y $R_1 - 2R_2$:

$$\left(\begin{array}{ccc|ccc} 1 & 0 & -5 & 1 & -2 & 0 \\ 0 & 1 & 4 & 0 & 1 & 0 \\ 0 & 0 & 1 & -5 & 4 & 1 \end{array}\right)$$

El tercer pivote ya es 1. Se limpia su columna con $R_1 + 5R_3$ y $R_2 - 4R_3$:

$$\left(\begin{array}{ccc|ccc} 1 & 0 & 0 & -24 & 18 & 5 \\ 0 & 1 & 0 & 20 & -15 & -4 \\ 0 & 0 & 1 & -5 & 4 & 1 \end{array}\right) \implies A^{-1} = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}.$$

Idea clave

Que la inversa salga con puros enteros no es suerte: aquí $\det A = 1$, y en la fórmula de la adjunta de abajo se divide entre $\det A$. Si el determinante fuera 3, casi seguro aparecerían tercios.

Método 2: la matriz adjunta

Definición 9.4 (Adjunta)**.** Sea C la matriz de cofactores de A, con $C_{ij} = (-1)^{i+j} \det M_{ij}$ como en la clase de determinantes. La **adjunta** es su transpuesta, $\operatorname{Adj}(A) = C^T$. Si $\det A \neq 0$,

$$A^{-1} = \frac{1}{\det A} \operatorname{Adj}(A).$$

Por qué funciona: la entrada (i, j) de $A \cdot \operatorname{Adj}(A)$ es $a_{i1}C_{j1} + \cdots + a_{in}C_{jn}$, el renglón i de A contra los cofactores del renglón j.

- Si $i = j$, es la expansión por cofactores del renglón i, o sea $\det A$.
- Si $i \neq j$, es la expansión de una matriz en la que el renglón j se reemplazó por el renglón i. Esa matriz tiene dos renglones iguales y su determinante es 0 (regla 4).

Entonces $A \cdot \mathrm{Adj}(A) = (\det A)\, I$, y dividiendo entre $\det A$ queda la fórmula.

Ojito...

La transpuesta es lo que más se olvida. El cofactor C_{ij} va en la posición (j, i) de la adjunta, no en la (i, j). Si se omite la transpuesta, la matriz sale mal y la comprobación $AA^{-1} = I$ falla.

El procedimiento es: calcular $\det A$ y revisar que no sea cero, calcular los n^2 cofactores, transponer y dividir entre $\det A$.

Ejemplo 9.5. Invertir $A = \begin{pmatrix} 4 & 7 \\ 2 & 6 \end{pmatrix}$.

Determinante. $\det A = (4)(6) - (7)(2) = 24 - 14 = 10$. Como es distinto de cero, la inversa existe.

Cofactores. En 2×2 cada menor es una sola entrada, la que queda al tachar renglón y columna. Con el tablero $\left(\begin{smallmatrix} + & - \\ - & + \end{smallmatrix}\right)$:

$$C_{11} = +6, \qquad C_{12} = -2, \qquad C_{21} = -7, \qquad C_{22} = +4.$$

Adjunta e inversa.

$$C = \begin{pmatrix} 6 & -2 \\ -7 & 4 \end{pmatrix} \implies \mathrm{Adj}(A) = C^T = \begin{pmatrix} 6 & -7 \\ -2 & 4 \end{pmatrix} \implies A^{-1} = \frac{1}{10}\begin{pmatrix} 6 & -7 \\ -2 & 4 \end{pmatrix} = \begin{pmatrix} \frac{3}{5} & -\frac{7}{10} \\ -\frac{1}{5} & \frac{2}{5} \end{pmatrix}.$$

Comprobación.

$$AA^{-1} = \frac{1}{10}\begin{pmatrix} 4 & 7 \\ 2 & 6 \end{pmatrix}\begin{pmatrix} 6 & -7 \\ -2 & 4 \end{pmatrix} = \frac{1}{10}\begin{pmatrix} 24-14 & -28+28 \\ 12-12 & -14+24 \end{pmatrix} = \frac{1}{10}\begin{pmatrix} 10 & 0 \\ 0 & 10 \end{pmatrix} = I_2.$$

Idea clave

En 2×2 la adjunta se escribe de memoria: se intercambian las entradas de la diagonal y se les cambia el signo a las otras dos.

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Sirve para matrices chicas y para explicar la relación entre determinante, cofactores e inversa. Para n grande hay que calcular n^2 determinantes de orden $n - 1$, y eso ya no conviene.

Método 3: factorización LU

Definición 9.6 (Factorización LU)**.** Escribir $A = LU$, con L triangular inferior con unos en la diagonal y U triangular superior. U es la matriz que deja la eliminación gaussiana y L guarda los multiplicadores m_{ij} debajo de la diagonal, cada uno en la posición donde se usó.

Aquí se supone que la eliminación no necesita intercambiar renglones. Si los necesita, la factorización es $PA = LU$, como en la clase de determinantes.

La inversa $X = A^{-1}$ cumple $AX = I$, que es n sistemas, uno por columna: $A\,x_k = e_k$, con e_k la columna k de la identidad. Con $A = LU$, cada sistema se parte en dos triangulares:

$$L\,y_k = e_k \quad \text{(sustitución hacia adelante)}, \qquad U\,x_k = y_k \quad \text{(sustitución hacia atrás)}.$$

Las x_k son las columnas de A^{-1}.

Idea clave

La gracia es que la factorización se hace **una sola vez**, con costo $\sim n^3/3$. Cada sistema triangular después cuesta solo $\sim n^2$. Con muchos lados derechos, sean las columnas de I o muchos vectores b distintos, se reutilizan L y U y no se vuelve a eliminar.

Ejemplo 9.7. Factorizar e invertir $A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix}$.

Eliminación. El primer pivote es 2, con multiplicadores $m_{21} = 4/2 = 2$ y $m_{31} = 8/2 = 4$. Después el segundo pivote es 1, con $m_{32} = 3/1 = 3$:

$$A \xrightarrow{R_2 - 2R_1,\ R_3 - 4R_1} \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 3 & 5 \end{pmatrix} \xrightarrow{R_3 - 3R_2} \begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix} = U, \qquad L = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}.$$

De paso, $\det A = \det U = (2)(1)(2) = 4 \neq 0$, así que la inversa existe.

Columna 1. $L\,y_1 = e_1$ se resuelve de arriba hacia abajo, y $U\,x_1 = y_1$ de abajo hacia arriba:

$$\begin{aligned} y_{11} &= 1, & 2x_{31} &= 2 \implies x_{31} = 1, \\ 2(1) + y_{21} &= 0 \implies y_{21} = -2, & x_{21} + 1 &= -2 \implies x_{21} = -3, \\ 4(1) + 3(-2) + y_{31} &= 0 \implies y_{31} = 2, & 2x_{11} - 3 + 1 &= 1 \implies x_{11} = \tfrac{3}{2}. \end{aligned}$$

Columnas 2 y 3. El mismo procedimiento con e_2 y e_3 da

$$y_2 = \begin{pmatrix} 0 \\ 1 \\ -3 \end{pmatrix} \to x_2 = \begin{pmatrix} -\frac{1}{2} \\ \frac{5}{2} \\ -\frac{3}{2} \end{pmatrix}, \qquad y_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \to x_3 = \begin{pmatrix} 0 \\ -\frac{1}{2} \\ \frac{1}{2} \end{pmatrix}.$$

Por ejemplo, en $U\,x_2 = y_2$ se despeja primero $2x_{32} = -3$, luego $x_{22} = 1 - x_{32} = \frac{5}{2}$, y al final $2x_{12} = 0 - x_{22} - x_{32} = -1$.

Inversa. Se juntan las tres columnas:

$$A^{-1} = \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} & -\frac{1}{2} & 0 \\ -3 & \frac{5}{2} & -\frac{1}{2} \\ 1 & -\frac{3}{2} & \frac{1}{2} \end{pmatrix}.$$

Ojito...

Aquí los multiplicadores entran a L con su signo tal cual porque todas las operaciones fueron de la forma $R_i - m_{ij}R_j$. Si una flecha dice $R_i + 3R_j$, en L va -3. Es la misma trampa de la clase de determinantes.

Resolver sistemas con la inversa

Si A es invertible, el sistema $AX = B$ tiene solución única, y se obtiene multiplicando ambos lados por A^{-1} por la izquierda:

$$AX = B \implies A^{-1}AX = A^{-1}B \implies X = A^{-1}B.$$

Ejemplo 9.8. Resolver $4x + 7y = 1$, $2x + 6y = 0$. La matriz de coeficientes es la del método 2, cuya inversa ya se tiene:

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} \frac{3}{5} & -\frac{7}{10} \\ -\frac{1}{5} & \frac{2}{5} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{3}{5}(1) - \frac{7}{10}(0) \\ -\frac{1}{5}(1) + \frac{2}{5}(0) \end{pmatrix} = \begin{pmatrix} \frac{3}{5} \\ -\frac{1}{5} \end{pmatrix}.$$

Sustituyendo: $4(\frac{3}{5}) + 7(-\frac{1}{5}) = \frac{12-7}{5} = 1$ y $2(\frac{3}{5}) + 6(-\frac{1}{5}) = \frac{6-6}{5} = 0$. Satisface las dos ecuaciones.

Resultado

$x = \frac{3}{5}$, $y = -\frac{1}{5}$.

Ojito...

$X = A^{-1}B$ es la forma de escribir la solución, no la forma de calcularla. En software numérico casi nunca se calcula A^{-1}: se factoriza $A = LU$ y se resuelven los dos sistemas triangulares con B directamente. Sale más barato, porque calcular la inversa equivale a resolver n sistemas en vez de uno, y además acumula menos error de redondeo.

Cómo elegir el método

Método	Costo	Cuándo usarlo
Gauss-Jordan	$\sim n^3$	A mano, cualquier tamaño chico o mediano
Adjunta	n^2 determinantes	2×2, 3×3 o simbólica
LU	$\sim n^3/3$, luego $\sim n^2$ por columna	Muchos lados derechos, cómputo

Donde aparece: análisis de circuitos y redes eléctricas, transformaciones geométricas en gráficos por computadora (deshacer una rotación o un escalamiento es aplicar la inversa) y el modelo de entrada-salida de Leontief en economía. Ahí A dice cuánto consume cada sector de los demás para producir una unidad y d es la demanda externa; la producción que hace falta es $(I - A)^{-1}d$.

10. Eigenvalores y eigenvectores

28 de septiembre de 2026

Resumen rápido. Qué es un eigenvector: una dirección que la matriz no gira, solo estira, encoge o voltea. Cómo se calculan con el polinomio característico $\det(A-\lambda I)=0$ y luego resolviendo un sistema homogéneo por cada eigenvalor. Multiplicidad algebraica y geométrica, propiedades que conectan con determinante, traza e inversa, diagonalización $A=PDP^{-1}$ para sacar potencias, el método de la potencia y dónde aparece todo esto en computación.

La idea: direcciones que la matriz no gira

Una matriz A de $n\times n$ es una transformación: toma un vector v y regresa otro vector Av. En general Av apunta hacia otro lado, la matriz gira y estira al mismo tiempo. Pero casi siempre hay algunas direcciones especiales en las que A *no* gira nada: el vector sale sobre la misma recta por el origen, nada más más largo, más corto o al revés.

Definición 10.1 (Eigenvalor y eigenvector)**.** Sea A de $n\times n$. Un escalar λ es un **eigenvalor** (o valor propio) de A si existe un vector $v\neq 0$ tal que

$$Av=\lambda v.$$

Ese v es un **eigenvector** (o vector propio) asociado a λ. Al par (λ, v) se le llama eigenpar.

El prefijo *eigen* viene del alemán y quiere decir "propio": son los valores y vectores propios de la matriz, los que dicen cómo actúa ella en particular.

- $\lambda>1$: en esa dirección A estira.
- $0<\lambda<1$: encoge.
- $\lambda<0$: voltea el sentido, y además estira o encoge según $|\lambda|$.
- $\lambda=0$: aplasta esa dirección al origen, $Av=0$.

Ojito...

El vector cero queda excluido a propósito. $A\cdot 0=\lambda\cdot 0$ se cumple para cualquier λ, así que si se permitiera, todo número sería eigenvalor y la definición no diría nada. El eigen*valor* $\lambda=0$ sí está permitido; el eigen*vector* cero, no.

Ejemplo 10.2. Comprobar si $u=\begin{pmatrix}1\\1\end{pmatrix}$ y $w=\begin{pmatrix}1\\0\end{pmatrix}$ son eigenvectores de $A=\begin{pmatrix}4&1\\2&3\end{pmatrix}$.

$$Au=\begin{pmatrix}4+1\\2+3\end{pmatrix}=\begin{pmatrix}5\\5\end{pmatrix}=5\begin{pmatrix}1\\1\end{pmatrix},\qquad Aw=\begin{pmatrix}4\\2\end{pmatrix}.$$

Au es $5u$, así que u es eigenvector con eigenvalor 5. $Aw=(4,2)$ no es múltiplo de $(1,0)$, porque ningún λ hace $\lambda\cdot 0=2$. Entonces w no es eigenvector: A lo gira.

Si v es eigenvector, cualquier múltiplo cv con $c\neq 0$ también lo es, porque $A(cv)=c\,Av=c\lambda v=\lambda(cv)$. Por eso no se habla de *el* eigenvector sino de una dirección. En el ejemplo, $(2,2)$ y $(-7,-7)$ son igual de válidos que $(1,1)$.

Ejemplo 10.3 (Tres transformaciones del plano)**. Escalamiento.** $A = \begin{pmatrix} 3 & 0 \\ 0 & \frac{1}{2} \end{pmatrix}$ estira el eje x al triple y encoge el eje y a la mitad. Los eigenvectores son los ejes: $(1,0)$ con $\lambda = 3$ y $(0,1)$ con $\lambda = \frac{1}{2}$. En una matriz diagonal los eigenvalores se leen directo en la diagonal.

Reflexión sobre la recta $y = x$. $A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ intercambia las coordenadas. Lo que está sobre la recta no se mueve: $A(1,1) = (1,1)$, eigenvalor 1. Lo que está sobre la recta perpendicular se voltea: $A(1,-1) = (-1,1) = -(1,-1)$, eigenvalor -1.

Rotación de 90°. $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ gira todo vector un cuarto de vuelta. Ninguna dirección del plano sale sobre sí misma, así que no hay eigenvectores reales. Más abajo se ve que sus eigenvalores son complejos, $\pm i$.

El polinomio característico

La definición no dice cómo encontrar λ, porque tiene dos incógnitas multiplicándose, λ y v. El truco es pasar todo de un lado:

$$Av = \lambda v \iff Av - \lambda I v = 0 \iff (A - \lambda I)\, v = 0.$$

Hace falta el I porque $A - \lambda$ no tiene sentido: no se le resta un número a una matriz. $\lambda v = \lambda I v$ sí.

Lo que queda es un **sistema homogéneo** con matriz $A - \lambda I$. De la clase de sistemas, un homogéneo siempre tiene la solución trivial $v = 0$, y tiene otras soluciones exactamente cuando la matriz es singular. De la clase de inversa, singular es lo mismo que determinante cero. Entonces:

$$\lambda \text{ es eigenvalor de } A \iff (A - \lambda I)v = 0 \text{ tiene solución } v \neq 0 \iff \det(A - \lambda I) = 0.$$

Con eso la v desaparece y queda una ecuación solo en λ.

Definición 10.4 (Polinomio y ecuación característica)**.** El **polinomio característico** de A es $p(\lambda) = \det(A - \lambda I)$. Es un polinomio de grado n en λ. La **ecuación característica** es $p(\lambda) = 0$, y sus raíces son los eigenvalores de A.

Idea clave

Todo el tema descansa en una cadena de tres clases: eigenvalor → sistema homogéneo con solución no trivial → matriz singular → determinante cero. Si se entiende esa cadena, el procedimiento sale solo.

Como p tiene grado n, una matriz de $n \times n$ tiene a lo más n eigenvalores distintos. Contando repeticiones y admitiendo raíces complejas, tiene exactamente n, por el teorema fundamental del álgebra.

El procedimiento completo es:

1. Calcular $p(\lambda) = \det(A - \lambda I)$: restar λ a cada entrada de la diagonal y sacar el determinante con cualquiera de los métodos de la clase de determinantes.
2. Resolver $p(\lambda) = 0$. Las raíces son los eigenvalores.
3. Para cada eigenvalor λ_i, resolver el sistema homogéneo $(A - \lambda_i I)v = 0$ por eliminación gaussiana. Sus soluciones no nulas son los eigenvectores.

Idea clave

En 2×2 el polinomio se escribe de memoria:

$$\det \begin{pmatrix} a-\lambda & b \\ c & d-\lambda \end{pmatrix} = (a-\lambda)(d-\lambda) - bc = \lambda^2 - (a+d)\,\lambda + (ad-bc).$$

El coeficiente de λ es menos la **traza** $\operatorname{tr}(A) = a + d$, la suma de la diagonal, y el término independiente es $\det A$. O sea $p(\lambda) = \lambda^2 - \operatorname{tr}(A)\,\lambda + \det A$.

Ejemplo completo en 2×2

Ejemplo 10.5. Encontrar eigenvalores y eigenvectores de $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$.

Polinomio. $\operatorname{tr}(A) = 7$ y $\det A = 12 - 2 = 10$, así que

$$p(\lambda) = \lambda^2 - 7\lambda + 10 = (\lambda - 5)(\lambda - 2).$$

Los eigenvalores son $\lambda_1 = 5$ y $\lambda_2 = 2$.

Eigenvector para $\lambda_1 = 5$. Se resta 5 en la diagonal y se escalona:

$$A - 5I = \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix} \xrightarrow{R_2 + 2R_1} \begin{pmatrix} -1 & 1 \\ 0 & 0 \end{pmatrix}.$$

Queda una sola ecuación, $-x + y = 0$, o sea $y = x$. Con $x = t$ libre, $v = t\,(1, 1)$. Se toma $v_1 = (1, 1)$.

Eigenvector para $\lambda_2 = 2$.

$$A - 2I = \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix} \xrightarrow{R_2 - R_1} \begin{pmatrix} 2 & 1 \\ 0 & 0 \end{pmatrix}.$$

Queda $2x + y = 0$, o sea $y = -2x$. Con $x = t$, $v = t\,(1, -2)$. Se toma $v_2 = (1, -2)$.

Comprobación.

$$Av_1 = \begin{pmatrix} 4+1 \\ 2+3 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \end{pmatrix} = 5v_1, \qquad Av_2 = \begin{pmatrix} 4-2 \\ 2-6 \end{pmatrix} = \begin{pmatrix} 2 \\ -4 \end{pmatrix} = 2v_2.$$

Resultado

$\lambda_1 = 5$ con $v_1 = (1, 1)$, y $\lambda_2 = 2$ con $v_2 = (1, -2)$.

Ojito...

Al escalonar $A - \lambda I$ **siempre** tiene que aparecer al menos un renglón de ceros. Si sale con pivote en todas las columnas, la única solución es $v = 0$, y eso quiere decir que el λ está mal: se equivocó uno al factorizar p o al restar en la diagonal. Es una comprobación gratis a media cuenta.

Ejemplo en 3×3 y eigenespacios

Definición 10.6 (Eigenespacio)**.** Para un eigenvalor λ, el **eigenespacio** E_λ es el conjunto de todas las soluciones de $(A - \lambda I)v = 0$: los eigenvectores de λ más el vector cero. Es el espacio nulo de $A - \lambda I$.

Por el teorema de rango de la clase de sistemas, la dimensión de E_λ es el número de variables libres, $n - \mathrm{Ran}(A - \lambda I)$. Puede ser una recta, un plano o algo más grande.

Ejemplo 10.7. Encontrar eigenvalores y eigenespacios de $A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$.

Polinomio. Para aligerar la cuenta se escribe $\mu = 2 - \lambda$ en la diagonal y se expande por el primer renglón:

$$\begin{aligned} \det \begin{pmatrix} \mu & 1 & 1 \\ 1 & \mu & 1 \\ 1 & 1 & \mu \end{pmatrix} &= \mu(\mu^2 - 1) - 1(\mu - 1) + 1(1 - \mu) \\ &= \mu^3 - 3\mu + 2 = (\mu - 1)^2(\mu + 2). \end{aligned}$$

Regresando a λ: $\mu - 1 = 1 - \lambda$ y $\mu + 2 = 4 - \lambda$, entonces

$$p(\lambda) = (1 - \lambda)^2(4 - \lambda).$$

Los eigenvalores son $\lambda = 4$ y $\lambda = 1$, este último como raíz doble.

Eigenespacio de $\lambda = 4$.

$$A - 4I = \begin{pmatrix} -2 & 1 & 1 \\ 1 & -2 & 1 \\ 1 & 1 & -2 \end{pmatrix} \longrightarrow \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{pmatrix}.$$

Dos pivotes, una variable libre: $x = z$, $y = z$. Con $z = t$, E_4 es la recta generada por $(1, 1, 1)$.

Eigenespacio de $\lambda = 1$.

$$A - I = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \xrightarrow{R_2 - R_1,\ R_3 - R_1} \begin{pmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

Un pivote, dos variables libres. La ecuación es $x + y + z = 0$, así que con $y = s$ y $z = t$:

$$v = \begin{pmatrix} -s - t \\ s \\ t \end{pmatrix} = s \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} + t \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}.$$

E_1 es un plano, el que es perpendicular a $(1, 1, 1)$.

Comprobación. $A(1, 1, 1) = (4, 4, 4)$ y $A(-1, 1, 0) = (-2 + 1, -1 + 2, -1 + 1) = (-1, 1, 0)$.

Resultado

$\lambda = 4$ con $E_4 = \mathrm{gen}\{(1, 1, 1)\}$, y $\lambda = 1$ con $E_1 = \mathrm{gen}\{(-1, 1, 0),\ (-1, 0, 1)\}$.

Idea clave

Para 3×3 en adelante, factorizar p es lo difícil. Dos atajos: si la matriz tiene un patrón, como aquí la diagonal repetida, conviene un cambio de variable; y si hay que adivinar raíces enteras, solo pueden ser divisores del término independiente, que es $\det A$.

Multiplicidad algebraica y geométrica

Una raíz repetida de p puede dar un eigenespacio grande, como en el ejemplo anterior, o uno chico. Para distinguir se usan dos números.

Definición 10.8 (Multiplicidades)**.** Sea λ un eigenvalor de A.

- Su **multiplicidad algebraica** es cuántas veces aparece λ como raíz de p.
- Su **multiplicidad geométrica** es la dimensión de E_λ, o sea cuántos eigenvectores linealmente independientes tiene.

Siempre se cumple $1 \leq$ geométrica $\leq$ algebraica.

En el ejemplo de 3×3, $\lambda = 1$ tiene algebraica 2 y geométrica 2: la raíz doble trajo un plano entero de eigenvectores. No siempre pasa.

Ejemplo 10.9 (Matriz defectuosa)**.** Sea $A = \begin{pmatrix} 3 & 1 \\ 0 & 3 \end{pmatrix}$. Es triangular, así que $p(\lambda) = (3-\lambda)^2$ y el único eigenvalor es $\lambda = 3$, con multiplicidad algebraica 2.

$$A - 3I = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

Ya está escalonada, con un pivote. La ecuación es $y = 0$ y x queda libre: $E_3 = \text{gen}\{(1,0)\}$, una recta. Multiplicidad geométrica 1.

Geométricamente, A estira todo por 3 y además desliza en horizontal: el eje x se queda en su lugar, pero cualquier vector con $y \neq 0$ se ladea. Solo sobrevive una dirección.

Cuando la geométrica es menor que la algebraica se dice que la matriz es **defectuosa**: le faltan eigenvectores. Eso importa en la diagonalización, más abajo.

Eigenvalores complejos

Ejemplo 10.10. Para la rotación $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ se tiene $\text{tr}(A) = 0$ y $\det A = 0 - (-1) = 1$, así que

$$p(\lambda) = \lambda^2 + 1 = 0 \implies \lambda = \pm i.$$

Para $\lambda = i$:

$$A - iI = \begin{pmatrix} -i & -1 \\ 1 & -i \end{pmatrix}.$$

El primer renglón da $-ix - y = 0$, o sea $y = -ix$, y el segundo es el mismo multiplicado por i. Con $x = 1$, $v = (1, -i)$. Para $\lambda = -i$ sale el conjugado, $v = (1, i)$.

Ojito...

Una matriz con entradas reales puede tener eigenvalores complejos, y cuando los tiene vienen en pares conjugados $a \pm bi$. En la práctica casi siempre indican una rotación escondida en la transformación. En 2×2 se detectan antes de factorizar: si el discriminante $\text{tr}(A)^2 - 4\det A$ es negativo, las raíces son complejas. Aquí da $0 - 4 = -4$.

Propiedades

Sean $\lambda_1, \ldots, \lambda_n$ los eigenvalores de A, contados con su multiplicidad algebraica.

1. **Suma y producto.**
$$\lambda_1 + \cdots + \lambda_n = \operatorname{tr}(A), \qquad \lambda_1 \cdots \lambda_n = \det A.$$
Salen de comparar coeficientes de $p(\lambda)$ con su forma factorizada $(\lambda_1 - \lambda)\cdots(\lambda_n - \lambda)$; evaluando en $\lambda = 0$ queda $p(0) = \det A = \lambda_1 \cdots \lambda_n$. En el ejemplo de 3×3: $4 + 1 + 1 = 6 = 2 + 2 + 2$ y $4 \cdot 1 \cdot 1 = 4 = \det A$.

2. **Singularidad.** A es invertible si y solo si 0 no es eigenvalor. Es la propiedad anterior: el determinante es el producto de los eigenvalores y se anula justo cuando uno de ellos es cero.

3. **Triangulares.** Si A es triangular (o diagonal), sus eigenvalores son las entradas de la diagonal, porque $A - \lambda I$ también es triangular y su determinante es el producto $(a_{11} - \lambda)\cdots(a_{nn} - \lambda)$.

4. **Potencias.** Si $Av = \lambda v$, entonces $A^k v = \lambda^k v$. Se aplica A una vez más: $A^2 v = A(\lambda v) = \lambda A v = \lambda^2 v$, y así sucesivamente. Mismo eigenvector, eigenvalor elevado a la k.

5. **Inversa.** Si A es invertible y $Av = \lambda v$, entonces $A^{-1} v = \frac{1}{\lambda} v$. Se multiplica $Av = \lambda v$ por A^{-1} y se divide entre λ, que no es cero por la propiedad 2.

6. **Transpuesta.** A y A^T tienen los mismos eigenvalores, porque $\det(A^T - \lambda I) = \det\left((A - \lambda I)^T\right) = \det(A - \lambda I)$. Los eigenvectores en general son distintos.

7. **Independencia.** Eigenvectores de eigenvalores distintos son linealmente independientes. Con n eigenvalores distintos hay n eigenvectores independientes.

8. **Simétricas.** Si A es real y simétrica, todos sus eigenvalores son reales y los eigenvectores de eigenvalores distintos son ortogonales. El ejemplo de 3×3 lo muestra: $(1, 1, 1) \cdot (-1, 1, 0) = 0$.

Idea clave

Las propiedades 1 y 3 sirven para revisar la cuenta sin volver a hacerla. Si la suma de los eigenvalores que salieron no da la traza, algo está mal antes de siquiera buscar eigenvectores.

Ojito...

Los eigenvalores **no** se conservan con operaciones elementales de renglón. Escalonar A primero y luego leer la diagonal da cualquier cosa. La propiedad 3 aplica a una matriz que ya es triangular de origen, no a una que se triangularizó con Gauss. Se escalona $A - \lambda I$, nunca A.

Diagonalización

Supóngase que A de $n \times n$ tiene n eigenvectores linealmente independientes $v_1, \ldots, v_n$ con eigenvalores $\lambda_1, \ldots, \lambda_n$. Se ponen como columnas de una matriz P y los eigenvalores en una diagonal D, en el mismo orden:

$$P = \begin{pmatrix} v_1 & v_2 & \cdots & v_n \end{pmatrix}, \qquad D = \begin{pmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & & \lambda_n \end{pmatrix}.$$

Por la multiplicación por bloques, AP tiene columnas Av_i, y PD tiene columnas $\lambda_i v_i$. Son iguales, así que $AP = PD$. Como las columnas de P son independientes, P es invertible, y

$$A = PDP^{-1}.$$

Definición 10.11 (Matriz diagonalizable)**.** A es **diagonalizable** si existe P invertible y D diagonal con $A = PDP^{-1}$. Esto pasa si y solo si A tiene n eigenvectores linealmente independientes, es decir, si la multiplicidad geométrica de cada eigenvalor es igual a la algebraica.

- Con n eigenvalores distintos, siempre es diagonalizable (propiedad 7).
- Toda matriz real simétrica es diagonalizable.
- La matriz defectuosa $\left(\begin{smallmatrix} 3 & 1 \\ 0 & 3 \end{smallmatrix}\right)$ no lo es: solo tiene un eigenvector independiente y P no se puede armar.

Idea clave

Diagonalizar es cambiar de coordenadas. P^{-1} traduce un vector a coordenadas de eigenvectores, D estira cada coordenada por su eigenvalor sin mezclar nada, y P regresa a las coordenadas originales. En la base de eigenvectores la matriz más enredada se vuelve un escalamiento por ejes.

Para lo que más sirve es para las potencias. Al multiplicar $A^k = (PDP^{-1})(PDP^{-1})\cdots(PDP^{-1})$ los $P^{-1}P$ de en medio se cancelan y queda

$$A^k = PD^kP^{-1}, \qquad D^k = \begin{pmatrix} \lambda_1^k & & \\ & \ddots & \\ & & \lambda_n^k \end{pmatrix}.$$

Elevar una diagonal es elevar cada entrada. En vez de $k-1$ productos de matrices, bastan dos.

Ejemplo 10.12. Diagonalizar $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$ y dar una fórmula para A^k.

P y D. Con los eigenpares del ejemplo de 2×2, $(5,(1,1))$ y $(2,(1,-2))$:

$$P = \begin{pmatrix} 1 & 1 \\ 1 & -2 \end{pmatrix}, \qquad D = \begin{pmatrix} 5 & 0 \\ 0 & 2 \end{pmatrix}.$$

P^{-1}. Con la fórmula de 2×2 de la clase de inversa, $\det P = -2 - 1 = -3$:

$$P^{-1} = \frac{1}{-3}\begin{pmatrix} -2 & -1 \\ -1 & 1 \end{pmatrix} = \frac{1}{3}\begin{pmatrix} 2 & 1 \\ 1 & -1 \end{pmatrix}.$$

A^k. Primero PD^k, que multiplica cada columna de P por su eigenvalor a la k:

$$PD^k = \begin{pmatrix} 5^k & 2^k \\ 5^k & -2\cdot 2^k \end{pmatrix}, \qquad A^k = PD^kP^{-1} = \frac{1}{3}\begin{pmatrix} 2\cdot 5^k + 2^k & 5^k - 2^k \\ 2\cdot 5^k - 2\cdot 2^k & 5^k + 2\cdot 2^k \end{pmatrix}.$$

Comprobación. Con $k=1$ sale $\frac{1}{3}\left(\begin{smallmatrix} 12 & 3 \\ 6 & 9 \end{smallmatrix}\right) = A$. Con $k=2$ la fórmula da $\frac{1}{3}\left(\begin{smallmatrix} 54 & 21 \\ 42 & 33 \end{smallmatrix}\right) = \left(\begin{smallmatrix} 18 & 7 \\ 14 & 11 \end{smallmatrix}\right)$, y directo

$$A^2 = \begin{pmatrix} 16+2 & 4+3 \\ 8+6 & 2+9 \end{pmatrix} = \begin{pmatrix} 18 & 7 \\ 14 & 11 \end{pmatrix}.$$

Resultado

$$A^k = \frac{1}{3}\begin{pmatrix} 2\cdot 5^k + 2^k & 5^k - 2^k \\ 2\cdot 5^k - 2\cdot 2^k & 5^k + 2\cdot 2^k \end{pmatrix}.$$

Idea clave

La fórmula dice algo más: cuando k crece, 5^k le gana por mucho a 2^k, y A^k se parece cada vez más a $\frac{5^k}{3}\left(\begin{smallmatrix} 2 & 1 \\ 2 & 1 \end{smallmatrix}\right)$. A la larga manda el eigenvalor más grande en valor absoluto. En eso se basa el método de la siguiente sección.

Ojito...

El orden importa: la columna i de P tiene que ser el eigenvector de la entrada i de D. Si se ponen los eigenvalores en un orden y los eigenvectores en otro, PDP^{-1} ya no da A.

Método de la potencia

Para matrices grandes nadie calcula $p(\lambda)$: el polinomio de una matriz de 1000×1000 tiene grado 1000, y encontrar sus raíces es numéricamente inestable. Cuando solo interesa el eigenvalor dominante, el de mayor valor absoluto, hay un método iterativo muy simple.

Se parte de un vector x_0 cualquiera y se repite

$$x_{k+1} = \frac{Ax_k}{c_k},$$

donde c_k es la entrada de mayor valor absoluto de Ax_k. Dividir entre c_k solo sirve para que los números no crezcan sin control. Si hay un eigenvalor dominante λ_1, x_k tiende a su eigenvector y c_k tiende a λ_1.

Idea clave

Por qué funciona: x_0 se escribe como combinación de eigenvectores, $x_0 = a_1v_1 + a_2v_2 + \cdots$. Aplicar A k veces da $a_1\lambda_1^k v_1 + a_2\lambda_2^k v_2 + \cdots$, y como $|\lambda_1|$ es el más grande, el primer término aplasta a los demás. El error baja en cada paso por un factor $|\lambda_2/\lambda_1|$.

Ejemplo 10.13. Aplicar el método a $A = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$ con $x_0 = (1, 0)$.

$$\begin{aligned} Ax_0 &= (4,\ 2), & c_0 &= 4, & x_1 &= (1,\ 0.5), \\ Ax_1 &= (4.5,\ 3.5), & c_1 &= 4.5, & x_2 &= (1,\ 0.778), \\ Ax_2 &= (4.778,\ 4.333), & c_2 &= 4.778, & x_3 &= (1,\ 0.907), \\ Ax_3 &= (4.907,\ 4.721), & c_3 &= 4.907, & x_4 &= (1,\ 0.962). \end{aligned}$$

x_k se acerca a $(1, 1)$ y c_k a 5, que es el eigenpar dominante ya conocido. La distancia de la segunda coordenada a 1 va 0.5, 0.222, 0.093, 0.038: se multiplica cada vez por $\approx 0.4 = 2/5 = \lambda_2/\lambda_1$, como predice la teoría.

Ojito...

Si $|\lambda_2|$ está muy cerca de $|\lambda_1|$, el factor se acerca a 1 y la convergencia es lentísima. Si hay dos eigenvalores dominantes de igual magnitud, por ejemplo 3 y -3, el método oscila y no converge.

Para qué sirve en computación

Ejemplo 10.14 (Cadena de Markov)**.** Un modelo de clima con dos estados: si hoy hay sol, mañana hay sol con probabilidad 0.9; si hoy llueve, mañana hay sol con probabilidad 0.5. Con el vector de probabilidades $x = (\text{sol}, \text{lluvia})$, un día después se tiene $x' = Mx$ con

$$M = \begin{pmatrix} 0.9 & 0.5 \\ 0.1 & 0.5 \end{pmatrix}.$$

Cada columna suma 1 porque es una distribución de probabilidad. La pregunta es qué proporción de días soleados hay a la larga, o sea un x que ya no cambie: $Mx = x$. Es un eigenvector con $\lambda = 1$.

Eigenvalores. $\operatorname{tr}(M) = 1.4$ y $\det M = 0.45 - 0.05 = 0.4$, así que $p(\lambda) = \lambda^2 - 1.4\lambda + 0.4 = (\lambda - 1)(\lambda - 0.4)$.

Eigenvector para $\lambda = 1$.

$$M - I = \begin{pmatrix} -0.1 & 0.5 \\ 0.1 & -0.5 \end{pmatrix} \xrightarrow{R_2 + R_1} \begin{pmatrix} -0.1 & 0.5 \\ 0 & 0 \end{pmatrix} \implies x = 5y.$$

Como es una distribución, se normaliza para que sume 1: $5y + y = 1$, $y = \frac{1}{6}$.

Resultado

A la larga, $\frac{5}{6}$ de los días hay sol y $\frac{1}{6}$ llueve, sin importar cómo esté el clima hoy. El otro eigenvalor, 0.4, dice qué tan rápido se olvida la condición inicial: la diferencia se multiplica por 0.4 cada día.

Donde más aparece:

- **PageRank.** La web es una cadena de Markov gigante: cada página reparte su probabilidad entre las páginas a las que enlaza. La importancia de cada página es la entrada correspondiente del eigenvector con $\lambda = 1$, y se calcula con el método de la potencia porque la matriz tiene miles de millones de renglones.
- **Análisis de componentes principales (PCA).** Se toma la matriz de covarianza de los datos, que es simétrica. Sus eigenvectores son las direcciones de mayor varianza y sus eigenvalores dicen cuánta varianza explica cada una. Reducir dimensión es quedarse con los eigenvectores de los eigenvalores más grandes.
- **Estabilidad de sistemas dinámicos.** En $x_{k+1} = Ax_k$, si todos los eigenvalores cumplen $|\lambda| < 1$, el sistema se apaga hacia cero; si alguno tiene $|\lambda| > 1$, explota. Lo mismo decide si el gradiente de una red recurrente se desvanece o se dispara.
- **Grafos.** Los eigenvalores de la matriz de adyacencia o de la laplaciana dicen si el grafo es conexo, cuántas componentes tiene y cómo partirlo en comunidades (agrupamiento espectral).

11. Descomposición en valores singulares (SVD) *30 de septiembre de 2026*

Resumen rápido. Exposición de Erick Rodríguez y Osvaldo Cornelio. La SVD escribe *cualquier* matriz, cuadrada o no, como $A = U\Sigma V^T$: una rotación, un estiramiento por ejes y otra rotación. Se saca con los eigenvalores y eigenvectores de A^TA, así que es la continuación directa de la clase anterior. Se vio la definición, las propiedades, la interpretación geométrica, un ejemplo completo de 3×2 y aplicaciones: compresión de imágenes, indexación semántica y sistemas de recomendación.

Por qué hace falta

La diagonalización $A = PDP^{-1}$ de la clase anterior es muy útil, pero tiene tres limitaciones:

1. Solo aplica a matrices **cuadradas**. Una tabla de datos con 1000 usuarios y 50 películas es de 1000×50 y ni siquiera tiene eigenvalores.
2. No toda cuadrada es diagonalizable: las defectuosas no lo son.
3. Aunque exista, P en general no es ortogonal, y los eigenvalores pueden salir negativos o complejos.

La SVD resuelve las tres: existe para toda matriz real de $m \times n$, las dos matrices de los lados son ortogonales y los números de en medio son reales y no negativos.

Matrices ortogonales

Antes de la definición hace falta un concepto.

Definición 11.1 (Matriz ortogonal)**.** Una matriz cuadrada Q es **ortogonal** si $Q^TQ = QQ^T = I$, o sea si $Q^{-1} = Q^T$. Equivalentemente, sus columnas son **ortonormales**: cada una mide 1 y cualesquiera dos distintas son perpendiculares,

$$q_i \cdot q_j = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}.$$

La entrada (i, j) de Q^TQ es justo $q_i \cdot q_j$, por eso las dos formas de decirlo son la misma. Lo importante de una ortogonal es que **no cambia longitudes ni ángulos**:

$$\|Qx\|^2 = (Qx)^T(Qx) = x^TQ^TQx = x^Tx = \|x\|^2.$$

Geométricamente es una rotación o una reflexión. A esto se le llama invariancia isométrica.

Ejemplo 11.2. La rotación por un ángulo θ, $Q = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$, es ortogonal: cada columna cumple $\cos^2\theta + \sin^2\theta = 1$, y el producto punto entre ellas es $-\cos\theta\sin\theta + \sin\theta\cos\theta = 0$.

Idea clave

Invertir una ortogonal es gratis: basta transponerla. Por eso, cuando aparece una en una factorización, deshacerla no cuesta nada ni acumula error numérico.

Definición

Definición 11.3 (Descomposición en valores singulares)**.** Toda matriz real A de $m \times n$ se puede escribir como

$$A = U\Sigma V^T,$$

donde

- U es de $m \times m$ y ortogonal. Sus columnas $u_1, \ldots, u_m$ son los **vectores singulares izquierdos**.
- Σ es de $m \times n$, con ceros fuera de la diagonal principal. En la diagonal van los **valores singulares** $\sigma_1 \geq \sigma_2 \geq \cdots \geq 0$.
- V es de $n \times n$ y ortogonal. Sus columnas $v_1, \ldots, v_n$, que son los renglones de V^T, son los **vectores singulares derechos**.

Ojito...

En las láminas de la exposición las cuatro matrices aparecían como de $m \times m$. Las dimensiones correctas son las de arriba, y se revisan con la regla del producto: $(m \times m)(m \times n)(n \times n) = m \times n$. U tiene el tamaño de los renglones de A, V el de sus columnas, y Σ el mismo tamaño que A.

Cuando A no es cuadrada, Σ tampoco. Por ejemplo, con $m = 3$ y $n = 2$ solo hay dos valores singulares y sobra un renglón de ceros:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix}.$$

En general hay $\min(m, n)$ valores singulares.

De dónde sale: la matriz A^TA

La idea es convertir el problema de una matriz rectangular en uno de eigenvalores de una matriz cuadrada y simétrica. Si $A = U\Sigma V^T$, entonces

$$A^TA = (U\Sigma V^T)^T(U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T\Sigma)V^T.$$

$\Sigma^T\Sigma$ es diagonal de $n \times n$ con entradas σ_i^2. Eso es una diagonalización de A^TA con $P = V$. Así que:

- Las columnas de V son eigenvectores de A^TA.
- Los eigenvalores de A^TA son los σ_i^2, y por eso $\sigma_i = \sqrt{\lambda_i}$.

Que esto siempre se pueda hacer depende de dos hechos sobre A^TA:

1. **Es simétrica**, porque $(A^TA)^T = A^T(A^T)^T = A^TA$. Por la propiedad 8 de la clase anterior, sus eigenvalores son reales, se puede diagonalizar y sus eigenvectores se pueden escoger ortonormales. Eso da una V ortogonal.

2. **Sus eigenvalores son ≥ 0.** Si $A^TAv = \lambda v$ con $\|v\| = 1$,

$$\lambda = \lambda\, v^Tv = v^TA^TAv = (Av)^T(Av) = \|Av\|^2 \geq 0.$$

   Por eso la raíz cuadrada siempre existe y los σ_i son reales y no negativos.

Falta U. Para cada $\sigma_i \neq 0$ se define

$$u_i = \frac{Av_i}{\sigma_i}.$$

Estos vectores salen ortonormales solos:

$$u_i \cdot u_j = \frac{(Av_i)^T(Av_j)}{\sigma_i\sigma_j} = \frac{v_i^T(A^TAv_j)}{\sigma_i\sigma_j} = \frac{\sigma_j^2\, v_i \cdot v_j}{\sigma_i\sigma_j} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}.$$

Despejando, $Av_i = \sigma_i u_i$ para cada i. Juntando todas las columnas, $AV = U\Sigma$, y como $V^{-1} = V^T$, queda $A = U\Sigma V^T$.

Idea clave

La relación $Av_i = \sigma_i u_i$ es el corazón de la SVD. Se parece a $Av = \lambda v$, pero con dos vectores distintos: A manda la dirección v_i del espacio de entrada a la dirección u_i del espacio de salida, multiplicada por σ_i. Con una matriz rectangular no puede ser el mismo vector, porque v_i vive en $\mathbb{R}^n$ y u_i en $\mathbb{R}^m$.

Si $m > n$, o si hay valores singulares cero, las fórmulas anteriores no alcanzan para llenar las m columnas de U. Las que faltan se completan con cualquier conjunto de vectores ortonormales perpendiculares a los que ya se tienen. No afectan el producto, porque en Σ multiplican a renglones de ceros.

Procedimiento

1. Calcular A^TA, de $n \times n$.
2. Sacar sus eigenvalores con $\det(A^TA - \lambda I) = 0$ y ordenarlos de mayor a menor.
3. Valores singulares: $\sigma_i = \sqrt{\lambda_i}$. Armar Σ del tamaño de A con ellos en la diagonal.
4. Para cada λ_i, resolver $(A^TA - \lambda_i I)v = 0$ y **normalizar** el eigenvector, $v_i = v/\|v\|$. Las v_i son las columnas de V.
5. Para cada $\sigma_i \neq 0$, calcular $u_i = Av_i/\sigma_i$.
6. Si faltan columnas de U, completarlas con vectores ortonormales perpendiculares a los anteriores.

Ojito...

Tentación: sacar U por separado como eigenvectores de AA^T, que también funciona en teoría. El problema es el signo: cada eigenvector se puede tomar como v o $-v$, y si U y V se escogen por separado, puede salir un u_i con el signo equivocado y $U\Sigma V^T$ ya no da A. Con $u_i = Av_i/\sigma_i$ el signo queda amarrado a v_i y no hay forma de fallar.

Idea clave

Conviene usar A^TA o AA^T según cuál sea más chica. Si A es de 3×2, A^TA es de 2×2 y AA^T de 3×3. Las dos tienen los mismos eigenvalores distintos de cero; la grande solo agrega ceros.

Ejemplo completo

Ejemplo 11.4. Calcular la SVD de $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$, de 3×2.

Paso 1: A^TA.

$$A^TA = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1+0+1 & 0+0+1 \\ 0+0+1 & 0+1+1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Sale simétrica, como tiene que ser.

Paso 2: eigenvalores. Con el atajo de 2×2, traza 4 y determinante 3:

$$\det(A^TA-\lambda I)=(2-\lambda)^2-1=\lambda^2-4\lambda+3=(\lambda-3)(\lambda-1).$$

Ordenados: $\lambda_1=3$, $\lambda_2=1$.

Paso 3: valores singulares y Σ. $\sigma_1=\sqrt{3}\approx 1.732$ y $\sigma_2=\sqrt{1}=1$. Como A es de 3×2, Σ también:

$$\Sigma=\begin{pmatrix}\sqrt{3}&0\\0&1\\0&0\end{pmatrix}.$$

Paso 4: V. Para $\lambda_1=3$:

$$A^TA-3I=\begin{pmatrix}-1&1\\1&-1\end{pmatrix}\xrightarrow{R_2+R_1}\begin{pmatrix}-1&1\\0&0\end{pmatrix}\implies y=x\implies v=(1,1).$$

Su norma es $\sqrt{1^2+1^2}=\sqrt{2}$, así que $v_1=\frac{1}{\sqrt{2}}(1,1)$. Para $\lambda_2=1$:

$$A^TA-I=\begin{pmatrix}1&1\\1&1\end{pmatrix}\xrightarrow{R_2-R_1}\begin{pmatrix}1&1\\0&0\end{pmatrix}\implies y=-x\implies v=(1,-1),$$

y normalizado $v_2=\frac{1}{\sqrt{2}}(1,-1)$. Entonces

$$V=\frac{1}{\sqrt{2}}\begin{pmatrix}1&1\\1&-1\end{pmatrix},\qquad V^T=\frac{1}{\sqrt{2}}\begin{pmatrix}1&1\\1&-1\end{pmatrix}.$$

Aquí $V=V^T$ porque V salió simétrica, pero eso es casualidad de este ejemplo.

Paso 5: u_1 y u_2.

$$Av_1=\frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\\2\end{pmatrix}\implies u_1=\frac{Av_1}{\sqrt{3}}=\frac{1}{\sqrt{6}}\begin{pmatrix}1\\1\\2\end{pmatrix},$$

$$Av_2=\frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\\0\end{pmatrix}\implies u_2=\frac{Av_2}{1}=\frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\\0\end{pmatrix}.$$

La tercera entrada de u_1 es $\frac{2}{\sqrt{6}}$, que en las láminas aparece como $\sqrt{2/3}$; es el mismo número.

Paso 6: completar u_3. U debe ser de 3×3 y solo hay dos columnas. Se busca $u_3=(x,y,z)$ perpendicular a las dos:

$$u_2\cdot u_3=0\implies \tfrac{1}{\sqrt{2}}(x-y)=0\implies y=x,$$
$$u_1\cdot u_3=0\implies \tfrac{1}{\sqrt{6}}(x+y+2z)=0\implies 2x+2z=0\implies z=-x.$$

Con $x=1$ queda $w=(1,1,-1)$, de norma $\sqrt{3}$, así que $u_3=\frac{1}{\sqrt{3}}(1,1,-1)$.

Resultado

$$A=\underbrace{\begin{pmatrix}\frac{1}{\sqrt{6}}&\frac{1}{\sqrt{2}}&\frac{1}{\sqrt{3}}\\\frac{1}{\sqrt{6}}&-\frac{1}{\sqrt{2}}&\frac{1}{\sqrt{3}}\\\frac{2}{\sqrt{6}}&0&-\frac{1}{\sqrt{3}}\end{pmatrix}}_{U}\underbrace{\begin{pmatrix}\sqrt{3}&0\\0&1\\0&0\end{pmatrix}}_{\Sigma}\underbrace{\begin{pmatrix}\frac{1}{\sqrt{2}}&\frac{1}{\sqrt{2}}\\\frac{1}{\sqrt{2}}&-\frac{1}{\sqrt{2}}\end{pmatrix}}_{V^T}$$

Comprobación. $U\Sigma$ solo usa las dos primeras columnas de U, multiplicadas por σ_1 y σ_2; la tercera choca con el renglón de ceros:

$$U\Sigma = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \sqrt{2} & 0 \end{pmatrix}, \qquad U\Sigma V^T = \begin{pmatrix} \frac{1}{2}+\frac{1}{2} & \frac{1}{2}-\frac{1}{2} \\ \frac{1}{2}-\frac{1}{2} & \frac{1}{2}+\frac{1}{2} \\ 1+0 & 1-0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = A.$$

Idea clave

Hay un atajo para u_3. Las columnas de U que sobran son perpendiculares a todo lo que A puede producir, o sea a las columnas de A. Eso equivale a resolver $A^T u = 0$: aquí $x + z = 0$ y $y + z = 0$, que da $(1, 1, -1)$ directo, sin pasar por u_1 y u_2.

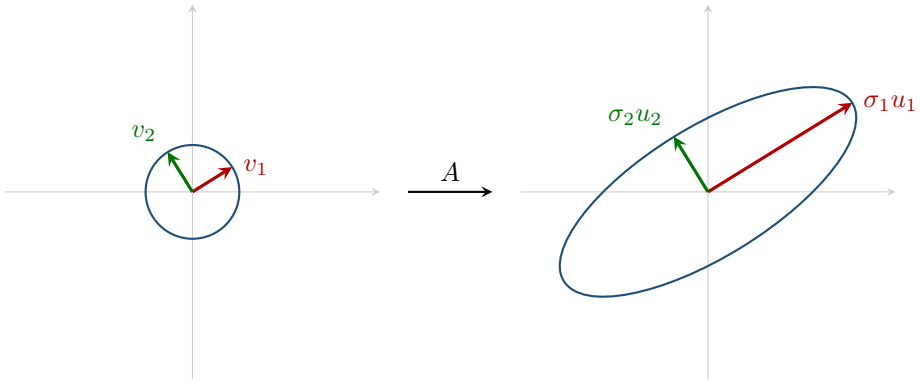
Interpretación geométrica

Leyendo $Ax = U\Sigma V^T x$ de derecha a izquierda, A hace tres cosas en orden:

1. V^T **rota** (o refleja) el espacio de entrada, llevando los v_i a los ejes coordenados.
2. Σ **estira** cada eje por su σ_i. Si $m \neq n$, además agrega o quita dimensiones.
3. U **rota** el resultado hasta dejar los ejes sobre los u_i.

Las rotaciones no deforman nada, así que toda la deformación de A está en Σ. Por eso A convierte el círculo unitario en una elipse cuyos semiejes miden σ_1 y σ_2 y apuntan en las direcciones u_1 y u_2.

Ejemplo 11.5 (El ejemplo gráfico de la exposición)**.** $A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$ tiene traza 5 y determinante 5, así que sus eigenvalores son $\frac{5 \pm \sqrt{5}}{2}$, o sea 3.62 y 1.38. Como es simétrica y sus eigenvalores son positivos, su SVD coincide con su diagonalización: $\sigma_1 = 3.62$, $\sigma_2 = 1.38$, y $U = V$ con columnas $(0.85, 0.53)$ y $(-0.53, 0.85)$, salvo signos.



Círculo unitario Elipse imagen

El vector v_1 sale estirado 3.62 veces y v_2 solo 1.38. Cualquier otro vector del círculo termina en algún punto de la elipse entre esos dos extremos.

Ojito...

Que SVD y diagonalización coincidan es exclusivo de las matrices simétricas con eigenvalores ≥ 0. Si A es simétrica pero tiene un eigenvalor negativo, $\sigma = |\lambda|$ y el signo se pasa a u o a v. Si A no es simétrica, los eigenvalores y los valores singulares en general no tienen nada que ver.

Propiedades

1. **Ortogonalidad.** $U^TU = UU^T = I_m$ y $V^TV = VV^T = I_n$, o sea $U^{-1} = U^T$ y $V^{-1} = V^T$.

2. **No negatividad y orden.** $\sigma_1 \geq \sigma_2 \geq \cdots \geq 0$. Los σ_i son únicos; U y V no, porque cada par (u_i, v_i) se puede cambiar por $(-u_i, -v_i)$.

3. **Rango.** El rango de A es el número de valores singulares distintos de cero. Es la forma más confiable de calcularlo en computadora: en vez de preguntar si un pivote es exactamente cero, se ve qué σ_i son despreciables.

4. **Norma.** σ_1 es lo más que A puede estirar un vector unitario, $\sigma_1 = \max_{\|x\|=1} \|Ax\|$. Es el semieje mayor de la elipse.

5. **Energía.** La suma de los cuadrados de todas las entradas de A es igual a la suma de los σ_i^2:

$$\sum_{i,j} a_{ij}^2 = \sigma_1^2 + \sigma_2^2 + \cdots .$$

   En el ejemplo, A tiene cuatro unos, así que da 4, y $\sigma_1^2 + \sigma_2^2 = 3 + 1 = 4$. Cada σ_i^2 dice qué parte de la "energía" de la matriz carga su dirección.

6. **Determinante.** Si A es cuadrada, $|\det A| = \sigma_1\sigma_2 \cdots \sigma_n$, porque $\det U$ y $\det V$ valen ± 1.

SVD como suma y SVD truncada

Multiplicando $U\Sigma V^T$ por bloques, columna de U por renglón de V^T, la SVD se puede escribir como suma de matrices de rango 1:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_r u_r v_r^T,$$

donde r es el rango. Cada término $u_i v_i^T$ es una matriz de $m \times n$ hecha con un solo vector columna por un solo vector renglón, y va pesado por σ_i. Como los σ_i vienen ordenados, los primeros términos son los que más pesan.

Definición 11.6 (SVD truncada)**.** Quedarse con los primeros k términos,

$$A_k = \sigma_1 u_1 v_1^T + \cdots + \sigma_k u_k v_k^T,$$

da la mejor aproximación de rango k de A (teorema de Eckart-Young): ninguna otra matriz de rango k queda más cerca. El error cometido es $\sigma_{k+1}^2 + \cdots + \sigma_r^2$ en energía.

Ejemplo 11.7. La mejor aproximación de rango 1 de $A = \left(\begin{smallmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{smallmatrix}\right)$ es

$$A_1 = \sigma_1 u_1 v_1^T = \sqrt{3} \cdot \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 2 & 2 \end{pmatrix},$$

porque $\sqrt{3}/(\sqrt{6}\sqrt{2}) = \sqrt{3}/\sqrt{12} = 1/2$. Lo que se tira es

$$A - A_1 = \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \\ 0 & 0 \end{pmatrix} = \sigma_2 u_2 v_2^T,$$

cuya energía es $4 \cdot \frac{1}{4} = 1 = \sigma_2^2$. Se conserva $3/4$ de la energía con la mitad de los términos.

Idea clave

Así funciona la compresión con SVD. Guardar A_k requiere k valores singulares, k vectores de tamaño m y k de tamaño n: en total $k(m+n+1)$ números en vez de mn. Una imagen en escala de grises de 1000×1000 con $k = 50$ ocupa $50 \cdot 2001 = 100\,050$ números en lugar de $1\,000\,000$, alrededor del $10\,\%$. En las imágenes reales los σ_i caen rápido, así que con k chico casi no se nota la diferencia.

Pseudoinversa

Una matriz rectangular no tiene inversa, pero con la SVD se define lo más parecido. Si Σ^+ es la matriz de $n \times m$ que tiene $1/\sigma_i$ en la diagonal (solo para los $\sigma_i \neq 0$), la **pseudoinversa** es

$$A^+ = V\Sigma^+ U^T = \frac{1}{\sigma_1} v_1 u_1^T + \cdots + \frac{1}{\sigma_r} v_r u_r^T.$$

Deshace a A en todas las direcciones donde A no destruyó información.

Ejemplo 11.8. Para la A de 3×2 del ejemplo completo:

$$A^+ = \frac{1}{\sqrt{3}} v_1 u_1^T + v_2 u_2^T = \frac{1}{6}\begin{pmatrix} 1 & 1 & 2 \\ 1 & 1 & 2 \end{pmatrix} + \frac{1}{2}\begin{pmatrix} 1 & -1 & 0 \\ -1 & 1 & 0 \end{pmatrix} = \frac{1}{3}\begin{pmatrix} 2 & -1 & 1 \\ -1 & 2 & 1 \end{pmatrix}.$$

Se comprueba que $A^+ A = I_2$: el primer renglón de A^+ contra las columnas de A da $\frac{1}{3}(2+0+1) = 1$ y $\frac{1}{3}(0-1+1) = 0$.

Su uso principal es resolver sistemas $Ax = b$ que no tienen solución, como los que salen de ajustar una recta a muchos puntos con ruido. $x = A^+ b$ es la solución de **mínimos cuadrados**: la que hace $\|Ax - b\|$ lo más chico posible.

Para qué sirve en computación

- **Compresión de imágenes.** Una imagen es una matriz de intensidades. La SVD truncada se queda con las k direcciones de más energía. Además de comprimir, quita ruido: el ruido se reparte entre muchos σ_i chicos, que son justo los que se tiran.
- **Indexación semántica latente (LSI).** Se arma una matriz término-documento, con un renglón por palabra y una columna por documento. Su SVD truncada agrupa palabras que aparecen en contextos parecidos: "coche" y "automóvil" quedan cerca en el espacio de los primeros v_i aunque nunca aparezcan en el mismo documento. Un buscador así encuentra documentos por concepto y no solo por palabra exacta.
- **Sistemas de recomendación.** La matriz usuario-película tiene casi todas sus entradas vacías. Se aproxima con una factorización de rango bajo; los k factores son "gustos ocultos" (acción, comedia, películas de autor) que nadie definió a mano. Las entradas vacías de la aproximación son las calificaciones predichas.

- **PCA.** Si X son los datos centrados, un renglón por muestra, los v_i de su SVD son las componentes principales, y $\sigma_i^2/(N-1)$ es la varianza que explica cada una. Es el mismo PCA de la clase anterior, solo que sin formar la matriz de covarianza, lo cual es más estable numéricamente.

12. Introducción a la estadística

7 de octubre de 2026

Resumen rápido. Arranca la segunda parte del curso, dedicada a la estadística. Se presentaron el temario, la forma de evaluar, el libro y los detalles del proyecto. Luego se vieron las dos ramas de la estadística: la descriptiva, que resume y presenta lo que se observó, y la inferencial, que a partir de una muestra dice algo sobre toda la población, con un margen de error y un nivel de confianza. Entre las dos sustentan el método científico.

La segunda parte del curso

El temario arranca con las definiciones básicas y la importancia de la estadística, la presentación del libro que se va a usar y los detalles del proyecto. La evaluación de esta parte queda así:

Actividad	**Peso**
Presentación por equipos	10 %
Ejercicios rápidos	5 %
Proyecto por equipos	15 %
Defensa personal individual	20 %
Total	**50 %**

La defensa individual es lo que más pesa: el proyecto se hace en equipo, pero cada quien tiene que poder explicarlo.

El libro

Calling Bullshit: The Art of Skepticism in a Data-Driven World, de Carl T. Bergstrom y Jevin D. West (2020). No es un libro de fórmulas: trata de cómo detectar cuándo los números, las gráficas y los estudios se usan para engañar, a propósito o por descuido. Es el otro lado de la estadística: además de saber calcular, saber cuándo desconfiar de un resultado.

Qué es la estadística

Definición 12.1 (Estadística)**.** La ciencia que se ocupa de recolectar, organizar, analizar e interpretar datos, para describir lo que se observó y para sacar conclusiones cuando no se puede observar todo.

Antes de separar sus dos ramas hacen falta cuatro términos, porque la diferencia entre las ramas está justo ahí:

- **Población**: el conjunto completo sobre el que se quiere saber algo. Todos los votantes del país, todas las ejecuciones posibles de un programa.
- **Muestra**: la parte de la población que sí se observa. Las 400 personas encuestadas, las 30 ejecuciones que se corrieron.
- **Parámetro**: un número que describe a la población, como la proporción real de votantes a favor. Casi nunca se conoce.
- **Estadístico**: un número calculado con la muestra, como la proporción a favor entre los encuestados. Este sí se conoce, y se usa para estimar el parámetro.

La estadística se divide en dos ramas:

- **Descriptiva**: pone los datos en una forma que se pueda entender.
- **Inferencial**: usa los datos para sacarles jugo, analizarlos y concluir algo más allá de ellos, siempre con un margen de error y un nivel de confianza.

Estadística descriptiva

Resume un conjunto de datos con unos cuantos números y gráficas, para entender y comunicar lo que se observó. Su límite es ese: describe los datos que se tienen y no saca conclusiones sobre nada que no se haya medido. Sus herramientas se agrupan en tres tipos:

- **Tendencia central**, dónde está el centro de los datos: la **media** (el promedio), la **mediana** (el valor de en medio al ordenarlos) y la **moda** (el que más se repite).
- **Dispersión**, qué tan separados están: el **rango** (máximo menos mínimo), la **varianza** y la **desviación estándar**, que es la raíz de la varianza y queda en las mismas unidades que los datos.
- **Presentación**: tablas de frecuencias, histogramas, diagramas de caja.

Para una muestra de n datos, la media y la varianza son

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad s^2 = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \bar{x})^2, \qquad s = \sqrt{s^2}.$$

Se divide entre $n-1$ y no entre n porque s^2 se usa para estimar la varianza de la población, y con n la subestimaría: las desviaciones se miden contra $\bar{x}$, que está calculada con los mismos datos y por eso queda más cerca de ellos que la media real.

Ejemplo 12.2 (Tiempos de ejecución)**.** Un programa se corrió 7 veces y tardó, en milisegundos,

$$12,\ 13,\ 14,\ 14,\ 15,\ 16,\ 42.$$

Tendencia central. La suma es 126, así que $\bar{x} = 126/7 = 18$. Ordenados, el de en medio es el cuarto: la mediana es 14. El que más se repite también es 14.

Dispersión. El rango es $42-12 = 30$. Las desviaciones respecto de la media son $-6, -5, -4, -4, -3, -2, 24$, y sus cuadrados

$$36 + 25 + 16 + 16 + 9 + 4 + 576 = 682,$$
$$s^2 = \frac{682}{6} = 113.67, \qquad s = 10.66 \text{ ms}.$$

La corrida de 42 ms jala la media a 18, más arriba que seis de los siete datos, y ella sola aporta 576 de los 682 de la suma de cuadrados. Sin esa corrida, la media y la mediana valen 14 y la desviación estándar baja a 1.41. La mediana no se movió: es más robusta a valores atípicos que la media.

Todo esto describe estas 7 corridas. Si el programa va a tardar 18 ms en otra máquina, o si la corrida de 42 fue un accidente, ya no es pregunta de la descriptiva.

Estadística inferencial

Parte de una muestra representativa para hablar de toda la población. Como solo se observó una parte, cualquier conclusión lleva incertidumbre, y la inferencial la mide en lugar de ignorarla. Hace dos cosas principales:

- **Estimar parámetros**, casi siempre con un **intervalo de confianza**: un rango de valores que, con cierto nivel de confianza, contiene al parámetro real.
- **Poner a prueba hipótesis**: decidir si lo que se ve en la muestra es un efecto real o se explica por el azar de haber tomado esa muestra y no otra.

Ejemplo 12.3 (Intervalo de confianza: una encuesta)**.** Se pregunta a 400 personas si están a favor de una propuesta y 208 dicen que sí: $\hat{p} = 208/400 = 0.52$. ¿Está a favor la mayoría de la población?

La proporción de la muestra cambia de una muestra a otra. Cuánto cambia lo mide su error estándar:

$$EE = \sqrt{\frac{\hat{p}\,(1-\hat{p})}{n}} = \sqrt{\frac{0.52 \cdot 0.48}{400}} = 0.025.$$

Con 95 % de confianza, el **margen de error** es $1.96 \cdot EE = 0.049$, y el intervalo

$$0.52 \pm 0.049 = [\,0.471,\ 0.569\,].$$

La proporción real puede estar entre 47.1 % y 56.9 %. Como el intervalo incluye valores por debajo del 50 %, la encuesta **no** permite decir que la mayoría está a favor, aunque en la muestra haya ganado el sí.

El 1.96 sale de la distribución normal: el 95 % de su área queda a menos de 1.96 desviaciones estándar del centro. Más confianza pide un intervalo más ancho, y más datos lo angostan: el error estándar baja con $\sqrt{n}$, así que para partir el margen a la mitad hay que cuadruplicar la muestra.

Ejemplo 12.4 (Prueba de hipótesis: ¿la moneda está cargada?)**.** Se lanza una moneda 100 veces y salen 62 águilas. ¿Está cargada, o fue suerte?

Hipótesis. La hipótesis nula, H_0, es la que dice que no pasa nada: la moneda es justa, $p = 0.5$. La alternativa, H_1, es que sí está cargada, $p \neq 0.5$.

Qué esperaría H_0. Con una moneda justa, en 100 lanzamientos salen en promedio 50 águilas, con desviación estándar $\sqrt{100 \cdot 0.5 \cdot 0.5} = 5$. Las 62 están a

$$z = \frac{62 - 50}{5} = 2.4$$

desviaciones estándar del centro.

Valor p. Es la probabilidad de ver algo así de extremo, o más, si H_0 fuera cierta. Con la aproximación normal, quedar a 2.4 desviaciones o más, para cualquiera de los dos lados, tiene probabilidad $p = 0.016$.

Decisión. Se fija de antemano un nivel de significancia, típicamente $\alpha = 0.05$. Como $0.016 < 0.05$, se rechaza H_0: es muy poco probable que una moneda justa dé 62 águilas, así que hay evidencia de que está cargada. Con 55 águilas, $z = 1$ y $p = 0.32$: algo así pasa seguido con una moneda justa y no se rechazaría nada.

Ojito...

No rechazar H_0 no prueba que sea cierta, solo dice que los datos no alcanzan para descartarla. Y el valor p no es la probabilidad de que H_0 sea cierta, es la probabilidad de los datos suponiendo que lo es.
Además, todo depende de que la muestra sea representativa. En 1936 la revista *Literary Digest* encuestó a más de dos millones de personas, sacadas sobre todo de directorios telefónicos y registros de autos, y predijo que Landon le ganaba a Roosevelt. Roosevelt ganó con cerca del 61 %. En plena crisis, quien tenía teléfono y auto no representaba al votante promedio, y ningún tamaño de muestra corrige un sesgo así.

Diferencias entre las dos ramas

	Descriptiva	**Inferencial**
Objetivo	Resumir y presentar lo observado	Concluir algo sobre la población
Alcance	Solo los datos que se tienen	Más allá de los datos, a partir de una muestra
Herramientas	Media, mediana, moda, rango, desviación estándar, tablas y gráficas	Intervalos de confianza, pruebas de hipótesis
Incertidumbre	No hay: los números son exactos para esos datos	Siempre hay: margen de error y nivel de confianza
Pregunta típica	¿Cuánto tardaron estas 7 corridas?	¿Cuánto tardará el programa en general?

Las dos van juntas: la inferencial trabaja sobre estadísticos que calcula la descriptiva, como la media o la proporción de la muestra.

Estadística y método científico

Las dos ramas sustentan el método científico. Se observa un fenómeno y se describe con la estadística descriptiva; se plantea una hipótesis; se diseña un experimento que junte una muestra; y con la estadística inferencial se decide si los datos apoyan la hipótesis o se explican por azar.

Idea clave

En computación esto aparece cada vez que se compara un sistema contra otro con pocos datos. En Fundamentos para el Análisis Automático de Lenguaje, GloVe sacó un MAP de 0.5221 contra 0.5376 de tf-idf, medido sobre solo 10 consultas. La descriptiva dice que en esas 10 ganó tf-idf; si con otras consultas también ganaría, o si la diferencia es ruido, es una pregunta de la inferencial.

13. Estadística descriptiva: datos, variables y escalas *12 de octubre de 2026*

Resumen rápido. Antes de resumir datos hay que saber de dónde salen y qué tipo de datos son. Un dato es el último paso de una cadena: fenómeno, constructo, operacionalización y medición. Se definieron población, muestra y observación, y las tres cosas que hacen falta para entender cualquier dato: variabilidad, incertidumbre y sesgo. Después, cómo clasificar una variable con dos preguntas: qué significan las comparaciones entre sus valores, que da la escala de medición (nominal, ordinal, intervalo, razón), y qué valores puede tomar, que la hace discreta o continua. La escala decide qué resúmenes tienen sentido.

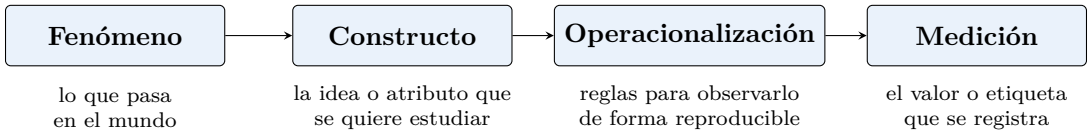
Qué es la estadística descriptiva

Definición 13.1 (Estadística descriptiva)**.** La parte de la estadística que organiza, resume y presenta un conjunto de datos, con tablas, gráficas y unos cuantos números, para que se pueda entender y comunicar lo que se observó. Describe solo los datos que se tienen: no generaliza a nada que no se haya medido.

La clase del 7 la presentó por sus herramientas: media, mediana, moda, rango y desviación estándar. Esta clase va un paso antes. Para saber qué herramienta usar hay que saber qué tipo de dato se tiene: la media de unos tiempos de ejecución tiene sentido, pero la media de unos códigos postales no, aunque los dos sean números. Y para entender un dato hay que saber cómo se produjo.

Del fenómeno a la medición

Un dato no aparece solo. Es el resultado de una cadena de decisiones:



- **Fenómeno.** Algo que ocurre y que llama la atención, todavía sin forma de medirlo: “el sistema se siente lento”.
- **Constructo.** La idea o atributo concreto que se va a estudiar del fenómeno. “Lento” puede ser el tiempo de respuesta, el tiempo de arranque o el uso de memoria; hay que escoger uno.
- **Operacionalización.** Las reglas para observar el constructo de forma reproducible: qué se mide, con qué instrumento, en qué unidades y en qué condiciones. Cualquiera que siga las mismas reglas debe obtener una medición comparable.
- **Medición.** El valor o la etiqueta que se registra al aplicar esas reglas a un caso concreto.

Ejemplo 13.2 (Dos cadenas completas)**.** La misma cadena para dos fenómenos de áreas muy distintas:

	Rendimiento de un sistema	**Estrés en estudiantes**
Fenómeno	El sistema se siente lento	Los estudiantes de posgrado dicen estar agotados
Constructo	Tiempo de respuesta	Estrés percibido
Operacionalización	Milisegundos entre que llega la petición y sale la respuesta, medidos en el servidor, 30 peticiones con la caché caliente	Cuestionario de 10 preguntas, cada una de 0 a 4, sumadas: puntaje de 0 a 40
Medición	14.2 ms	23 puntos

Ojito...

La operacionalización decide qué se mide de verdad. Si un equipo mide el tiempo de respuesta en el servidor y otro en el navegador del usuario, el segundo incluye la red y le saldrán números más grandes. Los dos midieron "tiempo de respuesta" y los dos tienen razón, pero sus datos no se pueden comparar. Por eso un dato sin su operacionalización dice poco: antes de discutir un número, hay que preguntar cómo se midió. Y hay que preguntar si las reglas capturan de verdad el constructo; un cuestionario de estrés que en realidad mide cansancio físico es reproducible, pero mide otra cosa.

Población, muestra y observación

Definición 13.3 (Población)**.** El conjunto completo de unidades sobre las que se quiere saber algo. Puede ser enorme o incluso infinito: todas las ejecuciones que va a tener un programa en producción.

Definición 13.4 (Muestra)**.** El subconjunto de la población que sí se observa y se mide. Las 30 ejecuciones que se registraron.

Definición 13.5 (Observación)**.** Cada unidad de la muestra junto con los valores que se le midieron. En una tabla de datos es un renglón: la ejecución número 17, con su lenguaje, su número de hilos y su tiempo.

Con la observación vienen otros dos términos. Una **variable** es una característica que se mide en cada observación, y en la tabla es una columna. Un **dato** es el valor de una variable en una observación: una celda.

Ejemplo 13.6 (La tabla de esta clase)**.** Siete ejecuciones de distintos programas en un servidor. Cada renglón es una observación y cada columna una variable; se va a usar en el resto de la clase.

Ejec.	**Lenguaje**	**Prioridad**	**Hilos**	**Tiempo (ms)**	**Temp. CPU (°C)**	**Inicio**
1	Python	alta	4	14.2	61.5	09:15
2	C++	baja	8	3.8	55.0	09:40
3	Python	media	2	21.7	58.3	10:05
4	Java	alta	8	7.1	63.2	10:30
5	C++	media	4	4.5	57.9	11:00
6	Python	baja	1	39.0	52.4	11:20
7	Java	media	2	9.6	56.1	11:45

La población son todas las ejecuciones del servidor; la muestra, estas siete. La observación 6 es la ejecución en Python de prioridad baja con un hilo que tardó 39.0 ms.

Variabilidad, incertidumbre y sesgo

Definición 13.7 (Variabilidad)**.** Que los valores de una variable cambien de una observación a otra. Viene de dos lados: las unidades de verdad son distintas entre sí, y además cada medición trae un poco de ruido.

En la tabla, los tiempos van de 3.8 a 39.0 ms porque son programas distintos. Pero aun corriendo el mismo programa siete veces, como en el ejemplo de la clase del 7, salieron tiempos entre 12 y 42 ms. Si no hubiera variabilidad bastaría una sola medición y no haría falta la estadística.

Definición 13.8 (Incertidumbre)**.** Lo que no se sabe sobre el valor real que se quiere conocer, porque solo se observó una muestra o porque las mediciones son imperfectas. La estadística no la elimina; la cuantifica, con herramientas como el error estándar y los intervalos de confianza de la clase del 7.

Definición 13.9 (Sesgo)**.** Un error sistemático: las mediciones, o la muestra, se desvían del valor real siempre en la misma dirección. A diferencia del ruido, no se cancela al promediar.

Los sesgos más comunes:

- **De selección**: la muestra no representa a la población. La encuesta de *Literary Digest* de la clase del 7.
- **De medición**: el instrumento está mal calibrado. Una báscula que siempre marca un kilo de más.
- **De respuesta**: las personas contestan distinto de lo que es. Al preguntar cuánto ejercicio hacen, la gente reporta más del que hace.



El centro de la diana es el valor real. La variabilidad es qué tan regados quedan los tiros; el sesgo es qué tan lejos del centro queda su promedio.

Ejemplo 13.10 (Tres básculas)**.** Una persona que pesa 70.0 kg se pesa cuatro veces en cada una de tres básculas:

Báscula	**Mediciones (kg)**				**Promedio**
A	69.8	70.3	70.1	69.9	70.03
B	68.5	71.4	69.2	70.9	70.00
C	71.0	71.1	70.9	71.0	71.00

A es la primera diana: poca variabilidad y sin sesgo. **B** es la segunda: cada medición puede fallar por más de un kilo, pero los errores van para los dos lados y el promedio cae justo en 70.0. **C** es la tercera: casi no varía, rango de 0.2 kg, y por eso parece confiable, pero siempre marca un kilo de más.

Con más mediciones, el promedio de B se acerca cada vez más al valor real: la incertidumbre que causa la variabilidad baja con más datos. El de C se queda en 71 aunque se pese mil veces. Más datos no corrigen el sesgo.

Ojito...

Un sesgo con poca variabilidad es el más peligroso, porque los datos se ven consistentes y dan confianza. La báscula C da casi lo mismo cada vez, y nada en sus datos avisa que está mal. El sesgo solo se detecta comparando contra algo externo: una pesa de valor conocido, o revisando cómo se armó la muestra.

Cómo clasificar una variable

Toda variable se clasifica contestando dos preguntas:

1. **¿Qué significado tienen las comparaciones entre sus valores?** Si solo se puede decir que dos valores son iguales o distintos, o también cuál es mayor, o cuánto mayor, o cuántas veces mayor. La respuesta es su **escala de medición**: nominal, ordinal, intervalo o razón.

2. **¿Qué conjunto de valores puede tomar?** Valores separados que se cuentan, o cualquier valor dentro de un intervalo. La respuesta dice si es **discreta** o **continua**.

Antes de las escalas hay una división más gruesa: si los valores son etiquetas o cantidades.

Variables categóricas

Sus valores son categorías o etiquetas, y cada observación cae en una. También se les llama cualitativas. En la tabla, **lenguaje** y **prioridad**. Pueden ser nominales u ordinales.

Ojito...

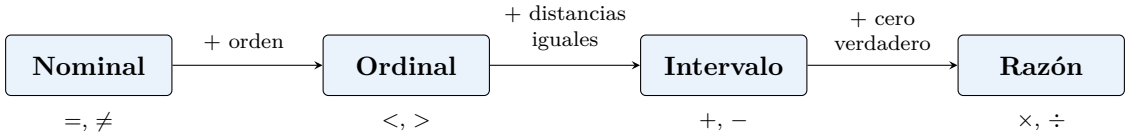
Que una variable venga en números no la hace numérica. Un código postal, un número de cuenta o codificar 1 = Python, 2 = C++ y 3 = Java siguen siendo etiquetas. Con esa codificación el promedio de la columna de lenguaje daría 1.86, y ese número no significa nada: no hay un lenguaje que esté "un poco antes de C++".

Variables numéricas

Sus valores son cantidades: miden cuánto hay de algo, y hacer aritmética con ellos tiene sentido. También se les llama cuantitativas. En la tabla, **hilos**, **tiempo**, **temperatura** e **inicio**. Pueden ser de intervalo o de razón, y discretas o continuas.

Escalas de medición

Las cuatro escalas forman una jerarquía. Cada una conserva todo lo de la anterior y agrega una propiedad:



Escala nominal

Los valores son nombres de categorías sin ningún orden. Solo conserva la **identidad**: se puede decir si dos observaciones son iguales o diferentes, y nada más. No hay orden, ni distancia, ni proporciones entre valores. Ejemplos: lenguaje de programación, tipo de sangre, carrera, color.

Los resúmenes válidos son los que solo cuentan: **frecuencias**, **proporciones** y **moda**.

Ejemplo 13.11 (El lenguaje de la tabla)**.** Contando cuántas veces aparece cada categoría:

Lenguaje	Frecuencia	Proporción
Python	3	$3/7 = 0.43$
C++	2	$2/7 = 0.29$
Java	2	$2/7 = 0.29$
Total	7	1.00

La moda es Python. No hay mediana: para tenerla habría que ordenar los lenguajes, y cualquier orden sería inventado.

Escala ordinal

Las categorías tienen un orden natural, pero las distancias entre ellas no están definidas. Conserva la **identidad** y el **orden**: se sabe que alta está por encima de media, pero no cuánto. No garantiza que los intervalos entre niveles sean iguales. Ejemplos: prioridad baja, media y alta; nivel de inglés; las escalas de acuerdo de "muy en desacuerdo" a "muy de acuerdo"; el lugar en una carrera.

Además de lo de la nominal, como hay orden se pueden usar la **mediana** y los **percentiles**.

Ejemplo 13.12 (La prioridad de la tabla)**.** Ordenadas las siete:

$$\text{baja},\ \text{baja},\ \text{media},\ \text{media},\ \text{media},\ \text{alta},\ \text{alta}.$$

La de en medio es la cuarta: la mediana es **media**. La moda también, con 3 de 7.

Ojito...

El lugar en una carrera es ordinal. Entre el primero y el segundo puede haber una décima de segundo y entre el segundo y el tercero un minuto; los lugares no lo dicen. Por eso promediar valores ordinales es dudoso. Con las respuestas $1, 2, 2, 3, 4, 4, 4, 5, 5$ en una escala de acuerdo, la media daría 3.33, y eso supone que pasar de "en desacuerdo" a "neutral" es la misma distancia que de "de acuerdo" a "muy de acuerdo". La mediana, 4, no supone nada. En la práctica se promedian escalas así todo el tiempo, pero hay que saber que se está agregando un supuesto.

Escala de intervalo

Los valores son números con distancias iguales: la diferencia entre dos valores significa lo mismo en cualquier parte de la escala. Pero el cero es **arbitrario**: es una convención, no la ausencia de lo que se mide. Se pueden sumar y restar valores, así que tienen sentido la **media** y la **desviación estándar**. Lo que no tiene sentido son las razones: decir que un valor es el doble de otro. Ejemplos: temperatura en grados Celsius o Fahrenheit, el año del calendario, la hora del día.

Ejemplo 13.13 (Por qué 20 °C no es el doble de 10 °C)**.** Las diferencias sí funcionan: de 10 a 20 °C hay el mismo calentamiento que de 20 a 30 °C. Pero si se pasan a Fahrenheit,

$$10\,^\circ\text{C} = 50\,^\circ\text{F}, \qquad 20\,^\circ\text{C} = 68\,^\circ\text{F}, \qquad \frac{68}{50} = 1.36.$$

La misma pareja de temperaturas da razón 2 en una escala y 1.36 en otra. Una afirmación que cambia con las unidades no habla de la temperatura, habla de dónde se puso el cero.

En la tabla, la ejecución 4 dejó el procesador a 63.2 °C y la 6 a 52.4 °C. Decir que la 4 lo calentó 10.8 °C más tiene sentido; decir que lo calentó un 20 % más, no.

Escala de razón

Tiene todo lo de la de intervalo y además un **cero verdadero**: cero quiere decir que no hay nada de lo que se mide. Con eso las razones tienen sentido, y se puede decir que un valor es el doble o la mitad de otro. Ejemplos: tiempo de ejecución, número de hilos, peso, longitud, ingreso, temperatura en kelvin.

Ejemplo 13.14 (Razones en la tabla)**.** La ejecución 6 tardó 39.0 ms y la 2 tardó 3.8 ms:

$$\frac{39.0}{3.8} = 10.26.$$

La 6 tardó diez veces más. En segundos, 0.0390/0.0038 da lo mismo, porque cero milisegundos y cero segundos son el mismo cero: no haber tardado nada.

Con razón también tiene sentido el **coeficiente de variación**, la desviación estándar dividida entre la media, que mide la dispersión en relación con el tamaño de los datos. Para los tiempos de la tabla, $\bar{x} = 14.27$ ms y $s = 12.55$ ms, así que $CV = 0.88$: la dispersión es casi tan grande como la media. Con temperaturas en Celsius el CV no sirve, porque depende de dónde está el cero.

Resumen de las escalas

Escala	Conserva	Resúmenes válidos	Ejemplos
Nominal	Identidad	Frecuencias, proporciones, moda	Lenguaje, tipo de sangre
Ordinal	Identidad y orden	Lo anterior, mediana y percentiles	Prioridad, nivel de inglés, lugar en una carrera
Intervalo	Lo anterior y distancias iguales	Lo anterior, media y desviación estándar	Temperatura en °C, año, hora del día
Razón	Lo anterior y cero verdadero	Lo anterior, razones y coeficiente de variación	Tiempo, hilos, peso, temperatura en kelvin

Idea clave

Siempre se puede bajar de escala, pero nunca subir. Los tiempos se pueden agrupar en “rápido”, “normal” y “lento” y tratarlos como ordinales, perdiendo información. Lo que no se puede es sacar distancias de una variable ordinal, ni razones de una de intervalo: esa información nunca se midió.

Naturaleza de los valores: discretas y continuas

La segunda pregunta es qué valores puede tomar la variable.

Definición 13.15 (Variable discreta)**.** Toma valores separados que se pueden contar: entre dos valores consecutivos no hay valores intermedios posibles. Casi siempre sale de contar algo: número de hilos, de errores, de palabras en un documento, de alumnos en un salón.

Definición 13.16 (Variable continua)**.** Puede tomar cualquier valor dentro de un intervalo: entre dos valores cualesquiera siempre cabe otro. Sale de medir algo: tiempo, temperatura, peso, longitud.

En la tabla, los **hilos** son discretos: una ejecución usa 2 o 3 hilos, nunca 2.5. El **tiempo** es continuo: entre 14.2 y 14.3 ms hay una infinidad de duraciones posibles.

Ojito...

Dos confusiones comunes.

- Una variable continua siempre se registra redondeada, porque todo instrumento tiene una precisión. Que los tiempos aparezcan con un decimal no los vuelve discretos: la variable es continua, lo discreto es el registro.
- El promedio de una variable discreta no tiene que ser uno de sus valores. Los hilos de la tabla suman 29, y su media es $29/7 = 4.14$ hilos. Ninguna ejecución usó 4.14 hilos, pero el número sí dice algo: en promedio se usaron un poco más de cuatro.

Las variables categóricas, nominales u ordinales, son discretas por naturaleza: hay un número finito de categorías y nada entre ellas.

La tabla, clasificada

Juntando las dos preguntas para cada columna:

Variable	**Tipo**	**Escala**	**Valores**
Lenguaje	categórica	nominal	discreta
Prioridad	categórica	ordinal	discreta
Hora de inicio	numérica	intervalo	continua
Temperatura en °C	numérica	intervalo	continua
Hilos	numérica	razón	discreta
Tiempo (ms)	numérica	razón	continua

Observación. La hora de inicio es de intervalo porque las 00:00 no es la ausencia de tiempo, es una convención para empezar a contar el día. Entre las 09:15 y las 11:45 pasaron 2.5 horas, eso sí tiene sentido; decir que las 11:45 es "más del doble" que las 05:00 no. La **duración**, en cambio, sí es de razón: una ejecución de 40 ms tarda el doble que una de 20.

Con la clasificación hecha, la elección de resúmenes es automática: a lenguaje se le sacan frecuencias y moda, a prioridad además la mediana, a temperatura y hora además media y desviación estándar, y a hilos y tiempo además razones y coeficiente de variación.

14. Variables aleatorias y distribuciones

14 de octubre de 2026

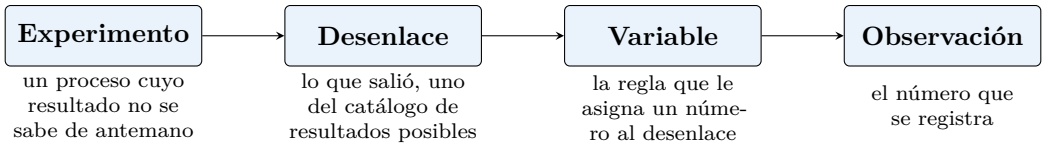
Resumen rápido. De los datos se pasa a lo que los produce. Un experimento tiene desenlaces posibles, una variable aleatoria les asigna un número y una observación es el valor que salió. Contando las observaciones se arma una distribución de frecuencias, la distribución empírica, y lo que se busca es asociarla a un modelo probabilístico que describa a toda la población. Las distribuciones son discretas o continuas según la variable: en las discretas hay probabilidad en cada valor; en las continuas solo en intervalos, como área bajo una curva. Se describen con tres funciones: de masa, de densidad y acumulada.

Para qué sirven las distribuciones en computación

Una distribución dice qué valores puede tomar una variable y qué tan probable es cada uno. Con eso se pueden:

- **Contestar preguntas.** ¿Qué fracción de las peticiones a un servidor tarda más de 30 ms? ¿Cuántas fallas hay que esperar en un lote de mil? Al final de la clase se contesta la primera.
- **Implementar clasificadores.** Un clasificador de Naive Bayes aprende, para cada clase, la distribución de cada característica, y clasifica un ejemplo nuevo según con qué clase es más probable. Un filtro de spam estima qué tan probable es la palabra *gratis* en el spam y en el correo normal.
- **Simular y detectar anomalías.** Generar datos sintéticos que se comporten como los reales, o marcar como sospechoso un valor que el modelo considera muy improbable.

Del experimento a la variable



Definición 14.1 (Experimento aleatorio)**.** Un procedimiento que se puede repetir en las mismas condiciones y cuyo resultado no se conoce antes de hacerlo. Lanzar dos monedas, mandar una petición a un servidor, escoger un documento al azar de una colección.

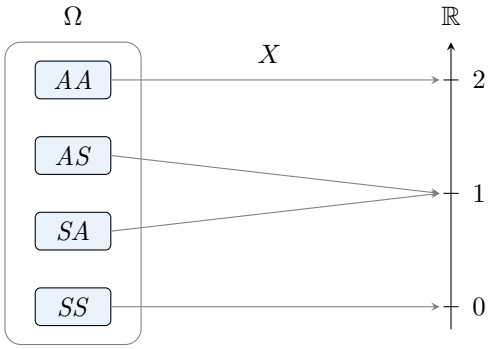
Definición 14.2 (Desenlace y espacio muestral)**.** Un **desenlace** es cada resultado posible del experimento. El **espacio muestral**, Ω, es el catálogo de todos los desenlaces posibles. Queda delimitado antes de hacer el experimento: se sabe qué puede pasar aunque no se sepa qué va a pasar.

Definición 14.3 (Variable aleatoria)**.** Una función $X : \Omega \to \mathbb{R}$ que le asigna un número a cada desenlace. La regla X queda definida antes de observar nada; la incertidumbre está en qué desenlace va a ocurrir, no en la regla.

Definición 14.4 (Observación)**.** El valor que toma la variable cuando el experimento se hace una vez: si ocurrió el desenlace ω, la observación es $x = X(\omega)$.

La convención es usar mayúscula para la variable, X, que es la regla, y minúscula para un valor observado, x. $P(X = 1)$ se lee "la probabilidad de que la variable tome el valor 1".

Ejemplo 14.5 (Dos monedas)**. Experimento:** lanzar dos monedas. **Espacio muestral:** $\Omega = \{AA,\ AS,\ SA,\ SS\}$, con A para águila y S para sol. **Variable:** $X =$ número de águilas.



$X(AA) = 2$, $X(AS) = X(SA) = 1$ y $X(SS) = 0$. Dos desenlaces distintos pueden dar el mismo valor. Si al lanzar sale SA, la observación es $x = 1$.

Ejemplo 14.6 (Una petición al servidor)**.** El mismo experimento puede tener varias variables. Al mandar una petición, el desenlace es todo lo que pasó: si llegó, cuánto tardó, qué respondió. De ahí salen

- T = tiempo de respuesta en milisegundos, que puede valer cualquier número positivo;
- $Y = 1$ si la petición falló y 0 si no.

Una observación podría ser $t = 14.2$ y $y = 0$.

Ojito...

Lo aleatorio de una variable aleatoria no está en la función. X = número de águilas es una regla fija y sin sorpresas: dado el desenlace, el valor es seguro. Lo que no se sabe es qué desenlace va a salir.

Espacio muestral, población y muestra

Son tres conjuntos distintos que se confunden fácilmente:

	Qué es	**En el servidor**
Espacio muestral	Los desenlaces posibles de **una** realización del experimento	Cualquier tiempo positivo, con o sin falla
Población	Todas las unidades o valores sobre los que se quiere concluir	Los tiempos de todas las peticiones que recibe el servidor
Muestra	Las observaciones que de verdad se registraron: un número finito, y pueden estar sesgadas	Los 100 tiempos medidos el lunes en la mañana

La muestra es un subconjunto de la población, y el espacio muestral define qué valores puede contener la población. Si la muestra se tomó solo el lunes en la mañana, cuando hay poca carga, está sesgada respecto a la población, como en la clase del 12.

Distribuciones de frecuencia

Definición 14.7 (Distribución de frecuencias)**.** Una tabla que lista cada valor posible de la variable, o cada intervalo de valores, junto con cuántas veces apareció en la muestra.

Con n observaciones y el valor x_i apareciendo n_i veces:

- **Frecuencia absoluta**, n_i: cuántas veces apareció. Las absolutas suman n.
- **Frecuencia relativa**, $f_i = n_i/n$: qué fracción de la muestra es. Las relativas suman 1, y sirven para comparar muestras de tamaños distintos.
- **Frecuencia acumulada**, N_i o F_i: cuántas observaciones, o qué fracción, quedaron en x_i o por debajo. Solo tiene sentido si los valores tienen orden.
- **Distribución empírica**: la asignación de cada valor a su frecuencia relativa. Es la distribución **de la muestra**: lo que se observó, no lo que es en general.

Ejemplo 14.8 (Las dos monedas, lanzadas 20 veces)**.** Se repitió el experimento 20 veces y se anotó el número de águilas de cada lanzamiento:

x	**Absoluta** n_i	**Relativa** f_i	**Acum. absoluta**	**Acum. relativa**
0	6	0.30	6	0.30
1	9	0.45	15	0.75
2	5	0.25	20	1.00
Total	20	1.00		

La distribución empírica es $0 \mapsto 0.30$, $1 \mapsto 0.45$, $2 \mapsto 0.25$.

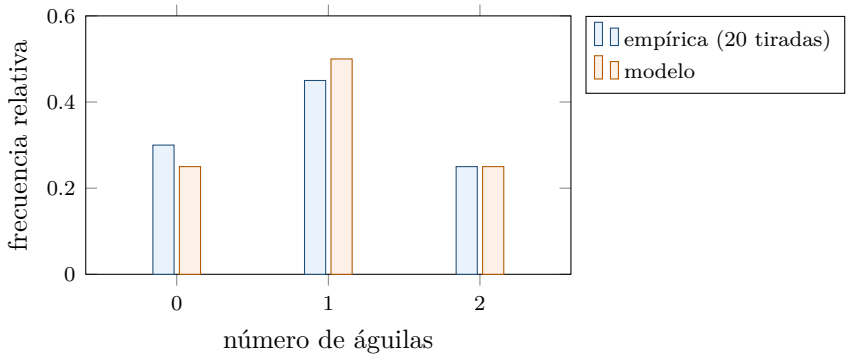
De la distribución empírica al modelo

Lo que se quiere no es describir estas 20 tiradas, sino el comportamiento de la población: qué pasa con las monedas en general. La distribución empírica es una aproximación a eso, y cambia con cada muestra. Por eso se intenta asociarla a un **modelo probabilístico** ya establecido: una suposición matemática que se aproxima al proceso que genera los datos.

Para dos monedas justas, cada uno de los cuatro desenlaces tiene probabilidad $1/4$, y el modelo es

$$P(X=0) = \tfrac{1}{4}, \qquad P(X=1) = \tfrac{1}{4} + \tfrac{1}{4} = \tfrac{1}{2}, \qquad P(X=2) = \tfrac{1}{4},$$

porque $X = 1$ ocurre con dos desenlaces, AS y SA.



La empírica no coincide exactamente con el modelo: con 20 tiradas salió 0.30 donde el modelo dice 0.25. Es la variabilidad de la muestra. Con más repeticiones la empírica se va acercando al modelo, si el modelo es correcto; si no se acerca, el modelo está mal y la moneda está cargada.

El modelo más simple de todos es el de **Bernoulli**: un solo ensayo con dos resultados, éxito o fracaso.

$$P(Y=1) = p, \qquad P(Y=0) = 1-p.$$

La variable Y de la petición, falló o no, es una Bernoulli. Contar cuántos éxitos hay en n ensayos de Bernoulli independientes da la **binomial**; el número de águilas en dos monedas es una binomial con $n = 2$ y $p = 1/2$.

Qué es una distribución

Definición 14.9 (Distribución de probabilidad)**.** La descripción de qué valores puede tomar una variable aleatoria y con qué probabilidad toma cada uno, o cada intervalo de valores.

Con una distribución la pregunta cambia. Ya no es "¿cuál fue el valor?", que es la observación, sino "¿cómo se distribuyen los valores?", que es el comportamiento de la variable en general.

La forma de la distribución depende de la naturaleza de la variable, la de la clase del 12:

- **Variables discretas.** Los valores se pueden contar uno por uno, y cada valor tiene su propia probabilidad. La distribución dice cuánta probabilidad le toca a cada valor.
- **Variables continuas.** Hay una infinidad de valores en cualquier intervalo, y ninguno tiene probabilidad propia. La distribución dice cuánta probabilidad le toca a cada intervalo.

Distribuciones discretas

Indican la probabilidad de observar **exactamente** el valor x:

$$p(x) = P(X = x).$$

A p se le llama función de masa de probabilidad. Tiene tres propiedades:

1. $0 \leq p(x) \leq 1$ para todo x: son probabilidades.
2. $\sum_x p(x) = 1$: algún valor tiene que salir, y la probabilidad total se reparte entre todos.
3. $P(X \in A) = \sum_{x \in A} p(x)$: la probabilidad de un conjunto de valores es la suma de las de cada uno.

Ejemplo 14.10 (Dos monedas)**.** Con $p(0) = 0.25$, $p(1) = 0.5$ y $p(2) = 0.25$, la suma es 1. La probabilidad de que salga al menos un águila es

$$P(X \geq 1) = p(1) + p(2) = 0.5 + 0.25 = 0.75.$$

Ejemplo 14.11 (Fallas en un lote de peticiones)**.** Si cada petición falla con probabilidad $p = 0.02$, de forma independiente, la probabilidad de que ninguna de 10 falle es

$$P(\text{ninguna falla}) = (1 - 0.02)^{10} = 0.98^{10} = 0.817,$$

y la de que falle al menos una, $1 - 0.817 = 0.183$. Aunque cada petición casi nunca falla, en casi uno de cada cinco lotes falla alguna.

Las distribuciones discretas también cubren a las variables categóricas. Los valores no tienen que ser números: la distribución del lenguaje en la tabla de la clase del 12 es $P(\text{Python}) = 3/7$, $P(\text{C++}) = 2/7$, $P(\text{Java}) = 2/7$, y cumple las tres propiedades.

Modelo	Valores	Describe	Ejemplo
Bernoulli	0 o 1	un ensayo de sí o no	¿falló la petición?
Binomial	$0, 1, \ldots, n$	éxitos en n ensayos	fallas en un lote de 10
Poisson	$0, 1, 2, \ldots$	eventos en un intervalo	peticiones por segundo
Categórica	k categorías	una etiqueta	lenguaje del programa

Distribuciones continuas

En una variable continua los valores posibles no se cuentan uno por uno, sino por intervalos. La probabilidad se reparte a lo largo de la recta como un área bajo una curva, y solo los intervalos tienen probabilidad. La de un valor exacto es cero.

Definición 14.12 (Función de densidad de probabilidad)**.** Una función f tal que la probabilidad de que X caiga en un intervalo es el área bajo f en ese intervalo:

$$P(a \le X \le b) = \int_a^b f(x)\,dx.$$

Cumple $f(x) \ge 0$ para todo x y $\int_{-\infty}^{\infty} f(x)\,dx = 1$: el área total es 1.

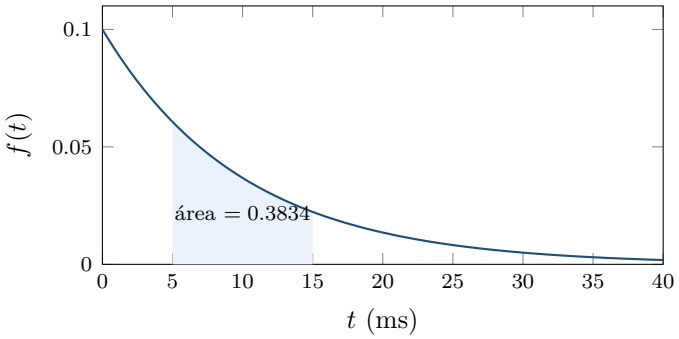
Ejemplo 14.13 (Tiempo de respuesta con un modelo exponencial)**.** Supongamos que el tiempo de respuesta T, en milisegundos, sigue una distribución exponencial con media de 10 ms:

$$f(t) = 0.1\,e^{-0.1t} \quad \text{para } t \ge 0,$$

y $f(t) = 0$ para $t < 0$. ¿Qué fracción de las peticiones tarda entre 5 y 15 ms?

$$\begin{aligned} P(5 \le T \le 15) &= \int_5^{15} 0.1\,e^{-0.1t}\,dt = \Big[-e^{-0.1t} \Big]_5^{15} \\ &= e^{-0.5} - e^{-1.5} = 0.6065 - 0.2231 = 0.3834. \end{aligned}$$

Un 38 % de las peticiones.



Por qué un valor exacto tiene probabilidad cero

Con el mismo modelo, intervalos cada vez más angostos alrededor de 10 ms:

Intervalo	Probabilidad
$[9.9,\ 10.1]$	0.007358
$[9.99,\ 10.01]$	0.000736
$[9.999,\ 10.001]$	0.000074

Cada vez que el intervalo se hace diez veces más angosto, la probabilidad baja diez veces. En el límite, un intervalo de ancho cero, que es un solo valor, tiene probabilidad cero. Por eso $P(T = 10) = 0$, aunque 10 ms sea un valor perfectamente posible, y por eso en una continua da igual escribir $\le$ o $<$.

Ojito...

$f(x)$ **no es una probabilidad**. Es probabilidad por unidad de longitud, como la densidad de un material es masa por unidad de volumen. Lo que sí es probabilidad es $f(x)$ por el ancho de un intervalo chico: $f(10) = 0.0368$, y $0.0368 \cdot 0.2 = 0.00736$, justo la primera fila de la tabla. Como no es probabilidad, puede valer más de 1: si el mismo tiempo se mide en segundos, la densidad en cero es 100, porque toda la probabilidad se aprieta en un rango de centésimas de segundo.

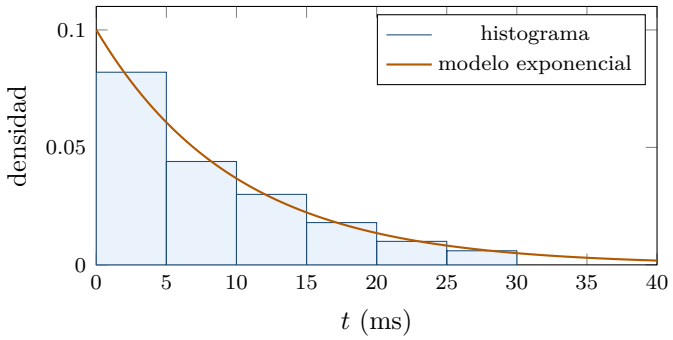
Del histograma a la densidad

Para una variable continua, la distribución empírica se arma agrupando las observaciones en intervalos. Si la altura de cada barra es la frecuencia relativa dividida entre el ancho del intervalo, el área de cada barra es su frecuencia relativa, y el histograma queda en la misma escala que una densidad.

Ejemplo 14.14 (100 tiempos medidos)**.** En intervalos de 5 ms:

Intervalo (ms)	$[0,5)$	$[5,10)$	$[10,15)$	$[15,20)$	$[20,25)$	$[25,30)$
Frecuencia absoluta	41	22	15	9	5	3
Frecuencia relativa	0.41	0.22	0.15	0.09	0.05	0.03
Altura ($f_i/5$)	0.082	0.044	0.030	0.018	0.010	0.006

Las 5 observaciones restantes tardaron 30 ms o más.



El histograma sigue a la curva: el modelo exponencial describe bien estos datos. Con más observaciones e intervalos más angostos, el histograma se parece cada vez más a una densidad.

Ojito...

El exponencial se escogió aquí porque sus cuentas son sencillas. Los tiempos de respuesta reales suelen tener una cola más larga, con más peticiones muy lentas de las que predice. Un modelo es una suposición, y comparar el histograma con la curva es justo la forma de revisar si la suposición se sostiene.

Modelo	**Valores**	**Describe**	**Ejemplo**
Uniforme	$[a,b]$	todo el intervalo igual de probable	lo que devuelve `random()`
Exponencial	$t \geq 0$	tiempos de espera	tiempo hasta la siguiente petición
Normal	todos los reales	suma de muchos efectos chicos	errores de medición

Tres formas de describir una distribución

- **Función de masa** (PMF, *probability mass function*): $p(x) = P(X = x)$. Solo para discretas. Dice cuánta probabilidad hay **en** cada valor.

- **Función de densidad** (PDF, *probability density function*): $f(x)$. Solo para continuas. Dice qué tan concentrada está la probabilidad **alrededor** de cada valor; la probabilidad sale de su área.
- **Función de distribución acumulada** (CDF, *cumulative distribution function*): $F(x) = P(X \leq x)$. Para las dos. Dice cuánta probabilidad hay **hasta** cada valor.

La acumulada se obtiene de las otras dos:

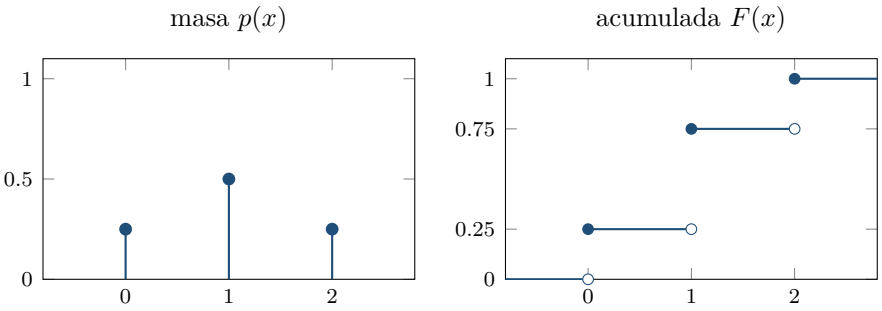
$$F(x) = \sum_{t \leq x} p(t) \quad \text{(discreta)}, \qquad F(x) = \int_{-\infty}^{x} f(t)\, dt \quad \text{(continua)},$$

y en el caso continuo, al revés, $f(x) = F'(x)$. Toda acumulada empieza en 0, termina en 1 y nunca baja. Con ella cualquier intervalo sale con una resta:

$$P(a < X \leq b) = F(b) - F(a).$$

Ejemplo 14.15 (Las dos monedas: masa y acumulada)**.**

$$F(x) = \begin{cases} 0 & x < 0, \\ 0.25 & 0 \leq x < 1, \\ 0.75 & 1 \leq x < 2, \\ 1 & x \geq 2. \end{cases}$$



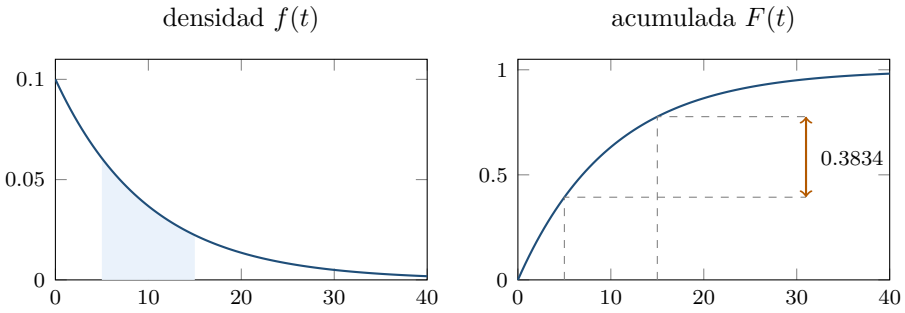
La acumulada de una discreta es una escalera: es plana entre los valores posibles y salta en cada uno, y el tamaño del salto es la masa de ese valor. El punto relleno marca dónde está la función en cada salto. Es la columna de frecuencia acumulada relativa del ejemplo de las 20 tiradas, pero con las probabilidades del modelo.

Ejemplo 14.16 (El tiempo de respuesta: densidad y acumulada)**.** Integrando la densidad exponencial desde 0:

$$F(t) = \int_0^t 0.1\, e^{-0.1s}\, ds = 1 - e^{-0.1t} \quad \text{para } t \geq 0.$$

El intervalo de antes sale con la resta, sin integrar otra vez:

$$P(5 < T \leq 15) = F(15) - F(5) = 0.7769 - 0.3935 = 0.3834.$$



El área sombreada de la izquierda es la misma probabilidad que la distancia vertical de la derecha. La densidad muestra dónde se concentran los tiempos; la acumulada contesta directamente preguntas de "hasta tanto".

Y la pregunta del principio: ¿qué fracción de las peticiones tarda más de 30 ms?

$$P(T > 30) = 1 - F(30) = e^{-3} = 0.0498.$$

Una de cada veinte. Las 100 observaciones del histograma tenían 5 arriba de 30 ms, justo lo que predice el modelo.

Función	**Para**	**Qué da**	**Propiedades**
Masa $p(x)$	discretas	$P(X = x)$	$0 \leq p \leq 1$, suma 1
Densidad $f(x)$	continuas	probabilidad por unidad, cerca de x	$f \geq 0$, área total 1, puede pasar de 1
Acumulada $F(x)$	las dos	$P(X \leq x)$	de 0 a 1, nunca baja; escalera en discretas, curva suave en continuas

Ojito...

La acumulada necesita que los valores tengan orden, porque "hasta x" presupone un antes y un después. Para una variable nominal, como el lenguaje, hay función de masa pero no acumulada: $P(X \leq \text{C++})$ no significa nada. Es la misma restricción de la clase del 12, donde la frecuencia acumulada y la mediana empezaban en la escala ordinal.

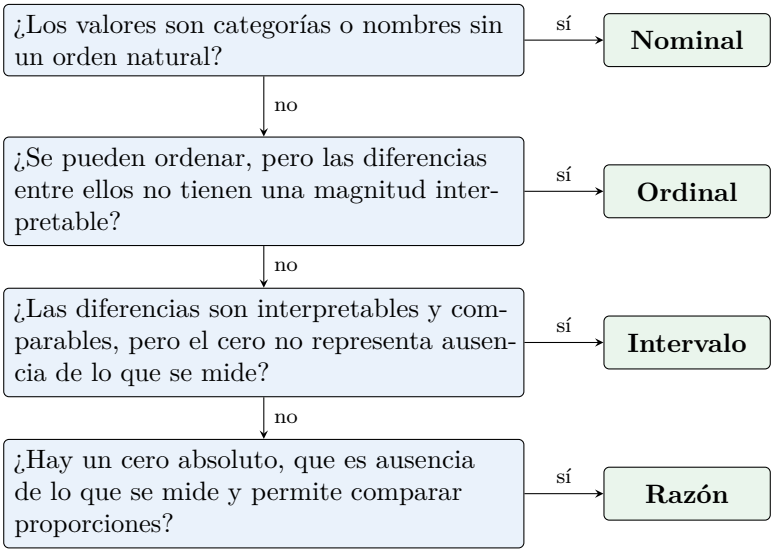
15. Distribuciones conjuntas

19 de octubre de 2026

Resumen rápido. Se cerró el tema de escalas con cuatro preguntas que deciden la escala de una variable. Después, distribuciones de dos variables a la vez: la tabla conjunta, las preguntas marginales, que miran una variable sola, y las condicionales, que fijan el valor de la otra. Dos variables son independientes cuando conocer una no cambia la distribución de la otra. Se cerró con los errores más frecuentes al hablar de distribuciones y una lista de verificación de ocho preguntas para analizar cualquier variable.

Cuatro preguntas para decidir la escala

La clase del 12 definió las cuatro escalas. Para clasificar una variable concreta basta contestar estas preguntas en orden; la primera con respuesta afirmativa da la escala.



Ejemplo 15.1 (Cuatro variables de una encuesta)**.** Pasando cada una por las preguntas:

- **Carrera**: computación, óptica, electrónica. Sí a la primera pregunta: nominal.
- **Nivel de satisfacción**, de "nada" a "mucho". No a la primera, sí a la segunda: hay orden, pero no se sabe si de "poco" a "regular" hay lo mismo que de "regular" a "mucho". Ordinal.
- **Año de nacimiento**. Entre 1998 y 2000 hay dos años, igual que entre 2000 y 2002; pero el año 0 no es "ausencia de tiempo". Intervalo.
- **Horas de estudio a la semana**. Cero horas es no estudiar, y 10 horas es el doble que 5. Razón.

Las nominales y las ordinales son categóricas. Cuando no hace falta tanto detalle, basta una clasificación más gruesa: **categórica** contra **numérica**, y si es numérica, **discreta** o **continua**. Para escoger gráficas y resúmenes básicos esa división suele alcanzar.

Distribuciones conjuntas

Hasta ahora cada distribución era de una sola variable. Muchas preguntas involucran dos a la vez: ¿el filtro marca como spam a los correos que de verdad son spam?, ¿los programas en Python tardan más que los de C++?

Definición 15.2 (Distribución conjunta)**.** Para dos variables X y Y, la distribución conjunta da la probabilidad de cada combinación de valores:

$$p(x, y) = P(X = x \text{ y } Y = y).$$

Con variables categóricas o discretas se escribe como una tabla: un renglón por cada valor de X, una columna por cada valor de Y, y en cada celda la probabilidad o el conteo de esa combinación.

Cumple lo mismo que una de una variable: cada celda está entre 0 y 1, y todas juntas suman 1.

Ejemplo 15.3 (La matriz de confusión es una distribución conjunta)**.** El filtro de spam de Aprendizaje Computacional se probó con 1000 correos. Hay dos variables por correo: la clase real R y la predicha $\hat{R}$. Dividiendo los conteos entre 1000:

	$\hat{R} = \text{spam}$	$\hat{R} = \text{legítimo}$	**Total**
$R = \text{spam}$	0.08	0.02	**0.10**
$R = \text{legítimo}$	0.03	0.87	**0.90**
Total	**0.11**	**0.89**	1.00

La celda 0.08 es $P(R = \text{spam},\ \hat{R} = \text{spam})$: el 8 % de los correos era spam y el filtro lo detectó.

Preguntas marginales y condicionales

Con una tabla conjunta se pueden hacer dos tipos de pregunta.

Marginal: una variable sola

Una pregunta marginal se fija en una sola variable e ignora la otra: ¿qué fracción de los correos es spam?, sin importar lo que dijo el filtro. Se contesta sumando la tabla a lo largo de la variable que se ignora:

$$P(X = x) = \sum_{y} p(x, y).$$

Las sumas quedan en los márgenes de la tabla, y de ahí el nombre. En el ejemplo, $P(R = \text{spam}) = 0.08 + 0.02 = 0.10$ es la suma del primer renglón, y $P(\hat{R} = \text{spam}) = 0.08 + 0.03 = 0.11$ la de la primera columna.

Condicional: fijando la otra variable

Una pregunta condicional fija el valor de una variable y pregunta por la otra solo dentro de ese grupo: de los correos que *son* spam, ¿qué fracción detectó el filtro? Se toma solo el renglón o la columna que corresponde y se reescala para que sume 1:

$$P(Y = y \mid X = x) = \frac{p(x, y)}{P(X = x)}.$$

Ejemplo 15.4 (Dos condicionales del filtro)**. De los correos que son spam**, se toma el primer renglón y se divide entre su total:

$$P(\hat{R} = \text{spam} \mid R = \text{spam}) = \frac{0.08}{0.10} = 0.80.$$

Es el **recall** de Aprendizaje Computacional.

De los correos que el filtro marcó como spam, se toma la primera columna:

$$P(R = \text{spam} \mid \hat{R} = \text{spam}) = \frac{0.08}{0.11} = 0.727.$$

Es la **precisión**. Las dos métricas eran probabilidades condicionales sobre la misma tabla; solo cambia cuál variable se fija.

Ojito...

El orden importa: $P(A \mid B)$ y $P(B \mid A)$ son números distintos, aquí 0.80 y 0.727. Confundirlas es de los errores más caros. Una prueba médica puede detectar al 99 % de los enfermos, $P(\text{positivo} \mid \text{enfermo}) = 0.99$, y aun así la mayoría de los positivos ser sanos, si la enfermedad es rara: lo que le importa al paciente es $P(\text{enfermo} \mid \text{positivo})$, que puede ser muy baja.

Independencia

Definición 15.5 (Variables independientes)**.** X y Y son independientes si conocer el valor de una no cambia la distribución de la otra:

$$P(Y = y \mid X = x) = P(Y = y) \quad \text{para todos los } x, y.$$

Equivalentemente, la conjunta es el producto de las marginales: $p(x, y) = P(X = x)\, P(Y = y)$.

En una tabla se reconoce porque todos los renglones, una vez reescalados, son iguales entre sí e iguales a la marginal.

Ejemplo 15.6 (Lenguaje y turno: independientes)**.** 100 ejecuciones, según el lenguaje y si corrieron en la mañana o en la tarde:

	Mañana	**Tarde**	**Total**
Python	30	20	50
C++	18	12	30
Java	12	8	20
Total	60	40	100

La fracción que corrió en la mañana es la misma en cada lenguaje, $30/50 = 18/30 = 12/20 = 0.6$, e igual a la marginal, $60/100$. Saber el lenguaje no dice nada del turno. Y la conjunta es el producto: $P(\text{Python},\ \text{mañana}) = 0.30 = 0.5 \cdot 0.6$.

Ejemplo 15.7 (El filtro: muy dependientes)**.** Si la clase real y la predicha fueran independientes, la celda spam-spam valdría $P(R = \text{spam})\, P(\hat{R} = \text{spam}) = 0.10 \cdot 0.11 = 0.011$. Vale 0.08, siete veces más. Es lo que se espera de un buen clasificador: su predicción depende mucho de la clase real. Un filtro independiente de la clase real sería uno que adivina.

Errores frecuentes al hablar de distribuciones

- **Confundir la distribución empírica con la poblacional.** La empírica es la de la muestra y cambia con cada muestra. En la clase del 14, 20 tiradas de dos monedas dieron 0.30 de cero águilas, y el modelo dice 0.25. Ni una muestra es la población, ni la población se parece siempre a la muestra.

- **Leer una densidad como probabilidad puntual.** $f(10) = 0.0368$ no es la probabilidad de tardar 10 ms; esa es cero. La densidad solo da probabilidad al integrarla sobre un intervalo, y puede valer más de 1.

- **Comparar histogramas con distintos intervalos sin advertirlo.** Con los 100 tiempos de la clase del 14, la barra de $[0, 5)$ tiene 41 observaciones; con intervalos de 10 ms la de $[0, 10)$ tiene 63. Son los mismos datos, pero las alturas no se pueden comparar. Hay que usar los mismos intervalos, o graficar densidad en lugar de conteos.

- **Reportar una media sin dispersión ni forma.** Los conjuntos $\{14, 15, 15, 16\}$ y $\{5, 10, 20, 25\}$ tienen la misma media, 15, y no se parecen en nada. Una media sola tampoco avisa si hay un valor extremo jalándola.

- **Leer asociación como causalidad.** En una tabla conjunta de meses del año, la venta de helados y los ahogamientos suben juntos. Los helados no ahogan a nadie: los dos dependen del calor. Una tercera variable que mueve a las dos se llama **variable de confusión**.

- **Olvidar que las categorías nominales no tienen orden.** Codificar los lenguajes como 1, 2 y 3 y sacar su promedio, o su mediana, produce un número sin significado.

Lista de verificación para analizar una variable

1. ¿Qué experimento o proceso generó los datos?
2. ¿Cuál es la variable aleatoria que se midió?
3. ¿La variable es categórica, discreta o continua?
4. ¿La distribución observada parece representativa de la población?
5. ¿Conviene una tabla, una gráfica de barras o un histograma?
6. ¿Hay valores extremos, asimetría o varios grupos mezclados?
7. ¿Las variables se comparan de forma marginal o condicional?
8. ¿La conclusión distingue lo que se describió de lo que se está infiriendo?

Ejemplo 15.8 (Los tiempos de respuesta de la clase del 14)**.** Las ocho preguntas aplicadas a esos datos:

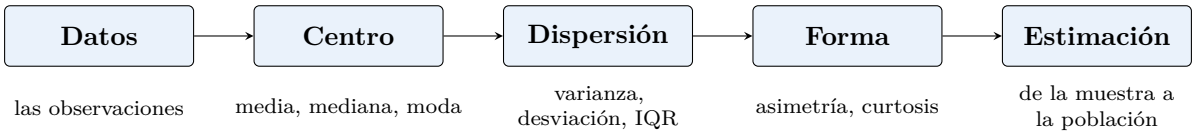
#	**Respuesta**
1	Se mandaron peticiones al servidor el lunes en la mañana y se midió cuánto tardó cada una.
2	T, el tiempo de respuesta en milisegundos.
3	Continua, de razón.
4	Probablemente no: el lunes en la mañana hay poca carga, y en horas pico los tiempos serían otros.
5	Histograma, porque es continua. Para una categórica serían tabla o barras.
6	Sí: cola larga a la derecha, con 5 de 100 arriba de 30 ms.
7	Marginal si se miran todos los tiempos juntos; condicional si se separan por hora o por tipo de petición.
8	"En la muestra, el 5 % tardó más de 30 ms" es descripción. "El 5 % de las peticiones tarda más de 30 ms" es inferencia, y por el punto 4 no está justificada.

16. Centro, dispersión y forma

21 de octubre de 2026

Resumen rápido. Cómo describir un conjunto de datos con números. Primero se separó lo que se calcula con la muestra, una estadística, de lo que se quiere conocer de la población, un parámetro, y se definió la esperanza. Luego los tres aspectos de una distribución: el centro (media, mediana, moda), la dispersión (varianza, desviación estándar, rango intercuartílico, y por qué la varianza muestral divide entre $n-1$) y la forma (asimetría y curtosis). Las cuatro se unifican como momentos. Se cerró con el sesgo de un estimador, distinto de los otros sesgos, y con qué resumen usar según el tipo de variable.

Cómo describir un conjunto de datos



Cada etapa contesta una pregunta: dónde están los datos, qué tan regados, con qué forma, y qué dice todo eso de la población. Un solo número nunca basta; el error de reportar una media sin dispersión ni forma era uno de los de la clase del 19.

Ejemplo 16.1 (Los datos de esta clase)**.** Diez tiempos de respuesta, en milisegundos, ya ordenados:

$$12,\ 13,\ 13,\ 14,\ 15,\ 15,\ 15,\ 17,\ 20,\ 36.$$

Todas las medidas de la clase se calculan sobre ellos.

Estadística, estimador y parámetro

Definición 16.2 (Parámetro)**.** Un número que describe a la población: su media, su varianza, la proporción de algo. Es fijo, pero casi nunca se conoce.

Definición 16.3 (Estadística)**.** Un número que se calcula a partir de una muestra. Cambia de una muestra a otra.

Definición 16.4 (Estimador)**.** Una estadística que se usa para aproximar un parámetro de la población. La media de la muestra, $\bar{x}$, es un estimador de la media de la población, μ.

Para no confundirlos, cada cosa tiene su símbolo. Las letras griegas son para la población y las latinas para la muestra; un gorro sobre un parámetro, como $\hat{p}$, quiere decir "el estimador de ese parámetro".

Medida	Población (parámetro)	Muestra (estadística)
Tamaño	N	n
Media	μ	$\bar{x}$
Varianza	σ^2	s^2
Desviación estándar	σ	s
Proporción	p	$\hat{p}$
Mediana	M	$\tilde{x}$
Correlación	ρ	r
Parámetro en general	θ	$\hat{\theta}$

Esperanza

Definición 16.5 (Esperanza)**.** Si un experimento se repite muchas veces, la esperanza $E[X]$ es el valor al que tiende el promedio de los resultados. Se calcula pesando cada valor por su probabilidad:

$$E[X] = \sum_x x\, p(x) \quad \text{(discreta)}, \qquad E[X] = \int_{-\infty}^{\infty} x\, f(x)\, dx \quad \text{(continua)}.$$

Es la media de la población, $\mu = E[X]$: la media de la distribución, no la de una muestra.

Ejemplo 16.6 (Un dado)**.**

$$E[X] = 1 \cdot \tfrac{1}{6} + 2 \cdot \tfrac{1}{6} + \cdots + 6 \cdot \tfrac{1}{6} = \frac{21}{6} = 3.5.$$

Ningún lanzamiento da 3.5, pero el promedio de mil lanzamientos queda muy cerca. En la clase del 14, el tiempo exponencial con $f(t) = 0.1\, e^{-0.1t}$ tiene esperanza $1/0.1 = 10$ ms: la "media de 10 ms" con la que se construyó.

Propiedades de la esperanza

Con a, b y c constantes:

1. $E[c] = c$: una constante no varía, su promedio es ella misma.
2. $E[aX + b] = a\, E[X] + b$: cambiar de unidades o recorrer los datos hace lo mismo con el promedio.
3. $E[X + Y] = E[X] + E[Y]$, **siempre**, sean o no independientes.
4. $E[XY] = E[X]\, E[Y]$, pero **solo** si X y Y son independientes.

Ejemplo 16.7 (Dos dados)**.** Si X es un dado, $E[2X + 1] = 2 \cdot 3.5 + 1 = 8$. Si X y Y son dos dados, la suma tiene esperanza $E[X + Y] = 3.5 + 3.5 = 7$, sin tener que listar las 36 combinaciones. Como los dados son independientes, $E[XY] = 3.5 \cdot 3.5 = 12.25$.

Ojito...

La esperanza pasa por las funciones lineales, pero no por las demás: en general $E[g(X)] \neq g(E[X])$. Para un dado,

$$E[X^2] = \frac{1 + 4 + 9 + 16 + 25 + 36}{6} = \frac{91}{6} = 15.17, \qquad (E[X])^2 = 3.5^2 = 12.25.$$

La diferencia, 2.92, no es casualidad: es la varianza del dado, como se ve más adelante.

Medidas de tendencia central

Media muestral

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Para los datos de la clase, la suma es 170 y $\bar{x} = 17$ ms.

La media es el **centro de gravedad** de los datos: si cada dato fuera una pesa sobre una regla, la regla se equilibraría en $\bar{x}$. Por eso las desviaciones respecto a la media siempre suman cero:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0.$$

Con los datos: $-5-4-4-3-2-2-2+0+3+19=0$. Los nueve primeros quedan, en total, 19 por debajo, y el 36 solo los compensa estando 19 por encima.

Como estimador de μ tiene dos propiedades buenas:

$$E[\bar{x}] = \mu, \qquad \mathrm{Var}(\bar{x}) = \frac{\sigma^2}{n}.$$

En promedio le atina a la media de la población, y con más datos varía menos: es el error estándar de la clase del 7.

Ojito...

La media es sensible a los valores extremos. El 36 la jala a 17, por encima de siete de los diez datos. Si en lugar de 36 hubiera sido 360, la media saltaría a 49.4 ms, un valor que no se parece a ninguna petición.

Mediana

El valor que queda en medio al ordenar los datos. Con n impar es el de en medio; con n par, el promedio de los dos centrales. Aquí, $\tilde{x} = (15+15)/2 = 15$ ms. La mitad de los datos queda abajo y la mitad arriba.

Es **robusta**: si el 36 fuera 360, la mediana seguiría en 15, porque solo depende del orden. Necesita que los valores se puedan ordenar, así que existe desde la escala ordinal.

Moda

El valor que más se repite: aquí 15, que aparece tres veces. Puede haber varias, o ninguna si nada se repite. Es la única medida de centro para variables nominales, como el lenguaje más común.

Idea clave

En una distribución con cola a la derecha las tres se ordenan

$$\text{moda} \le \text{mediana} \le \text{media},$$

porque la cola jala más a la media que a la mediana, y a la moda no la mueve. En los datos: 15, 15 y 17. Con cola a la izquierda el orden se invierte, y en una simétrica coinciden. Comparar la media con la mediana es la forma más rápida de detectar asimetría.

Dispersión y varianza

Qué es la dispersión

Qué tan separados están los datos entre sí, o de su centro. Dos conjuntos pueden tener el mismo centro y nada más en común:

$$A = \{14, 15, 15, 16\}, \qquad B = \{5, 10, 20, 25\}.$$

Los dos tienen media 15. En A todos están a lo más a 1 de la media; en B, hasta a 10. Un sistema con los tiempos de A es predecible, uno con los de B no, aunque los dos "tarden 15 en promedio".

Rango y rango intercuartílico

El **rango**, máximo menos mínimo, es la medida más simple, pero depende solo de los dos valores más extremos: aquí $36 - 12 = 24$ ms, casi todo por el 36.

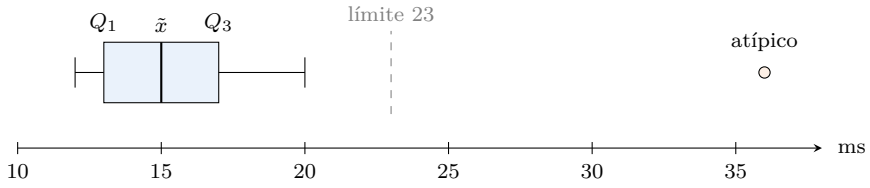
El **rango intercuartílico** (IQR) mide el ancho del 50 % de en medio. El primer cuartil Q_1 deja abajo una cuarta parte de los datos y el tercero, Q_3, tres cuartas partes:

$$\mathrm{IQR} = Q_3 - Q_1.$$

Con la mediana de cada mitad: la mitad baja es $12, 13, 13, 14, 15$, así que $Q_1 = 13$; la alta es $15, 15, 17, 20, 36$, así que $Q_3 = 17$. IQR $= 4$ ms, y el 36 no lo afectó.

Observación. Hay varias convenciones para calcular cuartiles con pocos datos, y distintos programas dan valores un poco distintos. Con muchos datos la diferencia desaparece.

El **diagrama de caja** dibuja estas medidas. La caja va de Q_1 a Q_3 con una raya en la mediana. Los bigotes llegan hasta el dato más lejano que no pase de 1.5 IQR desde la caja, y lo que queda más allá se marca como valor atípico. Aquí el límite superior es $17 + 1.5 \cdot 4 = 23$, y el 36 queda fuera:



Varianza

La varianza es el promedio de las desviaciones al cuadrado respecto a la media. Para la población,

$$\sigma^2 = E\big[(X - \mu)^2\big].$$

Se elevan al cuadrado por dos razones. Las desviaciones con signo suman cero, como se vio con la media, así que su promedio no dice nada. Y el cuadrado castiga más las desviaciones grandes: una desviación de 10 pesa 100, cien veces más que una de 1.

Varianza muestral

Con una muestra, la media de la población no se conoce y se mide contra $\bar{x}$. Se divide entre $n - 1$, no entre n:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2.$$

Ejemplo 16.8. Las desviaciones son $-5, -4, -4, -3, -2, -2, -2, 0, 3, 19$, y sus cuadrados

$$25 + 16 + 16 + 9 + 4 + 4 + 4 + 0 + 9 + 361 = 448.$$

$$s^2 = \frac{448}{10 - 1} = 49.78 \text{ ms}^2.$$

El 36 solo aporta 361 de los 448.

Desviación estándar

La varianza queda en unidades al cuadrado: 49.78 milisegundos cuadrados no significa nada intuitivo. La desviación estándar es su raíz, y regresa a las unidades de los datos:

$$s = \sqrt{s^2} = \sqrt{49.78} = 7.06 \text{ ms}.$$

Se lee como la distancia típica de un dato a la media. Con datos de forma parecida a una normal, cerca del 68 % cae a menos de una desviación de la media y cerca del 95 % a menos de dos. Aquí, $17 \pm 7.06 = [9.94,\ 24.06]$ contiene nueve de los diez datos.

Corrección de Bessel

¿Por qué $n-1$? Las desviaciones se miden contra $\bar{x}$, que se calculó con los mismos datos. $\bar{x}$ es justo el punto que hace más chica la suma de cuadrados: contra cualquier otro valor, incluida la media real μ, la suma sale mayor. Así que $\sum(x_i - \bar{x})^2$ se queda corta respecto a lo que daría μ, y dividir entre n subestima la varianza. En promedio,

$$E\left[\frac{1}{n}\sum(x_i - \bar{x})^2\right] = \frac{n-1}{n}\,\sigma^2,$$

y dividir entre $n-1$ corrige exactamente ese factor. Otra forma de verlo: las n desviaciones suman cero, así que conociendo $n-1$ la última queda determinada. Solo $n-1$ son libres; se dice que hay $n-1$ **grados de libertad**.

Ejemplo 16.9 (Todas las muestras posibles)**.** Una población de tres valores, $\{1, 3, 5\}$, con $\mu = 3$ y

$$\sigma^2 = \frac{(1-3)^2 + (3-3)^2 + (5-3)^2}{3} = \frac{8}{3} = 2.667.$$

Se toman muestras de tamaño $n = 2$, con reemplazo. Hay 9 posibles, todas igual de probables:

Muestra	$\bar{x}$	$\sum(x_i - \bar{x})^2$	**Entre** $n = 2$	**Entre** $n - 1 = 1$
$(1, 1)$	1	0	0	0
$(1, 3)$	2	2	1	2
$(1, 5)$	3	8	4	8
$(3, 1)$	2	2	1	2
$(3, 3)$	3	0	0	0
$(3, 5)$	4	2	1	2
$(5, 1)$	3	8	4	8
$(5, 3)$	4	2	1	2
$(5, 5)$	5	0	0	0
Promedio			$12/9 = 1.333$	$24/9 = 2.667$

Dividiendo entre n, el promedio sobre todas las muestras es 1.333, la mitad de la varianza real: el factor $(n-1)/n = 1/2$. Dividiendo entre $n-1$ es 2.667, exactamente σ^2.

Propiedades de la varianza

1. $\text{Var}(X) \geq 0$, y vale 0 solo si X es constante.
2. $\text{Var}(X + b) = \text{Var}(X)$: recorrer todos los datos no cambia qué tan separados están.
3. $\text{Var}(aX) = a^2\,\text{Var}(X)$, y por eso la desviación estándar se multiplica por $|a|$.

4. $\mathrm{Var}(X) = E[X^2] - (E[X])^2$: el promedio de los cuadrados menos el cuadrado del promedio.

5. Si X y Y son independientes, $\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$.

Ejemplo 16.10 (Las propiedades con un dado)**.** Por la propiedad 4, con las cuentas del ojo de la esperanza:

$$\mathrm{Var}(X) = 15.17 - 12.25 = 2.92.$$

$\mathrm{Var}(2X+1) = 4 \cdot 2.92 = 11.67$: el $+1$ no cuenta y el 2 entra al cuadrado. La suma de dos dados tiene varianza $2.92 + 2.92 = 5.83$. Y pasar los tiempos de milisegundos a segundos multiplica por $1/1000$: la desviación estándar se divide entre 1000 y la varianza entre un millón.

Momentos

La media y la varianza son dos casos de una misma familia. Un **momento** es la esperanza de una potencia de la variable, y cada potencia describe un aspecto distinto de la distribución. El momento de orden k viene en tres versiones:

Familia	**Definición**	**Se mide desde**
Crudo	$\mu'_k = E[X^k]$	el cero
Central	$\mu_k = E\big[(X-\mu)^k\big]$	la media
Central estandarizado	$\tilde{\mu}_k = E\left[\left(\dfrac{X-\mu}{\sigma}\right)^k\right] = \dfrac{\mu_k}{\sigma^k}$	la media, en desviaciones estándar

Orden	**Describe**	**El que se usa**	**Es**
1	el centro	crudo	la media, μ
2	la dispersión	central	la varianza, σ^2
3	la asimetría	central estandarizado	la asimetría
4	las colas y los extremos	central estandarizado	la curtosis

Por qué se estandarizan el tercero y el cuarto. El tercer momento central de unos tiempos está en ms^3 y el cuarto en ms^4: su valor cambia con las unidades y con la escala de los datos, y no se pueden comparar dos distribuciones. Dividiendo entre σ^3 y σ^4 quedan sin unidades, y solo hablan de la forma: la asimetría de unos tiempos es la misma medida en milisegundos o en segundos.

Con una muestra se usan los momentos muestrales $m_k = \frac{1}{n}\sum(x_i - \bar{x})^k$. Con los datos de la clase,

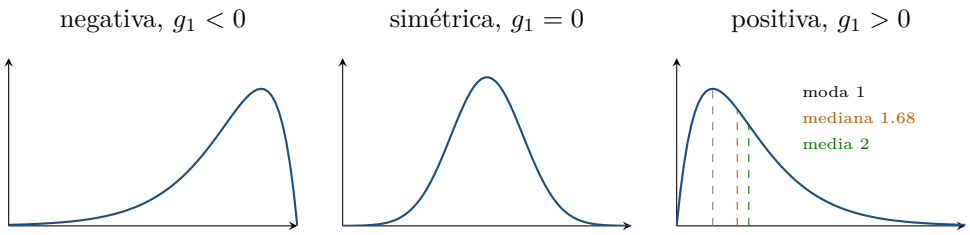
$$m_2 = \frac{448}{10} = 44.8, \qquad m_3 = \frac{6582}{10} = 658.2, \qquad m_4 = \frac{131\,668}{10} = 13\,166.8.$$

Asimetría

Mide qué tan simétrica es la distribución, y hacia qué lado tiene la cola:

$$g_1 = \frac{m_3}{m_2^{3/2}}.$$

El cubo conserva el signo de cada desviación, así que las de un lado compensan las del otro. Si la distribución es simétrica se cancelan y $g_1 = 0$. Si tiene una cola larga a la derecha, las desviaciones grandes y positivas dominan y $g_1 > 0$; con cola a la izquierda, $g_1 < 0$.



Ejemplo 16.11 (La asimetría de los datos)**.**

$$g_1 = \frac{658.2}{44.8^{3/2}} = \frac{658.2}{299.86} = 2.20.$$

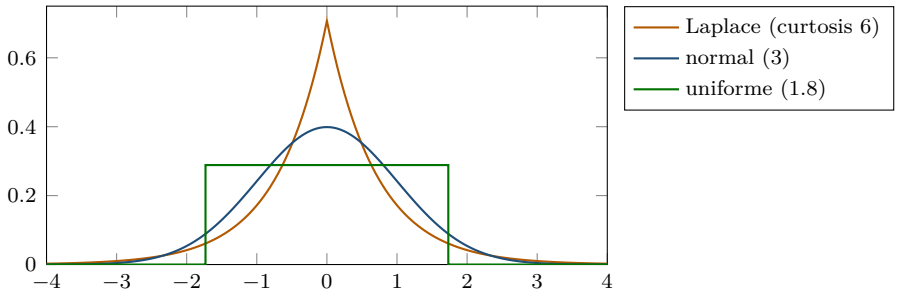
Asimetría positiva fuerte. Viene casi toda del 36: su desviación al cubo es $19^3 = 6859$, y las otras nueve juntas suman -277. Coincide con lo que ya decían la media y la mediana: $17 > 15$.

Curtosis

$$\text{curtosis} = \frac{m_4}{m_2^2}.$$

Tradicionalmente se describe como qué tan picuda o chata es la distribución. Lo que mide de verdad es el peso de las **colas**: la cuarta potencia hace que los valores lejanos dominen la suma, así que una curtosis alta indica que hay extremos más frecuentes o más lejanos de lo normal. La referencia es la normal, con curtosis 3; por eso se reporta también el **exceso de curtosis**, curtosis menos 3.

- **Leptocúrtica**, curtosis mayor que 3: colas pesadas, extremos frecuentes. La de Laplace tiene 6.
- **Mesocúrtica**, igual a 3: la normal.
- **Platicúrtica**, menor que 3: colas ligeras, sin extremos. La uniforme tiene 1.8.



Las tres tienen media 0 y varianza 1. La de Laplace es más alta en el centro, pero sobre todo baja más despacio en las orillas: un valor a 4 desviaciones es mucho más probable que en la normal. La uniforme no tiene colas: nada pasa de ± 1.73.

Ejemplo 16.12 (La curtosis de los datos)**.**

$$\text{curtosis} = \frac{13\,166.8}{44.8^2} = \frac{13\,166.8}{2007.04} = 6.56,$$

un exceso de 3.56: cola pesada. De la suma de cuartas potencias, 131 668, el 36 solo aporta $19^4 = 130\,321$, el 99 %. Es la muestra más clara de que la curtosis habla de extremos, no de la forma del centro.

Sesgo de un estimador

Definición 16.13 (Sesgo de un estimador)**.** La diferencia entre lo que el estimador da en promedio y el parámetro que quiere estimar:

$$\text{sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta.$$

Si es cero, el estimador es **insesgado**: en promedio, sobre todas las muestras posibles, le atina.

Es qué tan lejos de la realidad queda la *fórmula*, en promedio.

- $\bar{x}$ es insesgado para μ.
- La varianza dividida entre n tiene sesgo $\frac{n-1}{n}\sigma^2 - \sigma^2 = -\frac{\sigma^2}{n}$: siempre se queda corta. Con $n-1$ el sesgo es cero; es lo que mostró la tabla de las nueve muestras.

Ojito...

s^2 es insesgado para σ^2, pero s no lo es para σ: la raíz no es lineal, y la esperanza no pasa por ella, igual que con $E[X^2]$. s subestima un poco a σ. Con muestras grandes el efecto es despreciable.

El sesgo del estimador es una propiedad de la fórmula, no de los datos. No hay que confundirlo con los otros sesgos de las clases anteriores:

Sesgo	Dónde está el problema	Ejemplo
Del estimador	en la fórmula	dividir la varianza entre n
De muestreo	la muestra no representa a la población	la encuesta de *Literary Digest*; medir el servidor solo el lunes en la mañana
De confusión	una tercera variable mueve a las dos que se comparan	helados y ahogamientos, movidos por el calor
De interpretación	en la conclusión, no en los datos	concluir sobre toda la población con una muestra sesgada, o leer causalidad en una asociación

Un estimador insesgado no salva a una muestra sesgada: $\bar{x}$ de los tiempos del lunes en la mañana le atina en promedio a la media de los lunes en la mañana, no a la de todo el día.

Qué resumen usar según el tipo de variable

Variable	Centro	Dispersión
Nominal	moda	frecuencias
Ordinal	mediana, percentiles	rango, IQR
Cuantitativa simétrica	media	desviación estándar
Cuantitativa asimétrica	mediana	IQR

Idea clave

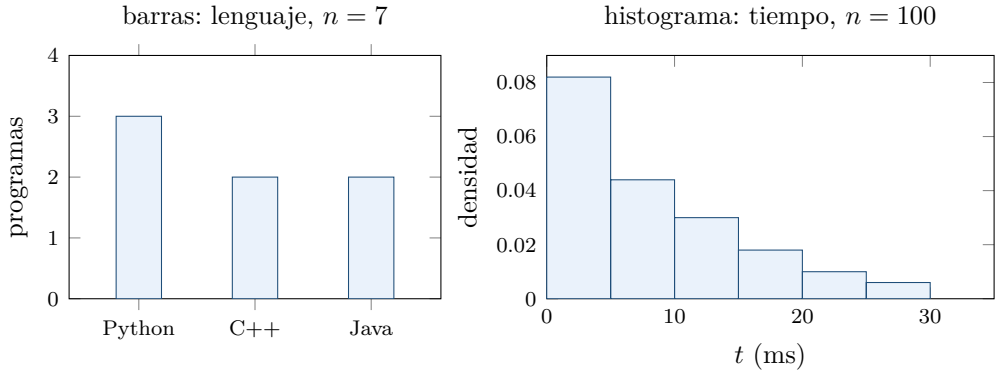
Los datos de la clase son cuantitativos y muy asimétricos, con $g_1 = 2.20$. Reportarlos como 17 ± 7.06 ms da una impresión falsa: la media queda por encima de siete de los diez datos, y el 7.06 lo infla un solo valor; sin el 36, la desviación estándar sería 2.42. Lo honesto es la mediana y el IQR, 15 ms con un IQR de 4, y mencionar aparte el valor atípico de 36.

17. Gráficas de distribuciones y modelos importantes *26 de octubre de 2026*

Resumen rápido. Dos objetivos: escoger la gráfica correcta para una distribución y reconocer las distribuciones que más aparecen. Primero las gráficas: el histograma no es una gráfica de barras; el diagrama de caja compara grupos y marca atípicos, pero esconde la forma; el violín y el frijol la recuperan, y el Q-Q compara los datos contra un modelo. Luego los errores frecuentes al graficar y qué gráfica contesta qué pregunta. Después los modelos, cada uno con su ejemplo: Bernoulli, binomial y Poisson entre las discretas; uniforme y normal entre las continuas; y la ji cuadrada, la t y la F, que dependen de los grados de libertad.

Histograma contra gráfica de barras

Se parecen porque los dos son barras, pero contestan cosas distintas. La **gráfica de barras** cuenta categorías; el **histograma** reparte una variable numérica en intervalos que cubren la recta.



La de la izquierda es la tabla de lenguajes de la clase del 12; la de la derecha, los 100 tiempos de la clase del 14.

	Barras	**Histograma**
Variable	categórica	numérica
Eje horizontal	categorías; si son nominales, el orden da igual	una escala numérica con orden fijo
Las barras	separadas, porque entre Python y C++ no hay nada	pegadas, porque los intervalos cubren la recta
Lo que se lee	la altura	el área, si el eje es densidad
Lo que decide quien grafica	el orden de las categorías	el ancho y el inicio de los intervalos

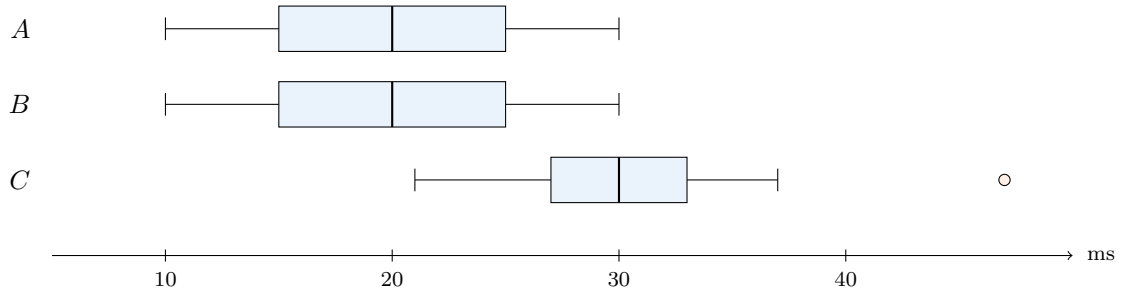
Diagrama de caja para comparar grupos

El diagrama de caja de la clase del 21 resume una variable en cinco números: mínimo, Q_1, mediana, Q_3 y máximo, con los atípicos aparte. Lo que lo hace útil es que ocupa poco, y varios caben uno encima de otro sobre la misma escala.

Ejemplo 17.1 (Tres servidores)**.** Se midieron 40 tiempos de respuesta en cada uno de tres servidores. En el A los tiempos se reparten parejo entre 10 y 30 ms. El B tiene un caché: la mitad de las peticiones lo encuentra y tarda alrededor de 15 ms, y la otra mitad no y tarda alrededor de 25. El C es más lento, y una petición tardó 47.

Servidor	n	mín	Q_1	mediana	Q_3	máx	$\bar{x}$	s
A	40	10	15	20	25	30	20.0	5.86
B	40	10	15	20	25	30	20.0	5.54
C	40	21	27	30	33	47	30.2	4.59

En C el IQR es 6, así que la cerca de arriba queda en $33 + 1.5 \cdot 6 = 42$: el 47 es atípico, y el bigote llega al dato más alto que no la pasa, 37.



De un vistazo: C es unos 10 ms más lento que los otros dos, menos disperso, y tiene un atípico. A y B salen idénticos.

Ojito...

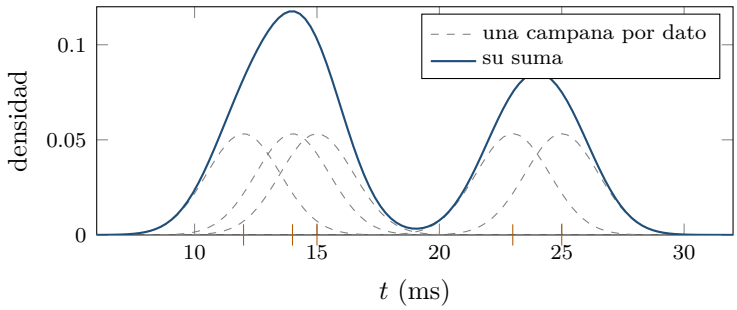
A y B tienen los mismos cinco números, así que su caja es la misma, y no son el mismo servidor: en B casi no hay peticiones de 20 ms, que es justo su mediana. La caja resume la posición y la dispersión, pero no la forma. Una distribución con dos modos no se ve.

Diagrama de violín

El violín dibuja la densidad de los datos a los dos lados de un eje, como un espejo, y suele llevar adentro una caja angosta. Donde el violín es ancho hay muchos datos; donde se adelgaza, pocos.

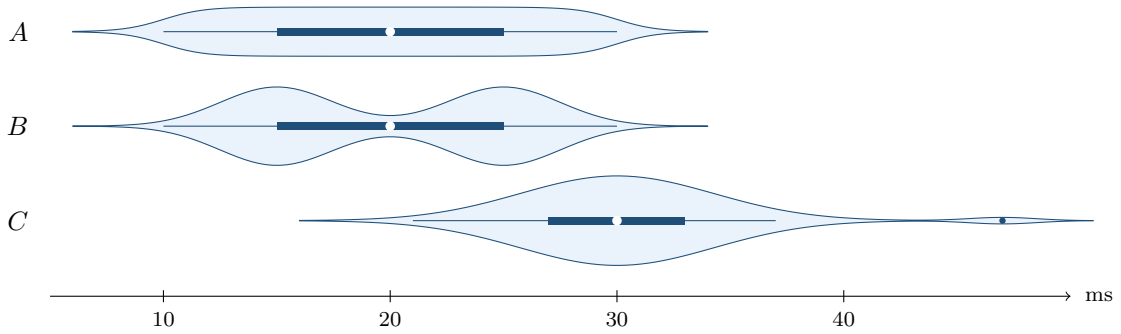
De dónde sale la silueta

La silueta es una **densidad estimada por núcleos** (KDE, por *kernel density estimation*). Sobre cada dato se pone una campana chica de área $1/n$ y se suman todas. El resultado es una curva suave de área 1, como la densidad de la clase del 14, pero sacada de los datos y no de un modelo.



Cinco datos: 12, 14, 15, 23 y 25 ms. Los tres primeros están juntos y sus campanas se apilan en un pico; los otros dos hacen otro. El ancho de cada campana, el **ancho de banda**, hace con la curva lo mismo que el ancho de los intervalos con el histograma: angosto da una curva con un pico por dato, ancho la aplana.

Ejemplo 17.2 (Los tres servidores en violín)**.** Los mismos datos del diagrama de caja, con ancho de banda de 1.5 ms y la caja adentro:

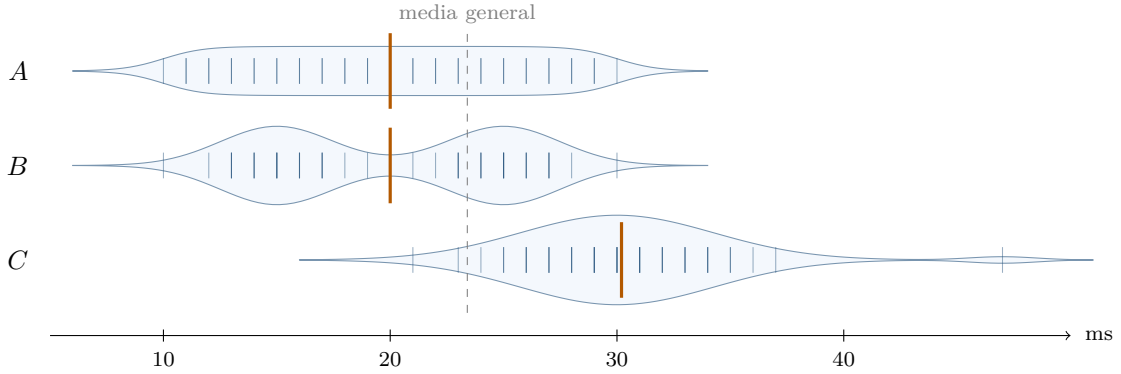


Ahora A y B ya no se confunden. A es una banda pareja: todos los tiempos entre 10 y 30 son igual de comunes. B tiene dos bultos, las peticiones que encontraron el caché y las que no, y una cintura en 20 ms, su mediana, donde casi no hay datos. El atípico de C queda como una pestaña chica en 47.

Diagrama de frijol

El diagrama de frijol (*bean plot*) es un violín que además dibuja **cada observación** como una raya corta. Dos datos repetidos caen en la misma raya, que se ve más oscura. Lleva también una raya larga en la media de cada grupo y una línea punteada en la media de todos los datos juntos.

Ejemplo 17.3 (Los tres servidores en frijol)**.** Los mismos datos. La media de los 120 tiempos juntos es 23.4 ms:



En A las rayas están a intervalos regulares; en B se amontonan en dos grupos y dejan un hueco entre 19 y 21; en C el 47 queda solo. Contando rayas se ve que cada grupo tiene 40 datos, algo que ni la caja ni el violín dicen.

	Caja	**Violín**	**Frijol**
Muestra	cinco números y atípicos	la forma, con la caja adentro	la forma y cada dato
Esconde	la forma y el tamaño n	el tamaño n	nada, pero se satura con miles de datos
Conviene	muchos grupos, o buscar atípicos	comparar formas entre pocos grupos	muestras chicas o medianas

Gráfica Q-Q

Las tres gráficas anteriores describen los datos. La gráfica Q-Q (cuantil contra cuantil) contesta otra pregunta: ¿los datos se parecen a una distribución teórica, casi siempre la normal?

Definición 17.4 (Cuantil)**.** El cuantil p de una distribución es el valor que deja abajo una fracción p de ella. La mediana es el cuantil 0.5; Q_1 y Q_3, los cuantiles 0.25 y 0.75.

Definición 17.5 (Gráfica Q-Q)**.** Grafica los cuantiles de los datos contra los cuantiles de la distribución teórica. Si los datos vienen de esa distribución, salvo por su centro y su escala, los puntos caen sobre una recta.

Para construirla con n datos:

1. Ordenar los datos: $x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)}$. El dato $x_{(i)}$ es el cuantil empírico de $p_i = (i - 0.5)/n$. Se resta 0.5 para no pedir el cuantil 1, que en la normal está en el infinito.

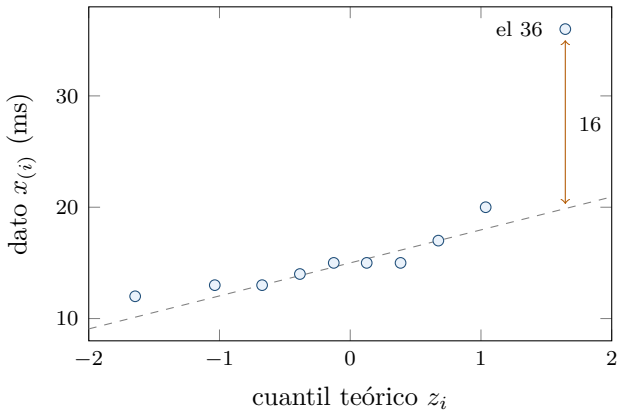
2. Calcular el cuantil teórico z_i de la normal estándar que deja abajo p_i.

3. Graficar los puntos $(z_i,\ x_{(i)})$ y una recta de referencia. La usual pasa por los cuartiles de los dos lados.

Ejemplo 17.6 (Los diez tiempos de la clase del 21)**.** Ordenados, con su p_i y su z_i:

i	1	2	3	4	5	6	7	8	9	10
$x_{(i)}$	12	13	13	14	15	15	15	17	20	36
p_i	0.05	0.15	0.25	0.35	0.45	0.55	0.65	0.75	0.85	0.95
z_i	−1.64	−1.04	−0.67	−0.39	−0.13	0.13	0.39	0.67	1.04	1.64

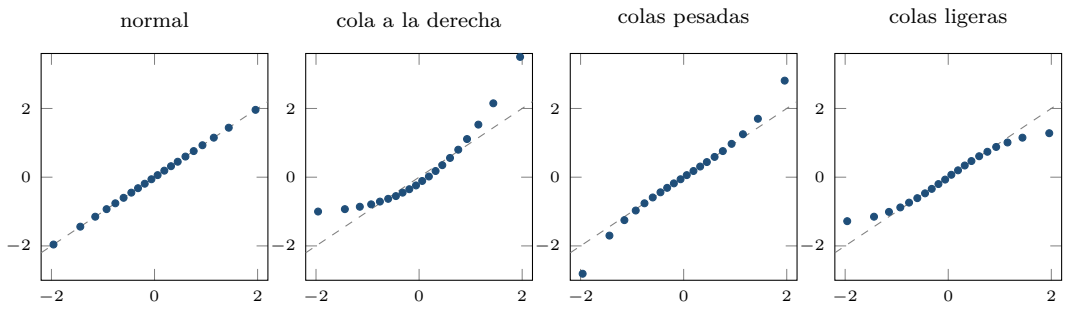
La recta de referencia une $(-0.674,\ 13)$ con $(0.674,\ 17)$, los dos cuartiles: pendiente $4/1.349 = 2.97$ y ordenada 15.



En medio los puntos siguen la recta. Arriba se despegan: la recta dice que en una normal el dato más alto de diez estaría en $15 + 2.97 \cdot 1.645 = 19.9$ ms, y salió 36, unos 16 ms arriba. Abajo pasa lo contrario: el 12 queda por encima de los 10.1 que tocaría. La cola de abajo es más corta que la de una normal y la de arriba mucho más larga. Es la asimetría a la derecha de la clase del 21, $g_1 = 2.20$, vista en una gráfica.

Cómo leer una gráfica Q-Q

Cada forma de despegarse de la recta corresponde a una forma de la distribución. En las cuatro gráficas siguientes, 20 datos de cuatro modelos, escalados para que la recta de referencia sea la diagonal:

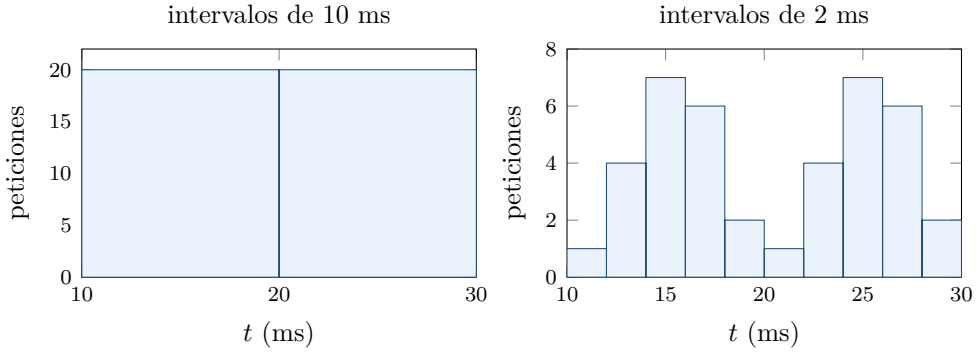


- **Normal**: los puntos siguen la diagonal.
- **Cola a la derecha** (una exponencial): curva hacia arriba. Los datos altos están más lejos de lo que diría la normal y los bajos, más cerca. Es el caso de los tiempos.
- **Colas pesadas** (una t con 3 grados de libertad, más adelante): forma de S. Los extremos de los dos lados se salen, abajo hacia abajo y arriba hacia arriba.
- **Colas ligeras** (una uniforme, como el servidor A): la S al revés. Los extremos se quedan cortos, porque los datos no pasan de un límite.

Errores frecuentes al visualizar distribuciones

- **Usar histograma para una variable nominal.** Con barras pegadas, Python, C++ y Java parecen tramos de una escala continua, con un orden y un ancho que no tienen. Para categorías van barras separadas.
- **Mover los intervalos hasta que aparezca la historia que se quería.** El ancho y el inicio de los intervalos cambian la forma del histograma, y con los mismos datos se pueden contar historias opuestas. Ver el ejemplo de abajo.
- **Tomar la gráfica Q-Q como prueba definitiva de normalidad.** Es un diagnóstico visual, no una prueba. Con 10 datos, una muestra que sí viene de una normal se tuerce por puro azar. Y que los puntos sigan la recta no demuestra que los datos sean normales: solo dice que la gráfica no muestra nada en contra.
- **Ocultar el tamaño de la muestra, las unidades o el criterio de atípicos.** Una caja con $n = 8$ y otra con $n = 8000$ se dibujan igual, y no merecen la misma confianza. Unos bigotes al mínimo y al máximo no son los de 1.5 IQR. Sin unidades, 30 puede ser milisegundos o segundos. Todo eso va en el eje o en el pie de la figura.
- **Comparar grupos con escalas de eje distintas.** Si A se grafica de 0 a 40 ms y C de 20 a 50, las dos cajas quedan en el mismo lugar del papel y parecen iguales, cuando C es 10 ms más lento. Varios grupos van sobre el mismo eje, como en las figuras de esta clase.

Ejemplo 17.7 (Los mismos 40 tiempos del servidor B)**.** Dos histogramas de los mismos datos, con intervalos de 10 y de 2 ms:



Con intervalos de 10 ms salen dos barras de 20, y la historia es "los tiempos se reparten parejo"; el servidor A da casi lo mismo, 19 y 21. Con intervalos de 2 ms aparecen los dos grupos del caché. Ninguno de los dos histogramas miente, pero solo el segundo deja ver lo que pasa. Lo honesto es probar varios anchos y reportar el que muestra la estructura, diciendo cuál fue.

Qué gráfica contesta qué pregunta

Pregunta	**Gráfica**
¿Cuántos hay de cada categoría?	barras
¿Cómo se distribuye una variable numérica?	histograma o densidad
¿Cómo se comparan varios grupos?	cajas sobre el mismo eje
¿Hay valores atípicos?	caja
¿Los grupos tienen la misma forma, o alguno tiene dos modos?	violín
¿Cuántos datos hay y dónde cae cada uno?	frijol, o los puntos sueltos
¿Los datos se parecen a una normal, u otro modelo?	Q-Q

Distribuciones importantes

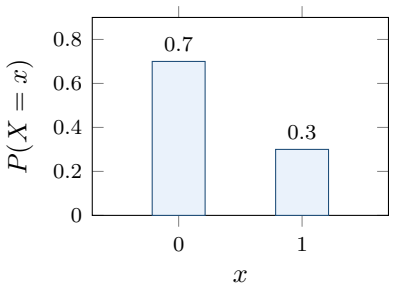
En la clase del 14 quedaron en dos tablas cortas. Aquí va cada una con su fórmula, su media y su varianza, un ejemplo y su gráfica. Las tres primeras son discretas y tienen función de masa; las demás son continuas y tienen densidad.

Bernoulli

Un solo ensayo con dos resultados: éxito (1) con probabilidad p o fracaso (0). Se escribe $X \sim \text{Bernoulli}(p)$:

$$P(X = 1) = p, \qquad P(X = 0) = 1 - p, \qquad E[X] = p, \qquad \text{Var}(X) = p\,(1 - p).$$

Ejemplo 17.8 (¿Es spam?)**.** Un correo es spam con probabilidad $p = 0.3$. Con $X = 1$ si es spam, $E[X] = 0.3$ y $\text{Var}(X) = 0.3 \cdot 0.7 = 0.21$. La media de una Bernoulli es la proporción de éxitos: el promedio de muchos ceros y unos es la fracción de unos.



Binomial

El número de éxitos en n ensayos de Bernoulli independientes, todos con la misma p. Se escribe $X \sim \text{Bin}(n, p)$:

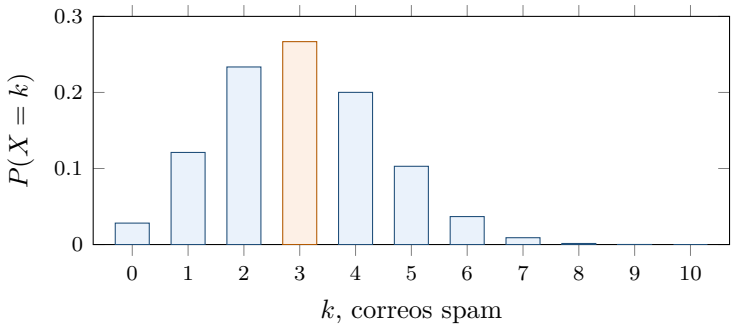
$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \ldots, n; \qquad E[X] = np, \qquad \text{Var}(X) = np\,(1-p).$$

El $\binom{n}{k}$ cuenta de cuántas formas se pueden escoger cuáles k de los n ensayos son los éxitos, y $p^k(1-p)^{n-k}$ es la probabilidad de cada una de esas formas.

Ejemplo 17.9 (Spam en 10 correos)**.** Llegan 10 correos, cada uno spam con $p = 0.3$ y sin depender de los demás. ¿Qué probabilidad hay de que exactamente 3 sean spam?

$$P(X = 3) = \binom{10}{3} 0.3^3\, 0.7^7 = 120 \cdot 0.027 \cdot 0.0824 = 0.2668.$$

Se esperan $E[X] = 10 \cdot 0.3 = 3$, con varianza $10 \cdot 0.3 \cdot 0.7 = 2.1$. Que la mitad o más sean spam, sumando las barras de 5 a 10, tiene probabilidad 0.1503.



La barra naranja es $P(X = 3)$. La forma tiene una joroba alrededor de $np = 3$ y una cola a la derecha, porque $p < 0.5$; con $p = 0.5$ sería simétrica.

Poisson

El número de eventos en un intervalo de tiempo o de espacio, cuando ocurren de forma independiente y a una tasa promedio λ constante. Se escribe $X \sim \text{Poisson}(\lambda)$:

$$P(X = k) = \frac{e^{-\lambda}\,\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots; \qquad E[X] = \lambda, \qquad \text{Var}(X) = \lambda.$$

No tiene tope: en un segundo pueden llegar 0, 10 o 100 peticiones, aunque las muy grandes sean improbables. Que la media y la varianza coincidan es su firma: si en los datos la varianza sale mucho mayor que la media, el modelo de Poisson no sirve.

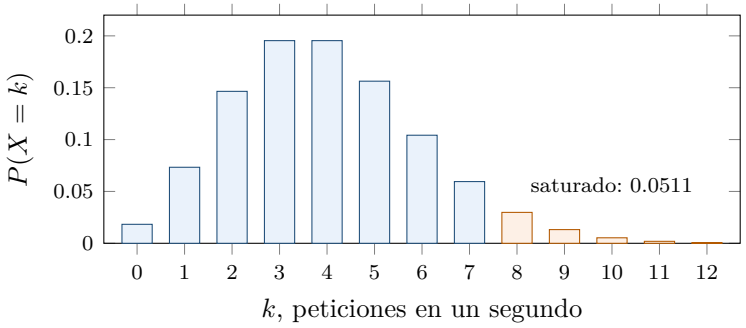
Ejemplo 17.10 (Peticiones por segundo)**.** A un servidor llegan en promedio $\lambda = 4$ peticiones por segundo.

$$P(X = 6) = \frac{e^{-4}\,4^6}{6!} = \frac{0.0183 \cdot 4096}{720} = 0.1042.$$

Si el servidor solo atiende 7 por segundo, se satura cuando llegan 8 o más:

$$P(X \geq 8) = 1 - \sum_{k=0}^{7} P(X = k) = 1 - 0.9489 = 0.0511,$$

uno de cada veinte segundos.



Idea clave

La Poisson es el límite de la binomial cuando hay muchos ensayos y cada uno es raro, con $\lambda = np$. Si en un segundo hay 1000 clientes que podrían mandar una petición, cada uno con probabilidad 0.004, la binomial da $P(X = 6) = 0.1043$ y la Poisson con $\lambda = 4$ da 0.1042. Por eso sirve para contar cosas raras entre muchas oportunidades: peticiones, errores en un log, paquetes perdidos.

Uniforme

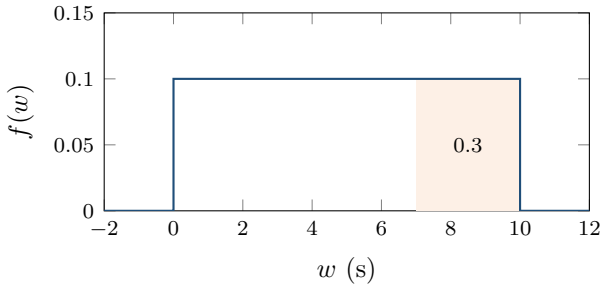
Todos los valores de un intervalo $[a, b]$ son igual de probables. Se escribe $X \sim U(a, b)$:

$$f(x) = \frac{1}{b-a} \quad \text{para } a \leq x \leq b; \qquad E[X] = \frac{a+b}{2}, \qquad \operatorname{Var}(X) = \frac{(b-a)^2}{12}.$$

La densidad es un rectángulo de base $b-a$ y altura $1/(b-a)$, así que la probabilidad de un subintervalo es su largo entre $b-a$.

Ejemplo 17.11 (Esperar a un proceso periódico)**.** Un trabajo corre cada 10 segundos. Una petición llega en un momento cualquiera y espera $W \sim U(0, 10)$ segundos a la siguiente corrida.

$$P(W > 7) = \frac{10-7}{10} = 0.3, \qquad E[W] = 5 \text{ s}, \qquad \sigma = \sqrt{\frac{100}{12}} = 2.89 \text{ s}.$$



Idea clave

`random()` devuelve una $U(0,1)$, y de ella sale cualquier otra distribución. Si $U \sim U(0,1)$, entonces $T = -10\ln(1-U)$ es la exponencial con media 10 ms de la clase del 14: se despeja t de $u = F(t) = 1 - e^{-0.1t}$. Así se simulan tiempos de respuesta con un generador uniforme.

Normal

La campana. Se escribe $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}; \qquad E[X] = \mu, \qquad \mathrm{Var}(X) = \sigma^2.$$

Es simétrica alrededor de μ, y σ dice qué tan ancha es. Todas las normales son la misma curva recorrida y estirada: si $X \sim N(\mu, \sigma^2)$, la variable **estandarizada**

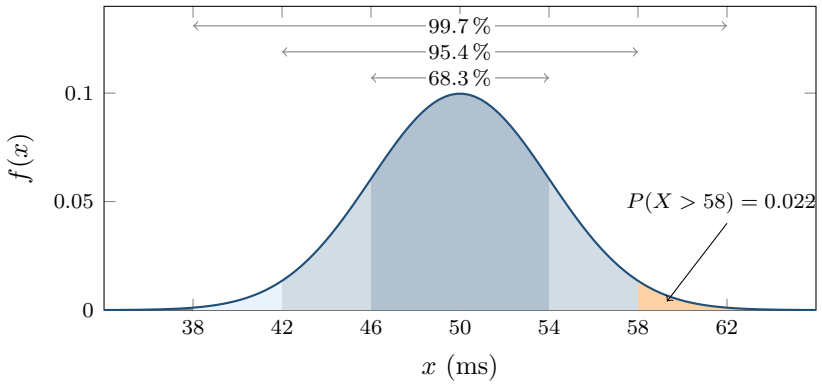
$$Z = \frac{X - \mu}{\sigma}$$

es una $N(0,1)$, la **normal estándar**. Por eso basta una sola tabla, la de Z. Z cuenta a cuántas desviaciones estándar de la media está un valor. Aparece tanto porque la suma de muchos efectos chicos e independientes tiende a ser normal; eso lo dice el teorema central del límite.

Ejemplo 17.12 (Latencia de un enlace)**.** La latencia de un enlace estable es $N(50, 4^2)$, en ms. ¿Qué fracción de los paquetes tarda más de 58 ms?

$$P(X > 58) = P\left(Z > \frac{58-50}{4}\right) = P(Z > 2) = 0.0228.$$

Y menos de 45 ms: $P(X < 45) = P(Z < -1.25) = 0.1056$.



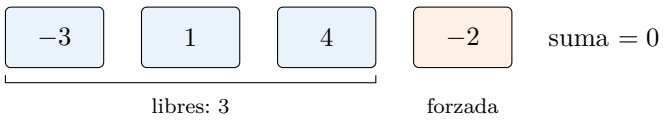
Las bandas son la regla 68-95-99.7: a una, dos y tres desviaciones de la media cae el 68.3 %, el 95.4 % y el 99.7 % de los valores. Es la que se usó en la clase del 21 para leer la desviación estándar.

Grados de libertad

Las tres distribuciones que faltan, la ji cuadrada, la t y la F, no modelan datos sino **estadísticas**: números calculados con una muestra. Su forma depende de cuánta información trae la muestra, y esa información se mide en grados de libertad.

Definición 17.13 (Grados de libertad)**.** El número de valores de un cálculo que pueden variar libremente una vez impuestas las restricciones. Casi siempre es el número de datos menos el número de cantidades que se estimaron con esos mismos datos.

El caso de la clase del 21: las desviaciones respecto a la media muestral suman cero. Con cuatro datos, si se conocen tres desviaciones la cuarta ya está decidida:



Por eso la varianza muestral divide entre $n-1$: de las n desviaciones solo $n-1$ son información nueva. La misma cuenta aparece en otros lados:

- Una tabla de conteos de 6 categorías que suman 60 tiene 5 grados de libertad: el sexto conteo es 60 menos los otros cinco.
- Una recta ajustada a n puntos estima dos números, pendiente y ordenada, y deja $n-2$ grados de libertad para medir qué tan lejos quedan los puntos.

Más grados de libertad quieren decir más información, y una estadística que varía menos. Las tres distribuciones siguientes llevan los grados de libertad como parámetro.

Ji cuadrada

Si $Z_1, \ldots, Z_k$ son normales estándar independientes, la suma de sus cuadrados

$$Q = Z_1^2 + Z_2^2 + \cdots + Z_k^2$$

sigue una **ji cuadrada con k grados de libertad**, $Q \sim \chi^2_k$, con $E[Q] = k$ y $\mathrm{Var}(Q) = 2k$. Como es una suma de cuadrados, nunca es negativa. Con k chica está pegada al cero con cola a la derecha; al crecer k se corre a la derecha y se vuelve más simétrica.

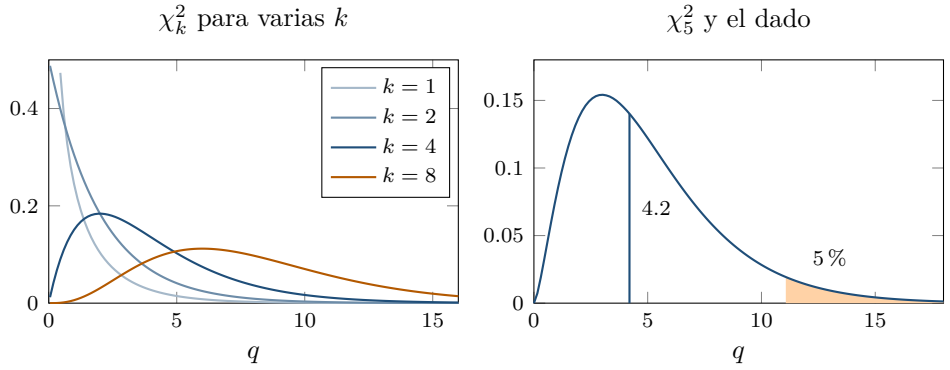
Aparece cada vez que se suman desviaciones al cuadrado. Si los datos son normales, $(n-1)\,s^2/\sigma^2 \sim \chi^2_{n-1}$, con los $n-1$ grados de libertad de la varianza muestral. También aparece en la prueba de bondad de ajuste, que compara conteos observados con los que predice un modelo, y en la de independencia de las tablas conjuntas de la clase del 19.

Ejemplo 17.14 (¿El generador de dados está cargado?)**.** Un programa simula 60 tiradas de un dado. Si es justo, cada cara debería salir $E = 10$ veces. Se mide qué tan lejos quedaron los conteos observados O:

Cara	1	2	3	4	5	6
O	8	9	12	11	6	14
$(O-E)^2/E$	0.4	0.1	0.4	0.1	1.6	1.6

$$\chi^2 = \sum \frac{(O-E)^2}{E} = 4.2.$$

Si el dado es justo, esta estadística sigue una χ^2_5: seis conteos que suman 60 dan 5 grados de libertad. En una χ^2_5, solo el 5 % de los valores pasa de 11.07, y 4.2 queda en la parte más común de la curva. Las diferencias son las que el azar produce solo; no hay evidencia de que esté cargado.



t de Student

Si $Z \sim N(0,1)$ y $V \sim \chi^2_\nu$ son independientes,

$$T = \frac{Z}{\sqrt{V/\nu}}$$

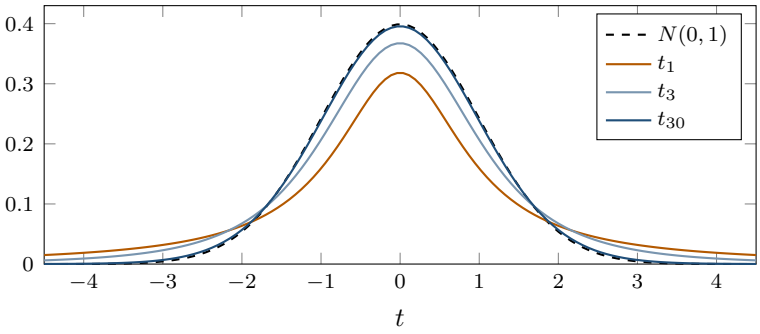
sigue una t **con ν grados de libertad**, $T \sim t_\nu$. Es simétrica alrededor de 0, como la normal estándar, pero con colas más pesadas. $E[T] = 0$ si $\nu > 1$ y $\mathrm{Var}(T) = \nu/(\nu-2)$ si $\nu > 2$, mayor que 1. Al crecer ν se acerca a la $N(0,1)$, y con $\nu = 30$ ya casi no se distinguen.

Sale al estandarizar un promedio cuando σ no se conoce. Con datos normales, $(\bar{x} - \mu)/(\sigma/\sqrt{n})$ es una $N(0,1)$; si σ se cambia por la s de la muestra,

$$\frac{\bar{x} - \mu}{s/\sqrt{n}} \sim t_{n-1}.$$

El denominador es el error estándar de la clase del 7, estimado. s también varía de muestra en muestra, y esa incertidumbre extra es la que engorda las colas. Con pocos datos s es poco confiable y la t es mucho más ancha que la normal; con muchos, $s \approx \sigma$ y la diferencia desaparece.

Ejemplo 17.15 (Diez mediciones)**.** Con $n = 10$ hay 9 grados de libertad. En la normal, el 95 % central va de -1.96 a 1.96; en la t_9, de -2.262 a 2.262. Si se usara la normal con solo 10 datos, un valor más allá de ± 1.96 no saldría el 5 % de las veces sino el 8.2 %. Con 3 grados de libertad la diferencia es enorme: $P(|T| > 3) = 0.0577$, contra 0.0027 en la normal, unas 21 veces más.



La t_1 apenas se levanta en el centro y en ± 4 todavía está muy por encima de la normal. La t_{30} queda casi encima de la curva punteada.

F de Fisher

Si $V_1 \sim \chi^2_{d_1}$ y $V_2 \sim \chi^2_{d_2}$ son independientes,

$$F = \frac{V_1/d_1}{V_2/d_2}$$

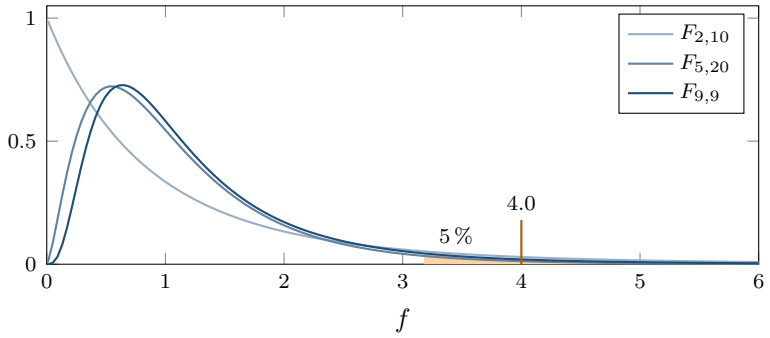
sigue una F **con** d_1 **y** d_2 **grados de libertad**, $F \sim F_{d_1,d_2}$. Lleva dos parámetros, uno por cada ji cuadrada, y el orden importa: d_1 es el del numerador. Es positiva, con cola a la derecha, y está centrada cerca de 1: $E[F] = d_2/(d_2-2)$ si $d_2 > 2$.

Sirve para comparar varianzas. Si dos grupos normales tienen la misma varianza, el cociente de sus varianzas muestrales, s_1^2/s_2^2, sigue una $F_{n_1-1,\,n_2-1}$. Un cociente cerca de 1 es lo esperado; uno muy grande dice que la primera varianza es mayor. Es también la base del análisis de varianza (ANOVA), que compara las medias de varios grupos.

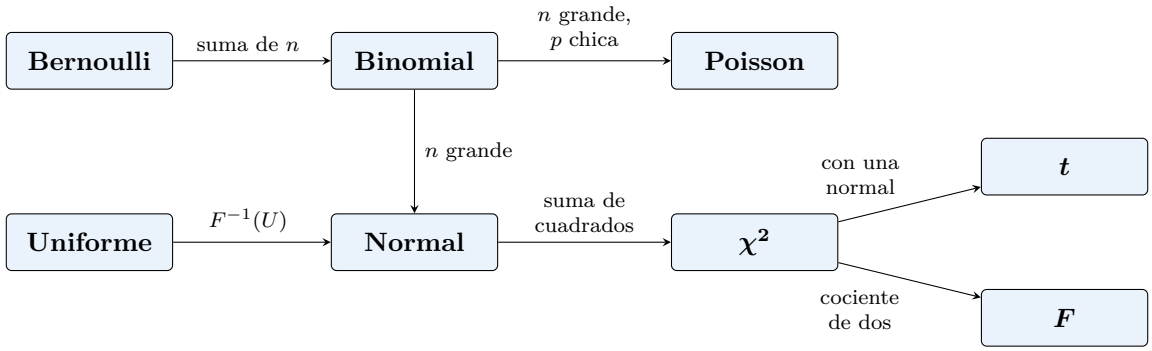
Ejemplo 17.16 (¿Un cambio de configuración redujo la variabilidad?)**.** Antes del cambio, 10 mediciones dieron $s_1^2 = 16$ ms^2; después, otras 10 dieron $s_2^2 = 4$ ms^2.

$$F = \frac{s_1^2}{s_2^2} = \frac{16}{4} = 4.0, \quad \text{con 9 y 9 grados de libertad.}$$

Si el cambio no hubiera hecho nada, el cociente seguiría una $F_{9,9}$, y valores arriba de 3.18 salen solo el 5 % de las veces. 4.0 queda en esa cola: es difícil que fuera azar, y el cambio sí redujo la variabilidad. Supone que los tiempos son normales; con una cola larga como la de los diez tiempos de la clase del 21, la prueba F no es confiable.



Cómo se relacionan



La flecha de la uniforme dice que de ella se genera cualquiera, como la exponencial de la idea de arriba. La de la binomial a la normal es el teorema central del límite: una binomial es una suma de Bernoulli, y una suma de muchas cosas independientes se vuelve normal.

Modelo	Parámetros	Media	Varianza	Para qué
Bernoulli	p	p	$p(1-p)$	¿sí o no?
Binomial	n, p	np	$np(1-p)$	¿cuántos de n?
Poisson	λ	λ	λ	¿cuántos en un intervalo?
Uniforme	a, b	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	todo igual de probable
Normal	μ, σ^2	μ	σ^2	suma de muchos efectos chicos
Ji cuadrada	k	k	$2k$	sumas de cuadrados, conteos
t	ν	0	$\frac{\nu}{\nu-2}$	promedio con σ desconocida
F	d_1, d_2	$\frac{d_2}{d_2-2}$	$\frac{2d_2^2(d_1+d_2-2)}{d_1(d_2-2)^2(d_2-4)}$	comparar varianzas

Ojito...

Ningún dato "es" Poisson o normal. El modelo es una suposición, y las gráficas de la primera mitad de la clase son la forma de revisarla: el histograma y el violín para ver la forma, el Q-Q para compararla con el modelo. Los diez tiempos de la clase del 21 no pasan por normales, y cualquier cuenta que lo suponga, como la t o la F, hereda ese problema.

18. IID, error estándar y teoremas de muestreo

28 de octubre de 2026

Resumen rápido. Qué hace falta para que el promedio de una muestra sirva, y qué tan bien sirve. Primero la suposición que está detrás de casi toda la estadística: observaciones independientes e idénticamente distribuidas (IID), y dónde se rompe en computación: validación cruzada, benchmarks y series de tiempo. Luego el error de muestreo y su tamaño típico, el error estándar $\sigma/\sqrt{n}$, que explica por qué partir el error a la mitad cuesta cuatro veces más datos, y en qué se distingue de la desviación estándar. Se cerró con los tres resultados que justifican usar $\bar{x}$: la ley de los grandes números, el teorema central del límite y la desigualdad de Chebyshev.

Casi toda la clase usa la misma población: tiempos de respuesta que siguen el modelo exponencial de la clase del 14, con media $\mu = 10$ ms. En la exponencial la desviación estándar es igual a la media, así que también $\sigma = 10$ ms. Es muy asimétrica, y por eso sirve para ver qué resultados dependen de la forma de los datos y cuáles no.

Independientes e idénticamente distribuidas

Una muestra es una lista de observaciones $X_1, X_2, \ldots, X_n$. Casi todo lo que sigue supone dos cosas de ellas, y son dos cosas distintas: una se puede cumplir sin la otra.

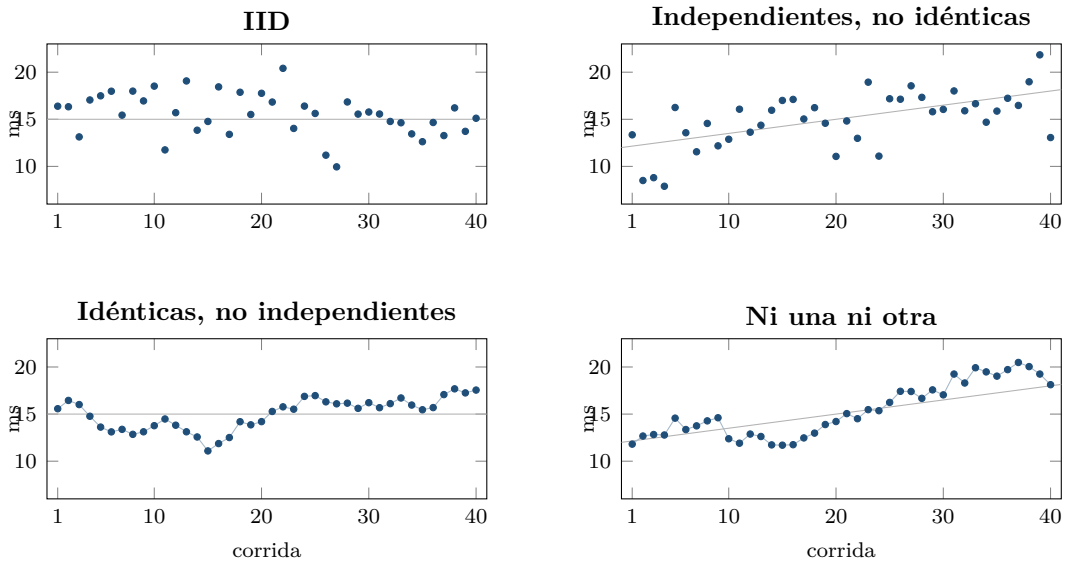
- **Independencia**: el valor de una observación no dice nada de las demás. Es la definición de la clase del 19, extendida a n variables.
- **Idéntica distribución**: todas salen de la misma distribución, con la misma media y la misma varianza.

Definición 18.1 (Variables IID)**.** $X_1, \ldots, X_n$ son **independientes e idénticamente distribuidas** si su distribución conjunta es el producto de las marginales,

$$P(X_1 \le x_1, \ldots, X_n \le x_n) = P(X_1 \le x_1) \cdots P(X_n \le x_n) \quad \text{para todos los } x_1, \ldots, x_n,$$

y todas las marginales son la misma distribución. Sortear con reemplazo de una población da una muestra IID.

En una muestra IID el orden no importa: si se barajan las observaciones, la secuencia se ve igual. Por eso la forma más rápida de sospechar de la suposición es graficar los datos en el orden en que se tomaron. Las cuatro combinaciones, con 40 corridas simuladas de un programa:



- **IID**: corridas con la máquina en reposo. Cada tiempo sale de la misma normal con media 15 ms y no depende de los anteriores; los puntos rebotan sin patrón alrededor de la línea gris.
- **Independientes, no idénticas**: la máquina se calienta y baja su frecuencia, así que cada corrida tarda en promedio un poco más que la anterior. El ruido de cada una es independiente, pero la media cambia: la corrida 40 no sale de la misma distribución que la 1.
- **Idénticas, no independientes**: la carga del servidor cambia despacio, y una corrida lenta suele ir seguida de otra lenta. Cada tiempo, visto solo, sale de la misma normal con media 15; lo que se rompe es que cada uno arrastra al siguiente.
- **Ni una ni otra**: las dos cosas a la vez.

Ojito...

El panel de abajo a la izquierda parece tener una tendencia, y no la tiene: la distribución de cada corrida es la misma de principio a fin. Como cada valor arrastra al siguiente, una racha larga en 40 corridas se ve como una deriva. Con datos dependientes, una muestra chica engaña más.

Por qué importa en computación

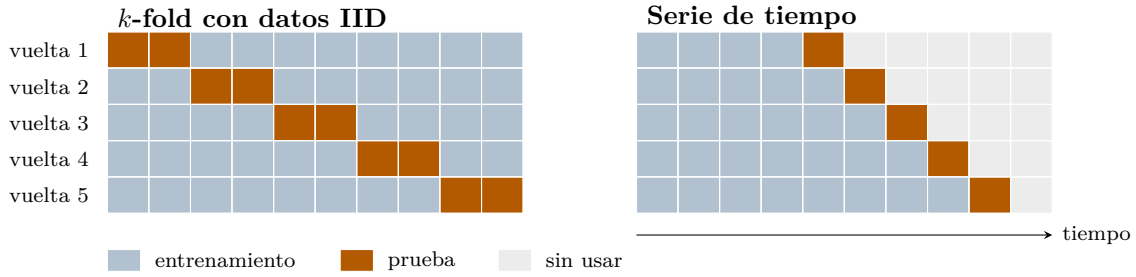
Las fórmulas de esta clase suponen IID. Cuando la suposición falla, las cuentas siguen saliendo, pero dicen algo falso, y casi siempre a favor de quien las hizo: el error parece más chico de lo que es.

Validación cruzada

En la validación cruzada con k bloques (k-fold) los datos se parten en k partes; se entrena con $k-1$, se evalúa con la que sobra, y se repite hasta que cada parte fue la de prueba una vez. El promedio de los k errores estima qué tan bien le irá al modelo con datos nuevos. Eso supone que los datos de prueba son nuevos de verdad, o sea, que son independientes de los de entrenamiento. Se rompe cuando hay **grupos**: varias radiografías del mismo paciente, varios mensajes del mismo usuario, o casi duplicados. Si el mismo paciente queda en entrenamiento y en prueba, el modelo aprende a reconocer al paciente y no la enfermedad, y el error de la validación sale optimista. La salida es partir por grupo: todos los datos de un paciente van al mismo bloque.

Series de tiempo

En una serie de tiempo el valor de hoy depende del de ayer: las observaciones no son independientes, y muchas veces tampoco idénticas, porque hay tendencia o temporada. Barajar y hacer k-fold deja entrenar con el futuro para predecir el pasado. La validación correcta avanza en el tiempo: se entrena con todo lo anterior y se prueba con lo que sigue.



A la izquierda cualquier bloque puede ser el de prueba porque el orden no importa. A la derecha la prueba siempre queda después de todo el entrenamiento, que es la situación en la que el modelo se va a usar.

Benchmarks

Correr un programa 30 veces seguidas no da 30 observaciones IID. La primera corrida paga el calentamiento: caché fría, compilación *just in time*, archivos que todavía no están en memoria. Si la máquina se calienta, las últimas son más lentas, como en el segundo panel. Y un proceso que despierta a media medición afecta a varias corridas seguidas, como en el tercero. Antes de promediar:

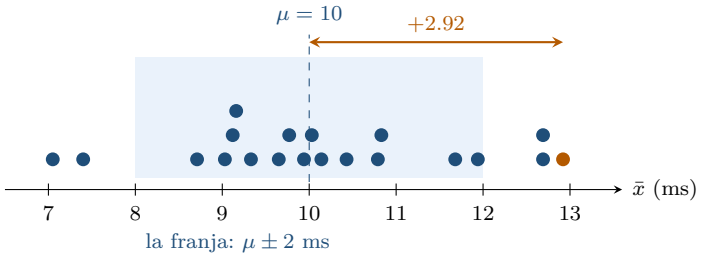
- descartar las corridas de calentamiento;
- intercalar las versiones que se comparan, $A, B, A, B, \ldots$, en lugar de todas las A y luego todas las B, para que una deriva de la máquina no se confunda con una diferencia entre programas;
- graficar los tiempos en el orden en que se midieron, como arriba, y buscar patrones.

Error de muestreo

Definición 18.2 (Error de muestreo)**.** La diferencia entre una estadística y el parámetro que estima, como $\bar{x} - \mu$, que aparece solo por haber observado una muestra y no a toda la población.

No es una equivocación: nadie hizo nada mal. Otra muestra da otro $\bar{x}$ y otro error, unas veces positivo y otras negativo. Con un estimador insesgado, como $\bar{x}$, en promedio se cancela. Es lo contrario del sesgo de la clase del 12: el sesgo empuja siempre hacia el mismo lado y no se va con más datos; el error de muestreo es aleatorio y se encoge conforme crece n.

Ejemplo 18.3 (Veinte muestras de la misma población)**.** Se toman 20 muestras de $n = 25$ tiempos de la exponencial con $\mu = 10$ ms, y se calcula $\bar{x}$ en cada una:



La muestra que dio $\bar{x} = 12.92$ tiene un error de muestreo de $+2.92$ ms; la que dio 7.05, de -2.95. Ninguna está mal hecha. Las 20 medias promedian 10.17, cerca de μ, y 15 de ellas caen en la franja de ± 2 ms. Ese 2 no es casualidad: es el error estándar, el tema de la sección que sigue.

Error estándar

Definición 18.4 (Error estándar)**.** La desviación estándar de un estimador sobre todas las muestras posibles: el tamaño típico de su error de muestreo. Para la media de n observaciones IID con desviación estándar σ,

$$EE(\bar{x}) = \frac{\sigma}{\sqrt{n}}.$$

Como σ casi nunca se conoce, se estima con la de la muestra: $\widehat{EE} = s/\sqrt{n}$. En inglés es el *standard error*, SE.

La fórmula sale de las propiedades de la varianza de la clase del 21:

$$\begin{aligned}
\operatorname{Var}(\bar{x}) &= \operatorname{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) && \textit{(definición de } \bar{x}\textit{)} \\
&= \frac{1}{n^2}\operatorname{Var}\left(\sum_{i=1}^{n} X_i\right) && \textit{(propiedad 3, con } a = 1/n\textit{)} \\
&= \frac{1}{n^2}\sum_{i=1}^{n}\operatorname{Var}(X_i) && \textit{(propiedad 5: son independientes)} \\
&= \frac{1}{n^2}\, n\,\sigma^2 && \textit{(idénticas: todas tienen varianza } \sigma^2\textit{)} \\
&= \frac{\sigma^2}{n},
\end{aligned}$$

y la raíz da $EE = \sigma/\sqrt{n}$.

Idea clave

Las dos letras de IID entran en renglones distintos. La independencia deja partir la varianza de la suma en una suma de varianzas; sin ella aparecen covarianzas. La idéntica distribución hace que todas valgan σ^2; sin ella no hay un solo σ que poner en la fórmula.

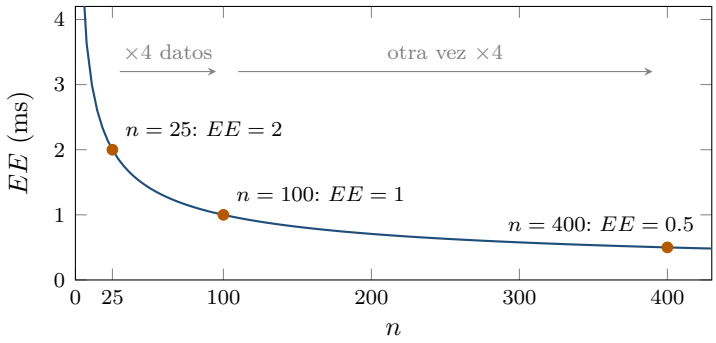
En el ejemplo de las veinte muestras, $EE = 10/\sqrt{25} = 2$ ms: la franja del dibujo era $\mu \pm EE$. Con una normal se esperaría cerca del 68 % adentro, unas 14 de 20; cayeron 15.

¿Cuántas observaciones necesito?

El error estándar baja con $\sqrt{n}$, no con n. Despejando,

$$n = \left(\frac{\sigma}{EE}\right)^2,$$

así que pedir la mitad de error cuesta cuatro veces más datos, y pedir la décima parte cuesta cien veces más.



Ejemplo 18.5 (Los tiempos de la clase del 21)**.** Diez tiempos con $s = 7.06$ ms:

$$\widehat{EE} = \frac{7.06}{\sqrt{10}} = 2.23 \text{ ms}.$$

Para bajarlo a la mitad, 1.12 ms, hacen falta $4 \cdot 10 = 40$ corridas. Para llegar a 0.5 ms,

$$n = \left(\frac{7.06}{0.5}\right)^2 = 199.4,$$

o sea 200 corridas. Se redondea hacia arriba: con 199 el error estándar todavía queda un poco arriba de 0.5.

Ojito...

La fórmula supone IID. Si las mediciones están correlacionadas positivamente, como en el panel de la carga del servidor, $s/\sqrt{n}$ subestima el error. Cuando cada corrida tiene correlación ρ con la anterior, el error estándar real es, para n grande,

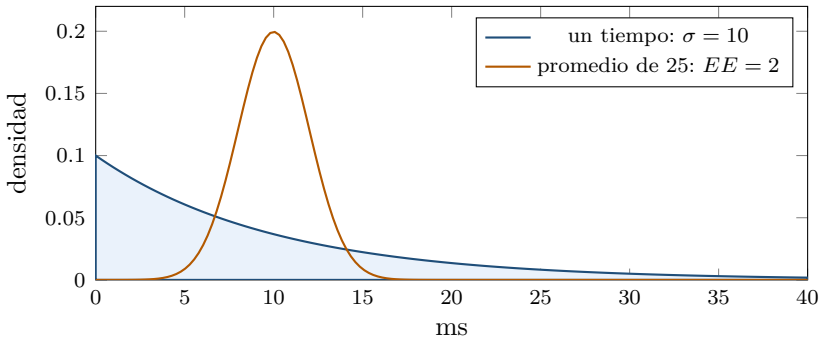
$$EE \approx \frac{\sigma}{\sqrt{n}}\sqrt{\frac{1+\rho}{1-\rho}}.$$

Con $\rho = 0.9$ el factor es $\sqrt{19} = 4.36$: 1000 mediciones seguidas valen como unas $1000 \cdot 0.1/1.9 = 53$ independientes. Más datos del mismo tipo compran mucha menos precisión de la que parece.

Desviación estándar contra error estándar

Se escriben parecido y se confunden mucho, pero contestan preguntas distintas.

	Desviación estándar	**Error estándar**
Mide	qué tan regados están los datos	qué tan regado está $\bar{x}$ de una muestra a otra
Se calcula	s	$s/\sqrt{n}$
Al crecer n	se estabiliza cerca de σ	baja hacia 0, como $1/\sqrt{n}$
Contesta	¿cómo es una observación típica?	¿qué tan bien conozco la media?



La curva azul es la de los tiempos individuales: muy ancha, con cola larga. La naranja es la de $\bar{x}$ con $n = 25$: centrada en el mismo μ, cinco veces más angosta. Más datos no cambian la azul; angostan la naranja.

Ejemplo 18.6 (Dos formas de reportar los mismos datos)**.** Con los tiempos de la clase del 21:

- 17 ± 7.06 ms, con la desviación estándar, dice que una petición típica queda a unos 7 ms de la media.
- 17 ± 2.23 ms, con el error estándar, dice que la media de la población se conoce con una incertidumbre de unos 2 ms.

Las dos son ciertas y responden cosas distintas. Lo que no se vale es escribir 17 ± 2.23 sin decir cuál es.

Ojito...

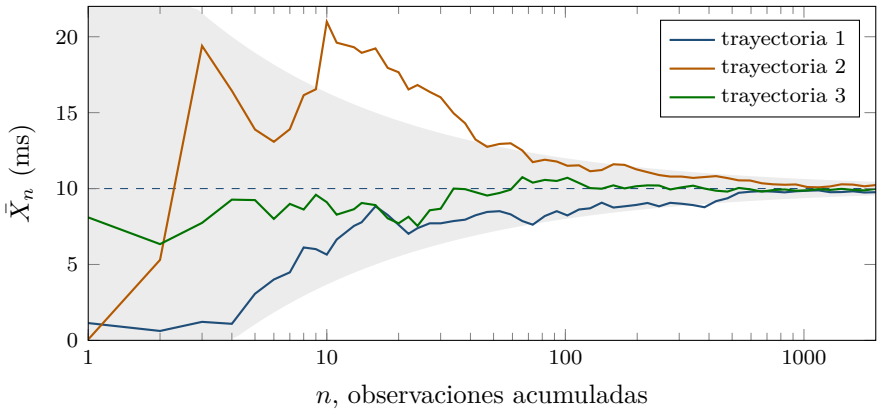
Graficar barras de error estándar cuando se quiere mostrar la variabilidad de los datos los hace ver mucho más estables de lo que son. Con un millón de peticiones el error estándar sería $7.06/1000 = 0.007$ ms, y aun así una petición sola puede tardar 36. Es pariente del error de la clase del 26 de ocultar n: sin n, no se puede pasar de una a la otra.

Ley de los grandes números

Teorema 18.7 (Ley de los grandes números)**.** *Si $X_1, X_2, \ldots$ son IID con media μ, el promedio de las primeras n, $\bar{X}_n$, se acerca a μ conforme n crece: para cualquier margen $\varepsilon > 0$,*

$$P\left(\left|\bar{X}_n - \mu\right| \geq \varepsilon\right) \longrightarrow 0 \quad \textit{cuando } n \to \infty.$$

Es lo que hace que $\bar{x}$ sirva para estimar μ, y lo que la definición de esperanza de la clase del 21 daba por hecho: que el promedio de muchas repeticiones tiende a $E[X]$. La ley lo vuelve teorema. La versión de arriba es la ley *débil*; la fuerte dice algo más: con probabilidad 1, la sucesión de promedios converge.



Tres veces se van sacando tiempos uno por uno y se grafica el promedio acumulado; el eje horizontal es logarítmico. Al principio cada trayectoria va por su lado: con 10 datos, una va en 5.65 y otra en 20.99. Con 2000 las tres están entre 9.76 y 10.23. La franja gris es $\mu \pm 2\,EE = 10 \pm 20/\sqrt{n}$: la ley dice que las trayectorias se meten al embudo, y el error estándar dice qué tan rápido se cierra.

Ojito...

La ley no dice que la suerte se compense. Si una moneda justa da 10 águilas seguidas, el siguiente lanzamiento sigue siendo 50/50. En los 990 siguientes se esperan 495 águilas: en total 505 de 1000, una proporción de 0.505. El exceso de 5 águilas sobre las 500 esperadas no se corrige nunca; se diluye entre cada vez más lanzamientos. Creer que "ya toca sol" es la falacia del jugador.

Teorema central del límite

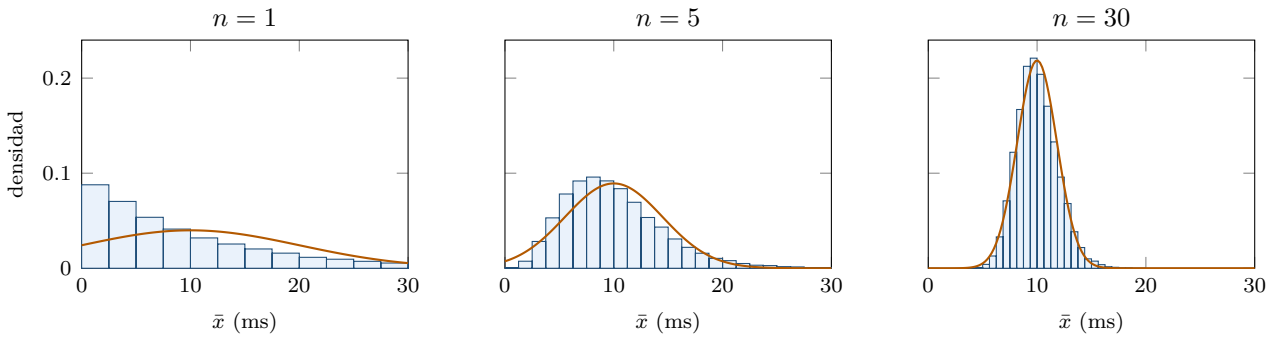
La ley de los grandes números dice a dónde va $\bar{x}$. El teorema central del límite dice cómo se reparte alrededor de μ mientras llega.

Teorema 18.8 (Teorema central del límite)**.** *Si $X_1, \ldots, X_n$ son IID con media μ y varianza σ^2 finita, para n grande*

$$\bar{X}_n \approx N\left(\mu,\ \frac{\sigma^2}{n}\right), \qquad \text{o sea} \qquad Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \approx N(0,1),$$

sin importar la distribución de las X_i.

Lo sorprendente es la última frase. Los datos pueden ser asimétricos, discretos o de cualquier forma; mientras tengan varianza finita, su promedio termina pareciendo normal. Es la razón por la que la normal aparece en todas partes, la "suma de muchos efectos chicos" de la tabla de la clase del 14. Con 20 000 muestras de cada tamaño:



Las barras son los promedios simulados y la curva naranja es la normal que promete el teorema, $N(10, 100/n)$. Los tres paneles tienen los mismos ejes, para que se compare el ancho sin trampa.

- Con $n = 1$ el "promedio" es un solo dato, y se ve la exponencial tal cual. La normal le queda muy mal: hasta le da probabilidad a tiempos negativos.
- Con $n = 5$ ya tiene joroba, pero sigue cargado a la izquierda con cola a la derecha.
- Con $n = 30$ casi no se distingue de la normal, centrada en 10 con desviación $10/\sqrt{30} = 1.83$; la simulación dio 1.84.

Ejemplo 18.9 (¿Qué tan seguido el promedio pasa de 12 ms?)**.** Con $n = 25$, el error estándar es 2, y por el teorema

$$P(\bar{x} > 12) \approx P\left(Z > \frac{12 - 10}{2}\right) = P(Z > 1) = 0.159.$$

La probabilidad exacta, que se puede calcular porque la suma de exponenciales tiene distribución conocida, es 0.157: la aproximación es muy buena. Con $n = 5$, en cambio, $Z = 2/(10/\sqrt{5}) = 0.45$ y el teorema da 0.327 contra una exacta de 0.285. Con pocos datos y una distribución tan asimétrica, la aproximación todavía falla por cuatro puntos.

Idea clave

El 1.96 del intervalo de confianza de la clase del 7 sale de aquí. Por el teorema, $\bar{x}$ cae a menos de $1.96\,EE$ de μ el 95 % de las veces, sin importar cómo se distribuyan los datos. La regla de "$n \geq 30$" es una convención: con datos muy asimétricos o con colas pesadas hacen falta más.

Ojito...

El teorema habla de la distribución del promedio, no de los datos. Con un millón de tiempos, los tiempos siguen siendo exponenciales; lo que se vuelve normal es $\bar{x}$. Para revisar si los datos mismos son normales está la gráfica Q-Q de la clase del 26, no este teorema.

Desigualdad de Chebyshev

Teorema 18.10 (Desigualdad de Chebyshev)**.** *Para cualquier variable con media μ y desviación estándar σ finitas, y cualquier $k > 0$,*

$$P(\,|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

No supone nada sobre la forma de la distribución. A más de 2 desviaciones de la media puede quedar a lo más una cuarta parte de la probabilidad; a más de 3, a lo más una novena parte. Dicho al revés, al menos el 75 % queda a menos de 2σ y al menos el 88.9 % a menos de 3σ, para cualquier distribución.

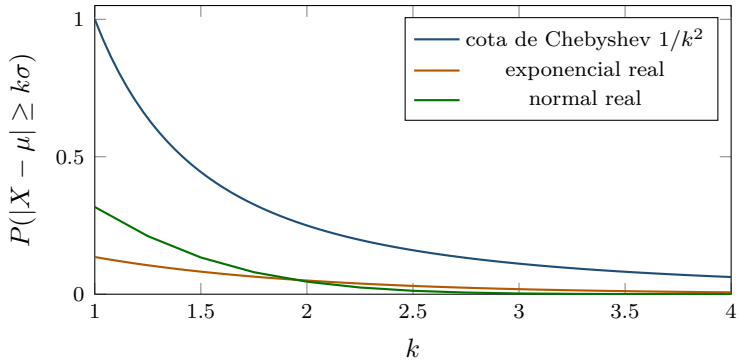
Por qué es cierta

Para una variable discreta, partiendo de la varianza:

$$\begin{aligned}\sigma^2 &= \sum_x (x-\mu)^2\, p(x) \quad \textit{(definición de varianza)}\\ &\geq \sum_{|x-\mu|\geq k\sigma} (x-\mu)^2\, p(x) \quad \textit{(se quitan términos, todos} \geq 0\textit{)}\\ &\geq \sum_{|x-\mu|\geq k\sigma} k^2\sigma^2\, p(x) \quad \textit{(en esos términos, } (x-\mu)^2 \geq k^2\sigma^2\textit{)}\\ &= k^2\sigma^2\, P(\,|X-\mu|\geq k\sigma) \quad \textit{(la suma de } p(x) \textit{ es esa probabilidad).}\end{aligned}$$

Al dividir entre $k^2\sigma^2$ queda la desigualdad. La idea: cada pedazo de probabilidad que queda lejos le aporta a la varianza al menos $k^2\sigma^2$. Si hubiera más de $1/k^2$ lejos, la varianza pasaría de σ^2. Para continuas es la misma cuenta con integrales.

Qué tan holgada es



k	Cota de Chebyshev	Normal	Exponencial
1	1 (no dice nada)	0.317	0.135
2	0.250	0.046	0.050
3	0.111	0.003	0.018
4	0.063	0.0001	0.007

La cota siempre se cumple y casi siempre sobra. Es el precio de no suponer nada: tiene que valer también para la peor distribución posible.

Ejemplo 18.11 (Peticiones lentas)**.** ¿Qué fracción de las peticiones tarda 30 ms o más? Con $\mu = \sigma = 10$, 30 está a 2σ de la media, así que Chebyshev garantiza que es a lo más $1/4$, sin saber nada de la forma. Sabiendo que es exponencial, la fracción real es $e^{-30/10} = e^{-3} = 0.050$: cinco veces menos que la cota.

Aplicada al promedio

$\bar{x}$ tiene media μ y desviación $\sigma/\sqrt{n}$. Con Chebyshev y $\varepsilon = k\,\sigma/\sqrt{n}$:

$$P(\,|\bar{x}-\mu|\geq \varepsilon) \leq \frac{\sigma^2}{n\,\varepsilon^2}.$$

El lado derecho se va a cero cuando n crece, y eso es exactamente la ley de los grandes números: Chebyshev la demuestra en un renglón. También da un tamaño de muestra que no depende de la forma de los datos.

Ejemplo 18.12 (Tamaño de muestra por las dos vías)**.** Se quiere que $\bar{x}$ quede a menos de $\varepsilon = 1$ ms de μ con probabilidad de al menos 0.95, y $\sigma = 10$.

- **Chebyshev**: basta $\sigma^2/(n\varepsilon^2) \leq 0.05$, o sea $n \geq 100/0.05 = 2000$.
- **Teorema central del límite**: basta $1.96\,\sigma/\sqrt{n} \leq 1$, o sea $n \geq (1.96 \cdot 10)^2 = 384.2$, 385 datos.

Chebyshev pide cinco veces más, pero su respuesta está garantizada con cualquier distribución. La del teorema es una aproximación que vale cuando n ya es grande, y aquí lo es.

Ojito...

En las notas quedó "distancia de Chebyshev", pero el tema de la clase es la *desigualdad*. La distancia de Chebyshev es otra cosa: la distancia entre dos vectores medida con la coordenada que más difiere, $\max_i |x_i - y_i|$, la del rey en el ajedrez.

Qué garantiza cada resultado

Resultado	Qué dice	Qué supone
Error estándar	el error típico de $\bar{x}$ es $\sigma/\sqrt{n}$	IID, σ finita
Grandes números	$\bar{x}$ se acerca a μ	IID, media finita
Central del límite	alrededor de μ, $\bar{x}$ se reparte como $N(\mu, \sigma^2/n)$	IID, σ finita, n grande
Chebyshev	a $k\sigma$ o más queda a lo más $1/k^2$	solo σ finita

Idea clave

Los cuatro suponen IID o algo parecido, salvo Chebyshev aplicada a una sola variable. Por eso la primera pregunta ante cualquier promedio no es cuántos datos tiene, sino si sus datos son IID: graficarlos en orden, buscar grupos y revisar si el tiempo importa.