

K-SVD desde cero

Proyecto 1, Matemáticas para la Computación

Dra. Hayde Peregrina Barreto

Dr. Luis Villaseñor Pineda

Otoño 2026 - Bryan Ezequiel Violante Arriaga

Índice

1. Introducción: qué es K-SVD y para qué sirve	2
2. Las herramientas de álgebra lineal	4
3. Los datos: del ECG a la matriz X	9
4. El diccionario: átomos, D y α	14
5. La SVD: descomposición en valores singulares	18
6. OMP: cómo cada ventana escoge sus átomos	22
7. Actualización de átomos: el paso de la SVD	28
8. K-SVD completo: el ciclo, el código y cómo correrlo	34
A. Glosario	37

1. Introducción: qué es K-SVD y para qué sirve

Resumen rápido. Este documento explica el proyecto completo sin suponer que se sabe nada de antemano. Primero repasa las herramientas de álgebra lineal que se usan; después sigue los datos desde el ECG hasta la matriz X , explica qué es un diccionario, qué es la SVD, cómo funciona OMP y cómo K-SVD junta todo. Cada concepto trae un ejemplo chico resuelto a mano con todas las cuentas.

El objetivo del proyecto

El enunciado pide implementar K-SVD y obtener una **base entrenada** para algún tipo de señal, de manera que se pueda comparar la señal original con su reconstrucción hecha a partir de una representación dispersa.

Dicho más simple: se quiere aprender, a partir de un electrocardiograma (ECG), un conjunto de **formas básicas**, y después demostrar que cualquier pedazo de ese ECG se puede volver a armar sumando **muy pocas** de esas formas.

La idea central: armar cosas con pocas piezas

Piensa en un juego de piezas de construcción. Con un juego de 256 piezas distintas se arman muchísimas figuras, y cada figura usa solo unas cuantas piezas, no las 256. Si las piezas son buenas, cualquier figura sale con pocas; si son malas, cada figura necesita muchas o no sale bien.

En el proyecto la correspondencia es esta:

Juego de piezas	Proyecto	Tamaño
una pieza	un átomo : una forma de onda	128 números
el juego completo	el diccionario D	256 átomos
una figura	una ventana : un pedazo del ECG	128 números
las instrucciones	los pesos α	casi todos en cero

K-SVD es el algoritmo que **aprende buenas piezas**: empieza con piezas más o menos al azar y las va mejorando hasta que con pocas se arma cualquier pedazo del ECG.

Por qué importa que sean pocas

A esto se le llama **representación dispersa**: dispersa porque casi todos los pesos valen cero. Sirve para tres cosas.

- **Comprimir.** Una ventana son 128 números. Si se arma con 8 átomos, basta guardar 8 índices y 8 pesos.
- **Quitar ruido.** El ruido no se parece a ningún átomo, así que al reconstruir con pocos átomos se queda fuera.
- **Entender la señal.** Los átomos aprendidos son las formas que más se repiten. En el ECG resultan ser los picos del latido y sus ondas.

El algoritmo en una mirada

K-SVD repite dos pasos. En cada uno se deja algo fijo y se mejora lo otro. La figura 1 lo resume; cada caja tiene su sección más adelante.




Figura 1: El ciclo de K-SVD.

Se parece a **k-means**, el algoritmo de agrupamiento. En k-means cada punto usa exactamente un centroide, y actualizar un centroide es sacar un promedio. En K-SVD cada ventana usa varios átomos, y actualizar un átomo es sacar una SVD. El nombre sale de ahí: K átomos, cada uno actualizado con una **SVD**.

El ejemplo de juguete

Casi todo se explica con un ejemplo que cabe en una hoja: átomos de 3 números en lugar de 128, y 4 átomos en lugar de 256. Los números se escogieron a mano para que las cuentas salgan limpias.

$$D = \begin{pmatrix} 1 & 0.6 & 0 & 0 \\ 0 & 0.8 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad X = \begin{pmatrix} 1 & 0.9 \\ 1 & 1 \\ 0.5 & 0 \end{pmatrix}$$

Las columnas de D son los átomos A , B , C y E ; las de X son dos ventanas, v_1 y v_2 . El proyecto real funciona exactamente igual, solo que más grande:

	Juguete	Proyecto
largo de una ventana	3	128 muestras
número de átomos	4	256
número de ventanas	2	2539 de entrenamiento
tamaño de D	3×4	128×256
tamaño de X	3×2	128×2539

2. Las herramientas de álgebra lineal

Resumen rápido. Todo K-SVD se escribe con unas pocas operaciones: vectores, producto punto, norma, matrices, matriz por vector, la matriz de rango 1 y los eigenvalores. Aquí se repasan una por una, cada una con un ejemplo, y diciendo para qué se va a usar.

Vectores

Definición 2.1 (Vector). Un **vector** es una lista ordenada de números. Cada número es una **componente**. En este documento los vectores se escriben de pie, como columna:

$$v = \begin{pmatrix} 1 \\ 1 \\ 0.5 \end{pmatrix} \quad \text{o, para ahorrar espacio,} \quad v = (1, 1, 0.5).$$

Una ventana del ECG es un vector de 128 componentes; un átomo, también.

Dos operaciones básicas se hacen componente por componente:

Ejemplo 2.2 (Suma y multiplicación por un número).

$$\begin{aligned} 0.25 \cdot (1, 0, 0) &= (0.25, 0, 0) \\ 1.25 \cdot (0.6, 0.8, 0) &= (1.25 \cdot 0.6, 1.25 \cdot 0.8, 1.25 \cdot 0) = (0.75, 1, 0) \\ (0.25, 0, 0) + (0.75, 1, 0) &= (0.25 + 0.75, 0 + 1, 0 + 0) = (1, 1, 0) \end{aligned}$$

Sumar vectores multiplicados por números se llama hacer una **combinación lineal**. Es exactamente lo que se hace al armar una ventana con átomos: cada átomo por su peso, y todo sumado.

Producto punto

Definición 2.3 (Producto punto). El **producto punto** de dos vectores del mismo tamaño multiplica componente por componente y suma todo:

$$u \cdot v = u_1v_1 + u_2v_2 + \cdots + u_nv_n.$$

El resultado es un solo número.

Ejemplo 2.4. Con $B = (0.6, 0.8, 0)$ y $x = (1, 1, 0.5)$:

$$B \cdot x = (0.6)(1) + (0.8)(1) + (0)(0.5) = 0.6 + 0.8 + 0 = 1.4.$$

Idea clave

El producto punto mide **qué tanto se parecen** dos vectores. Si los dos miden 1, el producto punto es el coseno del ángulo entre ellos:

- vale 1 si apuntan exactamente igual;
- vale 0 si son perpendiculares, es decir, si no tienen nada en común;
- vale -1 si apuntan exactamente al revés.

OMP usa esto para decidir qué átomo se parece más a lo que falta por explicar de una ventana.

Norma: el largo de un vector

Definición 2.5 (Norma). La **norma** de un vector es su largo: la raíz de la suma de los cuadrados de sus componentes,

$$\|v\| = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2} = \sqrt{v \cdot v}.$$

Ejemplo 2.6.

$$\|(1, 1, 0.5)\| = \sqrt{1^2 + 1^2 + 0.5^2} = \sqrt{1 + 1 + 0.25} = \sqrt{2.25} = 1.5.$$

Un vector de norma 1 se llama **unitario**. Cualquier vector distinto de cero se vuelve unitario dividiéndolo entre su norma; a eso se le llama **normalizar**:

$$\frac{(1, 1, 0.5)}{1.5} = (0.667, 0.667, 0.333), \quad \|(0.667, 0.667, 0.333)\| = 1.$$

Normalizar conserva la dirección y solo cambia el largo. Todos los átomos del diccionario son unitarios.

Vectores perpendiculares

Dos vectores son **perpendiculares** (u **ortogonales**) si su producto punto es cero. Con los átomos del ejemplo:

$$\begin{aligned} A \cdot E &= (1)(0) + (0)(1) + (0)(0) = 0 && \text{perpendiculares} \\ A \cdot B &= (1)(0.6) + (0)(0.8) + (0)(0) = 0.6 && \text{no perpendiculares} \end{aligned}$$

Ojito...

En un espacio de n dimensiones caben como máximo n vectores perpendiculares entre sí: en 3 dimensiones, 3 (los tres ejes). El ejemplo tiene 4 átomos en 3 dimensiones, así que forzosamente algunos no son perpendiculares. En el proyecto pasa lo mismo: 256 átomos en 128 dimensiones.

Matrices

Una **matriz** es una tabla de números. Una matriz de $m \times n$ tiene m filas y n columnas. Se puede leer como n vectores columna puestos uno al lado del otro: así se leen D (una columna por átomo) y X (una columna por ventana).

La **transpuesta** M^T convierte filas en columnas:

$$M = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} \implies M^T = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}.$$

Una matriz es **simétrica** si es igual a su transpuesta.

Matriz por vector: dos maneras de leerlo

Multiplicar una matriz por un vector tiene dos lecturas, y las dos se usan en el proyecto.

Ejemplo 2.7 (Fila por fila). Cada componente del resultado es el producto punto de una fila de la matriz con el vector:

$$\begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 3 & 0 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \cdot 2 + 2 \cdot 1 \\ 0 \cdot 2 + 1 \cdot 1 \\ 3 \cdot 2 + 0 \cdot 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 1 \\ 6 \end{pmatrix}.$$

Ejemplo 2.8 (Como combinación de columnas). El mismo producto es la suma de las columnas de la matriz, cada una multiplicada por la componente correspondiente del vector:

$$\begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 3 & 0 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \\ 3 \end{pmatrix} + 1 \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 4 \\ 1 \\ 6 \end{pmatrix}.$$

Idea clave

La segunda lectura es la clave de todo el proyecto:

$$D \alpha = \alpha_1 d_1 + \alpha_2 d_2 + \cdots + \alpha_{256} d_{256}.$$

Multiplicar el diccionario por el vector de pesos *es* armar la ventana sumando átomos. Si casi todos los α_i son cero, la ventana se arma con pocos átomos.

Matriz por matriz

Para multiplicar M por N se multiplica M por cada columna de N , y los resultados se ponen como columnas. La entrada (i, j) del resultado es el producto punto de la fila i de M con la columna j de N . Para que se pueda, el número de columnas de M debe ser igual al número de filas de N :

$$(m \times k) \cdot (k \times n) = m \times n \quad (\text{las dos } k \text{ deben coincidir}).$$

Un caso que aparece mucho es $M^T M$. Su entrada (i, j) es el producto punto de la columna i de M con la columna j de M :

$$M^T M = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 \cdot 1 + 0 \cdot 0 + 1 \cdot 1 & 1 \cdot 0 + 0 \cdot 1 + 1 \cdot 1 \\ 0 \cdot 1 + 1 \cdot 0 + 1 \cdot 1 & 0 \cdot 0 + 1 \cdot 1 + 1 \cdot 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

$M^T M$ siempre es cuadrada y simétrica. La SVD la usa.

Columna por fila: matrices de rango 1

Una columna de m números por una fila de n números da una matriz de $m \times n$. Cada columna del resultado es la misma columna original, multiplicada por un número distinto:

$$\begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix} \begin{pmatrix} 3 & 1 \end{pmatrix} = \begin{pmatrix} 3 \cdot 1 & 1 \cdot 1 \\ 3 \cdot 2 & 1 \cdot 2 \\ 3 \cdot 0 & 1 \cdot 0 \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 6 & 2 \\ 0 & 0 \end{pmatrix}.$$

Definición 2.9 (Matriz de rango 1). Una matriz es de **rango 1** si se puede escribir como una columna por una fila. Todas sus columnas apuntan en la misma dirección; solo cambian de tamaño.

Idea clave

Un átomo (una columna) por sus pesos en varias ventanas (una fila) es una matriz de rango 1. Por eso, al actualizar un átomo, K-SVD busca la mejor aproximación de rango 1 de una matriz, y eso lo da la SVD.

Matrices ortogonales

Definición 2.10 (Matriz ortogonal). Una matriz cuadrada Q es **ortogonal** si $Q^T Q = I$. Es lo mismo que decir que sus columnas miden 1 y son perpendiculares entre sí, porque la entrada (i, j) de $Q^T Q$ es el producto punto de la columna i con la columna j .

Una matriz ortogonal es una **rotación** (o un reflejo): no cambia largos ni ángulos. Su inversa es gratis, porque es su transpuesta. Por ejemplo, girar un cuarto de vuelta:

$$Q = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \quad Q^T Q = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Ojito...

Simétrica y ortogonal son cosas distintas. La matriz $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ es simétrica pero no ortogonal: su primera columna, $(2, 1)$, mide $\sqrt{5}$ y no 1. No gira, estira.

Sistemas de ecuaciones con infinitas soluciones

Una ecuación con dos incógnitas, como $x + y = 2$, tiene infinitas soluciones: $(1, 1)$, $(2, 0)$, $(0, 2)$, $(1.5, 0.5)$. . . Si se pide la solución **con más ceros**, quedan dos: $(2, 0)$ y $(0, 2)$.

Idea clave

Es justo la situación del proyecto. Cada ventana da 128 ecuaciones ($x = D\alpha$, una por muestra) y hay 256 incógnitas (un peso por átomo). Hay infinitas soluciones, y de todas se busca la que tiene más ceros. Eso es lo que hace OMP.

Eigenvalores y eigenvectores

Definición 2.11 (Eigenvalor y eigenvector). Un vector $v \neq 0$ es **eigenvector** de una matriz cuadrada M si $Mv = \lambda v$ para algún número λ , su **eigenvalor**. Es una dirección que M no gira: solo la estira o la encoge por λ .

Los eigenvalores son las raíces de $\det(M - \lambda I) = 0$. Para una matriz de 2×2 el determinante es $\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$.

Ejemplo 2.12. Con $M = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$:

$$\begin{aligned} \det(M - \lambda I) &= \det \begin{pmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{pmatrix} = (2 - \lambda)^2 - 1 \\ &= \lambda^2 - 4\lambda + 3 = (\lambda - 3)(\lambda - 1) = 0. \end{aligned}$$

Los eigenvalores son $\lambda_1 = 3$ y $\lambda_2 = 1$. Para cada uno se resuelve $(M - \lambda I)v = 0$:

$$\lambda_1 = 3 : \quad \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} v = 0 \Rightarrow v = (1, 1),$$

$$\lambda_2 = 1 : \quad \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} v = 0 \Rightarrow v = (1, -1).$$

Comprobación: $M(1, 1) = (2 + 1, 1 + 2) = (3, 3) = 3(1, 1)$.

Idea clave

En el ejemplo, $(1, 1) \cdot (1, -1) = 0$: los dos eigenvectores son perpendiculares. No es casualidad. El **teorema espectral** dice que los eigenvectores de una matriz simétrica siempre se pueden escoger perpendiculares entre sí. Gracias a eso la SVD siempre tiene rotaciones.

3. Los datos: del ECG a la matriz X

Resumen rápido. El ECG llega como una tira de 650 000 números. Se corta en 5078 pedazos de 128, se pone cada pedazo como columna de una matriz, y a cada columna se le quita su promedio y se normaliza. El resultado es X , la matriz con la que trabaja K-SVD.

La señal

Un electrocardiograma mide el voltaje eléctrico del corazón a lo largo del tiempo. Se usa el **registro 100** de la base **MIT-BIH Arrhythmia**, de PhysioNet: 30 minutos del ECG de un paciente real.

El aparato mide el voltaje **360 veces por segundo**. Cada medición es un número en milivolts (mV) y se llama **muestra**. La lista completa de muestras, en orden de tiempo, es la **señal**:

$$\begin{array}{ll} \text{senal}[0] = -0.145 \text{ mV} & \text{el voltaje en } t = 0.000 \text{ s} \\ \text{senal}[1] = -0.145 \text{ mV} & \text{el voltaje en } t = 0.003 \text{ s} \\ \vdots & \\ \text{senal}[649999] = -1.280 \text{ mV} & \text{el voltaje en } t = 1805.6 \text{ s} \end{array}$$

Son $650\,000/360 = 1805.6$ segundos, o sea 30.1 minutos. En numpy es un arreglo de **una sola dimensión**, de forma $(650000,)$. El archivo original trae dos canales, uno por cada par de electrodos; `cargar_ecg()` se queda solo con el primero.




Figura 2: Los primeros dos segundos de la señal. Cada pico alto es un latido (el complejo QRS). Las líneas punteadas son los cortes de las ventanas de la siguiente sección.

Las ventanas

K-SVD no recibe la señal entera. La señal se **corta en pedazos del mismo tamaño**, uno tras otro, y a cada pedazo se le llama **ventana**. Cada ventana se pone **de pie, como columna**, y las columnas se acomodan una al lado de la otra. La figura 3 lo muestra con una señal de 12 muestras y ventanas de 4.




Figura 3: Una señal de 12 muestras cortada en ventanas de 4. Cada ventana pasa a ser una columna.

Hay tres palabras que no hay que confundir:

- **señal**: todo el arreglo (650 000 números);
- **muestra**: un solo número de la señal;
- **ventana**: un pedazo de muestras seguidas (128).

En el proyecto

Las ventanas son de 128 muestras (`TAM_VENTANA = 128` en `Utils.py`):

$$\frac{650\,000}{128} = 5078.1 \Rightarrow 5078 \text{ ventanas completas}, \quad 650\,000 - 5078 \cdot 128 = 16 \text{ muestras que sobran.}$$

Las 16 que sobran no alcanzan para una ventana y se descartan. No se rellenan con ceros, porque eso inventaría una forma de onda que no existe en el ECG. La ventana j es la columna

$$\text{ventana } j = \text{senal}[128j : 128j + 128],$$

que cubre de $0.356j$ a $0.356(j+1)$ segundos. La matriz de ventanas crudas mide 128×5078 ; su esquina superior izquierda es

	v0	v1	v2	v3	v4	v5
muestra 0	-0.145	-0.330	-0.295	-0.385	-0.315	-0.380
muestra 1	-0.145	-0.330	-0.310	-0.390	-0.305	-0.385
muestra 2	-0.145	-0.335	-0.290	-0.380	-0.315	-0.380
⋮						⋮

Casi todo vale alrededor de -0.3 mV: es la **línea base**, donde el corazón no hace nada visible. En la ventana 5, alrededor de la fila 23, sí hay un latido:

fila	19	20	21	22	23	24	25	26	27
mV	0.120	0.410	0.690	0.885	0.960	0.850	0.520	0.050	-0.320

Por qué se corta en ventanas

1. **K-SVD aprende de lo que se repite entre muchos ejemplos.** La señal entera es un solo ejemplo; cortada, da 5078. El corazón repite casi la misma forma en cada latido, así que muchas ventanas se parecen, y eso es justo lo que el diccionario aprende.

2. **Los átomos miden lo mismo que una ventana**, porque se suman para reconstruirla. Con la señal entera, cada átomo sería un ECG de 30 minutos, y habría que aprender 256 de ellos a partir de un solo ejemplo.
3. **Costo.** OMP y la SVD trabajan con matrices del tamaño de una ventana. Con 128 filas las cuentas son chicas.

Por qué 128

Una ventana de 128 muestras dura $128/360 = 0.356$ segundos. Un complejo QRS dura unos 100 ms, así que cabe completo y con margen. Un latido completo dura unos 800 ms y no cabe. Es lo bastante largo para que quepa la forma importante del latido y lo bastante corto para tener muchos ejemplos. Que sea potencia de 2 es costumbre, no necesidad: OMP y K-SVD funcionan igual con 120 o con 150.

Por qué cada ventana es una columna

Porque en álgebra lineal un vector se escribe como columna, y así se escribe toda la teoría del proyecto:

$$\underbrace{x}_{128 \times 1} = \underbrace{D}_{128 \times 256} \underbrace{\alpha}_{256 \times 1} \quad \underbrace{X}_{128 \times 5078} = \underbrace{D}_{128 \times 256} \underbrace{\alpha}_{256 \times 5078}.$$

Con las ventanas como columnas, una sola multiplicación reconstruye todas a la vez. Como filas también funcionaría, pero todo quedaría transpuesto y el código dejaría de leerse como las fórmulas.

Centrar y normalizar

Antes de entrar a X , a cada ventana (cada columna) se le hacen dos cosas:

$$1. \text{ centrar: } c \leftarrow c - \text{promedio}(c), \quad 2. \text{ normalizar: } c \leftarrow \frac{c}{\|c\|}.$$

El objetivo es que dos ventanas con **la misma forma** queden **iguales**, aunque el ECG las haya medido más arriba, más abajo, más fuertes o más débiles. Al diccionario solo le interesa la forma.

Ejemplo 3.1 (Centrar quita la altura). Dos ventanas con la misma forma, pero una medida 5 unidades más arriba porque la línea base subió con la respiración:

$$\begin{aligned} P &= (0, 0, 4, 0), & \text{promedio}(P) &= (0 + 0 + 4 + 0)/4 = 1, \\ Q &= (5, 5, 9, 5), & \text{promedio}(Q) &= (5 + 5 + 9 + 5)/4 = 6. \end{aligned}$$

Restando a cada una su promedio:

$$P - 1 = (-1, -1, 3, -1), \quad Q - 6 = (-1, -1, 3, -1).$$

Quedan iguales. Sin centrar, el diccionario gastaría átomos en aprender “qué tan arriba está la línea”, que no es parte del latido; el primer átomo aprendido sería una línea plana.

Ejemplo 3.2 (Normalizar quita el tamaño). Dos ventanas con la misma forma, una el doble de fuerte:

$$\begin{aligned} P &= (-1, -1, 3, -1), & \|P\| &= \sqrt{1 + 1 + 9 + 1} = \sqrt{12} = 3.464, \\ R &= (-2, -2, 6, -2), & \|R\| &= \sqrt{4 + 4 + 36 + 4} = \sqrt{48} = 6.928. \end{aligned}$$

Dividiendo cada una entre su norma:

$$\frac{P}{3.464} = \frac{R}{6.928} = (-0.289, -0.289, 0.866, -0.289).$$

Otra vez iguales, y ahora miden exactamente 1.

Ojito...

Sin normalizar, K-SVD le haría más caso a las ventanas grandes, porque pesan más en el error. Y OMP compara con productos punto, que crecen con el tamaño: una ventana grande se vería “más parecida” a todo solo por ser grande.

Ejemplo 3.3 (Con los números reales). La ventana 5 tiene su pico de 0.960 mV en la fila 23. Su promedio es -0.3494 , y ya centrada su norma es 2.8586. Entonces el valor que queda en X es

$$\frac{0.960 - (-0.3494)}{2.8586} = \frac{1.3094}{2.8586} = 0.458.$$




Figura 4: La ventana 5 antes y después de centrar y normalizar. Los números cambian pero la forma no: el pico sigue en la fila 23.

La matriz X

X tiene la misma forma que las ventanas crudas, 128×5078 , pero cada columna tiene promedio 0 y norma 1. Vista como mapa de calor (figura 5), cada franja vertical es una ventana; las manchas rojas son los picos de los latidos, y caen en filas distintas porque los latidos no quedan en la misma posición dentro de cada ventana. Esa variación es lo que el diccionario tiene que aprender a cubrir.




Figura 5: Las primeras 60 columnas de X .

Entrenamiento y prueba

X se parte a la mitad **en orden de tiempo**: las primeras 2539 ventanas entrenan y las últimas 2539 se usan al final para medir. No se reparte al azar porque las ventanas contiguas de un ECG se parecen muchísimo; al azar, en la prueba quedarían vecinas directas de las de entrenamiento, y el resultado se vería mejor de lo que es.

Varios pacientes

Con `Experimento.py --todos` se cargan los 48 registros de MIT-BIH. Cada paciente se corta en ventanas **por separado** y después se pegan las columnas, hasta $128 \times 243\,744$. Si primero se pegaran las señales y luego se cortara, alguna ventana quedaría con la mitad de un paciente y la mitad de otro: una forma que no existe. La partición entrenamiento y prueba también se hace dentro de cada paciente.

4. El diccionario: átomos, D y α

Resumen rápido. Un átomo es una forma de onda del tamaño de una ventana. El diccionario D los junta como columnas. Los pesos α dicen cuánto de cada átomo usa cada ventana, y $D\alpha$ reconstruye las ventanas. Aquí se presenta el ejemplo de juguete que usan las secciones de OMP y de actualización de átomos.

Qué es un átomo y qué es el diccionario

Definición 4.1 (Átomo). Un **átomo** es un vector del mismo tamaño que una ventana, con norma 1. Por sí solo no es un pedazo real del ECG: es una pieza con la que se arman pedazos.

Que mida 1 importa: así el átomo solo aporta **forma**, y el tamaño lo pone su peso. Si los átomos tuvieran largos distintos, al compararlos con una ventana ganarían los más largos por ser largos, no por parecerse más.

Definición 4.2 (Diccionario). El **diccionario** D es la matriz cuyas columnas son todos los átomos:

$$D = \begin{pmatrix} | & | & \cdots & | \\ d_0 & d_1 & & d_{255} \\ | & | & & | \end{pmatrix}, \quad 128 \times 256.$$

Las **columnas** de D son los átomos. Las **filas** son la posición en el tiempo dentro del átomo: la fila 23 de D es el mismo instante que la fila 23 de una ventana. Por eso, al sumar átomos, cada instante cae justo en su instante de la ventana.

Se llama diccionario por la analogía con uno de palabras: con un vocabulario fijo se escriben muchísimas oraciones, y cada oración usa pocas palabras. Aquí el vocabulario son formas de onda y las oraciones son ventanas.

El ejemplo de juguete

Átomos	Ventanas
$A = (1, 0, 0)$	$v_1 = (1, 1, 0.5)$
$B = (0.6, 0.8, 0)$	$v_2 = (0.9, 1, 0)$
$C = (0, 0, 1)$	
$E = (0, 1, 0)$	

Todos los átomos miden 1; por ejemplo, $\|B\| = \sqrt{0.6^2 + 0.8^2} = \sqrt{0.36 + 0.64} = 1$.




Figura 6: Los cuatro átomos y las dos ventanas del ejemplo, una barra por componente.

α : los pesos

Para cada ventana, α es un **vector** con un peso por átomo. Cada entrada es un número que dice cuánto de ese átomo se usa; un cero quiere decir que el átomo no se usa. Para la ventana 1:

$$\alpha^{(1)} = (0.25, 1.25, 0.5, 0).$$

De dónde salen estos números se desarrolla cuenta por cuenta en la sección de OMP; por ahora basta saber que los calcula OMP.

Reconstruir una ventana

La ventana se arma sumando cada átomo por su peso. Es la lectura de matriz por vector como combinación de columnas:

$$D \alpha^{(1)} = \begin{pmatrix} 1 & 0.6 & 0 & 0 \\ 0 & 0.8 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0.25 \\ 1.25 \\ 0.5 \\ 0 \end{pmatrix} = 0.25 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + 1.25 \begin{pmatrix} 0.6 \\ 0.8 \\ 0 \end{pmatrix} + 0.5 \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}.$$

Haciendo cada multiplicación y sumando:

$$\begin{pmatrix} 0.25 \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0.75 \\ 1 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ 0.5 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 0.5 \end{pmatrix} = v_1.$$

La ventana 1 sale exacta con tres átomos.

α de todas las ventanas: una matriz

Cada ventana tiene su vector de pesos. Puestos como columnas, α es una **matriz** con una fila por átomo y una columna por ventana:

$$\alpha = \begin{pmatrix} 0.25 & 0 \\ 1.25 & 1.34 \\ 0.5 & 0 \\ 0 & 0 \end{pmatrix} \begin{matrix} \leftarrow A \\ \leftarrow B \\ \leftarrow C \\ \leftarrow E \end{matrix} \quad \text{columnas: } v_1, v_2.$$

Se lee de dos maneras:

- **por columna:** la receta de una ventana. La ventana 2 es $1.34 \cdot B$;
- **por fila:** qué ventanas usan un átomo. La fila B tiene dos números distintos de cero, así que B lo usan las dos ventanas. Esta lectura es la que usa la actualización de átomos.

Una sola multiplicación reconstruye todo:

$$D \alpha = \begin{pmatrix} 1 & 0.804 \\ 1 & 1.072 \\ 0.5 & 0 \end{pmatrix} \quad \text{contra} \quad X = \begin{pmatrix} 1 & 0.9 \\ 1 & 1 \\ 0.5 & 0 \end{pmatrix}.$$

La ventana 1 sale exacta; la ventana 2 no, le falta $(0.096, -0.072, 0)$. OMP se detuvo ahí porque el error ya era menor que el objetivo, como se verá.

En el proyecto: casi todo es cero

En el proyecto α mide 256×2539 , y en cada columna solo unas 8 a 11 entradas son distintas de cero. La figura 7 ilustra cómo se ve una matriz así.




Figura 7: Ilustración de una matriz α dispersa: cada ventana usa solo unos pocos átomos.

Por qué 256 átomos

Tiene que haber **más átomos que muestras por ventana**. Con 128 átomos independientes, cada ventana se arma de una sola manera, y casi siempre con muchos átomos. Con 256 se puede armar de muchas maneras, y se escoge la que usa menos. Un diccionario con más átomos que dimensiones se llama **sobrecompleto**: el sistema $x = D\alpha$ queda con 128 ecuaciones y 256 incógnitas, con infinitas soluciones.

No se usan muchos más porque con 2539 ventanas de entrenamiento y 256 átomos, cada átomo se ajusta con unas 10 ventanas en promedio; con 1000 átomos serían 2 o 3, muy pocas. Además algunos quedarían sin uso, y el entrenamiento tarda en proporción al número de átomos. En la literatura se usan de 2 a 4 veces más átomos que el tamaño de la señal.

Los átomos no son perpendiculares

Con 256 átomos en 128 dimensiones, forzosamente muchos se “pisan”. En el ejemplo, $A \cdot B = 0.6$. Medido en el diccionario inicial real:

$ \text{coseno} $ entre átomos distintos	Valor
máximo (dos casi iguales)	0.995
promedio	0.226
pares casi perpendiculares (< 0.1)	35 %

Ojito...

Es una diferencia importante con la SVD, donde U y V sí son ortogonales. Y tiene una consecuencia en OMP: como los átomos se pisan, los pesos no se pueden sacar con un producto punto cada uno; hay que resolver un sistema. Se ve en la vuelta 3 del ejemplo de OMP.

El diccionario inicial y cuándo cambia

Al empezar, los 256 átomos son **256 ventanas reales de X escogidas al azar**, normalizadas. Así el entrenamiento arranca con formas que ya parecen de ECG y no con ruido.




Figura 8: Doce de los 256 átomos iniciales. Algunos tienen un pico y otros solo un escalón de la línea base.

El diccionario cambia **solo durante el entrenamiento**, y solo en el paso 2 de cada iteración. En el paso 1, OMP lo usa sin modificarlo. Al terminar las 20 iteraciones queda fijo, se guarda en `out/modelo.npz` y se usa tal cual para reconstruir las ventanas de prueba.

5. La SVD: descomposición en valores singulares

Resumen rápido. Cualquier matriz es girar, estirar cada eje y volver a girar: $A = U\Sigma V^T$. Se calcula con los eigenvalores de $A^T A$. Su primera pieza, $\sigma_1 u_1 v_1^T$, es la mejor aproximación de rango 1 de la matriz, y es la que usa K-SVD para mejorar cada átomo.

Qué es

Definición 5.1 (Descomposición en valores singulares). Toda matriz A de $m \times n$, cuadrada o no, se puede escribir como

$$\underbrace{A}_{m \times n} = \underbrace{U}_{m \times m} \underbrace{\Sigma}_{m \times n} \underbrace{V^T}_{n \times n},$$

donde U y V son ortogonales y Σ tiene ceros fuera de la diagonal. En la diagonal de Σ están los **valores singulares** $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$.

Las columnas $u_1, u_2, \dots$ de U se llaman vectores singulares izquierdos, y las columnas $v_1, v_2, \dots$ de V , derechos.

Qué significa: girar, estirar, girar

Multiplicar un vector x por A es hacer tres cosas en orden. Se lee de derecha a izquierda, porque es lo primero que le toca a x :

$$Ax = U(\Sigma(V^T x)) : \quad 1. V^T \text{ gira, } 2. \Sigma \text{ estira cada eje, } 3. U \text{ gira otra vez.}$$

Las rotaciones no deforman nada, así que toda la deformación de A vive en Σ . Por eso un círculo de radio 1 sale convertido en una elipse cuyos semiejes miden σ_1 y σ_2 (figura 9). Si algún σ vale 0, ese eje se aplasta; si $m \neq n$, Σ además agrega o quita dimensiones.




Figura 9: La SVD de $A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$ aplicada al círculo unitario, paso por paso. Es el ejemplo gráfico de la exposición de clase.

Cómo se calcula a mano

La idea clave es no atacar A directamente, sino $A^T A$, que **siempre** es cuadrada y simétrica, y a la que ya se le saben sacar eigenvalores y eigenvectores. Ejemplo:

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad 3 \times 2.$$

Paso 1: $A^T A$. Ya se calculó en la sección de herramientas:

$$A^T A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Paso 2: eigenvalores de $A^T A$. También se calcularon: $\lambda_1 = 3$ y $\lambda_2 = 1$, siempre de mayor a menor.

Paso 3: valores singulares. Son las raíces de los eigenvalores:

$$\sigma_1 = \sqrt{3} = 1.732, \quad \sigma_2 = \sqrt{1} = 1, \quad \Sigma = \begin{pmatrix} 1.732 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

Σ tiene el mismo tamaño que A .

Paso 4: V . Los eigenvectores de $A^T A$, normalizados:

$$(1, 1) \rightarrow \frac{(1, 1)}{\sqrt{2}} = (0.707, 0.707) = v_1, \quad (1, -1) \rightarrow (0.707, -0.707) = v_2,$$

$$V = \begin{pmatrix} 0.707 & 0.707 \\ 0.707 & -0.707 \end{pmatrix}.$$

Paso 5: U con $u = Av/\sigma$.

$$\begin{aligned} Av_1 &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix} = \begin{pmatrix} 0.707 \\ 0.707 \\ 1.414 \end{pmatrix}, & u_1 &= \frac{Av_1}{1.732} = \begin{pmatrix} 0.408 \\ 0.408 \\ 0.816 \end{pmatrix}, \\ Av_2 &= \begin{pmatrix} 0.707 \\ -0.707 \\ 0 \end{pmatrix}, & u_2 &= \frac{Av_2}{1} = \begin{pmatrix} 0.707 \\ -0.707 \\ 0 \end{pmatrix}. \end{aligned}$$

Paso 6: completar U . U debe ser de 3×3 y faltan columnas. La tercera es cualquier vector de largo 1 perpendicular a u_1 y u_2 . Se encuentra resolviendo $A^T u = 0$:

$$\begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = 0 \Rightarrow x + z = 0, y + z = 0 \Rightarrow u_3 = \frac{(1, 1, -1)}{\sqrt{3}}.$$

No afecta el resultado, porque en Σ le toca la fila de ceros.

Paso 7: comprobar. $U\Sigma$ son las dos primeras columnas de U multiplicadas por σ_1 y σ_2 :

$$U\Sigma V^T = \begin{pmatrix} 0.707 & 0.707 \\ 0.707 & -0.707 \\ 1.414 & 0 \end{pmatrix} \begin{pmatrix} 0.707 & 0.707 \\ 0.707 & -0.707 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} = A.$$

Resultado

El procedimiento a mano:

1. calcular $A^T A$;
2. sus eigenvalores λ , de mayor a menor;
3. $\sigma = \sqrt{\lambda}$, en la diagonal de Σ ;
4. sus eigenvectores normalizados, columnas de V ;
5. $u = Av/\sigma$, columnas de U ;
6. completar U con vectores perpendiculares si hace falta.

Por qué funciona

Por qué $A^T A$. Si ya se supiera que $A = U\Sigma V^T$, entonces

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T = V(\Sigma^T \Sigma)V^T,$$

porque $U^T U = I$. $\Sigma^T \Sigma$ es diagonal con los σ^2 . Esa expresión es una diagonalización de $A^T A$: las columnas de V son sus eigenvectores y sus eigenvalores son los σ^2 . De ahí $\sigma = \sqrt{\lambda}$.

Por qué la raíz siempre existe. Si v es eigenvector de $A^T A$ y mide 1,

$$\lambda = v^T (A^T A)v = (Av)^T (Av) = \|Av\|^2 \geq 0.$$

Un largo al cuadrado nunca es negativo.

Por qué V y U salen ortogonales. $A^T A$ es simétrica, así que sus eigenvectores son perpendiculares (teorema espectral). Para U :

$$u_1 \cdot u_2 = \frac{(Av_1) \cdot (Av_2)}{\sigma_1 \sigma_2} = \frac{v_1^T (A^T Av_2)}{\sigma_1 \sigma_2} = \frac{\sigma_2^2 (v_1 \cdot v_2)}{\sigma_1 \sigma_2} = 0,$$

y cada u mide 1 porque $\|Av\| = \sigma$.

Por qué el producto da A . De $u = Av/\sigma$ sale $Av_i = \sigma_i u_i$. Juntando todas las columnas, $AV = U\Sigma$; y como $V^{-1} = V^T$, queda $A = U\Sigma V^T$.

La SVD como suma de piezas de rango 1

Multiplicando por bloques, la SVD también se escribe como una suma:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots$$

Cada $u_i v_i^T$ es una columna por una fila: una matriz de rango 1. Como los σ vienen ordenados, la primera pieza es la que más pesa.

Teorema 5.2 (Eckart-Young). *Quedarse con las primeras k piezas da la **mejor aproximación de rango k** de A : ninguna otra matriz de rango k queda más cerca. Lo que se pierde son los σ que se tiraron:*

$$\|A - A_k\|^2 = \sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots$$

Ejemplo 5.3. En el ejemplo, con $k = 1$:

$$A_1 = \sigma_1 u_1 v_1^\top = 1.732 \begin{pmatrix} 0.408 \\ 0.408 \\ 0.816 \end{pmatrix} \begin{pmatrix} 0.707 & 0.707 \end{pmatrix} = \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \\ 1 & 1 \end{pmatrix}.$$

El error al cuadrado es $\sigma_2^2 = 1$, de una energía total $\sigma_1^2 + \sigma_2^2 = 4$: con una sola pieza se conserva el 75 %.

Qué pieza usa K-SVD

K-SVD usa solo la **primera pieza**. Al actualizar un átomo arma una matriz R con lo que ese átomo tiene que explicar en cada ventana y se pregunta qué átomo, por qué pesos, explica mejor a R . Un átomo por sus pesos es columna por fila, rango 1, y la mejor respuesta de rango 1 es la primera pieza de la SVD:

$$\text{átomo nuevo} = u_1, \quad \text{pesos nuevos} = \sigma_1 v_1.$$

Ojito...

El signo es arbitrario. Si se cambia el signo de u_i y de v_i a la vez, el producto no cambia. Por eso numpy a veces devuelve los vectores con el signo contrario al de las cuentas a mano, y es la misma solución. Además, `np.linalg.svd` no forma $A^\top A$, porque esa multiplicación pierde precisión; usa otro método (bidiagonalización de Golub-Kahan). La matemática es la misma, solo cambia cómo se hacen las cuentas.

6. OMP: cómo cada ventana escoge sus átomos

Resumen rápido. Con el diccionario fijo, OMP encuentra para cada ventana unos pocos átomos y sus pesos. Escoge un átomo a la vez, el que más se parece a lo que falta explicar, y en cada vuelta reajusta los pesos de todos los escogidos. Es el paso 1 de K-SVD, y lo único que produce es α .

El problema

Con el diccionario fijo, para cada ventana x se busca α tal que $x = D\alpha$. Son 128 ecuaciones y 256 incógnitas: hay **infinitas** soluciones, y se quiere la que tenga **más ceros**.

Encontrar la mejor exacta es carísimo: habría que probar todas las combinaciones de átomos. Solo para escoger 8 átomos de 256 hay

$$\binom{256}{8} \approx 4.1 \times 10^{14}$$

combinaciones. OMP la aproxima de forma **voraz**: escoge un átomo a la vez, el que más ayuda en ese momento, sin volver atrás.

El algoritmo

Algoritmo 6.1 Orthogonal Matching Pursuit sobre una ventana

Entrada: diccionario D , ventana x , error objetivo ε , tope k

Salida: pesos α con pocas entradas distintas de cero

```

1:  $r \leftarrow x$                                      // al inicio falta explicar todo
2:  $S \leftarrow \emptyset$                              // átomos escogidos
3: mientras  $\|r\| / \|x\| > \varepsilon$  y  $|S| < k$  hacer
4:   calcular  $|d_i \cdot r|$  para cada átomo  $i$ 
5:    $S \leftarrow S \cup \{\text{el átomo con el valor mayor}\}$ 
6:    $w \leftarrow$  pesos de mínimos cuadrados con los átomos de  $S$ 
7:    $r \leftarrow x - D_S w$ 
8: fin mientras
9: devolver  $\alpha$ , con  $w$  en los átomos de  $S$  y cero en los demás

```

En el proyecto, $\varepsilon = 0.1$ (ERROR_OMP) y $k = 16$ (MAX_ATOMOS_OMP). Por qué cada paso:

- **Comparar con el residual.** El producto punto mide parecido; como todos los átomos miden 1, el de valor absoluto mayor es el que mejor explica lo que falta. Se usa valor absoluto porque un átomo al revés, con peso negativo, explica igual.
- **Reajustar todos los pesos.** No solo se calcula el peso del átomo nuevo: se recalculan los de todos los escogidos. Eso es lo **ortogonal** del nombre, y hace que ningún átomo se repita.
- **Siempre contra lo que falta.** La comparación es contra el residual r , no contra la ventana original.

Los mínimos cuadrados del paso de pesos

Con los átomos escogidos se buscan los pesos que dejan la suma lo más cerca posible de x . ¿Cómo se reconocen esos pesos? Por una propiedad: **lo que sobra no debe parecerse a ningún átomo**

escogido. Si se pareciera a alguno, se podría mover su peso para explicar ese pedazo y el residual bajaría. Entonces el residual debe ser perpendicular a cada átomo escogido. Con dos átomos P y Q :

$$P \cdot (x - w_P P - w_Q Q) = 0, \quad Q \cdot (x - w_P P - w_Q Q) = 0.$$

Esas dos condiciones son todo. Falta despejarlas. Se reparte el producto punto, que se distribuye igual que una multiplicación normal:

$$P \cdot x - w_P (P \cdot P) - w_Q (P \cdot Q) = 0,$$

y pasando a la derecha lo que no tiene incógnita:

$$w_P (P \cdot P) + w_Q (P \cdot Q) = P \cdot x.$$

Lo mismo con la segunda condición. Son dos ecuaciones con dos incógnitas, y puestas en forma de matriz se llaman las **ecuaciones normales**:

$$\begin{pmatrix} P \cdot P & P \cdot Q \\ Q \cdot P & Q \cdot Q \end{pmatrix} \begin{pmatrix} w_P \\ w_Q \end{pmatrix} = \begin{pmatrix} P \cdot x \\ Q \cdot x \end{pmatrix}.$$

Cada renglón dice lo mismo: *el átomo de este renglón, contra lo reconstruido, debe dar lo mismo que ese átomo contra x .*

El caso de un solo átomo. Con un átomo P el sistema se encoge a 1×1 y queda una sola ecuación:

$$(P \cdot P) w_P = P \cdot x.$$

Y aquí entra un detalle del montaje: **los átomos están normalizados a norma 1**, así que $P \cdot P = \|P\|^2 = 1$. El sistema se vuelve $1 \cdot w_P = P \cdot x$, o sea

$$w_P = P \cdot x.$$

El peso del primer átomo *es* su producto punto con la ventana. Por eso en el ejemplo el 1.4 aparece dos veces: primero como el producto punto que hizo ganar a B , y después como su peso. No es coincidencia, es la misma cuenta.

Idea clave

Si los átomos son perpendiculares ($P \cdot Q = 0$) y miden 1, la matriz es la identidad y cada peso es simplemente su producto punto con x . Si **no** son perpendiculares, hay que resolver el sistema y los pesos se reparten. En el código esto es una línea, `np.linalg.lstsq`.

Ejemplo completo: la ventana 1

La ventana es $x = v_1 = (1, 1, 0.5)$, con $\|x\| = \sqrt{1+1+0.25} = 1.5$, y el objetivo es error menor a 0.1. Al inicio el residual es la ventana completa: $r = (1, 1, 0.5)$. La figura 10 resume las tres vueltas.



Figura 10: OMP sobre la ventana 1. En cada fila: lo que falta explicar antes de la vuelta (naranja), la reconstrucción después (azul) y el residual que queda (verde).

Vuelta 1

Comparar cada átomo con el residual:

$$A \cdot r = (1)(1) + (0)(1) + (0)(0.5) = 1$$

$$B \cdot r = (0.6)(1) + (0.8)(1) + (0)(0.5) = 1.4$$

$$C \cdot r = (0)(1) + (0)(1) + (1)(0.5) = 0.5$$

$$E \cdot r = (0)(1) + (1)(1) + (0)(0.5) = 1$$

El mayor es 1.4: gana B . Escogidos: $\{B\}$.

Peso. Hay un solo átomo escogido, así que las ecuaciones normales se reducen a una sola:

$$(B \cdot B) w_B = B \cdot x.$$

El lado izquierdo es $B \cdot B = (0.6)^2 + (0.8)^2 + 0^2 = 1$, porque los átomos se construyeron con norma 1. El derecho ya se calculó arriba: $B \cdot x = 1.4$. Entonces $1 \cdot w_B = 1.4$ y $w_B = 1.4$.

En otras palabras, el peso salió gratis: el producto punto que se usó para *elegir* el átomo sirve también como su *peso*. Eso solo pasa con el primer átomo, cuando no hay otros con los cuales repartirse la explicación.

Reconstrucción y residual:

$$1.4 B = (0.84, 1.12, 0), \quad r = x - 1.4 B = (1 - 0.84, 1 - 1.12, 0.5 - 0) = (0.16, -0.12, 0.5).$$

Error:

$$\|r\| = \sqrt{0.16^2 + 0.12^2 + 0.5^2} = \sqrt{0.0256 + 0.0144 + 0.25} = \sqrt{0.29} = 0.539, \quad \frac{0.539}{1.5} = 0.359 > 0.1.$$

Sigue.

Vuelta 2

Comparar con el residual nuevo, $r = (0.16, -0.12, 0.5)$:

$$A \cdot r = 0.16$$

$$B \cdot r = (0.6)(0.16) + (0.8)(-0.12) = 0.096 - 0.096 = 0$$

$$C \cdot r = 0.5$$

$$E \cdot r = -0.12$$

B da **cero**: lo que sobra ya no tiene nada de B , y así se garantiza que no se repite. Gana C , que tiene sentido: lo que más faltaba era el 0.5 de la tercera posición. Escogidos: $\{B, C\}$.

Pesos de B y C juntos. Aquí hay un punto que se presta a confusión. Los productos punto del lado derecho van contra la x **original**, no contra el residual, aunque el residual sea lo que se acaba de usar para escoger a C .

La razón es que son dos preguntas distintas. El residual contesta *cuál átomo entra*: es lo que falta por explicar, y se busca el átomo que más se le parezca. Pero una vez elegido el conjunto, la pregunta cambia a *con qué pesos*, y esa se responde minimizando $\|x - w_B B - w_C C\|$, que habla de x y no del residual de la vuelta anterior. Las ecuaciones normales salen de ahí, así que su lado derecho tiene que ser $B \cdot x$ y $C \cdot x$.

Esto es justamente lo *ortogonal* de Orthogonal Matching Pursuit: en cada vuelta se recalculan **todos** los pesos desde cero, incluidos los de los átomos viejos, en lugar de dejarlos fijos y solo agregar el nuevo. Los números:

$$B \cdot B = 1, \quad B \cdot C = 0, \quad C \cdot C = 1, \quad B \cdot x = 1.4, \quad C \cdot x = 0.5,$$

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} w_B \\ w_C \end{pmatrix} = \begin{pmatrix} 1.4 \\ 0.5 \end{pmatrix} \Rightarrow w_B = 1.4, \quad w_C = 0.5.$$

Como B y C son perpendiculares, cada ecuación tiene una sola incógnita y el peso de B no cambia.

Reconstrucción, residual y error:

$$1.4 B + 0.5 C = (0.84, 1.12, 0.5), \quad r = (0.16, -0.12, 0), \quad \frac{\sqrt{0.04}}{1.5} = \frac{0.2}{1.5} = 0.133 > 0.1.$$

Sigue.

Vuelta 3

Comparar, $r = (0.16, -0.12, 0)$:

$$\textcolor{blue}{A} \cdot r = 0.16, \quad \textcolor{brown}{B} \cdot r = 0, \quad \textcolor{teal}{C} \cdot r = 0, \quad \textcolor{orange}{E} \cdot r = -0.12.$$

Gana $\textcolor{blue}{A}$. Escogidos: $\{B, C, A\}$.

Pesos de los tres. Ahora hay tres átomos escogidos, así que el sistema crece a 3×3 . En el orden B, C, A queda:

$$\begin{pmatrix} B \cdot B & B \cdot C & B \cdot A \\ C \cdot B & C \cdot C & C \cdot A \\ A \cdot B & A \cdot C & A \cdot A \end{pmatrix} \begin{pmatrix} w_B \\ w_C \\ w_A \end{pmatrix} = \begin{pmatrix} B \cdot x \\ C \cdot x \\ A \cdot x \end{pmatrix}.$$

Son nueve casillas en la matriz y tres en el lado derecho, pero **cinco ya se calcularon en la vuelta 2** y se reusan: $B \cdot B = 1$, $B \cdot C = 0$, $C \cdot C = 1$, $B \cdot x = 1.4$, $C \cdot x = 0.5$. Y la matriz es simétrica, porque el producto punto no distingue el orden: $A \cdot B$ es lo mismo que $B \cdot A$. Así que solo faltan cuatro números, los que involucran al átomo nuevo:

$$\begin{aligned} B \cdot A &= (0.6)(1) + (0.8)(0) + (0)(0) = 0.6, & C \cdot A &= (0)(1) + (0)(0) + (1)(0) = 0, \\ A \cdot A &= (1)(1) + (0)(0) + (0)(0) = 1, & A \cdot x &= (1)(1) + (0)(1) + (0)(0.5) = 1. \end{aligned}$$

Aquí está lo importante: $B \cdot A = 0.6$, **distinto de cero**. A y B **no** son perpendiculares, y por eso esta vuelta es la primera en que el sistema de verdad hay que resolverlo. Sustituyendo los números:

$$\begin{pmatrix} 1 & 0 & 0.6 \\ 0 & 1 & 0 \\ 0.6 & 0 & 1 \end{pmatrix} \begin{pmatrix} w_B \\ w_C \\ w_A \end{pmatrix} = \begin{pmatrix} 1.4 \\ 0.5 \\ 1 \end{pmatrix}.$$

Pasarlo a ecuaciones. Una matriz por un vector es, renglón por renglón, un producto punto. El primer renglón $(1, 0, 0.6)$ contra (w_B, w_C, w_A) da $1 \cdot w_B + 0 \cdot w_C + 0.6 \cdot w_A$, y eso debe igualar al primer número de la derecha. Los tres renglones:

$$\begin{aligned} w_B + 0 w_C + 0.6 w_A &= 1.4 & (1) & & w_B + 0.6 w_A &= 1.4 & (1) \\ 0 w_B + w_C + 0 w_A &= 0.5 & (2) & \iff & w_C &= 0.5 & (2) \\ 0.6 w_B + 0 w_C + w_A &= 1 & (3) & & 0.6 w_B + w_A &= 1 & (3) \end{aligned}$$

Los ceros se van, y lo que queda deja ver la estructura: la ecuación (2) está sola, y las otras dos están enredadas entre sí.

Resolver. La (2) ya viene despejada: $w_C = 0.5$. Tiene sentido, C es perpendicular a los otros dos, así que nadie compite con él y se queda con su producto punto completo.

Quedan (1) y (3), dos ecuaciones con dos incógnitas. Se despeja w_A de la (3), que es la más directa:

$$0.6 w_B + w_A = 1 \implies w_A = 1 - 0.6 w_B.$$

Y esa expresión se mete en la (1), donde aparecía w_A , para que quede una sola incógnita:

$$\begin{aligned} w_B + 0.6 w_A &= 1.4 && \text{ecuación (1)} \\ w_B + 0.6(1 - 0.6 w_B) &= 1.4 && \text{se sustituye } w_A \\ w_B + 0.6 - 0.36 w_B &= 1.4 && \text{se reparte el 0.6} \\ 0.64 w_B &= 0.8 && \text{se juntan los } w_B \text{ y pasa el 0.6} \\ w_B &= \frac{0.8}{0.64} = 1.25. \end{aligned}$$

Con w_B ya conocido, se regresa a la expresión de w_A :

$$w_A = 1 - 0.6 \cdot 1.25 = 1 - 0.75 = 0.25.$$

Ojito...

El peso de B cambió de 1.4 a 1.25. En la vuelta 1, B explicaba sola la primera posición. Ahora A también aporta ahí, así que B ya no carga con todo. Si los pesos se sacaran con un producto punto cada uno, saldría $w_B = 1.4$ y $w_A = 1$, y la reconstrucción quedaría mal.

Reconstrucción, residual y error:

$$1.25 B + 0.5 C + 0.25 A = (0.75, 1, 0) + (0, 0, 0.5) + (0.25, 0, 0) = (1, 1, 0.5) = x.$$

El residual es $r = 0$ y el error es 0: se detiene.

Resultado

$$\alpha^{(1)} = (0.25, 1.25, 0.5, 0)$$

Vuelta	Gana	Pesos	Error
1	B	$B = 1.4$	0.359
2	C	$B = 1.4, C = 0.5$	0.133
3	A	$B = 1.25, C = 0.5, A = 0.25$	0

La ventana 2

La ventana es $x = v_2 = (0.9, 1, 0)$, con $\|x\| = \sqrt{0.81 + 1} = 1.345$.

Vuelta 1. Comparar con $r = x$:

$$A \cdot r = 0.9, \quad B \cdot r = 0.54 + 0.8 = 1.34, \quad C \cdot r = 0, \quad E \cdot r = 1.$$

Gana B con peso $w_B = 1.34$. Reconstrucción y residual:

$$1.34 B = (0.804, 1.072, 0), \quad r = (0.096, -0.072, 0), \quad \frac{\sqrt{0.0092 + 0.0052}}{1.345} = \frac{0.12}{1.345} = 0.089 < 0.1.$$

Se detiene con un solo átomo: no queda exacta, pero ya cumple el objetivo. $\alpha^{(2)} = (0, 1.34, 0, 0)$.

Lo que hay que recordar

1. Se compara contra **lo que falta**, no contra la ventana original. Por eso en la vuelta 2 gana C , aunque al inicio era el que menos se parecía.
2. Un átomo ya escogido da **cero** en las vueltas siguientes. Nunca se repite.
3. Los pesos viejos **se reajustan**: B pasó de 1.4 a 1.25.
4. Para en cuanto basta: error menor a 0.1 o 16 átomos.
5. Lo único que produce OMP es α . El diccionario no cambia.

7. Actualización de átomos: el paso de la SVD

Resumen rápido. Con los pesos de OMP fijos, se recorre cada átomo en orden. Se juntan las ventanas que lo usan, se les quita lo que explican los demás átomos, y a esa matriz se le saca la SVD: el átomo nuevo es u_1 y sus pesos nuevos son $\sigma_1 v_1$. En el ejemplo, el error total baja de 0.12 a 0.056.

Punto de partida

Del ejemplo de juguete y de OMP se tienen:

$$D = \begin{pmatrix} 1 & 0.6 & 0 & 0 \\ 0 & 0.8 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}, \quad X = \begin{pmatrix} 1 & 0.9 \\ 1 & 1 \\ 0.5 & 0 \end{pmatrix}, \quad \alpha = \begin{pmatrix} 0.25 & 0 \\ 1.25 & 1.34 \\ 0.5 & 0 \\ 0 & 0 \end{pmatrix}.$$

Con esto la ventana 1 sale exacta y a la ventana 2 le falta $(0.096, -0.072, 0)$: el error total es 0.12.

Qué quiere hacer este paso

OMP decidió **qué átomos usa cada ventana**. Ahora se cambia la pregunta: con esas decisiones fijas, ¿se pueden mejorar los átomos? Se revisa un átomo a la vez, **en orden**: A, B, C, E . Para cada uno, la pregunta es: si dejo fijos los demás átomos, ¿qué forma debería tener este átomo, y con qué pesos, para explicar lo mejor posible las ventanas que lo usan?

Ojito...

Solo se miran las ventanas que ya usan el átomo. Si se miraran todas, el átomo entraría en ventanas que no lo tenían y se perderían los ceros que OMP acababa de construir.

De dónde sale el residual

Tomemos el átomo j y las ventanas w que lo usan. Cada una de esas ventanas se reconstruye sumando varios átomos, y uno de los sumandos es el que estamos por cambiar:

$$\text{ventana} \approx \underbrace{\text{lo que aportan los otros átomos}}_{\text{se queda fijo}} + \underbrace{\alpha_{j,\ell} d_j}_{\text{esto se va a cambiar}}.$$

Si la parte fija se queda como está, lo único que el átomo j puede mejorar es **lo que sobra después de restarla**. Eso es el residual:

$$R = X_w - D \alpha_w, \quad \text{con la fila } j \text{ de } \alpha_w \text{ en cero.}$$

Poner esa fila en cero es la forma de decir *apaga el átomo j y déjame ver qué queda*. Si no se apagara, se estaría restando la contribución vieja del átomo, y el residual sería lo que falta *además* de lo que j ya hacía, que no es lo que se quiere mejorar.

Por qué la respuesta es una SVD

Ya con R , la pregunta es: ¿qué átomo d_j y qué pesos α_j dejan $d_j \alpha_j^\top$ lo más parecido posible a R ?

Y ahí está el truco. d_j es una columna y α_j una fila, así que su producto es una **matriz de rango 1**, siempre, sin importar qué valores tengan. Entonces la pregunta se traduce sola:

¿cuál es la mejor aproximación de rango 1 de R ?

Esa pregunta ya tiene respuesta, y es el teorema de Eckart-Young de la sección anterior: la mejor aproximación de rango 1 es $\sigma_1 u_1 v_1^T$. Comparando término a término:

$$d_j \alpha_j^T = \sigma_1 u_1 v_1^T \implies d_j = u_1, \quad \alpha_j = \sigma_1 v_1.$$

El átomo se queda con u_1 y el factor σ_1 se va a los pesos. El reparto es así y no al revés porque u_1 ya tiene norma 1, que es la condición que deben cumplir los átomos; si se le colgara el σ_1 al átomo, habría que renormalizarlo y el paso dejaría de ser el óptimo.

Idea clave

No se está *eligiendo* usar una SVD por conveniencia. La forma del problema, columna por fila, obliga a que la solución sea de rango 1, y para ese problema la SVD es la respuesta exacta. De ahí el nombre del algoritmo: una SVD por átomo, en cada iteración.

Algoritmo 7.1 Actualización del átomo j

Entrada: diccionario D , ventanas X , pesos α , átomo j

```

1:  $w \leftarrow$  ventanas con  $\alpha_{j,\ell} \neq 0$  // la fila  $j$  de  $\alpha$ 
2: si  $w$  está vacío entonces
3:    $d_j \leftarrow$  la ventana peor reconstruida, normalizada
4:   devolver
5: fin si
6:  $R \leftarrow X_w - D \alpha_w$ , con la fila  $j$  de  $\alpha_w$  en cero // lo que  $d_j$  debe explicar
7:  $U, \Sigma, V^T \leftarrow \text{SVD}(R)$ 
8:  $d_j \leftarrow u_1$ 
9:  $\alpha_{j,w} \leftarrow \sigma_1 v_1^T$ 
```

Átomo A

Qué ventanas lo usan. La fila A de α es $(0.25, 0)$: solo la ventana 1.

Residual. A la ventana 1 se le quita lo que aportan los otros átomos que usa, B y C :

$$R = v_1 - (1.25 B + 0.5 C) = (1, 1, 0.5) - (0.75, 1, 0) - (0, 0, 0.5) = (0.25, 0, 0).$$

Como solo una ventana usa A , R es una matriz de **una columna**.

SVD de una sola columna. Es el caso más simple: $R^T R = 0.25^2 = 0.0625$ es un solo número, su eigenvalor es el mismo, $\sigma = \sqrt{0.0625} = 0.25 = \|R\|$, $v = (1)$, y

$$u = \frac{R v}{\sigma} = \frac{(0.25, 0, 0)}{0.25} = (1, 0, 0).$$

Con una sola columna la SVD siempre da $u = R / \|R\|$ y $\sigma = \|R\|$.

Actualizar. A nuevo $= (1, 0, 0)$ y su peso es 0.25: **no cambia**, porque lo que le tocaba explicar ya apuntaba exactamente en su dirección.

Átomo B

Es el caso interesante, porque lo usan **dos** ventanas.

Qué ventanas lo usan. La fila B de α es $(1.25, 1.34)$: las dos.

Residual de cada ventana. A la ventana 1 se le quitan A y C ; la ventana 2 solo usa B , así que no se le quita nada:

$$\begin{aligned} R_1 &= (1, 1, 0.5) - (0.25, 0, 0) - (0, 0, 0.5) = (0.75, 1, 0), \\ R_2 &= (0.9, 1, 0). \end{aligned}$$

Como columnas:

$$R = \begin{pmatrix} 0.75 & 0.9 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}.$$

Qué se busca. Un átomo b de largo 1 y dos pesos (p_1, p_2) tales que $p_1 b \approx R_1$ y $p_2 b \approx R_2$; en forma de matriz, $b(p_1 \ p_2) \approx R$. Es columna por fila: rango 1. El B viejo, $(0.6, 0.8, 0)$, no le queda perfecto a ninguna: R_1 y R_2 apuntan un poco más a la derecha. Se busca **una sola dirección** que les quede lo mejor posible **a las dos a la vez**: la primera pieza de la SVD de R .

Paso 1: $R^T R$. Sus entradas son productos punto entre las columnas de R :

$$\begin{aligned} R_1 \cdot R_1 &= 0.75^2 + 1^2 = 0.5625 + 1 = 1.5625 \\ R_1 \cdot R_2 &= 0.75 \cdot 0.9 + 1 \cdot 1 = 0.675 + 1 = 1.675 \\ R_2 \cdot R_2 &= 0.9^2 + 1^2 = 0.81 + 1 = 1.81 \end{aligned}$$

$$R^T R = \begin{pmatrix} 1.5625 & 1.675 \\ 1.675 & 1.81 \end{pmatrix}.$$

Paso 2: eigenvalores. Para una de 2×2 , $\lambda^2 - (\text{traza}) \lambda + \det = 0$:

$$\begin{aligned} \text{traza} &= 1.5625 + 1.81 = 3.3725 \\ \det &= 1.5625 \cdot 1.81 - 1.675^2 = 2.8281 - 2.8056 = 0.0225 \\ \lambda &= \frac{3.3725 \pm \sqrt{3.3725^2 - 4 \cdot 0.0225}}{2} = \frac{3.3725 \pm \sqrt{11.2838}}{2} = \frac{3.3725 \pm 3.3591}{2} \\ \lambda_1 &= 3.3658, \quad \lambda_2 = 0.0067 \end{aligned}$$

Paso 3: valores singulares.

$$\sigma_1 = \sqrt{3.3658} = 1.8346, \quad \sigma_2 = \sqrt{0.0067} = 0.0818.$$

σ_1 es unas 22 veces mayor que σ_2 : R_1 y R_2 apuntan casi a la misma dirección. σ_1 explica $3.3658/3.3725$, es decir el 99.8 % de la energía.

Paso 4: v_1 . Se resuelve $(R^T R - \lambda_1 I) v = 0$:

$$\begin{pmatrix} -1.8033 & 1.675 \\ 1.675 & -1.5558 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = 0 \Rightarrow b = \frac{1.8033}{1.675} a = 1.0766 a.$$

Con $a = 1$, $v = (1, 1.0766)$, de largo $\sqrt{1 + 1.1591} = 1.4694$. Normalizado: $v_1 = (0.6806, 0.7327)$.

Paso 5: $u_1 = Rv_1/\sigma_1$.

$$Rv_1 = \begin{pmatrix} 0.75 \cdot 0.6806 + 0.9 \cdot 0.7327 \\ 1 \cdot 0.6806 + 1 \cdot 0.7327 \\ 0 \end{pmatrix} = \begin{pmatrix} 1.1698 \\ 1.4133 \\ 0 \end{pmatrix}, \quad u_1 = \frac{Rv_1}{1.8346} = \begin{pmatrix} 0.6377 \\ 0.7703 \\ 0 \end{pmatrix}.$$

Revisión: $\|u_1\| = \sqrt{0.4067 + 0.5934} = 1$.

Paso 6: qué se queda y qué se tira. La primera pieza de la SVD es

$$\sigma_1 u_1 v_1^T = 1.8346 \begin{pmatrix} 0.6377 \\ 0.7703 \\ 0 \end{pmatrix} \begin{pmatrix} 0.6806 & 0.7327 \end{pmatrix} = \begin{pmatrix} 0.797 & 0.858 \\ 0.962 & 1.035 \\ 0 & 0 \end{pmatrix} \quad \text{contra} \quad R = \begin{pmatrix} 0.75 & 0.9 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}.$$

Muy parecidas. La diferencia es lo que una sola dirección no puede explicar, y mide exactamente σ_2 :

$$R - \sigma_1 u_1 v_1^T = \begin{pmatrix} -0.047 & 0.042 \\ 0.038 & -0.035 \\ 0 & 0 \end{pmatrix}, \quad \sqrt{0.047^2 + 0.042^2 + 0.038^2 + 0.035^2} = 0.0818 = \sigma_2.$$

Paso 7: actualizar.

$$B_{\text{nuevo}} = u_1 = (0.6377, 0.7703, 0), \quad \text{pesos} = \sigma_1 v_1 = 1.8346 (0.6806, 0.7327) = (1.2486, 1.3442).$$

	Antes	Después
B	(0.6, 0.8, 0)	(0.6377, 0.7703, 0)
peso en v_1	1.25	1.2486
peso en v_2	1.34	1.3442




Figura 11: Las flechas grises son lo que cada ventana necesita (R_1 y R_2). El B viejo (naranja) coincide con R_1 pero no con R_2 . El B nuevo (azul) queda entre las dos: la dirección que mejor les queda a ambas a la vez.

Ojito...

Al correr el código, numpy devuelve $u_1 = (-0.6377, -0.7703, 0)$ y pesos $(-1.2486, -1.3442)$, todo con el signo al revés. Es la misma solución: menos por menos da más, y peso por átomo queda igual.

Átomo C

Qué ventanas lo usan. La fila C es $(0.5, 0)$: solo la ventana 1.

Residual. Detalle importante: B **ya cambió**, y el residual se calcula con el B nuevo y su peso nuevo:

$$1.2486 B_{\text{nuevo}} = (1.2486 \cdot 0.6377, 1.2486 \cdot 0.7703, 0) = (0.7962, 0.9618, 0),$$

$$R = (1, 1, 0.5) - (0.25, 0, 0) - (0.7962, 0.9618, 0) = (-0.0462, 0.0382, 0.5).$$

Con el B viejo esto habría sido exactamente $(0, 0, 0.5)$. Al mover B , a la ventana 1 le quedó un pequeño sobrante, y C lo absorbe.

SVD de una columna:

$$\sigma = \|R\| = \sqrt{0.00213 + 0.00146 + 0.25} = 0.5036, \quad C_{\text{nuevo}} = \frac{R}{\sigma} = (-0.0916, 0.0759, 0.9929),$$

con peso 0.5036. C se inclinó un poco para tapar el hueco que dejó el cambio de B . Por eso los átomos se actualizan **en orden**: cada uno aprovecha cómo quedaron los anteriores.

Átomo E

Qué ventanas lo usan. La fila E es $(0, 0)$: **ninguna**. No hay residual al que sacarle la SVD; si se dejara así, E nunca se usaría.

Reiniciarlo. Se reemplaza por la **ventana peor reconstruida**, que es donde más falta hace un átomo. Con el D y el α actuales, la ventana 1 tiene error 0, y a la ventana 2 le falta

$$(0.9, 1, 0) - 1.3442 B_{\text{nuevo}} = (0.9, 1, 0) - (0.8572, 1.0355, 0) = (0.0428, -0.0355, 0),$$

de tamaño 0.0556. La peor es la ventana 2, y E se vuelve esa ventana normalizada:

$$E_{\text{nuevo}} = \frac{(0.9, 1, 0)}{1.345} = (0.669, 0.743, 0).$$

Su fila en α sigue en cero: hasta la siguiente vuelta de OMP nadie lo usa, pero ya tiene una forma útil.

Resultado de la iteración

$$D_{\text{antes}} = \begin{pmatrix} 1 & 0.6 & 0 & 0 \\ 0 & 0.8 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad D_{\text{después}} = \begin{pmatrix} 1 & 0.6377 & -0.0916 & 0.669 \\ 0 & 0.7703 & 0.0759 & 0.743 \\ 0 & 0 & 0.9929 & 0 \end{pmatrix}$$

$$\alpha_{\text{antes}} = \begin{pmatrix} 0.25 & 0 \\ 1.25 & 1.34 \\ 0.5 & 0 \\ 0 & 0 \end{pmatrix} \quad \alpha_{\text{después}} = \begin{pmatrix} 0.25 & 0 \\ 1.2486 & 1.3442 \\ 0.5036 & 0 \\ 0 & 0 \end{pmatrix}$$

Resultado

Los **ceros de α siguen en el mismo lugar**: el paso 2 solo cambia los números que ya eran distintos de cero; quién usa qué átomo lo decide OMP. El error baja sin agregar ningún átomo:

	Antes	Después
ventana 1	0	0
ventana 2	0.12	0.0556
total	0.12	0.0556

Con esto termina **una iteración**. La siguiente empieza otra vez con OMP y el D nuevo; quizá la ventana 2 escoja ahora a E , que se le parece mucho, y quede casi perfecta con un solo átomo. En el proyecto pasa exactamente lo mismo, con 256 átomos de 128 números, 2539 ventanas y 20 iteraciones; cada R tiene decenas o cientos de columnas, una por ventana que usa el átomo.

8. K-SVD completo: el ciclo, el código y cómo correrlo

Resumen rápido. El ciclo completo, qué mejora con las iteraciones, los parámetros, dónde está cada parte en el código y cómo correr el entrenamiento, incluido el modo paso a paso.

El algoritmo

Algoritmo 8.1 K-SVD

Entrada: ventanas X (128×2539), número de átomos m , iteraciones T

Salida: diccionario D y pesos α

```

1:  $D \leftarrow m$  columnas de  $X$  escogidas al azar, normalizadas
2: para  $t = 1$  hasta  $T$  hacer
3:    $\alpha \leftarrow$  OMP de cada columna de  $X$  con  $D$  fijo                                // paso 1
4:   para  $j = 1$  hasta  $m$  hacer                                           // paso 2, en orden
5:     actualizar el átomo  $j$  y su fila de  $\alpha$  con la SVD
6:   fin para
7: fin para
8:  $\alpha \leftarrow$  OMP de cada columna de  $X$  con el  $D$  final
9: devolver  $D, \alpha$ 

```

Los dos pasos dependen uno del otro: el paso 1 escoge átomos según cómo es D *ahora*, y el paso 2 cambia D , así que con átomos nuevos quizá a una ventana le convenga escoger otros. Por eso se repite.

Qué mejora con las iteraciones

Ojito...

El error de reconstrucción casi no baja. Se queda alrededor de 0.10 porque ese *es* el criterio de paro de OMP: en cuanto una ventana llega al 10 % de error, OMP deja de agregarle átomos. Lo que mejora es la **dispersión**: cuántos átomos hacen falta para llegar a ese mismo error.

Con el registro 100 y los parámetros por omisión:

Medida	Valor
átomos por ventana, iteración 1	10.62
átomos por ventana, iteración 20	8.42
error en entrenamiento	0.1010
error en prueba (ventanas no vistas)	0.1148
error en prueba con 16 átomos	≈ 0.03

Que el error de prueba quede cerca del de entrenamiento indica que el diccionario **generaliza**: aprendió formas de ECG, no memorizó ventanas. Los átomos aprendidos (`out/atomos.pdf`) son complejos QRS en distintas posiciones y polaridades.

Parámetros

Todos viven en `src/Utils.py`:

Constante	Valor	Qué controla
REGISTRO	"100"	qué paciente se carga por omisión
TAM_VENTANA	128	muestras por ventana, y largo de cada átomo
N_ATOMOS	256	cuántos átomos tiene el diccionario
ERROR_OMP	0.1	OMP para cuando el error relativo baja de esto
MAX_ATOMOS_OMP	16	OMP para cuando ya usó esta cantidad de átomos
ITERACIONES_KSVD	20	cuántas veces se repiten los dos pasos
SEMILLA	7	para que el D inicial al azar sea siempre el mismo

Dónde está cada parte en el código

Parte	Archivo	Función
cargar el ECG, con caché local	Datos.py	cargar_ecg()
cortar en ventanas	Datos.py	partir_en_ventanas()
centrar, normalizar, armar X	Datos.py	construir_x()
entrenamiento y prueba	Experimento.py	partir_entrenamiento()
diccionario inicial	Ksvd.py	diccionario_inicial()
el ciclo completo	Ksvd.py	ksvd()
OMP de una ventana	Omp.py	omp()
OMP de todas las ventanas	Omp.py	omp_matriz()
actualizar un átomo (SVD)	Ksvd.py	actualizar_atomo()
átomo que nadie usa	Ksvd.py	_reiniciar_atomo()
figuras del reporte	Figuras.py	main()

Las líneas que hacen la SVD del átomo j , dentro de `actualizar_atomo()`:

```

1 w = np.flatnonzero(alpha[j, :])           # ventanas que lo usan
2 coeficientes = alpha[:, w].copy()
3 coeficientes[j, :] = 0.0                  # quitar el atomo j
4 residual = x[:, w] - d @ coeficientes     # la matriz R
5 u, sigma, vt = np.linalg.svd(residual, full_matrices=False)
6 d[:, j] = u[:, 0]                         # atomo nuevo = u_1
7 alpha[j, w] = sigma[0] * vt[0, :]         # pesos = sigma_1 v_1

```

Cómo correrlo

Preparar el entorno, una sola vez:

```

1 cd ~/inaoe/matcomp/proyecto1
2 python3 -m venv .venv
3 ./venv/bin/pip install -r requirements.txt

```

Entrenar, desde `src/` y con el Python del entorno:

```

1 cd ~/inaoe/matcomp/proyecto1/src
2 ../venv/bin/python Experimento.py           # registro 100
3 ../venv/bin/python Experimento.py --todos   # los 48 registros
4 ../venv/bin/python Experimento.py --registros 100 101
5 ../venv/bin/python Experimento.py --paso-a-paso # pausa en cada paso

```

El resultado queda en `out/modelo.npz`, y `Figuras.py` genera los PDF del reporte. Con los 48 registros el entrenamiento tarda del orden de horas; los registros se descargan una sola vez a `proyecto1/datos/`.

El modo paso a paso

Con `--paso-a-paso` la corrida se detiene en cada paso importante, muestra los datos con que está trabajando y espera una tecla: **E**nter sigue, **s** salta lo que queda de ese tipo de paso en la iteración, **c** corre sin pausas y **q** sale.

Pausa	Qué se ve
[datos]	cada paciente: la señal, las ventanas crudas y las normalizadas; luego la partición
[inicio]	el diccionario inicial D_0
[iteracion]	el arranque de cada iteración
[omp]	cada vuelta de OMP: candidatos, el que gana, pesos y residual
[alpha]	el resumen de OMP sobre todas las ventanas
[atomo]	cada átomo: sus ventanas, R , los valores singulares, el átomo viejo contra el nuevo y los pesos
[resumen]	fin de iteración: error, átomos por ventana y cuánto cambió D

OMP corre sobre 2539 ventanas por iteración, así que lo práctico es ver una o dos con detalle y presionar **s** para pasar a los átomos.

Resumen de todo




Figura 12: El proyecto de principio a fin.

A. Glosario

Término	Qué es	Tamaño
señal	el ECG completo de un paciente	650 000
muestra	un número de la señal: el voltaje en un instante	1
ventana	muestras seguidas de la señal	128
X	todas las ventanas, una por columna	128×5078
átomo	forma de onda de norma 1, del tamaño de una ventana	128
D	el diccionario: los átomos como columnas	128×256
α	los pesos: cuánto de cada átomo usa cada ventana	256×5078
residual	lo que todavía falta por explicar de una ventana	128
dispersión	cuántos átomos usa en promedio cada ventana	8 a 11
error relativo	$\ x - D\alpha\ / \ x\ $	
SVD	$A = U\Sigma V^T$: girar, estirar, girar	
OMP	algoritmo voraz que escoge los átomos de una ventana	
K-SVD	el ciclo OMP y SVD que aprende el diccionario	