

Proyecto 1

Representaciones dispersas con K-SVD sobre señales de ECG

Carlos Luis Bruzual Roa Arturo Zabdí Reyes Pérez
Sergio Cesar Villanueva Estrada Bryan Ezequiel Violante Arriaga

Otoño 2026

Resumen

Se implementó K-SVD para aprender un diccionario de 256 átomos sobre ventanas de 128 muestras de un electrocardiograma de MIT-BIH, con OMP como método de representación dispersa. El diccionario aprendido reconstruye las ventanas de prueba al 11.5 % de error con 9.5 átomos en promedio, contra 128 muestras originales, y sus átomos resultan ser complejos QRS. Comparado con un diccionario fijo de cosenos, con 8 átomos tiene la tercera parte del error; con 32 átomos el fijo lo alcanza. Entre pacientes el resultado depende del paciente y no de la serie de la base de datos.

1. Objetivo

Implementar K-SVD y obtener una base entrenada para un tipo de señal, de manera que se pueda comparar la señal original con su reconstrucción a partir de la representación dispersa.

Una señal x se modela como combinación lineal de unas pocas columnas, los *átomos*, de un diccionario D :

$$x \approx D\alpha, \quad D \in \mathbb{R}^{k \times m}, \quad m > k,$$

donde α tiene casi todas sus entradas en cero. Como el diccionario es sobrecompleto, el sistema tiene infinitas soluciones y de ellas se busca la más dispersa. Se eligió el ECG porque es una señal con estructura repetida, el latido, que un diccionario aprendido debería capturar con pocos átomos mejor que uno genérico.

2. Información utilizada

Se usó la base **MIT-BIH Arrhythmia** de PhysioNet: 48 registros de media hora, muestreados a 360 Hz, con dos canales. El entrenamiento usa el registro 100, canal 0 (derivación MLII); la prueba entre pacientes, los registros 101, 103, 200 y 208. La serie 100 son pacientes ambulatorios elegidos al azar y la serie 200 se escogió en la base por contener arritmias poco comunes. Los registros 102 y 104 se descartaron porque su canal 0 es V5 y no MLII.

Concepto	Valor
Muestras del registro 100	650 000 (30.1 min)
Longitud de ventana k	128 muestras (356 ms)
Ventanas, sin traslape	5078
Matriz de señales X	128×5078
Entrenamiento / prueba	2539 / 2539
Átomos del diccionario m	256

Tabla 1: Datos y dimensiones del problema.

A cada ventana se le resta su media y se normaliza a norma 1. Lo primero quita la deriva de línea base del electrodo, que de otro modo sería lo primero que aprendería el diccionario; lo segundo hace que las ventanas se distingan solo por su forma. La partición es **temporal**: la primera mitad del registro entrena y la segunda prueba. Repartir al azar dejaría en prueba ventanas contiguas a las de entrenamiento, casi idénticas, e inflaría el resultado.

3. Proceso

Representación dispersa con OMP. Dado D , Orthogonal Matching Pursuit construye α de forma voraz. En cada vuelta escoge el átomo de mayor $|d_i^T r|$, con r el residual, y recalcula por mínimos cuadrados los pesos de *todos* los átomos escogidos; eso deja el residual ortogonal a ellos y ningún átomo se repite. Se detiene cuando $\|r\|/\|x\| \leq 0.1$ o al llegar a 16 átomos.

Aprendizaje del diccionario con K-SVD. Se alternan dos pasos durante 20 iteraciones. Con D fijo se calcula α para todas las ventanas con OMP. Con el patrón de ceros de α fijo se actualiza cada átomo d_j : se toman solo las ventanas w que lo usan y se forma el residual sin su contribución,

$$R = X_w - D \alpha_w, \quad \text{con la fila } j \text{ de } \alpha_w \text{ en cero.}$$

El producto $d_j \alpha_j^T$ es una matriz de rango 1, así que el mejor átomo es la mejor aproximación de rango 1 de R , que por el teorema de Eckart-Young da la SVD:

$$R = U \Sigma V^T \implies d_j = u_1, \quad \alpha_j = \sigma_1 v_1.$$

Restringir a w conserva los ceros que encontró OMP. Un átomo que ninguna ventana usa se reemplaza por la ventana peor reconstruida. El diccionario inicial D_0 son 256 ventanas de entrenamiento tomadas al azar.

Verificación. Antes de usar el ECG, ambos algoritmos se probaron con datos sintéticos generados desde un diccionario conocido. OMP recuperó el conjunto exacto de átomos en el 99.3 % de 300 señales, y K-SVD recuperó 42 de 50 átomos con coseno mayor a 0.99 contra los originales.

La implementación está en Python con NumPy; los registros se leen con la biblioteca `wfdb` de PhysioNet.

4. Análisis de resultados

Lo que aprendió el diccionario

El error de entrenamiento queda en 0.101 desde la primera iteración, porque es el umbral de paro de OMP. Lo que mejora con las iteraciones es la **dispersión**: el promedio de átomos por ventana



Figura 1: Los átomos más usados del diccionario entrenado, con el número de ventanas de prueba en que participa cada uno. Son complejos QRS en distintas posiciones y polaridades.

baja de 10.62 a 8.42 para alcanzar el mismo error. En la mitad de prueba el error sube a 0.115 con 9.46 átomos por ventana, una brecha chica que indica que el diccionario no memorizó las ventanas de entrenamiento.

Los átomos más usados (figura 1) son complejos QRS desplazados dentro de la ventana y con ambas polaridades. El diccionario no guardó ventanas sino la forma del latido en distintas posiciones, que es lo que permite describir cualquier ventana con pocos de ellos.

Original contra reconstrucción

La figura 2 es la comparación que pide el objetivo. El primer átomo que escoge OMP ya tiene la forma del QRS; los siguientes corrigen detalles. El error baja de 0.185 con 2 átomos a 0.110 con 4, 0.062 con 8 y 0.034 con 16. Guardar la ventana con 9 átomos cuesta 9 coeficientes y 9 índices en lugar de 128 muestras.

Contra diccionarios que no aprendieron

El error de 0.115 no dice mucho sin una referencia. Se comparó contra dos diccionarios del mismo tamaño: D_0 , las ventanas sin entrenar, y una DCT sobrecompleta, el caso típico de diccionario fijo.

Átomos	Aprendido	D_0	DCT
1	0.327	0.342	0.798
2	0.232	0.257	0.682
4	0.174	0.205	0.540
8	0.130	0.162	0.363
16	0.101	0.125	0.184
32	0.081	0.088	0.074

Tabla 2: Error relativo sobre las 2539 ventanas de prueba según el número de átomos permitidos. En negritas el menor de cada renglón.




Figura 2: Una ventana de prueba con un latido completo. Izquierda: los primeros átomos en que se descompone. Derecha: su reconstrucción con 2, 4, 8 y 16 átomos, desplazada en vertical para que no se tape con la original.

Con pocos átomos, que es el régimen que importa en una representación dispersa, el diccionario aprendido gana en todos los casos: con 8 átomos tiene un 20 % menos de error que D_0 y la tercera parte que la DCT. Que D_0 quede tan cerca muestra que tomar ventanas reales ya es un buen punto de partida, y lo que agrega K-SVD es ajustarlas.

Con 32 átomos la DCT termina ganando. La explicación probable es que el diccionario aprendido se especializó en la forma del latido, y lo que queda sin explicar después de muchos átomos es ruido de alta frecuencia, que los cosenos representan mejor. No se verificó directamente, pero es consistente con que la DCT mejore mucho más rápido que los otros dos al pasar de 16 a 32 átomos.

Otros pacientes




Figura 3: Error con 8 átomos en cada paciente, usando el diccionario entrenado solo con el registro 100.

El diccionario del registro 100 se aplicó sin reentrenar a otros cuatro pacientes (figura 3). En los registros 103 y 208 el error es igual o menor que en la propia mitad de prueba del 100, y en 101 y 200 sube a 0.188 y 0.211, que se traduce en 11.5 y 12.6 átomos para llegar al umbral en lugar de 9.5. La serie no predice el resultado: el 208, de la serie de arritmias, se reconstruye tan bien como el 100, y el 101, de la misma serie que el 100, no. Un diccionario de un solo paciente cubre las morfologías parecidas a la suya pero no todas, y el siguiente paso natural es entrenar con varios pacientes, opción que ya admite la implementación.

5. Conclusiones

K-SVD aprendió un diccionario cuyos átomos son la forma del latido, y con él una ventana de 128 muestras se reconstruye al 10 % de error con unos 9 coeficientes. La ventaja sobre un diccionario fijo es grande precisamente donde importa, con pocos átomos, y desaparece cuando se permiten muchos. La SVD aparece como la solución exacta del paso de actualización: cada átomo es la mejor aproximación de rango 1 de lo que le toca explicar.

Referencias

- [1] M. Aharon, M. Elad y A. Bruckstein, *K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation*, IEEE Transactions on Signal Processing, 54(11), 4311-4322, 2006.
- [2] Y. C. Pati, R. Rezaeiifar y P. S. Krishnaprasad, *Orthogonal matching pursuit: recursive function approximation with applications to wavelet decomposition*, 27th Asilomar Conference on Signals, Systems and Computers, 40-44, 1993.
- [3] C. Eckart y G. Young, *The approximation of one matrix by another of lower rank*, Psychometrika, 1(3), 211-218, 1936.
- [4] G. B. Moody y R. G. Mark, *The impact of the MIT-BIH Arrhythmia Database*, IEEE Engineering in Medicine and Biology Magazine, 20(3), 45-50, 2001.
- [5] A. L. Goldberger et al., *PhysioBank, PhysioToolkit, and PhysioNet*, Circulation, 101(23), e215-e220, 2000.
- [6] Visual Kernel, *SEE Matrix*, serie de videos en YouTube sobre matrices, descomposición espectral y SVD. <https://www.youtube.com/playlist?list=PLWhu9osGd2dB9uMG5gKBARmk73oHUUQZS>