Actividad

En esta actividad se analiza el precio por noche de los anuncios de Airbnb en la Ciudad de México a partir del corte del 23 de septiembre de 2026 de Inside Airbnb[1], el mismo conjunto de datos del proyecto. Se conservan los 28,289 anuncios con precio entre 100 y 50,000 pesos y con número de baños registrado, publicados por 12,205 anfitriones.

El modelo tiene un propósito explicativo y no predictivo: se busca cuantificar la asociación entre el precio y un número reducido de atributos, cada uno con los demás constantes. Esta decisión orienta el resto del análisis, ya que exige predictores con baja correlación entre sí, coeficientes interpretables y errores estándar confiables.

Declaración de uso de IA: En esta actividad se utilizaron herramientas de inteligencia artificial como apoyo en el análisis de los datos, la generación de gráficas y la elaboración del código.

Selección de las variables

Se consideraron trece variables candidatas: características físicas del inmueble (recámaras, camas, baños y número de amenidades), ubicación geográfica (latitud y longitud), tipo de alojamiento (indicadora de alojamiento entero frente a cuarto), condición de superanfitrión, número de reseñas, días disponibles al año, noches mínimas, número de anuncios del anfitrión y antigüedad del anfitrión en la plataforma. Se calculó la correlación de Spearman entre todos los pares (Fig. 1), por ser robusta ante las colas largas que presentan varias de estas variables.

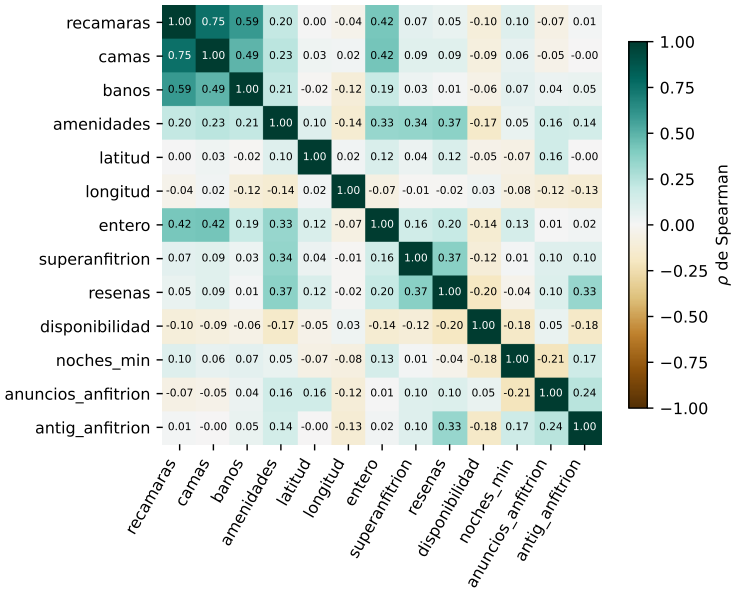


Fig. 1. Matriz de correlación de Spearman entre las trece variables candidatas ($n = 28{,}323$).

[1] https://insideairbnb.com/get-the-data/

Recámaras, camas y baños forman un bloque de alta correlación (0.49 a 0.75), pues las tres miden el tamaño del inmueble. Fuera de ese bloque se observan correlaciones moderadas, entre 0.33 y 0.42, del alojamiento entero con recámaras, camas y amenidades, y de las amenidades, las reseñas y la condición de superanfitrión entre sí.

Para la selección se evaluaron las 286 ternas posibles. Se consideraron admisibles las 190 en las que todos los pares cumplen $|\rho| < 0.3$, y entre ellas se eligió la de mayor asociación conjunta con el logaritmo del precio. La terna seleccionada es **baños, longitud y alojamiento entero**, con una correlación máxima de 0.19 entre sus pares y factores de inflación de la varianza de 1.01 en las tres variables. Cada una representa una dimensión distinta del anuncio: tamaño, ubicación y tipo de alojamiento. Para facilitar la interpretación, la longitud se expresa como distancia en kilómetros al este del meridiano del Ángel de la Independencia; al ser una transformación lineal, no modifica ninguna correlación.

Análisis exploratorio

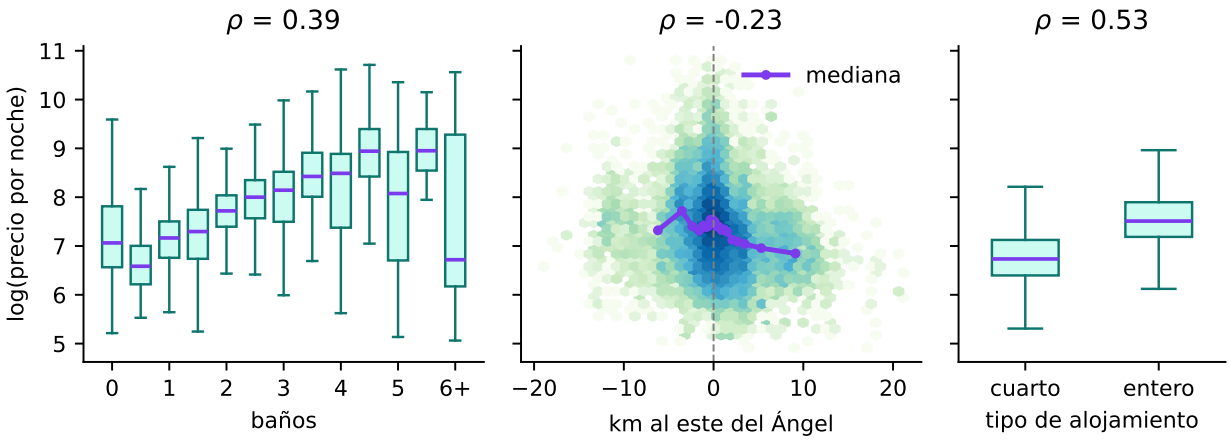


Fig. 2. Logaritmo del precio contra cada predictor. Las cajas omiten los valores atípicos; en el panel central, la línea es la mediana por veintil y la línea punteada marca el meridiano del Ángel.

La Fig. 2 muestra tres relaciones de forma distinta. El precio crece con el número de baños hasta alrededor de cinco, pero a partir de seis la dispersión aumenta y la mediana desciende, porque en ese grupo se concentran hostales con baños compartidos. En la dirección este-oeste, el precio alcanza su máximo ligeramente al poniente del Ángel y desciende hacia el oriente. El alojamiento entero tiene un precio mediano de 1,827 pesos, frente a 841 pesos de un cuarto.

Especificación y ajuste del modelo

El primer modelo relaciona linealmente el precio con las tres variables y se ajusta por mínimos cuadrados ordinarios. Su ajuste es pobre ($R^2 = 0.18$) y sus residuos presentan una asimetría de 7.1 y una curtosis de 94, producto de unos cuantos anuncios de precio muy alto que dominan la suma de cuadrados. Al tomar el logaritmo del precio el R^2 sube a 0.33 y los residuos se vuelven aproximadamente simétricos. El análisis de residuos por clase mostró, además, que los anuncios con seis o más baños aplanaban la pendiente del número de baños, por lo que esta variable se sustituyó por $\log(1 + \text{baños})$, que reduce la influencia de los valores extremos y admite anuncios sin baño. La Tabla 1 resume los tres modelos y el modelo final es

$$\log(\text{precio}) = \beta_0 + \beta_1 \log(1 + \text{baños}) + \beta_2\, \text{este} + \beta_3\, \text{entero} + \varepsilon, \tag{1}$$

Tabla 1. Comparación de los modelos ajustados. El RMSE del modelo 0 está en pesos y el de los demás en escala logarítmica; BP es el estadístico de Breusch-Pagan, con valor p prácticamente nulo en los tres casos.

Modelo	R^2	RMSE	Asimetría	Curtosis	BP
0: precio	0.181	2,330	7.10	93.8	1,124
1: log(precio)	0.328	0.605	0.46	3.98	4,158
2: con log(1 + baños)	0.347	0.596	0.60	2.96	1,584

donde *este* es la distancia en kilómetros al este del meridiano del Ángel y *entero* vale 1 para un alojamiento entero y 0 para un cuarto.

Los errores estándar se calcularon de forma robusta y agrupada por anfitrión, ya que los anuncios de un mismo anfitrión no son observaciones independientes. La diferencia es considerable: para el coeficiente de los baños, el error agrupado es seis veces mayor que el clásico, debido a los anfitriones que publican muchos anuncios similares. Los tres coeficientes son significativos con $p < 0.001$ (Tabla 2).

Tabla 2. Coeficientes del modelo final (1), con error estándar robusto agrupado por anfitrión e intervalo de confianza de 95 %.

Término	$\hat{\beta}$	EE	IC 95 %	Interpretación
Intercepto	6.252	0.054	[6.146, 6.358]	Cuarto sin baño en el meridiano del Ángel
log(1 + baños)	0.752	0.076	[0.602, 0.902]	Pasar de 1 a 2 baños se asocia con un precio 35.6 % mayor
Este (km)	−0.031	0.003	[−0.036, −0.026]	Cada kilómetro hacia el oriente reduce el precio 3.1 %
Entero	0.684	0.025	[0.634, 0.733]	Un alojamiento entero cuesta 98 % más que un cuarto

Diagnóstico

Los residuos del modelo final (Fig. 3) se distribuyen alrededor de cero sin tendencia respecto a los valores ajustados; las bandas verticales se deben al carácter discreto de dos de los predictores. La gráfica Q-Q indica colas más pesadas que las de una distribución normal en ambos extremos. La prueba de Breusch-Pagan rechaza la homocedasticidad: la desviación estándar residual es de 0.71 en cuartos y de 0.53 en alojamientos enteros, lo que justifica el uso de errores estándar robustos.

El hallazgo principal del diagnóstico aparece en el último panel. Con baño privado, el residuo crece con el número de baños; con baño compartido, decrece. El número de baños agrupa dos poblaciones con pendientes opuestas: en un inmueble privado, más baños indican un inmueble más grande y caro, mientras que en un hostal indican más camas en dormitorios compartidos y un precio menor. El modelo promedia ambas tendencias. Incorporar una indicadora de baño compartido elevaría el R^2 a 0.38, pero introduciría una cuarta variable correlacionada con el tipo de alojamiento. De forma análoga, los 755 anuncios situados a más de 6 km al poniente, principalmente en Cuajimalpa y Álvaro Obregón, resultan más baratos de lo que predice el término lineal; un término cuadrático en la posición este-oeste corrige este efecto, pero aporta menos de una centésima al R^2.

Para verificar la estabilidad del ajuste se reservó el 20 % de los anuncios como partición de prueba. El R^2 en prueba es de 0.343, frente a 0.348 en entrenamiento, y los coeficientes estimados varían solo en el tercer decimal, por lo que no hay evidencia de sobreajuste. Como herramienta de predicción el modelo es limitado: el error absoluto mediano en prueba es de 449 pesos, equivalente al 32 % del precio.

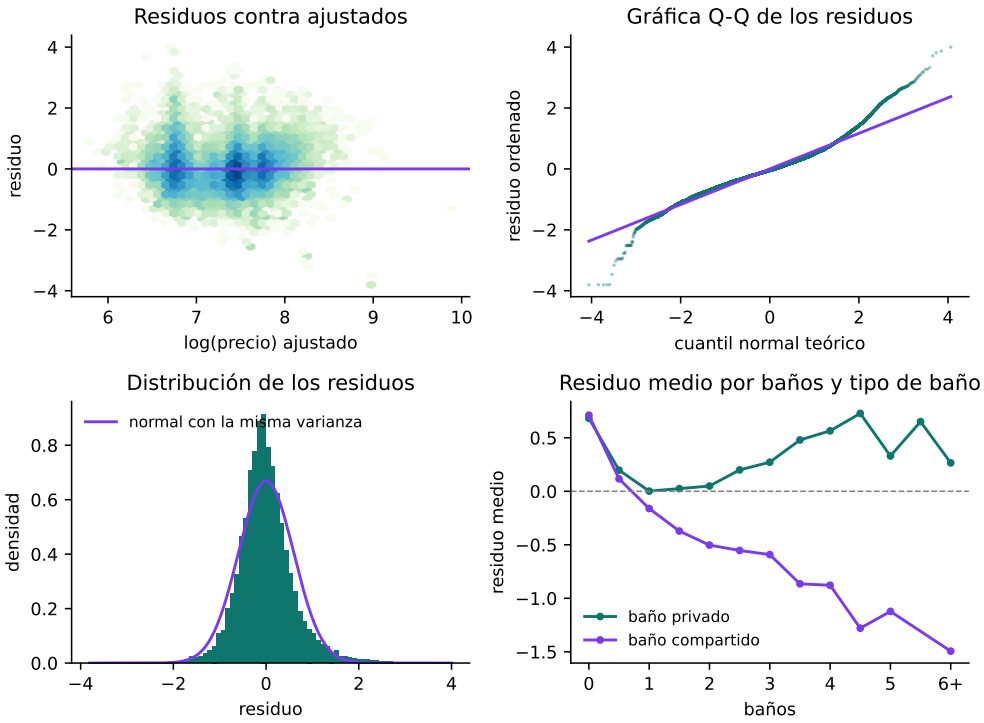


Fig. 3. Diagnóstico del modelo final. El último panel muestra el residuo medio por número de baños, por separado para baños privados y compartidos.

Interpretación

Al estar la respuesta en escala logarítmica, los efectos se expresan como cambios porcentuales. El tipo de alojamiento es el factor de mayor peso: con el mismo número de baños y la misma posición, un alojamiento entero cuesta aproximadamente el doble que un cuarto. Pasar de uno a tres baños se asocia con un aumento de 68 %, y desplazarse 5 km hacia el oriente, con una reducción de 14 %. A modo de referencia, el modelo estima un precio mediano de 1,732 pesos para un alojamiento entero con un baño sobre el meridiano del Ángel, y de 874 pesos para un cuarto con las mismas características.

Limitaciones

- El estudio es observacional; los coeficientes describen asociaciones y no efectos causales.
- El número de baños mezcla baños privados y compartidos, con relaciones opuestas con el precio.
- La posición este-oeste no captura la variación norte-sur ni las diferencias entre colonias vecinas.
- El precio corresponde al anunciado para las fechas cotizadas en un único corte, no al pagado por los huéspedes.

Conclusiones

Con tres variables poco correlacionadas, el modelo explica el 35 % de la variación del logaritmo del precio. El tipo de alojamiento es el determinante principal, seguido del número de baños y de la posición este-oeste. El diagnóstico de residuos identificó con precisión la principal deficiencia del modelo, la mezcla de baños privados y compartidos, que constituye la mejora más directa para una especificación posterior.