Actividad

Para esta tarea se usaron los datos de Airbnb de la Ciudad de México, el mismo dataset del proyecto, el corte de septiembre de 2026 de Inside Airbnb[1]. La idea principal es ver de qué depende el precio por noche de un anuncio (en el proyecto se detalla más). Para esta actividad se conservan los 24,763 anuncios que tienen precio entre 100 y 50 mil pesos y calificación.

Es importante aclarar que el modelo desarrollado es explicativo y no predictivo, o sea que no buscamos predecir el precio sino entender cómo cambia.

Disclaimer: Esta actividad se realizó con ayuda de herramientas de IA para el análisis de los datos y la generación de gráficos, así como para la generación del código de la actividad.

Selección de las variables

Se partió con once variables numéricas que podían tener que ver con el precio: capacidad, recámaras, camas, baños, distancia al Ángel de la Independencia, calificación, número de reseñas, días disponibles al año, noches mínimas, cuántos anuncios tiene el anfitrión y cuántos años lleva en Airbnb. Posteriormente se obtuvo la correlación de Spearman entre todas las variables. Se usó Spearman porque varias tienen valores muy extremos, como anfitriones con cientos de anuncios, y Pearson tiende a dejarse llevar por esos valores.

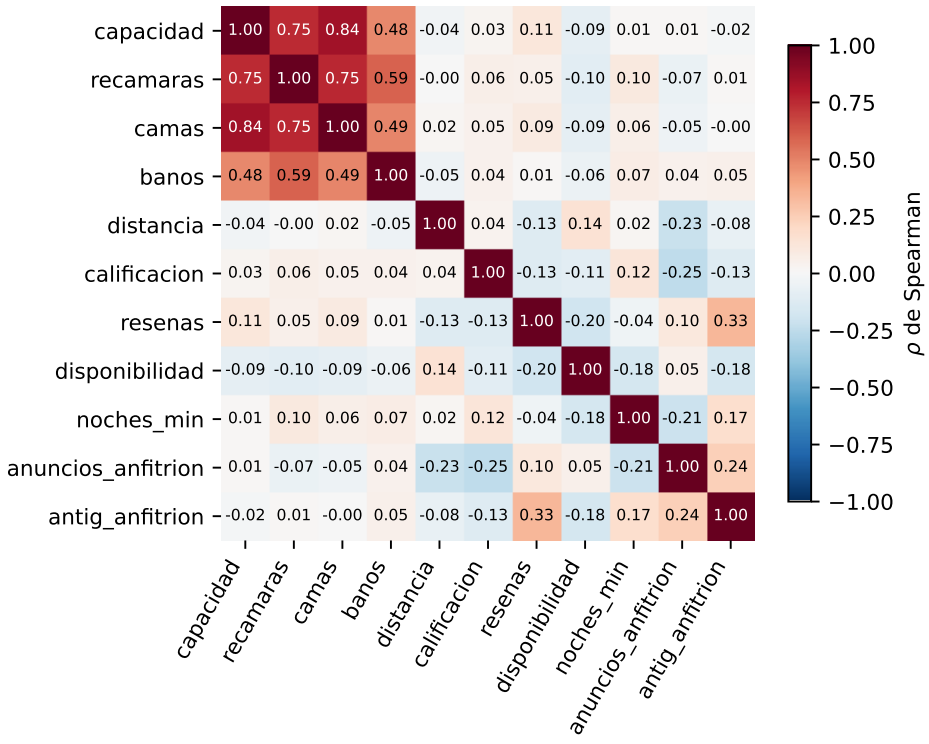


Fig. 1. Matriz de correlación de Spearman entre las once variables.

[1] https://insideairbnb.com/get-the-data/

Capacidad, recámaras y camas son casi la misma cosa: la correlación entre ellas va de 0.75 a 0.84, y los baños andan cerca, alrededor de 0.5. Todas miden qué tan grande es el lugar, así que solo una de ellas puede entrar al modelo.

Para escoger se probaron todas las combinaciones de tres variables, se conservaron las que no tenían ningún par con correlación arriba de 0.3, y de esas se seleccionó la que más se relacionaba con el precio: **capacidad, distancia y calificación**. La correlación más alta entre ellas es de 0.04, y cada una mide algo completamente distinto (tamaño, ubicación y calidad).

Cómo se ven

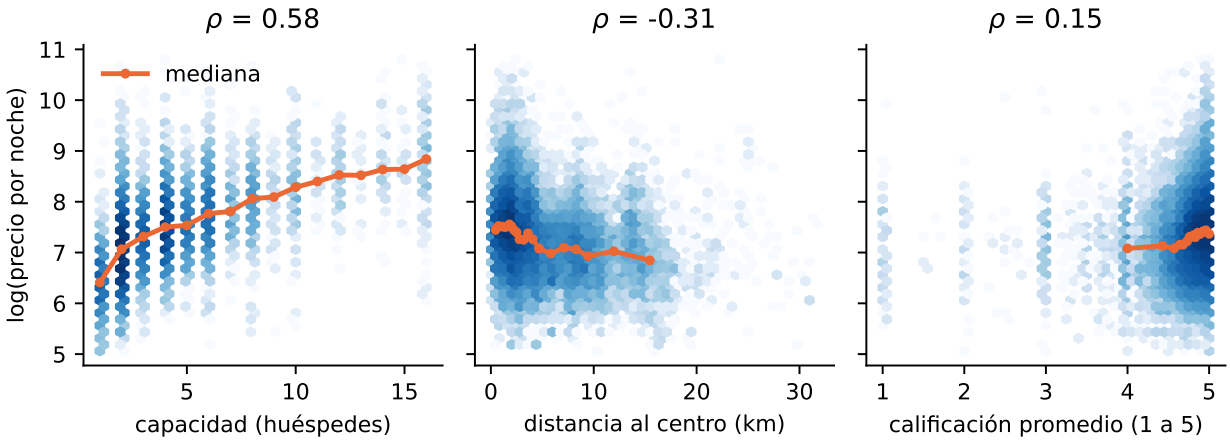


Fig. 2. El logaritmo del precio contra cada variable. Entre más oscuro el hexágono, más anuncios; la línea naranja es la mediana.

En la Fig. 2 se puede ver cómo el precio sube con la capacidad, pero cada huésped extra suma menos que el anterior. Con la distancia el precio baja rápido en los primeros 3 km y luego casi se aplana. La calificación es la más débil, porque casi todos tienen entre 4.5 y 5, y muchos de los que tienen 5 perfecto son anuncios nuevos con pocas reseñas (la mediana es de 4).

El modelo

Primero se ajustó el precio contra las tres variables tal cual. Salió un R^2 de 0.26, pero con residuos muy sesgados: unos cuantos anuncios carísimos movían todo el ajuste, y entre más caro el anuncio, más grande el error.

Después se tomó el logaritmo del precio para aplanar los precios altos, y el R^2 subió a 0.38. Los residuos todavía mostraban que el modelo se pasaba con los lugares muy chicos y muy grandes, y algo parecido con la distancia, así que también se tomó el logaritmo de la capacidad y de la distancia. El modelo final, con $R^2 = 0.425$, es

$$\begin{aligned}\log(\text{precio}) = 5.959 &+ 0.717\ \log(\text{capacidad}) \\ &- 0.182\ \log(\text{distancia}) + 0.164\,\text{calificación}\end{aligned}$$

Los tres coeficientes son distintos de cero. Los errores estándar se calcularon agrupando por anfitrión, porque un mismo anfitrión sube muchos anuncios parecidos y no son independientes. Si no se hacía así, los errores salían como de la mitad y el modelo parecía más preciso de lo que es.

Tabla 1. Coeficientes del modelo final, con su error estándar entre paréntesis.

Variable	$\hat{\beta}$	Qué quiere decir
log(capacidad)	0.717 (0.013)	De 2 a 4 huéspedes, el precio sube 64 %
log(distancia)	−0.182 (0.009)	De 2 a 8 km del Ángel, el precio baja 22 %
calificación	0.164 (0.020)	De 4.5 a 5 estrellas, el precio sube 8.5 %
intercepto	5.959 (0.101)	Nada útil: sería un lugar con cero estrellas

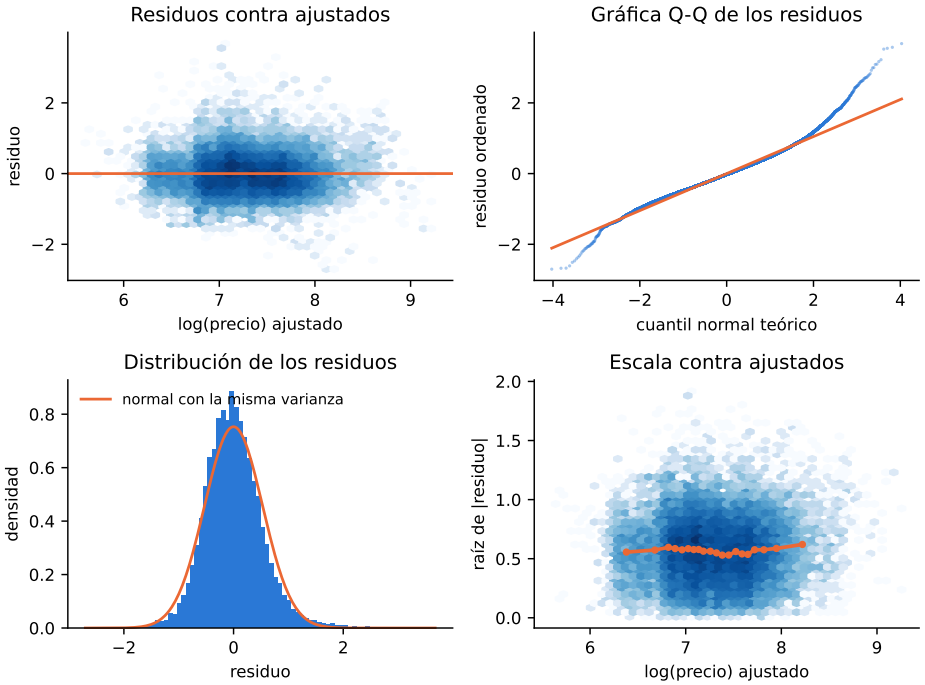


Fig. 3. Los residuos del modelo final.

Resultados

En la Fig. 3 los residuos quedan centrados en cero y sin ninguna forma rara. La gráfica Q-Q es casi una recta (solo se despega arriba), porque hay más anuncios caros de los que esperaría una normal. La dispersión de los errores es casi pareja.

Para comprobar que no fuera suerte, se separó el 20 % de los anuncios, se ajustó el modelo con el resto y se probó en esos: el R^2 salió igual, 0.425. Eso sí, para predecir no es gran cosa: en la mediana se equivoca por 434 pesos, como un tercio del precio. Es normal, porque le faltan cosas importantes.

Lo que el modelo no logra arreglar es la distancia: dos colonias a la misma distancia del Ángel pueden tener precios muy distintos, y eso ya no se corrige con logaritmos.

Conclusiones

Con tres variables y unos logaritmos se explica aproximadamente el 43 % de la variación del precio. Lo que falta es dónde está exactamente el lugar y qué tipo de lugar es.

Limitaciones

- No es causa y efecto. Agrandar la vivienda no garantiza cobrar 64 % más.